

UNIDAD 2 - Prueba de Hipótesis

Sirve para decidir si una afirmación respecto a un parámetro es verdadera o falsa, es decir probar una hipótesis respecto a un parámetro.

Es posible respaldar nuestra decisión con un cierto nivel de significación asociado a la prueba.

	Se Acepta H	Se Rechaza H
H es Verdadera	Decisión Correcta	Error de Tipo I
H es Falsa	Error de Tipo II	Decisión Correcta

Hipótesis Nula (H0): Es una hipótesis opuesta a lo que se quiere probar.

Ej: si se quiere determinar de dos sistemas de riego cuál es el de menor costo, se formula la hipótesis de que los dos sean igualmente costosos

Preceptos

1. Formular H0 y H1
2. Establecer nivel de significancia (α).
3. Construye un criterio para probar la H0 contra H1. (Intervalo de Confianza)
4. Calculo el estadístico.
5. Se acepta o rechaza H0 con un nivel de conf.

Curvas caract. de operación (Análisis de curvas)

Ej: Si el secado de pintura tiene una media de μ=20 min (curva roja: ET1) según el vendedor, pero nos miente y en realidad tiene una media de μ=21 min (curva azul ET2)

Si rechazamos H0 la probabilidad de hacer error tipo 1 es α

Cola derecha

Hipótesis relativa a 2 medias

Se quieren comparar las medias de dos poblaciones distintas. **H0:** μ1-μ2= δ, siendo δ una constante, gralmente es 0. (Al restar medias y sumar varianzas se forma una nueva población)

H1: μ1-μ2<δ o μ1-μ2>δ o μ1-μ2>δ

Si las poblaciones son normales, **se define un estadístico:**

1) Para n grande (n>30): σ^2 conocido

$$z = \frac{[\bar{x}_1 - \bar{x}_2] - \delta}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$$

σ^2 desconocido: sustituyendo σ1 y σ2 por s1 y s2

2) Para n chico (n<30) con σ^2 desconocido:

“Prueba t-bimuestral” (muestras independientes)

suponemos σ1= σ2 (=σ)

$$t = \frac{[(\bar{x}_1 - \bar{x}_2) - \delta]}{\sqrt{(n_1 - 1) \cdot (s_1)^2 + (n_2 - 1) \cdot (s_2)^2}} \cdot \sqrt{\frac{n_1 \cdot n_2 \cdot (n_1 + n_2 - 2)}{n_1 + n_2}}$$

con v = n1+ n2 - 2

3) Si las 2 poblac. no son independientes:

La muestra es la diferencia entre las 2 poblaciones relacionadas, con su signo.

“Prueba t Muestras Apareadas” (85 y 78) AyD

Media poblacional sea significativamente igual a una media esperada. **H0:** μ=μ0 **Ej:** Personas antes y desp. de 2 meses de dieta

1) Calculo la media muestral con las diferencias

$$\bar{x}_{diff} = \frac{9 + 13 + 2 + 5 - 2 + 6 + 5 + 2 + 6}{10} = 5.2$$

2) Calculo la desv. estándar muestral

$$s = \sqrt{\frac{\sum (x - \bar{x})^2}{n - 1}}$$

3) Aplico **t unimuestral** (media poblacional vs media esperada)

$$t = \frac{\bar{x}_{diff} - \mu}{\frac{s}{\sqrt{n}}}$$

Aceptando o rechazando la hipótesis u = media esperada

Z es igual que la t-unimuestral

TABLA PARA LA MEDIA			
acción	Tamaño muestral	σ conocida	σ desconocida
distribuida	Grande (n ≥ 30)	$\bar{x} \pm z_{\alpha} \cdot \sigma_{\bar{x}}$	$\bar{x} \pm z_{\alpha} \cdot s_{\bar{x}}$
	Chica (n < 30)	$\bar{x} \pm z_{\alpha} \cdot \sigma_{\bar{x}}$	$\bar{x} \pm t_{\alpha} \cdot s_{\bar{x}}$
no distribuida	Grande (n ≥ 30)	$\bar{x} \pm z_{\alpha} \cdot \sigma_{\bar{x}}$	$\bar{x} \pm z_{\alpha} \cdot s_{\bar{x}}$
	Chica (n < 30)	$\bar{x} \pm k \cdot \sigma_{\bar{x}}$ donde 1-1/k ² se define por Chebyshev	$\bar{x} \pm k \cdot s_{\bar{x}}$

UNIDAD 3 - Varianza y Proporciones

Estimacion de la varianza

1) s² es est insesg de σ² (solo si n-1 y no n en la fórmula). En cambio:

s es est sesg de la σ y en muestras chicas tiene un sesg significativo ⇒ usamos R (rango muestral)

R = max(X) - min(X), siendo X la muestra.

2) Si la población es normal y se toman muestras tamaño n→R tiene dist.normal con:

$$\mu_R = d_2 \sigma \quad (d_2 \text{ y } d_3 \text{ ctes y dependen de n, se sacan de una tabla})$$

R/d₃ ⇒ es un est insesg de σ desv. est pobla.

Se usa en **Control de Calidad**

3) Para n chico (n<30) → Dist Chi cuadrado

$$\chi^2 = \frac{(n-1) \cdot s^2}{\sigma^2} \quad \text{con } v = n-1 \text{ grados de libertad}$$

inter. confianz para σ²

$$\frac{(n-1) \cdot s^2}{\left(\chi^2\right)_{1-\frac{\alpha}{2}}} < \sigma^2 < \frac{(n-1) \cdot s^2}{\left(\chi^2\right)_{\frac{\alpha}{2}}}$$

inter. confianz para σ (aplicamos raíz)

$$\sqrt{\frac{(n-1) \cdot s^2}{\left(\chi^2\right)_{1-\frac{\alpha}{2}}}} < \sigma < \sqrt{\frac{(n-1) \cdot s^2}{\left(\chi^2\right)_{\frac{\alpha}{2}}}}$$

4) Para n grande (n>30)

a)

$$z = \frac{s - \sigma}{\frac{\sigma}{\sqrt{2 \cdot n}}}$$

Con desv. estándar y media sigma σ

inter. confianz para σ

$$\frac{s}{1 + \frac{z_{\alpha}}{\sqrt{2 \cdot n}}} < \sigma < \frac{s}{1 - \frac{z_{\alpha}}{\sqrt{2 \cdot n}}}$$

b)

También se podría usar la **chi cuadrado** ya que con n > 30 se aproxima a una **dist. normal**.

Hipótesis referida a una varianza

Se quiere probar **H0** de que la **varianza** de una población es igual a una determinada, contra una **H1** unilaterial o bilateral

Nunca se va a probar si la desviación estándar o varianza son más chicas. Por lo tanto siempre es de cola derecha.

H0: σ = σ0 desv. est (Varianza descon.)

n>30: $z = \frac{s - \sigma_0}{\frac{\sigma_0}{\sqrt{2 \cdot n}}}$

n<30: $\chi^2 = \frac{(n-1) \cdot s^2}{(\sigma_0)^2}$

H0: p = p0 proporción

$$z = \frac{x - n \cdot p_0}{\sqrt{n \cdot p_0 \cdot (1 - p_0)}}$$

considerando n grandes x = casos de éxito

GL = únicamente para calcular las absicas

Robustez: Resistencia a valores atípicos. La **mediana** es más robusta que la media.

Eficiencia: Precisión en condiciones ideales. La **media** es más eficiente que la mediana porque tiene menor dispersión.

Estimacion de proporciones

Ej: Proporción de personas que toman vino en Mendoza

- Tomo una muestra de **n=100** y encontré que **x=35** toman vino. Esto **no me permite concluir** que el 35% toma vino. (Pq es 1 muestra y seguramente no representativa)
- Debo establecer un inter. de conf. que me permita asegurar con cierto grado de confianza que la proporción real se encuentra en él.
- Puedo estimar la proporción poblacional p, a través de la estimación puntual **x/n**

$$p = \frac{x}{n} \rightarrow \text{casos de éxito} \quad \text{ensayos (muestra)}$$

q=1-p (fracasos)

Como **p** tiene **distribución binomial (dos resultados: 1 o 0, éxito o fracaso, etc)** se verifica:

$$\mu = n \cdot p \quad \sigma = \sqrt{n \cdot p \cdot (1 - p)}$$

2 formas de resolución:

a) **Gráfica** (tablas) menos precisa

b) **Análítica**, se debe cumplir que:

Si **n.p** y **(1-p).n** mayores a 5:

la **Dist Binom** se aproxima a una **Dist Normal**

Entonces Z es

$$Z = \frac{x - n \cdot p}{\sqrt{n \cdot p \cdot (1 - p)}}$$

Intervalo de cont para p

$$\frac{\bar{x}}{n} - z_{\alpha} \cdot \sqrt{\frac{\bar{x} \cdot \left(1 - \frac{\bar{x}}{n}\right)}{n}} < p < \frac{\bar{x}}{n} + z_{\alpha} \cdot \sqrt{\frac{\bar{x} \cdot \left(1 - \frac{\bar{x}}{n}\right)}{n}}$$

• Cálculo de n para lograr un grado de precisión

$$n = p \cdot (1 - p) \cdot \left(\frac{z_{\alpha}}{E}\right)^2$$

Si no conozco p (da 1/4) → si derivó e igualo a 0, obtengo p=0.5

-p=0.5 es el peor de los casos ,ya que **n tiene que ser muy grande** pero asegura contener la proporción (**Es muy costoso**). Tanto a la **der** como a la **izq** de la parábola

Aumentar el tamaño de la muestra reduce el margen de error (es decir, hace que el intervalo de confianza sea más estrecho) manteniendo el mismo nivel de confianza.

Mantener el mismo tamaño de muestra pero aumentar el nivel de confianza hará que el intervalo de confianza se haga más pequeño, porque estás buscando mayor seguridad de que el valor real esté

-Si **E** es muy chiquito entonces n va a ser grande

-**E** es fijado por el cliente.

-Nivel de conf es un acuerdo cliente-proveedor.

Hipótesis relativa a varias proporciones

Se prueba que todas las proporciones de distintas poblaciones binomiales sean significativamente iguales:

H0: p1 = p2 = ... = pk = p

H1: que al menos 1 no lo sea

Método 1: para n>30 (Muestras grandes)

La D.Binomial se aproxima a D.Normal, entonces, **se calcula para cada población:**

$$z_i = \frac{x_i - n_i \cdot p_i}{\sqrt{n_i \cdot p_i \cdot (1 - p_i)}}$$

- El cuadrado de una v. aleatoria con dist. normal, es una v. aleatoria con dist. **chi-cuadrado** con 1 gl

- La suma de **k** v aleatorias con distribuciones **chi-cuadrado** con 1gl dan otra v. aleatoria **chi-cuadrado** con k gl.

gl=grados de libertad

Dado que las pi son todas iguales por hipótesis nula y pn=xn/nn, se pueden sustituir por:

$$\hat{p} = \frac{x_1 + x_2 + \dots + x_k}{n_1 + n_2 + \dots + n_k}$$

suma de proporciones

• Obteniendo el estadístico:

$$\chi^2 = \sum_{i=1}^k \frac{(x_i - n_i \cdot \hat{p})^2}{n_i \cdot \hat{p} \cdot (1 - \hat{p})}$$

Dif grandes se mueve hacia la der, dif chicas hacia la izq

v=k-1 grados de libertad

Método 2: para simplificar el cálculo de chi cuadrado se hace una tabla

	Muestra 1	Muestra 2	...	Muestra k	Total
éxitos	x1	x2	...	xk	x
fallas	n1 - x1	n2 - x2	...	nk - xk	n - x
Total	n1	n2	...	nk	n

• Cada celda es una frecuencia observada.

Frecuencias esperadas

Éxitos $\frac{n_j \cdot x}{n}$ Fracasos $\frac{n_j \cdot (n - x)}{n}$

x = total de la fila

éxitos

n-x = total fila fallas

n = total final

$$\chi^2 = \sum_{i=1}^2 \sum_{j=1}^k \frac{(o_{i,j} - e_{i,j})^2}{e_{i,j}}$$

v=k-1 GL

• Este método es lo mismo que aplicar la fórmula del chi cuadrado que se vió más arriba.

Tablas R X C.

Estas tablas se usan en casos donde la clasificación **es de doble entrada con r filas y c columnas. No tengo la limitación de tener 2 filas como antes.**

Se busca que las proporciones de distintas poblaciones de muestras independientes sean signific. iguales. Las frecuencias esperadas se calculan igual que el método anterior. Ej: **H0: p1 = p2 = ... = pk = p**

	A	B	C	Xi
Nuevo	40	23	12	75
Usado	32	20	30	82
Reacondic	11	27	40	78
Nj	83	70	82	235

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(o_{i,j} - e_{i,j})^2}{e_{i,j}} \quad v=(r-1) \cdot (c-1) \text{ GL}$$

Se rechaza la Hipótesis Nula si el valor de χ2 excede a la absicisa.

Bondad de Ajuste

Si desconozco qué distribución tienen ciertos datos (frecuencias observadas), hago una prueba de Bondad de Ajuste para verificar si los datos siguen una distribución esperada (poisson , normal, etc)

H0: Los datos siguen la distribución de poisson

H1: No la siguen.

Ej: Se quieren ver cuántos mensajes le llegan a una empresa en intervalos de 5 min.

1. Divido los datos en fila (N.mensajes en intervalos de 5 min - es discreto)
2. Anoto las frec. obser. de cada fila
3. Calculo la prob. de cada fila según la dist.
4. Se calculan las frec. esp. (prob. de cada fila por el tamaño total de la muestra).
5. Si algún valor da < 5 en las frec esp. lo sumamos con el valor que tiene abajo/arriba y hacemos lo mismo con las observ.
6. Evaluamos chi cuadrado y tomamos decisión

$$\chi^2 = \sum_{i=1}^k \frac{(o_i - e_i)^2}{e_i} \quad v=k-m-1 \text{ GL}$$

k el número de filas y m parámetros de la distribución supuesta (Poisson, tiene λ ⇒ m = 1, en una dist normal: m=2 ⇒ μ y σ)

UNID. 4 - Pruebas no paramétricas

Las pruebas paramétricas asumen que los datos provienen de poblaciones con distribuciones conocidas (como la normal) y son más eficientes cuando las suposiciones se cumplen. En cambio, las **pruebas no paramétricas no requieren supuestos sobre la distribución**, pero suelen ser menos eficientes y requieren muestras más grandes para alcanzar la misma certeza.

Prueba del Signo

Sirve como **alternativa no paramétrica a T-Unimuestral (pueden ser apareadas o no, osea datos de antes y después)** donde **H0:** μ = μ0. Se aplica cuando se muestra de una **población simétrica** (elementos con misma probabilidad de ser mayor o menor a la media)

El **criterio** que se utiliza es reemplazar cada valor por los signos “+” o “-” según sea mayor o menor que la media (o mediana en su defecto), si es igual se ignora. Se considera siempre una prob **p=0.5**.

Ejemplo: μ0 = 98 y la alternativa μ > μ0. Se coloca + si es mayor a 98, - si no lo es, nada si es igual. Queda una cadena de signos: ++++++-----

Para **muest apareadas (A y D):** una H0 puede ser u1-u2=0 si u1>u2 es + y si u1<u2 es -

x es la cant de signos +. **n** la cantidad de signos totales. **Se calcula la prob de obtener “x” o más signos y si menor o igual a un α (ej: 0.01) se rechaza H0.**

$\sum_{i=9}^{10} \text{dbinom}(k, n, 0.5) = 0.011$ k: num de exitos n: total de signos 0,5: probabilidad

Prueba de Suma de Rangos

Existen dos pruebas: la U y la H.

Prueba U (Wilcoxon) - Alternativa no param. de t bimuestral

Se quiere probar si las medias de dos muestras son significativamente iguales. Se busca probar si las muestras vienen de poblaciones idénticas (Misma distribución: misma forma, μ y varianza)

Pasos

1. Unimos las muestras y las ordenamos de menor a mayor. (Rango=Sum de la posic.)
2. A cada valor se le indica a que muestra pertenece (I, II) y se le asigna un rango (posición). Si dos valores son iguales, se asigna un promedio de sus rangos.
3. Sumar los rangos de cada muestra R1 y R2. se comparan y se elije el Ri menor.
4. Se define el estadístico:

$$U_i = n_1 \cdot n_2 + \frac{n_i(n_i+1)}{2} - R_i$$

Si las n1 y n2 son > 8, U_i tiene una dist. normal.

gralm. prueba 2 colas

$$\mu_{U1} = \frac{n_1 \cdot n_2}{2} \quad \sigma_{U1} = \sqrt{\frac{n_1 \cdot n_2 \cdot (n_1 + n_2 + 1)}{12}}$$

Prueba H (Kruskal Wallis).
 Alternativa no paramétrica de **Anova**.
 Compara que **k** medias poblacionales (de k muestras) sean significativamente iguales. **H0:** $\mu_1 = \mu_2 = \dots = \mu_k$
 1. Unimos las k muestras y las ordenamos de forma creciente.
 2. A cada valor se le indica a que muestra pertenece (I, II, k) y se le asigna un rango (posición). Si dos valores son iguales, se asigna un promedio de sus rangos.
 3. Sumamos los rangos de cada muestra ($R_1, R_2, \dots, R_k$)
 4. Aplicamos la fórmula H, si $n_i > 5$.
 Aceptamos o rechazamos **H0**

$$H = \frac{12}{n \cdot (n+1)} \cdot \sum_{i=1}^k \frac{(R_i)^2}{(n_i)} - 3 \cdot (n+1)$$

 Distribución chi cuadrado con **k-1 grados de libertad**. **k** el numero de poblaciones.
n es la suma de todos los tamaños muestr

Pruebas de aleatoriedad
 Es necesario saber que seguridad hay de que una muestra sea aleatoria. Siempre es a 2 colas.
H0: El arreglo es aleatorio
H1: No lo es
Pasos: qnorm para las absicas
 1. Si es **prueba de corridas (datos booleanos)**, éxito o fracaso, 1 o 0, caro o barato):
 a) Armo la cadena de letras y corridas (EEEEEEFEFFFEFF)
 2. Si es **prueba de secuencias** (datos numéricos):
 a) **Calcular la mediana:** Se determina la mediana de los datos.
 b) Asignar **a y b**: Se etiquetan las observaciones como "a" si están por encima de la mediana y como "b" si están por debajo, armando la cadena.
 3. **Contar corridas (Rachas)**: Se cuentan la cantidad de secuencias consecutivas en las cadenas. **Ej:** u = 5
 4. **Aplicar la prueba:** Se calculan los parámetros para utilizar (**media de corridas y desv estandar de corridas**)

$$\mu_u = \frac{2 \cdot n_1 \cdot n_2}{n_1 + n_2} + 1$$

$$\sigma_u = \sqrt{\frac{2 \cdot n_1 \cdot n_2 \cdot (2 \cdot n_1 \cdot n_2 - n_1 - n_2)}{(n_1 + n_2)^2 \cdot (n_1 + n_2 - 1)}}$$

 5. Si **n1 y n2 > 10**, la dist del num de corridas se aproxima a una dist normal, aplico el estadístico **Z**

$$z = \frac{u - \mu_u}{\sigma_u}$$

 6. Verificar si se cumple la hipótesis nula.
Aleatoriedad por el lado derecho si u es grande (Alterna rápidamente). **por el lado izquierdo** cuando u es chico (pocas alteraciones)
 Se usa en **control de calidad** para dar **aleatoriedad a procesos**.
DCA- Tamaños muestrales distintos
 Se deben hacer los siguientes cambios:
 1. Cambiar n por ni en: SST, SS(Tr), C y T
 2. Cambiar k,n por N en: C (N es =Σni)
 Se usa ni (**tamaño de cada muestra**) en lugar de n (**tamaño de todas las muestras**)

$$\nu_1 := k - 1 = \nu$$

$$\nu_2 := \nu - \nu_1$$

Diseños en Bloques Aleatorios
 Se tienen **a** tratamientos y **b** bloques, con una observación por tratamiento en cada bloque. Se tiene dos criterios de clasificación.

$$y_{ij} = \mu + \alpha_i + \beta_j + \varepsilon_{ij}$$

 Probamos efectiv. de trata. **H0:** $\alpha_1 = \alpha_2 = \alpha_k = 0$ y **efectiv. de la división en bloque.** **H0:** $\beta_1 = \alpha_k = 0$
H1: Al menos una signif. distinta. Una $\alpha_i \neq 0$

Ej	Fuentes de Variación	Grados de Libertad	Suma de Cuadrados
Blancura	Tratamientos	a-1	SS(Tr)
ropa - muestra:	Bloques	b-1	SS(BI)
jabón de	Error	(a-1)·(b-1)	SSE
Total		a·b-1	SST


	Media Cuadrada	F
MS(Tr)=SS(Tr)/(a-1)	$F_{Tr} = \frac{MS(Tr)}{MSE}$	
MS(BI)=SS(BI)/(b-1)	$F_{BI} = \frac{MS(BI)}{MSE}$	
MSE=SSE/(a-1)·(b-1)		

Sum cuadrados del bloque
 Variabilidad de las media de los bloques respecto a la media general $T_{.j}$ es la suma de observ de una columna

$$SST(BI) = \frac{1}{a} \sum_{j=1}^b T_{.j}^2 - C$$

 Se requiere analizar la **relación** entre dos **variables cuantitativas**, para determinar si están asociadas, y si una puede predecir el valor de otra.
El coefic. de corr. no sirve: no explica una variable respecto de otra
Regresion lineal
 1) Tenemos un diagrama de dispersión donde hay dos variables relacionadas:
 - La independiente o **explicativa "x"** ej: edad
 - La dependiente o **explicada "y"** ej: tensión arterial
 2) Queremos encontrar la recta que mejor ajuste los valores, y que pueda ser utilizada para predecir los valores:
 - Para esto usamos el **método de los mínimos cuadrados**, que elige la recta de regresión que minimiza los errores de las diferencias verticales.
 3) La recta que mejor se ajusta es: **y=α + β.x**, que será estimada por:

$$\hat{y} = a + b \cdot x$$
 a y b (parámetros muestrales) son estimadores de α y β (parámetros poblacionales)

$$e_i = y_i - \hat{y}_i$$
 diferencias verticales ← (regresión y sobre x)


No es viable la suma de los errores, pq se cancelan los (+) con los (-)

 4) Se busca **minimizar la suma de los cuadrados de las diferencias** entre los valores reales y los valores estimados ⇒ **a y b se elegirán con:**
 Al cuadrado para que los errores no se cancelen, no utilizamos el valor absoluto debido a un problema de amiguedad en el f(x)' = 0

$$\sum_{i=1}^n [y_i - (a + b \cdot x_i)]^2$$

 5) Para minimizar la suma debemos hacer las **derivadas parciales** de los coeficientes **a y b, e igualarlos a 0**. Esto es debido a que la función es convexa entonces al igualar a 0 se encuentra el **mínimo** de la función

$$\sum_{i=1}^n y_i = a \cdot n + b \cdot \sum_{i=1}^n x_i$$

$$\sum_{i=1}^n y_i \cdot x_i = a \cdot \sum_{i=1}^n x_i + b \cdot \sum_{i=1}^n (x_i)^2$$

 6) Formamos un Sist de Ecuaciones Normales con las derivadas:

$$\begin{bmatrix} n & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n (x_i)^2 \end{bmatrix} \begin{pmatrix} a \\ b \end{pmatrix} = \begin{bmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n (y_i \cdot x_i) \end{bmatrix}$$
 Resolviendo el SEN por determinantes **obtenemos los valores de a y b que mejor se ajustan a la recta**
 Se puede calcular a con **intercept(x,y)** y b con **slope(x,y)**

Coeficiente de Correlación
 El coeficiente de correlación **sirve para indicar relaciones lineales y comportamientos entre dos variables**. Indica **asociacion**, no **causalidad**. Se denota comúnmente como **r** (correlación de Pearson) y **varía** en cualquier valor **entre -1 y 1**:
 • Si **r = 1** → Si una variable aumenta, la otra también
 • Si **r = -1** → Si una aumenta, la otra disminuye
 • Si **r = 0** → No hay relación lineal, puede haber de otro tipo
 Este coeficiente mide la relación entre 2 variables, **no permite explicar una en función de la otra**.
 En mathcad corr(x,y)

UNIDAD 6 - Anova Diseños completamente aleatorios DCA
 Interesa probar la hipótesis de que las **medias de k** muestras de tamaño **n** (tratamientos, grupos, métodos de producción) **son todas iguales**.
 Un **tratamiento** es algo que se aplica a un grupo para ver su efecto. En BA:
 Suponemos poblaciones normales con misma σ2

Ej Tamaño muestra:	Media	En BA:
duraznos	Coll: y11 a ya1	

$$y_{ij} = \mu + \alpha_i + \varepsilon_{ij}$$
Media de las medias μ
Error aleatorio εij. (son **V. Aleatorias** con dist norm, media 0, varianza común)
Efecto del tratamiento: $\alpha_i = \mu_i - \mu$
H0: $\mu_0 = \mu_1 = \mu_k$ es lo mismo que **H0:** $\alpha_0 = \alpha_1 = \alpha_k = 0$
H1: Al menos una signif. distinta. Una $\alpha_i \neq 0$
 1) **Termino de corrección** 2) **Vector de suma de filas**

$$C = \frac{1}{k \cdot n} \left(\sum_{i=1}^k \sum_{j=1}^n y_{ij} \right)^2$$

$$T_{.j} := \sum_{i=1}^k y_{i,j}$$

 4) **Suma de cuadrados de tratamiento**

$$SS(Tr) = (k - 1) \cdot \hat{\sigma}_H^2 = n \cdot \sum_{i=1}^k (\bar{y}_i - \bar{y})^2$$

$$SS(Tr) = \frac{1}{n} \cdot \sum_{i=1}^k (T_{.j})^2 - C$$
 Variabilidad de las medias de las muestras respecto de la media total.
 6) **Estadístico Fisher**

$$F = \frac{\frac{SS(Tr)}{k-1}}{\frac{SSE}{k \cdot (n-1)}}$$
 MS(Tr) MSE
Si F < Fa se acepta H0
 Variabilidad dentro de las muestras

Fuentes de Variación	Grados de Libertad	Suma de Cuadrados	Media Cuadrada	F
Tratamientos	k-1	SS(Tr)	MS(Tr)=SS(Tr)/(k-1)	MS(Tr)/MSE
Error	k·(n-1)	SSE	MSE=SSE/k·(n-1)	
Total	n·k-1	SST		

Fórmulas para Bloq Aleat: las **k** se cambian por **a** y las **n** por **b**


UNIDAD 5 - Ajuste de Curvas

Inferencias Basadas en Estimadores de Mínimos Cuadrados
 Si los datos del diag. de dispersión siguen una curva y se asume una relación lineal, la recta de regresión no representará bien la relación real, no interpreta lo que está ocurriendo. Aunq matemáticamente minimice los errores, no es el mejor ajuste.
 Se calculan **a y b**, a través de notaciones especiales **Sxx** (varianz de x), **Syy** (varianz de y), y **Sxy** (varianz de x e y)
 Se puede demostrar q tanto "a" como "b" presentan una dist. normal, cuyas medias (μa y μb) coinciden con los parámetros α y β. La estimación, se2* (n-2) se denomina **Suma de Cuadrados de Error**. En base

$$b = \frac{S_{xy}}{S_{xx}}$$

$$a = \bar{y} - b \cdot \bar{x}$$
 En base a esto se obtiene un **estimador t-student para alfa y otro para beta**

$$s_e^2 = \frac{S_{xx} \cdot S_{yy} - S_{xy}^2}{n \cdot (n-2) \cdot S_{xx}}$$

$$a - t_{\frac{\alpha}{2}} \cdot s_e \cdot \sqrt{\frac{n \cdot S_{xx}}{S_{xx} + (n \cdot x)^2}} < \alpha < a + t_{\frac{\alpha}{2}} \cdot s_e \cdot \sqrt{\frac{n \cdot S_{xx}}{S_{xx} + (n \cdot x)^2}}$$
 n = cant de puntos
 dist t-student con n-2 gl

 graficos Int de conf: alfa, beta
 Errores mínimos de estimación de a y b
 Para un punto específico grafico en un punto (mas preciso en el medio)

$$(a + b \cdot x_0) \pm t_{\frac{\alpha}{2}} \cdot s_e \cdot \sqrt{\frac{1}{n} + \frac{n \cdot (x_0 - \bar{x})^2}{S_{xx}}}$$
 con v = n-2 g d l
Las pruebas de hipótesis con β son muy importantes, pq indica el cambio promedio **Y** cuando **X** aumenta 1 unidad. Si **β=0**: **y** no depende de **x**

Regresion Curvilinea
 Cuando la relación no es lineal, se transforma la ecuación predictora para que los parámetros (α y β) sean lineales.
 Cuando obtenemos los valores de las estimaciones, los tenemos que volver a su forma original (deshaciendo todas las operaciones efectuadas para linealizarlos), para obtener sus verdaderas aproximaciones.
 Revertir los pasos
 exponencial $y = \alpha \cdot \beta^x \Rightarrow \log(y) = \log(\alpha) + x \cdot \log(\beta) \Rightarrow \left(\frac{A}{B} \right) = \left(\frac{10^a}{10^b} \right)$
 función semilogarítmica
 Obtenemos **a y b** con el **SEN**
 intercept(x,log(y)) y slope(x,log(y))
 potencial $y = \alpha x^\beta \Rightarrow \log(y) = \log(\alpha) + \beta \cdot \log(x) \Rightarrow \begin{matrix} A = 10^a \\ B = 10^b \end{matrix}$
 función logarítmica cpmpleta
 Obtenemos **a y b** con el **SEN**
 intercept(log(x),log(y)) y slope(log(x),log(y))
 Recíproca $y = 1 / (\alpha + \beta \cdot x) \Rightarrow \frac{1}{y} = \alpha + \beta x$
 Los a y b calculados no se modifican
 intercept(x,1/y) y slope(x,1/y)

Ajuste polinómico
 Si no sabemos cómo es la relación entre **x e y** (luego de haber probado con regresion curvilinea y regresion lineal), se busca el mejor ajuste a través de un polinomio de grado **p** (grado mínimo para no sobreajust.)

$$y = \beta_0 + \beta_1 \cdot x + \beta_2 \cdot x^2 + \dots + \beta_p \cdot x^p$$
 calculamos la suma de cuad. error
 Luego derivando respecto a los coeficientes beta e igualando a 0 para tener el error mínimo vamos a tener el SEN
 Resolviendo el SEN obtenemos los valores de beta que mejor se aproximan a los puntos
 Matriz Simétrica
 Comenzamos con un **ajuste lineal** (p=1) y calculamos la **varianza residual**.
Varianza Residual

$$\sigma_{res}^2 = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n - p}$$
 grados de libertad
 Probamos con un polinomio de grado 2, calculamos la **varianza residual** y la comparamos con la anterior.
 Seguimos aumentando el grado del polinomio y registrando la **varianza residual** en cada paso.
 Detenemos el proceso cuando se observa un "salto decreciente significativo"

Regresión Múltiple
 En la **regresión simple** había una **única variable independiente** (x) porque se trabajaba en el **plano**, ahora hay más. **Nos limitamos a 2 variables independientes para trabajar en el espacio**. Entonces **no se encuentra una línea sino que se encuentra un plano**. En **regresión múltiple**, se tiene **n** variables independientes xi (explicativas) y 1 dependiente yi (**explicada**)
 Se aplica el método de los **mínimos cuadrados** para obtener estimaciones de los coeficientes constantes:

$$\sum_{i=1}^n [y_i - (\beta_0 + \beta_1 \cdot x_{i1} + \beta_2 \cdot x_{i2})]^2$$
 se deriva, iguala a 0 y se arma **SEN**
 Las diferencias verticales son las distancias desde cada punto observado hasta el plano de regresión.

$$\begin{bmatrix} n & \sum_{i=1}^n x_{i1} & \sum_{i=1}^n x_{i2} \\ \sum_{i=1}^n x_{i1} & \sum_{i=1}^n (x_{i1})^2 & \sum_{i=1}^n (x_{i1} \cdot x_{i2}) \\ \sum_{i=1}^n x_{i2} & \sum_{i=1}^n (x_{i2} \cdot x_{i1}) & \sum_{i=1}^n (x_{i2})^2 \end{bmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n (y_i \cdot x_{i1}) \\ \sum_{i=1}^n (y_i \cdot x_{i2}) \end{pmatrix}$$