

UNIDAD 2 — Hipótesis

Tema A: Marco general

H_0 : contiene $=, \leq, \geq$. H_1 : contiene $<, >, \neq$ (según el signo define cola izq., der. o bilateral).

Procedimiento: 1) qué demostrar 2) plan-tear H_0, H_1 3) definir cola 4) fijar α 5) ele-gir estadístico 6) región de rechazo 7) cal-cular z_{calc}/t_{calc} 8) comparar vs. crítico o p vs α 9) decidir 10) interpretar.

$$z_{calc} = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$$

Elección de estadístico:

Población	n	σ conocida	σ desconocida
Normal	≥ 30	$\bar{x} \pm z_{\alpha} \sigma_{\bar{x}}$	$\bar{x} \pm z_{\alpha} s_{\bar{x}}$
	< 30	$\bar{x} \pm z_{\alpha} \sigma_{\bar{x}}$	$\bar{x} \pm t_{\alpha} s_{\bar{x}}$
No normal	≥ 30	$\bar{x} \pm z_{\alpha} \sigma_{\bar{x}}$	$\bar{x} \pm z_{\alpha} s_{\bar{x}}$
	< 30	$\bar{x} \pm k \sigma_{\bar{x}}$ (Chebyshev, $1 - 1/k^2$)	

Errores:

	Acepta H	Rechaza H
H verdadera	Correcta	Error I (α)
H falsa	Error II (β)	Correcta

Tema B: Hipótesis relativa a 2 medias

$H_0 : \mu_1 - \mu_2 = \delta$. Colas: $< \delta$ izq., $> \delta$ der., $\neq \delta$ bil.

$n > 30, \sigma^2$ conocido (sustituir por s_1, s_2 si desconocido):

$$z = \frac{(\bar{x}_1 - \bar{x}_2) - \delta}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}}$$

$n < 30, \sigma^2$ desc. (t-bimuestral, indep., $\sigma_1 = \sigma_2$):

$$t = \frac{(\bar{x}_1 - \bar{x}_2) - \delta}{\sqrt{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}} \cdot \sqrt{\frac{n_1 n_2 (n_1 + n_2 - 2)}{n_1 + n_2}}$$

con $\nu = n_1 + n_2 - 2$.

Muestras dependientes (pareadas): $d_i = x_{1i} - x_{2i}$;

$$s = \sqrt{\frac{\sum d_i^2 - n\bar{d}^2}{n - 1}} \quad t = \frac{\bar{d} - \mu_0}{s/\sqrt{n}} \quad (\nu = n - 1)$$

UNIDAD 3 — Estimación

Estimación de la varianza (muestras chicas)

R =rango=máx-mín. d_2, d_3 de tabla según

n ; $\mu_R = d_2 \sigma, \sigma_R = d_3 \sigma$.

$$\hat{\sigma} = \frac{R}{d_2}$$

Uso: Control de Calidad.

IC $\sigma^2, n < 30: \chi^2 = \frac{(n-1)s^2}{\sigma^2}, \nu = n - 1$.

$$\frac{(n-1)s^2}{\chi_{1-\alpha/2}^2} < \sigma^2 < \frac{(n-1)s^2}{\chi_{\alpha/2}^2}$$

(raíz cuadrada para IC de σ)

IC $\sigma, n > 30: z = \frac{s - \sigma}{\sigma/\sqrt{2n}}$

$$\frac{s}{1 + z_{\alpha/2}/\sqrt{2n}} < \sigma < \frac{s}{1 - z_{\alpha/2}/\sqrt{2n}}$$

Hipótesis $\sigma^2 = \sigma_0^2$: cola der.=variabilidad aumentó, izq.=disminuyó, bil.=cualquier alteración.

$$n < 30 : \chi^2 = \frac{(n-1)s^2}{\sigma_0^2}$$

$$n > 30 : z = \frac{s - \sigma_0}{\sigma_0/\sqrt{2n}}$$

Estimación de proporciones

$p = x/n$ (éxitos/ensayos), $q = 1 - p$. $\mu = np, \sigma = \sqrt{np(1-p)}$. Aprox. normal si $np > 5$ y $n(1-p) > 5$.

$$z = \frac{x - np}{\sqrt{np(1-p)}}$$

(se sustituye p por x/n en el denominador)

IC para p :

$$\frac{x}{n} \pm z_{\alpha/2} \sqrt{\frac{(x/n)(1-x/n)}{n}}$$

Tamaño de muestra: $n = p(1-p) \left(\frac{z_{\alpha/2}}{E}\right)^2$; si p desconocido usar $p = 0.5$ (peor caso, n máximo, función cóncava). E lo fija el cliente; nivel de conf. es acuerdo cliente-proveedor.

Hipótesis 1 proporción: $H_0 : p = p_0$

$$z = \frac{x - np_0}{\sqrt{np_0(1-p_0)}}$$

Varias proporciones (χ^2)

$H_0 : p_1 = \dots = p_k = p$. $z_i = \frac{x_i - n_i p_i}{\sqrt{n_i p_i (1 - p_i)}}$, $Z_i^2 \sim \chi_1^2$.

$$\hat{p} = \frac{\sum x_i}{\sum n_i} \quad \chi^2 = \sum_{i=1}^k \frac{(x_i - n_i \hat{p})^2}{n_i \hat{p} (1 - \hat{p})}, \quad \nu = k - 1$$

Método 2 (tabla $2 \times k$):

	M.1	M.2	...	M.k	Total
éxitos	x_1	x_2	...	x_k	x
fallas	$n_1 - x_1$	$n_2 - x_2$	...	$n_k - x_k$	$n - x$
Total	n_1	n_2	...	n_k	n

$$\chi^2 = \frac{\sum \sum \frac{(o_{ij} - e_{ij})^2}{e_{ij}}}{\text{total gral.}}, \quad \nu = k - 1.$$

Tablas RxC y bondad de ajuste

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(o_{ij} - e_{ij})^2}{e_{ij}}, \quad \nu = (r - 1)(c - 1)$$

Bondad de ajuste (ej. Poisson): H_0 : los datos siguen la distribución propuesta. Agrupar categorías con frec. esperada < 5 .

$$\chi^2 = \sum_{i=1}^k \frac{(o_i - e_i)^2}{e_i}, \quad \nu = k - m - 1$$

k =nº grupos, m =nº parámetros estimados (Poisson $m = 1$; Normal $m = 2: \mu, \sigma$).

$$P(X = x) = \frac{e^{-\lambda} \lambda^x}{x!}$$

UNIDAD 4 — No Param.

Prueba del Signo (1 muestra o apareadas)

Alternativa no paramétrica a t-Unimuestral. Reemplazar cada valor por $+/-$ según sea mayor/menor a la media o mediana (se ignora si es igual); prob. $p = 0.5$ siempre. x =cant. de signos $+$, n =total de signos. Se calcula $P(X \geq x)$ (dbinom) y si es $\leq \alpha$ se rechaza H_0 .

Prueba U (Wilcoxon, 2 muestras indep.)

Alternativa no paramétrica a t-bimuestral. Unir y ordenar ambas muestras; asignar rango (posición, promedio si hay empate); sumar R_1, R_2 y elegir el R_i menor.

$$U_i = n_1 n_2 + \frac{n_i(n_i + 1)}{2} - R_i$$

Si $n_1, n_2 > 8: U_i$ es aprox. normal (2 colas).

$$z = \frac{U_i - \mu_{U_i}}{\sigma_{U_i}}$$

$$\mu_{U1} = \frac{n_1 n_2}{2} \quad \sigma_{U1} = \sqrt{\frac{n_1 n_2 (n_1 + n_2 + 1)}{12}}$$

Prueba H (Kruskal-Wallis, $k \geq 3$ muestras indep.)

Alternativa no paramétrica a ANOVA. $H_0 : \mu_1 = \dots = \mu_k$. Unir las k muestras, ordenar creciente, asignar rango (promedio en empates), sumar R_i por muestra.

$$H = \frac{12}{n(n+1)} \sum_{i=1}^k \frac{R_i^2}{n_i} - 3(n+1)$$

Válido si $n_i > 5$. $H \sim \chi_{k-1}^2$. n =suma de todos los tamaños muestrales.

Pruebas de aleatoriedad (corridas)

H_0 : la secuencia es aleatoria. H_1 : no aleatoria (bil.) / demasiadas corridas (unil. der.) / muy pocas corridas (unil. izq.). Corrida=secuencia de letras iguales consecutivas. Datos binarios: cadena a/b directa. Numéricos: a si $>$ mediana, b si $<$ mediana, se omiten los iguales, se mantiene el orden original. n_1 =cant. de a , n_2 =cant. de b , u =cant. total de corridas.

$$\mu_u = \frac{2n_1 n_2}{n_1 + n_2} + 1$$

$$\sigma_u = \sqrt{\frac{2n_1 n_2 (2n_1 n_2 - n_1 - n_2)}{(n_1 + n_2)^2 (n_1 + n_2 - 1)}}$$

Si $n_1, n_2 > 10: Z_{calc} = (u - \mu_u)/\sigma_u$. u grande = alternancia excesiva; u chico = valores agrupados; $u \approx \mu_u$ = compatible con aleatoriedad.

UNIDAD 5 — Regresión

Método de los mínimos cuadrados

Recta poblacional $y = \alpha + \beta x$ estimada por $\hat{y} = a + bx$; $e_i = y_i - \hat{y}_i$ (diferencias verticales). Se minimiza $\sum [y_i - (a + bx_i)]^2$ (al cuadrado para que no se cancelen $+$ y $-$). Ecuaciones normales (derivando e igualando a 0):

$$\sum y_i = an + b \sum x_i$$

$$\sum y_i x_i = a \sum x_i + b \sum x_i^2$$

$$\begin{bmatrix} n & \sum x_i \\ \sum x_i & \sum x_i^2 \end{bmatrix} \begin{pmatrix} a \\ b \end{pmatrix} = \begin{bmatrix} \sum y_i \\ \sum y_i x_i \end{bmatrix}$$

a =intercept (x, y), b =slope (x, y).

Correlación

$$r = \frac{s_{xy}}{s_x \cdot s_y} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \cdot \sum (y_i - \bar{y})^2}}$$

$-1 \leq r \leq 1$. $r = 1$: recta pendiente positiva perfecta. $r = -1$: recta pendiente negativa perfecta. $r = 0$: sin asociación lineal apreciable (puede haber relación no lineal). r mide la relación entre 2 variables; no permite explicar una en función de la otra (no es causalidad).

Inferencias basadas en mínimos cuadrados

$$b = \frac{S_{xy}}{S_{xx}} \qquad a = \bar{Y} - b\bar{X}$$
$$s_e^2 = \frac{S_{xx}S_{yy} - S_{xy}^2}{n(n-2)S_{xx}} \quad (\nu = n-2) \qquad s_e = \sqrt{s_e^2}$$

IC:

$$a \pm t_{\alpha/2} s_e \sqrt{\frac{n S_{xx}}{S_{xx} + (n\bar{x})^2}} \qquad b \pm t_{\alpha/2} s_e \sqrt{\frac{n}{S_{xx}}}$$

$H_0 : \beta = 0$ vs $H_1 : \beta \neq 0$ (la más importante: indica si X influye linealmente en Y ; si $\beta = 0$, Y no depende de X). Estimación puntual en x_0 : $\hat{y}_0 = a + bx_0$.

Regresión curvilínea (linealizar)
Exponencial $y = \alpha\beta^x \Rightarrow y^* = \log_{10} y = a +$

bx , $\alpha = 10^a$, $\beta = 10^b$. Potencial $y = \alpha x^\beta \Rightarrow y^* = \log_{10} y$, $x^* = \log_{10} x : y^* = a + Bx^*$.
Recíproca $y = \frac{1}{\alpha + \beta x} \Rightarrow y^* = \frac{1}{y} = \alpha + \beta x$.
Ajuste polinómico y varianza residual
Grado p , coeficientes $b_0, \dots, b_p$; minimizar $\sum [y_i - (b_0 + b_1x_i + \dots + b_px_i^p)]^2$ y armar sistema de $p + 1$ ecuaciones normales (matriz de sumas de potencias de x).

$$\sigma_{res}^2 = \frac{\sum (y_i - \hat{y}_i)^2}{n - (p + 1)}$$

Se prueba grado 1 (recta), 2 (parábola), 3, ... y se elige el grado donde se observa la mayor caída de σ_{res}^2 ; subir más el grado aumenta el riesgo de sobreajuste.

Regresión múltiple
Incorpora $x_1, \dots, x_k$ variables independientes para explicar Y ; se estima un plano (o hiperplano) de regresión en vez de una recta.

UNIDAD 6 — ANOVA
Diseño completamente aleatorio (1 vía)

$H_0 : \mu_1 = \dots = \mu_k$; H_1 : al menos una distinta. k tratamientos, n obs. c/u. $\alpha_i = \bar{y}_{i.} - \bar{y}_{..}$. (si H_0 cierta, todos $\alpha_i = 0$).

$$C = \frac{T_{..}^2}{kn} \qquad SST = \sum \sum y_{ij}^2 - C$$
$$SS(Tr) = \frac{1}{n} \sum T_{i.}^2 - C = n \sum (\bar{y}_{i.} - \bar{y}_{..})^2$$
$$SSE = SST - SS(Tr)$$
$$F = \frac{SS(Tr)/(k-1)}{SSE/[k(n-1)]} = \frac{\hat{\sigma}_H^2}{\hat{\sigma}_W^2}$$

Fuente	gl	SC	MC
Tratam.	$k - 1$	$SS(Tr)$	$SS(Tr)/(k - 1)$
Error	$k(n - 1)$	SSE	$SSE/[k(n - 1)]$
Total	$nk - 1$	SST	

Diseño en bloques aleatorios
 $y_{ij} = \mu + \alpha_i + \beta_j + \epsilon_{ij}$, con $\sum \alpha_i = 0$, $\sum \beta_j = 0$; $\epsilon_{ij} \sim iid N(0, \sigma^2)$. $a=n^o$ tratamientos, $b=n^o$ bloques.

$$C = \frac{T_{..}^2}{ab} \qquad SST = \sum \sum y_{ij}^2 - C$$
$$SS(Tr) = \frac{1}{b} \sum T_{i.}^2 - C \quad (a-1 \text{ gl})$$

$$SS(Bl) = \frac{1}{a} \sum T_{.j}^2 - C \quad (b-1 \text{ gl})$$
$$SSE = SST - SS(Tr) - SS(Bl) \quad [(a-1)(b-1) \text{ gl}]$$
$$F_{Tr} = \frac{MS(Tr)}{MSE} \qquad F_{Bl} = \frac{MS(Bl)}{MSE}$$

Fuente	gl	SC
Tratam.	$a - 1$	$SS(Tr)$
Bloques	$b - 1$	$SS(Bl)$
Error	$(a-1)(b-1)$	SSE
Total	$ab - 1$	SST

Tamaños muestrales distintos (n_i)
Cambios respecto al diseño 1 vía: usar n_i (no n) en SST , $SS(Tr)$ y T ; usar $N = \sum n_i$ (no $k \cdot n$) en C .

$$C = \frac{T_{..}^2}{N} \qquad SST = \sum \sum y_{ij}^2 - C$$
$$SS(Tr) = \sum \frac{T_{i.}^2}{n_i} - C \qquad SSE = SST - SS(Tr)$$

gl: Tratamientos $k - 1$, Error $N - k$, Total $N - 1$.