

## 2.A Tema A — Hipótesis, procedimiento y errores

**Hipótesis nula ( $H_0$ ).** Es el punto de partida y se asume temporalmente para confrontarla con los datos. Contiene la igualdad:  $=$ ,  $\leq$  o  $\geq$ .

**Hipótesis alternativa ( $H_a$  o  $H_1$ ).** Expresa lo que se concluirá si existe evidencia suficiente para rechazar  $H_0$ . Se formula con  $<$ ,  $>$  o  $\neq$ .

**Procedimiento prueba hipotesis**

### Procedimiento prueba hipotesis

**Paso 1.** Preguntar qué quiere demostrar el problema. **Paso 2.** Formular  $H_0$  y  $H_1$ . **Paso 3.** Mirar el signo de  $H_1$  y determinar si la prueba es de cola izquierda o de cola derecha. **Paso 4.** Determinar el nivel de significancia  $\alpha$ . **Paso 5.** Elegir el estadístico:  $Z$ ,  $t$ ,  $ZX_1, \bar{x}_1$ ,  $tX_2, \bar{x}_2$  u otro que corresponda:  $z_{calc} = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$ . **Paso 6.** Encontrar el valor crítico y construir la región de rechazo. **Paso 7.** Calcular  $z_{calc}$  o  $t_{calc}$  con los datos de la muestra. **Paso 8.** Comparar el estadístico calculado con el valor crítico, o comparar el  $p$ -valor con  $\alpha$ . **Paso 9.** Decidir: rechazar  $H_0$  o no. **Paso 10.** Interpretar la decisión con sus palabras del problema.

## Eleccion estadistico

| Población                  | Tamaño de muestra   | $\sigma$ conocida                                                                              | $\sigma$ desconocida                                                                      |
|----------------------------|---------------------|------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------|
| Normalmente Distribuida    | Grande ( $n > 30$ ) | $\bar{x} \pm z_{\alpha} \cdot \sigma_x$                                                        | $\bar{x} \pm z_{\alpha} \cdot s_x$                                                        |
|                            | Chica ( $n < 30$ )  | $\bar{x} \pm z_{\alpha} \cdot \sigma_x$                                                        | $\bar{x} \pm t_{\alpha} \cdot s_x$                                                        |
| No Normalmente Distribuida | Grande ( $n > 30$ ) | $\bar{x} \pm z_{\alpha} \cdot \sigma_x$                                                        | $\bar{x} \pm z_{\alpha} \cdot s_x$                                                        |
|                            | Chica ( $n < 30$ )  | $\bar{x} \pm k \cdot \sigma_x$<br>donde $1-1/k^2$ se define por medio del Teorema de Chebyshev | $\bar{x} \pm k \cdot s_x$<br>donde $1-1/k^2$ se define por medio del Teorema de Chebyshev |

|                | Se Acepta H       | Se Rechaza H      |
|----------------|-------------------|-------------------|
| H es Verdadera | Decisión Correcta | Error de Tipo I   |
| H es Falsa     | Error de Tipo II  | Decisión Correcta |

fabricante afirma q el secado es 20m, el comprador pinta table-  
ros y lo rechaza si es mayor a 20.75min

- 20,75 es mi límite (elegido arbitrariamente)
- $\leftarrow$  hacia la izquierda del límite se acepta  $\rightarrow$  hacia la derecha del límite se rechaza
- El area gris es la probabilidad de rechazar algo correcto (error tipo I)
- El area amarillo es la probabilidad de aceptar algo incorrecto (error tipo II)

En el caso de q no lo elija arbitrariamente recorro al nivel de significancia  $\alpha$

## 2.B Tema B — Hipótesis relativa a 2 medias

Se comparan 2 medias poblaciones  $u_1 - u_2$   
 $H_0 : \mu_1 - \mu_2 = \delta$ ,  $\delta$  diferencia propuesta  
 $\mu_1 - \mu_2 < \delta$  cola izq.  $\mu_1 - \mu_2 > \delta$  cola der.  $\mu_1 - \mu_2 < \delta$  bil  

$$z = \frac{(x_{m1} - x_{m2}) - \delta}{\text{dif. entre medias muestrales}}$$

Si las poblaciones son normales, se define un estadístico:

1) Para  $n$  grande ( $n > 30$ ):  $\sigma^2$  conocido

$$z = \frac{[\bar{x}_1 - \bar{x}_2] - \delta}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \quad \downarrow \text{varianza de la media muestral}$$

2) Para **n chico** ( $n < 30$ ) con  $\sigma^2$  desconocida: “Prueba t-bimuestral” (muestras independientes) suponemos  $\sigma_1 = \sigma_2 (= \sigma)$

| Valor | Grupo | Rango | Valor | Grupo | Rango |
|-------|-------|-------|-------|-------|-------|
| 47    | B     | 1     | 60    | B     | 9     |
| 41    | C     | 2     | 62    | B     | 10    |
| 49    | C     | 3     | 64    | B     | 11    |
| 52    | B     | 4.5   | 65    | B     | 12    |
| 52    | C     | 4.5   | 66    | A     | 13    |
| 54    | A     | 6     | 67    | A     | 14    |
| 56    | C     | 7     | 69    | C     | 15    |
| 59    | B     | 8     | 71    | A     | 16    |
|       |       |       | 74    | A     | 17    |
|       |       |       | 77    | A     | 18    |

#### 4.3 Pruebas de aleatoriedad — Prueba de corridas

Sirven para comprobar si el orden de una muestra o proceso puede considerarse **aleatorio**. Se analiza si los valores se suceden sin un patrón sistemático. Una **corrida o racha** es una secuencia de una o más letras iguales consecutivas.

**Hipotesis**  
H0:el arreglo o secuencia es aleatorio  
H1:el arreglo no es aleatorio ⇒prueba bilateral  
H1:hay demasiadas corridas ⇒prueba unilateral derecha  
H1:hay muy pocas corridas ⇒prueba unilateral izquierda  
**Pasos**  
**1. Construir la cadena de letras.** -Si los datos son **binarios** — éxito/fracaso, 1/0, caro/barato—, se construye directamente una cadena de letras a y b. -Si los datos son **numéricos**:  
2. Asignar a a cada observación superior a la mediana.  
3. Asignar b a cada observación inferior a la mediana.  
4. Los valores iguales a la mediana se omiten.  
5. Mantener el orden original de los datos.  
**2. Contar las cantidades.** n1=cantidad de letras a; n2=cantidad de letras b; u=cantidad total de corridas  
**3. Calcular los parámetros de la distribución de corridas**

1. Calcular la mediana.  
2. Asignar a a cada observación superior a la mediana.  
3. Asignar b a cada observación inferior a la mediana.  
4. Los valores iguales a la mediana se omiten.  
5. Mantener el orden original de los datos.

**2. Contar las cantidades.** n1=cantidad de letras a; n2=cantidad de letras b; u=cantidad total de corridas  
**3. Calcular los parámetros de la distribución de corridas**  

$$\mu_u = \frac{2n_1n_2}{n_1 + n_2} + 1 \qquad \sigma_u = \sqrt{\frac{2n_1n_2(2n_1n_2 - n_1 - n_2)}{(n_1 + n_2)^2(n_1 + n_2 - 1)}}$$

**4. Aproximacion normal.** si n1>10 y n2>10 la dist. del num de corridas u se aproxima a una dist. normal, aplico estadístico z  

$$Z_{\text{calc}} = \frac{u - \mu_u}{\sigma_u}$$

**Interpretaciones**  
• u grande: demasiados cambios entre a y b; alternancia excesiva.  
• u chico: pocas alternancias; los valores iguales tienden a agruparse.  
• u cercano a  $\mu_u$ : comportamiento compatible con aleatoriedad.  
**Se usa en control de calidad para dar aleatoriedad a procesos**

| Dato  | .261 | .258 | .249 | .251 | .247 | .256 | .250     | .247 | .255 | .243 |
|-------|------|------|------|------|------|------|----------|------|------|------|
| Signo | a    | a    | b    | a    | b    | a    | (Empate) | b    | a    | b    |

$H_0$  : la secuencia es aleatoria       $H_1$  : hay demasiadas corridas (u >  $\mu_u$ )

#### 5.1 Metodos de los minimos cuadrados

Se requiere analizar la **relación** entre dos **variables cuantitativas**, **para** determinar si están asociadas, y si una puede predecir el valor de otra. El **coefic. de corr. no sirve**: no explica una variable respecto de otra

**Regresion lineal**

1) Tenemos un diagrama de dispersión donde hay dos variables relacionadas: - La independiente o **explicativa “x”** ej: edad. - La dependiente o **quemada “y”** ej: tensión arterial  
2) Queremos encontrar la recta que mejor ajuste los valores, y que pueda ser utilizada para predecir los valores: - Para esto usamos el **método de los mínimos cuadrados**, que elige la recta de regresión que minimiza los errores de las diferencias verticales.  
3) La recta que mejor se ajusta es: y=α + β .x , que será estimada por:

$$\widehat{y} = a + b \cdot x \qquad e_i = y_i - \widehat{y_i}$$
a y b (parámetros muestrales) son estimadores de α y β (parámetros poblacionales).  $e_i$ : diferencias verticales ← (regresión y sobre x)  
No es viable la suma de los errores, pq se cancelan los (+) con los (–)  
4) Se busca **minimizar la suma de los cuadrados de las diferencias** entre los valores reales y los valores estimados ⇒ **a y b se elegirán con:** **SCE**

$$\sum_{i=1}^n [y_i - (a + b \cdot x_i)]^2$$

Al cuadrado para que los errores no se cancelen, no utilizamos el valor absoluto debido a un problema de ambigüedad en el f(x<sup>y</sup>) = 0

5) Para minimizar la suma debemos hacer las **derivadas parciales** de los coeficientes **a y b, e igualarlos a 0**. Esto es debido a que la función es convexa entonces al igualar a 0 se encuentra el **mínimo** de la función

$$\sum_{i=1}^n y_i = a \cdot n + b \cdot \sum_{i=1}^n x_i \qquad \sum_{i=1}^n y_i \cdot x_i = a \cdot \sum_{i=1}^n x_i + b \cdot \sum_{i=1}^n (x_i)^2$$

6) Formamos un Sist de Ecuaciones Normales con las derivadas:

$$\left[ \begin{array}{cc} \sum_{i=1}^n x_i & \sum_{i=1}^n (x_i)^2 \end{array} \right] \cdot \left( \begin{array}{c} a \\ b \end{array} \right) = \left[ \begin{array}{c} \sum_{i=1}^n y_i \\ \sum_{i=1}^n (y_i \cdot x_i) \end{array} \right]$$

Resolviendo el SEN por determinantes **obtenemos los valores de a y b** que **mejor se ajustan a la recta**. Se puede calcular a con **intercept(x,y)** y b con **slope(x,y)**

#### 5.2 Inferencias basadas en min cuadrados

Una vez que calculamos a y b para nuestra muestra, la inferencia basada en min cuadrados nos permitirán saber que tan confiable es ese modelo para toda la población y no para una muestra en particular. La inferencia sirve para pasar de los estimadores muestrales a y b a conclusiones sobre los parámetros poblacionales **α y β**.

**Sxy (varianza de xy), Sxx(varianza de x)** me van a permitir estimar la pendiente b y la ordenada al origen a. Con **Syy(varianza de y)** voy a poder calcular la varianza residual muestral

$$\begin{aligned} (1) \text{ Calc.-->Sxy, Sxx, Syy} \qquad (2) \widehat{y} &= \sum_n \frac{y_i}{n} \qquad \widehat{x} = \sum_n \frac{x_i}{n} \\ (3) b &= \frac{S_{xy}}{S_{xx}} \qquad a = \bar{Y} - b\bar{X} \\ (4) \end{aligned}$$

$$s_e^2 = \frac{S_{xx} \cdot S_{yy} - S_{xy}^2}{n(n-2) \cdot S_{xx}} \qquad \text{n-2 gl} \qquad s_e = \sqrt{s_e^2}$$

$s_e^2 \rightarrow$  Varianza residual muestral;  $s_e \rightarrow$  Error estandar de estimacion; n->>cant. puntos  
Intervalos de conf. α y β

$$\alpha : t = \frac{a - \alpha}{s_e} \cdot \sqrt{\frac{n \cdot S_{xx}}{S_{xx} + (n \cdot \bar{x})^2}} \qquad \beta : t = \frac{b - \beta}{s_e} \cdot \sqrt{\frac{S_{xx}}{n}}$$

→ Se compara con el t.crit

$$a - t_{\frac{\alpha}{2}} s_e \sqrt{\frac{n S_{xx}}{S_{xx} + (n \bar{x})^2}} < \alpha < a + t_{\frac{\alpha}{2}} s_e \sqrt{\frac{n S_{xx}}{S_{xx} + (n \bar{x})^2}} \qquad b - t_{\frac{\alpha}{2}} s_e \sqrt{\frac{S_{xx}}{n}} < \beta < b + t_{\frac{\alpha}{2}} s_e \sqrt{\frac{S_{xx}}{n}}$$

Errores máximos de estimación de a y b

Las pruebas de hipotesis con **β** son muy importantes, pq indica el cambio promedio de **Y** cuando **X** aumenta 1 unidad. Si β=0: **y** no depende de **x (recta horizontal)**, si β ≠ 0 : **y** depende de x por lo que existe relacion lineal.

Habiendo comprobado q β ≠ 0 osea que existe relacion lineal, podemos utilizar dicha recta ajustada para realizar estimaciones. Podemos ver q pasa en un punto específico X0

#### 5.3 Regresion curvilinea

Ahora que pasa si al graficar el diagrama de dispersion vemos que los datos no siguen una trayectoria recta? queremos ajustar con linea recta pero el modelo no va a ser el mas adecuado ya q no representa la naturaleza del fenomeno. Es por esto q usamos un modelo curvilineo. Para lograr este modelo y que se comporte de manera lineal debemos aplicar una transformacion matematica a los datos originales y así poder aplicar el metodo de los minimos cuadrados que ya veniamos trabajando.

**Exponencial**  
 $y = \alpha \cdot \beta^x \Rightarrow \log_{10}(y) = \log_{10}(\alpha \cdot \beta^x) \Rightarrow \log_{10}(y) = \log_{10}(\alpha) + x \cdot \log_{10}(\beta)$   
 $y^* = \log_{10}(y)$ ,  $a = \log_{10}(\alpha)$ ,  $b = \log_{10}(\beta) \Rightarrow y^* = a + b \cdot x$        $\alpha = 10^a$      $\beta = 10^b$

**Potencial**  
 $y = \alpha \cdot x^\beta \Rightarrow \log_{10}(y) = \log_{10}(\alpha) + \beta \cdot \log_{10}(x)$   
 $\Rightarrow y^* = \log_{10}(y)$ ,  $x^* = \log_{10}(x)$ ,  $a = \log_{10}(\alpha)$ ,  $B = \beta \Rightarrow y^* = a + Bx^*$      $\alpha = 10^a$      $\beta = 10^b$

$$\begin{aligned} \textbf{Reciprocos} \qquad y &= \frac{1}{\alpha + \beta \cdot x} \Rightarrow \frac{1}{y} = \alpha + \beta \cdot x \\ \Rightarrow y^* &= \frac{1}{y} \qquad a = \alpha \qquad b = \beta \qquad \Rightarrow y^* = \alpha + \beta x \end{aligned}$$

#### 5.4 Ajuste polinomico

Si no sabemos cómo es la relación entre x e y (luego de haber probado con regresion curvilinea y regresion lineal), se busca el mejor ajuste a través de un polinomio de grado p (grado mínimo para no sobreajust.)  
**(1)** Para estimar los p+1 coeficientes óptimos (denotados en la muestra como  $b_0, b_1, \dots, b_p$ ), aplicamos el método de **Mínimos Cuadrados Ordinarios**. El objetivo es encontrar aquellos estimadores que minimicen de forma conjunta la **Suma de Cuadrados de Error (SCE)**, definida como:

$$S(b_0, \dots, b_p) = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n [y_i - \widehat{y_i}]^2 = \sum_{i=1}^n \left[ y_i - (b_0 + b_1 x_i + b_2 x_i^2 + \dots + b_p x_i^p) \right]^2$$

**(2)** Derivamos e igualamos a 0 los p+1 valor (b0,b1,b2....)

$$\begin{aligned} \frac{\partial S}{\partial b_k} &= \sum_{i=1}^n \underbrace{2}_{\text{Baja el exp.}} \cdot \underbrace{\left[ y_i - (b_0 + b_1 x_i + \dots + b_p x_i^p) \right]}_{\text{Lo de adentro intacto}} \cdot \underbrace{(-x_i^k)}_{\text{Deriv. resp. } b_k} = 0 \\ &\underbrace{b_0 \sum_{i=1}^n x_i^k + b_1 \sum_{i=1}^n x_i^{k+1} + \dots + b_p \sum_{i=1}^n x_i^{k+p}}_{\text{Fila de incógnitas}} = \underbrace{\sum_{i=1}^n (x_i^k y_i)}_{\text{Término indep.}} \end{aligned}$$

$$\begin{aligned} (3) \text{ Armamos sist. ec. y matriz} \qquad k = p : \quad &b_0 \sum_{i=1}^n x_i^0 + b_1 \sum_{i=1}^n x_i^{p+1} + \dots + b_p \sum_{i=1}^n x_i^{2p} = \sum_{i=1}^n (x_i^p y_i) \\ \left[ \begin{array}{cccc} \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 & \sum_{i=1}^n x_i^3 & \dots & \sum_{i=1}^n x_i^p \\ \sum_{i=1}^n x_i^2 & \sum_{i=1}^n x_i^3 & \sum_{i=1}^n x_i^4 & \dots & \sum_{i=1}^n x_i^{p+1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^n x_i^p & \sum_{i=1}^n x_i^{p+1} & \sum_{i=1}^n x_i^{p+2} & \dots & \sum_{i=1}^n x_i^{2p} \end{array} \right] \cdot \left[ \begin{array}{c} b_0 \\ b_1 \\ \vdots \\ b_p \end{array} \right] = \left[ \begin{array}{c} \sum_{i=1}^n y_i \\ \sum_{i=1}^n (x_i y_i) \\ \vdots \\ \sum_{i=1}^n (x_i^p y_i) \end{array} \right] \end{aligned}$$

#### 5.5 Metodo de la varianza residual

Para evitar el sobreajuste, se calcula la **varianza residual**:

$$\sigma_{\text{res}}^2 = \frac{\sum_{i=1}^n (y_i - \widehat{y_i})^2}{n - (p + 1)}$$

**Se comienza por :**

- n es la cantidad de puntos de la muestra.
- p es el grado del polinomio.
- p+1 es la cantidad de coeficientes estimados.
- n – p – 1 son los **grados de libertad del modelo**.
- $y_i - \widehat{y_i}$  es el residuo: diferencia entre el valor observado y el estimado.

Para cada uno se calcula la varianza residual y se compara los resultados. La suma de cuadrados de error vista en el numerador de la formula tiende a disminuir porque la curva se adapta mejor a los puntos. Tambien disminuyen los grados de libertad, porque se estiman mas coeficientes

**Para la seleccion:** Se selecciona el grado en el q se observa la mayor cía. Despues de este punto aumentar el grado puede ser innecesario ya q puede aumentar el riesgo de sobreajuste

**Ej:**

Dada una muestra de n = 10 mediciones industriales, se evalúa el ajuste de polinomios de grados sucesivos obteniéndose los siguientes resultados reales:

| Grado (p)      | SCE    | GL (n–p–1) | s <sup>2</sup> | ¿Se justifica?               |
|----------------|--------|------------|----------------|------------------------------|
| 1 (Lineal)     | 57.655 | 8          | <b>7.207</b>   | Modelo Base                  |
| 2 (Cuadrático) | 53.059 | 7          | <b>7.580</b>   | No, la varianza aumentó      |
| 3 (Cúbico)     | 6.124  | 6          | <b>1.021</b>   | Si, salto decreciente masivo |
| 4 (Cuártico)   | 4.959  | 5          | <b>0.992</b>   | No, reducción insignificante |

#### 5.6 Correlacion

**coeficiente correlacion:** El coeficiente de correlación sirve para indicar relaciones lineales y comportamientos entre dos variables. Indica asociación, no causalidad. Se denota comúnmente como r (correlación de Pearson) y varía en cualquier valor entre –1 y 1.

Si r = 1 → Si una variable aumenta, la otra también

Si r = –1 → Si una aumenta, la otra disminuye

Si r = 0 → No hay relación lineal, puede haber de otro tipo

$$\begin{aligned} r &= \frac{s_{xy}}{s_x \cdot s_y} \qquad (2) \qquad r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \qquad (3) \end{aligned}$$

#### 6.1 Diseños completamente aleatorios

La prueba ANOVA busca evaluar si las k medias poblacionales  $\mu_1, \mu_2, \dots, \mu_k$  son todas iguales entre sí:

$H_0 : \mu_1 = \mu_2 = \dots = \mu_k$  (Todas las medias poblacionales son iguales)  
 $H_1 : \text{ Al menos una media } \mu_i \text{ es distinta (Existe al menos un par } \mu_i \neq \mu_j \text{ para } i \neq j)$

Suponemos poblaciones normales con misma varianza, observaciones independientes. Podemos construir una matriz con k filas y n columnas

Primero considero el diseño completamente aleatorio con tamaños muestrales iguales. Tengo k tratamientos y cada uno tiene la misma cantidad n de observaciones. Las unidades experimentales se asignan aleatoriamente a cada tratamiento.

| Tratamiento / Muestra | Obs. 1          | Obs. 2          | ... | Obs. j          | ... | Obs. n          | Total (T <sub>i</sub> ) | Media (ȳ <sub>i</sub> ) |
|-----------------------|-----------------|-----------------|-----|-----------------|-----|-----------------|-------------------------|-------------------------|
| Muestra 1             | y <sub>11</sub> | y <sub>12</sub> | ... | y <sub>1j</sub> | ... | y <sub>1n</sub> | T <sub>1</sub>          | ȳ <sub>1</sub>          |
| Muestra 2             | y <sub>21</sub> | y <sub>22</sub> | ... | y <sub>2j</sub> | ... | y <sub>2n</sub> | T <sub>2</sub>          | ȳ <sub>2</sub>          |
| ...                   | ...             | ...             | ... | ...             | ... | ...             | ...                     | ...                     |
| Muestra i             | y <sub>i1</sub> | y <sub>i2</sub> | ... | y <sub>ij</sub> | ... | y <sub>in</sub> | T <sub>i</sub>          | ȳ <sub>i</sub>          |
| ...                   | ...             | ...             | ... | ...             | ... | ...             | ...                     | ...                     |
| Muestra k             | y <sub>k1</sub> | y <sub>k2</sub> | ... | y <sub>kj</sub> | ... | y <sub>kn</sub> | T <sub>k</sub>          | ȳ <sub>k</sub>          |
| Total / Gran Media    |                 |                 |     |                 |     |                 | T..                     | ȳ..                     |

**Efecto tratamiento (α)** Interpretacion. Si  $\widehat{y_i}$  (media muestra i) tienen un valor mas grande que  $\widehat{y_{..}}$  (media global o gran media) poniendo como ejemplo los detergente quier decir q ese detergente es positivo o mejor. Decir q las medias son iguales, los efectos serian 0.

**Para el calculo final del estadístico se realizan los sig calculos**  
1) vamos a definir un valor constante que es la suma de los elementos de la matriz elevado al cuadrado, multiplicado por 1/k.n

$$C = \frac{1}{k \cdot n} \left( \sum_{i=1}^k \sum_{j=1}^n y_{ij} \right)^2 \qquad \text{o simplemente haciendo--> } C = \frac{(T_{..})^2}{k \cdot n}$$

**C= termino de correccion**

2) vamos a calcular la suma de cuadrados total SST, tomando cada elemento de la matriz y elevando al cuadrado y sumando todo y restando el valor de “C” que calculamos recién. Es el primer miembro de la expresion.

$$SST = \sum_{i=1}^k \sum_{j=1}^n \left( y_{ij} \right)^2 - C$$

3) vamos a calcular una sumatoria llamada **suma de cuadrados de tratamientos**. Pertenece al ultimo termino de mi expresion. T<sub>i</sub> es la suma de todos los elementos de una fila de la matriz

$$SS(Tr) = n \sum_{i=1}^k (\widehat{y_i} - \widehat{y_{..}})^2 \text{ o } SS(Tr) = \frac{1}{n} \sum_{i=1}^k (T_{i..})^2 - C$$

4) podemos calcular la suma de cuadrados de error SSE con el SST y SS(Tr) calculados anteriormente

$$\begin{aligned} SSE &= SST - SS(Tr) \\ (5) \text{ finalmente defino el estadístico F, para zona critica} \qquad F &= \frac{\frac{SS(Tr)}{k-1}}{\frac{SSE}{n-k-1}} = \frac{\frac{\sigma_H^2}{\sigma_W^2}}{k \cdot (n-1)} \end{aligned}$$

media cuad. tratamiento(MS(Tr)) \searrow media cuad.error (MSE) \nearrow \rightarrow n1=k-1 gl      n2=k\*(n-1) gl  
 $\sigma_W^2 \rightarrow$  Estima varianza a lo alto;  $\sigma_W^2 \rightarrow$  Estima varianza a lo ancho; k= nº tratamientos

| Fuentes de Variación | Grados de Libertad | Suma de Cuadrados | Media Cuadrada      | F          |
|----------------------|--------------------|-------------------|---------------------|------------|
| <b>Tratamientos</b>  | k-1                | SS(Tr)            | MS(Tr)=SS(Tr)/(k-1) | MS(Tr)/MSE |
| <b>Error</b>         | k.(n-1)            | SSE               | MSE=SSE/k.(n-1)     |            |
| <b>Total</b>         | n.k-1              | SST               |                     |            |

**PARA k=4; n=12**    Error=total-tratamientos = (n.k-1) – (k-1) = nk – 1 – k + 1 = nk – k = k(n – 1)

#### 6.2 Tamaños muestrales distintos

cada fila tiene distintas cantidad de columnas

| Tratamiento  | Obs. 1          | Obs. 2          | ... | Obs. j          | ... | Obs. n <sub>i</sub>         | Tamaño (n <sub>i</sub> ) | Total (T <sub>i</sub> ) | Media (ȳ <sub>i</sub> ) |
|--------------|-----------------|-----------------|-----|-----------------|-----|-----------------------------|--------------------------|-------------------------|-------------------------|
| Muestra 1    | y <sub>11</sub> | y <sub>12</sub> | ... | y <sub>1j</sub> | ... | y <sub>1n<sub>1</sub></sub> | n <sub>1</sub>           | T <sub>1</sub>          | ȳ <sub>1</sub>          |
| Muestra 2    | y <sub>21</sub> | y <sub>22</sub> | ... | y <sub>2j</sub> | ... | y <sub>2n<sub>2</sub></sub> | n <sub>2</sub>           | T <sub>2</sub>          | ȳ <sub>2</sub>          |
| ...          | ...             | ...             | ... | ...             | ... | ...                         | ...                      | ...                     | ...                     |
| Muestra k    | y <sub>k1</sub> | y <sub>k2</sub> | ... | y <sub>kj</sub> | ... | y <sub>kn<sub>k</sub></sub> | n <sub>k</sub>           | T <sub>k</sub>          | ȳ <sub>k</sub>          |
| Total Global |                 |                 |     |                 |     |                             | N = ∑ n <sub>i</sub>     | T..                     | ȳ..                     |

Se deben hacer los siguientes cambios:

1. Cambiar **n** por **ni** en: SST, SS(Tr) , C y T

2. Cambiar **k,n** por **N** en: C (N es= ∑ni)

Se usa **ni (tamaño de cada muestra)** en lugar de **n (tamaño de todas las muestras)**

$$\begin{aligned} \nu_1 &:= k - 1 = \qquad \qquad \nu := N - 1 = \qquad \qquad \nu_2 := \nu - \nu_1 \\ C &= \frac{T^2}{N} \qquad \text{donde } N = \sum_{i=1}^k n_i \qquad SST = \sum_{i=1}^k \sum_{j=1}^{n_i} y_{ij}^2 - C \end{aligned}$$

$$SS(Tr) = \sum_{i=1}^k \frac{T_i^2}{n_i} - C \qquad SSE = SST - SS(Tr)$$

| Fuente de Variación | gl    | Suma de Cuadrados | Media Cuadrada (MS)           | F <sub>calc</sub>    |
|---------------------|-------|-------------------|-------------------------------|----------------------|
| Tratamientos        | k – 1 | SS(Tr)            | MS(Tr) = $\frac{SS(Tr)}{k-1}$ | $\frac{MS(Tr)}{MSE}$ |
| Error Aleatorio     | N – k | SSE               | MSE = $\frac{SSE}{N-k}$       |                      |
| Total               | N – 1 | SST               |                               |                      |

#### 6.3 Diseño en bloques aleatorios

El experimentador tiene a disposicion mediciones relativas a “a” tratamientos distribuidos en b bloques. Vamos a considerar el caso en q hay una observacion en cada tratamiento de cada bloque.

| Tratamiento   | Bloque 1        | Bloque 2        | ... | Bloque b        | Total (T <sub>i</sub> ) | Media (ȳ <sub>i</sub> ) | Efecto (α <sub>i</sub> )                          |
|---------------|-----------------|-----------------|-----|-----------------|-------------------------|-------------------------|---------------------------------------------------|
| Tratamiento 1 | y <sub>11</sub> | y <sub>12</sub> | ... | y <sub>1b</sub> | T <sub>1</sub>          | ȳ <sub>1</sub>          | α <sub>1</sub> = ȳ <sub>1</sub> – ȳ <sub>..</sub> |
| Tratamiento 2 | y <sub>21</sub> | y <sub>22</sub> | ... | y <sub>2b</sub> | T <sub>2</sub>          | ȳ <sub>2</sub>          | α <sub>2</sub> = ȳ <sub>2</sub> – ȳ <sub>..</sub> |
| ...           | ...             | ...             | ... | ...             | ...                     | ...                     | ...                                               |
| Tratamiento a | y <sub>a1</sub> | y <sub>a2</sub> | ... | y <sub>ab</sub> | T <sub>a</sub>          | ȳ <sub>a</sub>          | α <sub>a</sub> = ȳ <sub>a</sub> – ȳ <sub>..</sub> |
| Total Bloque  | T <sub>.1</sub> | T <sub>.2</sub> | ... | T <sub>.b</sub> | T..                     | ȳ..                     |                                                   |
| Media Bloque  | ȳ <sub>.1</sub> | ȳ <sub>.2</sub> | ... | ȳ <sub>.b</sub> |                         |                         |                                                   |
| Efecto Bloque | β <sub>1</sub>  | β <sub>2</sub>  | ... | β <sub>b</sub>  |                         |                         |                                                   |

El modelo matemático aditivo sin interacción es:

$$y_{ij} = \mu + \alpha_i + \beta_j + \epsilon_{ij} \quad \text{para } i = 1, \dots, a; \quad j = 1, \dots, b$$