

2.A Tema A — Hipótesis, procedimiento y errores

Hipótesis nula (H_0). Es el punto de partida y se asume temporalmente para confrontarla con los datos. Contiene la igualdad: $=, \leq$ o $\geq$.

Hipótesis alternativa (H_a o H_1). Expresa lo que se concluirá si existe evidencia suficiente para rechazar H_0 . Se formula con $<, >$ o $\neq$.

Procedimiento prueba hipotesis

Paso 1. Preguntar qué quiere demostrar el problema. **Paso 2.** Formular H_0 y H_1 . **Paso 3.** Mirar el signo de H_1 y determinar si la prueba es derecha, izquierda o bilateral. **Paso 4.** Fijar el nivel de significancia α . **Paso 5.** Elegir el estadístico: Z , t , $Z_{\bar{x}_1-\bar{x}_2}$, $t_{\bar{x}_1-\bar{x}_2}$ u otro que corresponda: $z_{calc} = \frac{\bar{x}-\mu_0}{\sigma/\sqrt{n}}$. **Paso 6.** Encontrar el valor crítico y construir la región de rechazo. **Paso 7.** Calcular z_{calc} , o t_{calc} con los datos de la muestra. **Paso 8.** Comparar el estadístico calculado con el valor crítico, o comparar el p-valor con α . **Paso 9.** Decidir: rechazar H_0 o no rechazar H_0 . **Paso 10.** Interpretar la decisión con las palabras del problema.

Eleccion estadistico

Población	Tamaño de la muestra	σ conocida	σ desconocida
Normalmente Distribuida	Grande ($n \geq 30$)	$\bar{x} \pm z_{\alpha} \cdot \sigma_x$	$\bar{x} \pm z_{\alpha} \cdot s_x$
	Chica ($n < 30$)	$\bar{x} \pm z_{\alpha} \cdot \sigma_x$	$\bar{x} \pm t_{\alpha} \cdot s_x$
No Normalmente Distribuida	Grande ($n > 30$)	$\bar{x} \pm z_{\alpha} \cdot \sigma_x$	$\bar{x} \pm z_{\alpha} \cdot s_x$
	Chica ($n < 30$)	$\bar{x} \pm k \cdot \sigma_x$ donde $1-1/k^2$ se define por medio del Teorema de Chebyshev	$\bar{x} \pm k \cdot s_x$ donde $1-1/k^2$ se define por medio del Teorema de Chebyshev

	Se Acepta H	Se Rechaza H
H es Verdadera	Decisión Correcta	Error de Tipo I
H es Falsa	Error de Tipo II	Decisión Correcta

fabricante afirma q el secado es 20m, el comprador pinta tableros y lo rechaza si es mayor a 20.75min

- 20.75 es mi límite (elegido arbitrariamente)
- ← hacia la izquierda del límite se acepta → hacia la derecha del límite se rechaza
- El area gris es la probabilidad de rechazar algo correcto (error tipo I)
- El area amarillo es la probabilidad de aceptar algo incorrecto (error tipo II)

En el caso de q no lo elija arbitrariamente recorro al nivel de significancia α

2.B Tema B — Hipótesis relativa a 2 medias

Se comparan 2 medias poblaciones u_1-u_2
 $H_0 : \mu_1 - \mu_2 = \delta$, δ diferencia propuesta
 $\mu_1 - \mu_2 < \delta$ cola izq. $\mu_1 - \mu_2 > \delta$ cola der. $\mu_1 - \mu_2 <> \delta$ bil
$$z = \frac{(x_{m1} - x_{m2}) - \delta}{\frac{\sigma_{x_{m1}} - \sigma_{x_{m2}}}{\sqrt{n_1 + n_2}}}$$
 dif. entre medias muestrales

Si las poblaciones son normales, se define un estadístico:

1) Para n grande ($n > 30$): σ^2 conocido

$$z = \frac{[\bar{x}_1 - \bar{x}_2] - \delta}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \quad \downarrow \text{varianza de la media muestral}$$

σ^2 desconocido: sustituyendo σ_1 y σ_2 por s_1 y s_2

2) Para n chico ($n < 30$) con σ^2 desconocida: "Prueba t-bimuestral" (muestras independientes) suponemos $\sigma_1 = \sigma_2 (= \sigma)$

$$t = \frac{[(\bar{x}_1 - \bar{x}_2) - \delta]}{\sqrt{(n_1 - 1) \cdot (s_1)^2 + (n_2 - 1) \cdot (s_2)^2}} \cdot \sqrt{\frac{n_1 \cdot n_2 \cdot (n_1 + n_2 - 2)}{n_1 + n_2}}$$

con $\nu = n_1 + n_2 - 2$

3) Si las 2 poblac. no son independientes: La muestra es la diferencia entre las 2 poblaciones relacionadas, con su signo.

Horas-hombre perdidas antes y después del programa.										
Planta	1	2	3	4	5	6	7	8	9	10
Antes	45	73	46	124	33	57	83	34	26	17
Después	36	60	44	119	35	51	77	29	24	11
d_i	9	13	2	5	-2	6	6	5	2	6
$\bar{x} =$	$\frac{9+13+2+5-2+6+6+5+2+6}{10} = 5.2$									

$$s = \sqrt{\frac{\sum d_i^2 - n \cdot \bar{x}^2}{n - 1}} \quad \text{n-1 para quitar sesgo}$$
$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} \quad \text{Aplica t-unimuestral}$$

conclus->eficaz qt(0.95, df = 9) Se rechaza h0

Ejemplo (fertilizante sobre producción de trigo):

24 parcelas iguales: 12 sin fertilizante (control) $\bar{x}_2 = 0.264 \text{ m}^3$, $s_2 = 0.02 \text{ m}^3$; 12 tratadas $\bar{x}_1 = 0.28 \text{ m}^3$, $s_1 = 0.022 \text{ m}^3$. Nivel de significación 5%.

$1 - H_0 : \mu_1 - \mu_2 = 0$ (la diferencia se debe al azar); $H_1 : \mu_1 > \mu_2$ (unilateral cola derecha). **2** - $\alpha = 0.05$; $t_{\alpha} = 1.717$ con $\nu = 22$ gl. **3** - Para trabajar con tablas normalizadas:

$$t = \frac{\left[\left(\frac{\bar{x}_1 - \bar{x}_2}{\sqrt{(n_1 - 1) \cdot (s_1)^2 + (n_2 - 1) \cdot (s_2)^2}} \right) - \delta \right]}{\sqrt{\frac{12 \cdot 12 \cdot (12 + 12 - 2)}{12 + 12}}} = 1.849$$

5- Dado que $1.849 > t_{0.05}$ ($t_{0.05} = 1.717$) se Rechaza la Hipótesis Nula $\mu_1 - \mu_2 = 0$. Vale decir, hay un incremento significativo en la producción de trigo por el empleo del fertilizante.

3.1 Estimacion de la varianza

En muestras pequeñas no resulta adecuado hacer la estimacion del sigma con el s, para ello se recurre al rango muestral R. El rango de un conjunto de valores es el maximo valor - el minimo valor. Voy a tener una poblacion normal con media mu y desviacion estandar sigma. Tomo muestras aleatorias de tamaño n y les calculo el rango R. Si encuentro la funcion densidad de probabilidad de esos rangos veo q tienen una distribucion normal cuya media vale $d_2 \cdot \sigma$ y cuya desviacion estandar es $d_3 \cdot \sigma$. Siendo d_2 y d_3 valores q tomo de una tabla para estos tamaños muestrales.

$$\delta = \frac{R}{d_2} \quad \mu_R = d_2 \cdot \sigma \quad \sigma_R = d_3 \cdot \sigma$$

Se usa en Control de Calidad

3) Para n chico ($n < 30$) --> Dist Chi cuadrado

$$\chi^2 = \frac{(n - 1) \cdot s^2}{\sigma^2} \quad \text{con } \nu = n - 1 \text{ gl}$$

inter. confianz para σ^2

$$\frac{(n - 1) \cdot s^2}{\chi^2_{1-\frac{\alpha}{2}}} < \frac{(n - 1) \cdot s^2}{\chi^2_{\frac{\alpha}{2}}} < \frac{(n - 1) \cdot s^2}{\chi^2_{1-\frac{\alpha}{2}}} < \sigma^2 < \frac{(n - 1) \cdot s^2}{\chi^2_{\frac{\alpha}{2}}}$$
$$\frac{(n - 1) \cdot s^2}{\chi^2_{1-\frac{\alpha}{2}}} < \sigma < \sqrt{\frac{(n - 1) \cdot s^2}{\chi^2_{\frac{\alpha}{2}}}}$$

inter. confianz para σ (aplicamos raíz)

$$\frac{(n - 1) \cdot s^2}{\chi^2_{1-\frac{\alpha}{2}}} < \sigma < \sqrt{\frac{(n - 1) \cdot s^2}{\chi^2_{\frac{\alpha}{2}}}}$$

4) Para n grande ($n > 30$) --> Dist Z y Chi cuadrado (innecesario) a)

$$z = \frac{s - \sigma}{\frac{\sigma}{\sqrt{2 \cdot n}}}$$
$$-z_{\alpha/2} < \frac{s - \sigma}{\frac{\sigma}{\sqrt{2n}}} < z_{\alpha/2}$$
$$\frac{s}{1 + \frac{z_{\frac{\alpha}{2}}}{\sqrt{2 \cdot n}}} < \sigma < \frac{s}{1 - \frac{z_{\frac{\alpha}{2}}}{\sqrt{2 \cdot n}}}$$

También se podría usar la chi cuadrado ya que con $n > 30$ se aproxima a una dist. normal.

Hipotesis referida a una varianza

Se quiere probar H_0 de que la varianza de una población es igual a una determinada, contra una H_1 unilateral o bilateral.

*cola derecha-> Detectar si la variabilidad del proceso aumentó (ej. máquina descalibrada).

*izquierda->Demostrar que la variabilidad disminuyó (ej. nuevo método más preciso).

*bilateral->Detectar cualquier alteración respecto a un estándar fijo (sea que la varianza suba o baje).

$$\text{n}<30: \chi^2 = \frac{(n - 1) \cdot s^2}{(\sigma_0)^2} \quad \text{n}>30: z = \frac{s - \sigma_0}{\frac{\sigma_0}{\sqrt{2 \cdot n}}}$$

3.2 Ejemplo — estimacion de la varianza

Las siguiente muestra aleatoria son mediciones de la capacidad de producción de calor (en millones de calorías por tonelada) de especímenes de carbón de una mina: 8260 8130 8350 8070 8340. Usar el rango de la muestra para estima σ de la capacidad de producción de calor del carbón de la mina.

1) Busco primero el mayor de los valores (8360) y los resto con el menor (8070), entonces el rango R me queda:

$$R = 8350 - 8070 = 280$$

2) busco en la tabla d_2 a cuanto equivale para $n = 5$

d_2	1.128	1.693	2.054	2.326	2.534	2.704	2.847	2.970	3.078
d_3	0.853	0.888	0.880	0.864	0.848	0.833	0.830	0.808	0.797
N	2	3	4	5	6	7	8	9	10

Luego la estimación de σ queda:

$$\sigma = \frac{R}{d_2} = \frac{280}{2.326} = 120.378$$

mientras que calculado directamente da:

$$s = \sqrt{\frac{8260^2 + 8130^2 + 8350^2 + 8070^2 + 8340^2 - 5 \cdot 8230^2}{4}} = 125.499$$

Es mucho mas confiable estimar por el R ya q me da menos

$$s = \sqrt{\frac{\sum (x_i^2) - n \cdot \bar{x}^2}{n - 1}}$$

3.3 Estimacion de proporciones

Ej: Proporción de personas que toman vino en Mendoza

- Tomo un muestra de n=100 y encontré que x=35 toman vino. Esto no me permite concluir que el 35% toma vino. (Pq es 1 muestra y seguramente no representativa)
- Debo establecer un inter. de conf. que me permita asegurar con cierto grado de confianza que la proporción real se encuentra en él.
- Puedo estimar la proporción poblacional p, a través de la estimación puntual x/n

$$p = \frac{x}{n} \rightarrow \text{casos de éxito} \quad q = 1 - p \rightarrow \text{ensayos (muestra) (fracasos)}$$

Como p tiene distribución binomial (dos resultados: 1 o 0, éxito o fracaso, etc) se verifica:

$$\mu = n \cdot p \quad \sigma = \sqrt{n \cdot p \cdot (1 - p)}$$

Al sumar todas esas respuestas individuales de 1 o 0, obténis tu variable "x" (los casos de éxito, que en este ejemplo son 35). Es esta variable "x" la que sigue una Distribución Binomial, porque representa "la cantidad de éxitos en "n" ensayos independientes".

• Éxito (1): Si toma vino. • Fracaso (0): No toma vino.

2 formas de resolución:

a) Gráfica (tablas) menos precisa

b) Analítica, se debe cumplir que: Si n.p y (1-p).n mayores a 5: la Dist Binom se aproxima a una Dist Normal

Entonces Z es (1)

$$z = \frac{x - n \cdot p}{\sqrt{n \cdot p \cdot (1 - p)}}$$

como resulta difícil despejar p, se reemplaza por x/n en el denominador (2)

$$-z_{\frac{\alpha}{2}} < \frac{x - n \cdot p}{\sqrt{n \cdot p \cdot (1 - p)}} < z_{\frac{\alpha}{2}} \quad -z_{\frac{\alpha}{2}} < \frac{x - n \cdot p}{\sqrt{n \cdot \frac{x}{n} \cdot \left(1 - \frac{x}{n}\right)}} < z_{\frac{\alpha}{2}}$$

Intervalo de conf para p (3)

$$\underbrace{\frac{x}{n}}_{\text{pivote}} - z_{\frac{\alpha}{2}} \sqrt{\frac{\frac{x}{n} \left(1 - \frac{x}{n}\right)}{n}} < p < \frac{x}{n} + z_{\frac{\alpha}{2}} \underbrace{\sqrt{\frac{\frac{x}{n} \left(1 - \frac{x}{n}\right)}{n}}}_{\text{Error max de estimación}}$$

• Cálculo de n para lograr un grado de precisión

$$n = p \cdot (1 - p) \cdot \left(\frac{z_{\frac{\alpha}{2}}}{E}\right)^2$$

Hipotesis relativa a una proporcion

$$\text{H0: } p = p_0 \quad \text{proporción} \quad z = \frac{p - p_0}{\sqrt{\frac{p_0 \cdot (1 - p_0)}{n}}} \quad \text{considerando n grandes} \quad x = \text{casos de éxito}$$

3.4 Hipotesis relativa a varias proporciones

Se prueba que todas las proporciones de distintas poblaciones binomiales sean significativamente iguales:

H0: $p_1 = p_2 = \dots = p_k = p$ H1: que al menos 1 no lo sea

Método 1: Si n.p y (1-p).n mayores a 5: La D.Binomial se aproxima a D.Normal, entonces, se calcula para cada población:

$$z_i = \frac{x_i - n_i \cdot p_i}{\sqrt{n_i \cdot p_i \cdot (1 - p_i)}} \quad Z_i^2 \sim \chi_1^2$$

- El cuadrado de una v. aleatoria con dist. normal, es una v. aleatoria con dist. chi-cuadrado con 1 gl. - La suma de k v. aleatorias con distribuciones chi-cuadrado con 1gl dan otra v. aleatoria chi-cuadrado con k gl. gl=grados de libertad

Dado que las p_i son todas iguales por hipótesis nula y $p_n = x_n / n_n$, se pueden sustituir por:

$$\hat{p} = \frac{x_1 + x_2 + \dots + x_k}{n_1 + n_2 + \dots + n_k} \quad \text{suma de proporciones}$$

• Obteniendo el estadístico:

$$\chi^2 = \sum_{i=1}^k \frac{\left(x_i - n_i \cdot \hat{p} \right)^2}{n_i \cdot \hat{p} \cdot \left(1 - \hat{p} \right)}$$

Dif grandes se mueve hacia la der, dif chicas hacia la izq. $\nu=k-1$ grados de libertad. fracasos esperados $n_i(1 - \hat{p})$; éxitos esperados $n_i \hat{p}$

Resultado	A	B	C	Total
Desmoronado	41	27	22	90
Resto intacto	79	53	78	210
Total	120	80	100	300

Se quiere determinar si la probabilidad de desmoronamiento es la misma para los materiales A, B y C. En cada material hay dos resultados posibles: desmoronado o resto intacto.

metodo 1

$$\chi^2 = \sum_{i=1}^3 \frac{\left(\widehat{x_i - n_i p} \right)^2}{n_i p (1 - p)} = \frac{(x_1 - n_1 p)^2}{n_1 p (1 - p)} + \frac{(x_2 - n_2 p)^2}{n_2 p (1 - p)} + \frac{(x_3 - n_3 p)^2}{n_3 p (1 - p)}$$

$$\nu = k - 1 = 3 - 1 = 2.$$

Método 2: para simplificar el cálculo de chi cuadrado se hace una tabla

	Muestra 1	Muestra 2	...	Muestra k	Total
éxitos	x_1	x_2	...	x_k	x
fallas	$n_1 - x_1$	$n_2 - x_2$	...	$n_k - x_k$	$n - x$
Total	n_1	n_2	...	n_k	n

• Cada celda es una frecuencia observada. Frecuencias esperadas

$$\text{Éxitos } \frac{n_j \cdot x}{n} \quad \text{Fracasos } \frac{n_j \cdot (n - x)}{n}$$

$$\chi^2 = \sum_{i=1}^2 \sum_{j=1}^k \frac{\left(o_{i,j} - e_{i,j} \right)^2}{e_{i,j}} \quad \nu=k-1 \text{ GL}$$

n_j = total columna j; x = total de la fila exitos; $n - x$ = total fila fallas; n = total final

• Este método es lo mismo que aplicar la fórmula del chi cuadrado que se vió más arriba.

Este método organiza los mismos datos en una tabla 2 x 3: dos resultados y tres materiales $\nu = k - 1 = 3 - 1 = 2$.

metodo 2

$$\chi^2 = \sum_{i=1}^2 \sum_{j=1}^3 \frac{\left(O_{ij} - E_{ij} \right)^2}{E_{ij}}, \quad E_{ij} = \frac{(\text{total fila } i)(\text{total columna } j)}{\text{total general}}$$

Esperadas	A	B	C	Total
Desmoronado	36	24	30	90
Intacto	84	56	70	210
Total	120	80	100	300

3.5 Tablas RxC y bondad de ajuste

igual a anterior no mas que mas de 2 resultados posibles. tenemos r filas x c columnas

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{\left(o_{i,j} - e_{i,j} \right)^2}{e_{i,j}} \quad \nu = (r - 1)(c - 1) \text{ gl}$$

Aprovechamiento en el programa de entrenamiento

	Debajo del Promedio	Promedio	Sobre el Promedio	Total
Deficiente	23	60	29	112
Promedio	28	79	60	60
Muy buena	9	49	63	63
Total	60	188	152	400

Bondad de ajuste. Compara la distribución observada con una distribución teórica propuesta: se determina si las diferencias son por azar o si el modelo teórico no ajusta.

Poisson modela la cantidad de sucesos en un intervalo fijo. H0: Los datos siguen la distribución de poisson. H1: No la siguen.

autos				
Número de mensajes en interv. de 5 min.	Frecuencias observadas		Probabilidad de Poisson	Frecuencias esperadas
0	3	} 18	0.010	1.0
1	15		0.046	18.4
2	47		0.107	42.8
3	76		0.163	65.2
4	68		0.187	74.8
5	74		0.173	69.2
6	46		0.132	52.8
7	39		0.087	34.8
8	15		0.050	20.0
9	9		0.025	10.0
10	5	} 10	0.012	4.8
11	2		0.005	2.0
12	2		0.002	0.8
13	1		0.001	0.4

--> hubieron 15 intervalos de 5 min en el q paso un solo auto. Se analizan 400 intervalos de 5 min (paso de autos) contra una Poisson con $\lambda=4.6$. En los extremos los valores son mas bajos: se agrupan las frec. esp. menores que 5 con el valor siguiente $\Rightarrow$ 10 grupos.

Estadístico para ver si las diferencias entre lo observado y lo esperado

son solo por casualidad:

$$\chi^2 = \sum_{i=1}^k \frac{(o_i - e_i)^2}{e_i} \quad \mathbf{v=k-m-1 \ GL}$$

K= n°grupos(10); m= 1 --> N° parametros (lamda); en dist. normal: m=2 ⇒ μ y σ

$$\chi^2 = \frac{(18 - 22.4)^2}{22.4} + \dots + \frac{(47 - 42.8)^2}{42.8} = 6.749$$

Cada probabilidad teórica sale de la fórmula de Poisson con λ = 4,6 (ej.: P(0) = e^{-4,6} = 0,010) y la frecuencia esperada de multiplicarla por los 400 intervalos (400 · 0,010 = 4; como es < 5 se agrupa con la de un auto).

$$\text{Poisson} \qquad P(X = x) = \frac{e^{-\lambda} \lambda^x}{x!}$$

4.1 Prueba del Signo (Una muestra)

Sirve como **alternativa no paramétrica a T-Unimuestral (pueden ser apareadas o no**, osea datos de antes y después) donde **H0: μ = μ0**. Se aplica cuando se muestra de una **población simétrica** (elementos con misma probabilidad de ser mayor o menor a la media)

$$t = \frac{\bar{x} - \mu_0}{s / \sqrt{n}}$$

El **criterio** que se utiliza es reemplazar cada valor por los signos “+” o “-” según sea mayor o menor que la media (o mediana en su defecto), si es igual se ignora. Se considera siempre una prob **p=0.5**.

Ejemplo: μ0 = 98 y la alternativa μ > μ0. Se coloca + si es mayor a 98, - si no lo es, nada si es igual. Queda una cadena de signos: + + + . + . + + . + + + + + +

Para **muest apareadas (A y D)**: una H0 puede ser u1-u2=0 si u1>u2 es + y si u1<u2 es -

x es la cant de signos +. **n** la cantidad de signos totales. **Se calcula la prob de obtener “x” o más signos y si menor o igual a un α (ej: 0.01) se rechaza H0.**

$$\sum_{k=9}^{10} \text{dbinom}(k, n, 0.5) = 0.011$$

k:num de exitos n: total de signos 0,5: probabilidad

octanaje lote nafta se quiere saber si el promedio supera los 98, con n=10
99.0 102.3 99.8 100.5 99.7 96.2 99.1 102.5 103.3

Apareadas — Caso Práctico:

Un ingeniero industrial evalúa la eficacia de un nuevo programa de seguridad para reducir los accidentes de trabajo en 10 plantas de fabricación. Se registran los accidentes antes y después del programa: Probar si el programa es eficaz para reducir la cantidad de

Tabla 1: Accidentes registrados en 10 plantas industriales

Planta	1	2	3	4	5	6	7	8	9	10
Antes	45	73	46	124	33	57	83	34	26	17
Después	36	60	44	119	35	51	77	29	24	11

H0 : μD = 0 (La mediana de las diferencias es cero, el programa no tiene efecto)

H1 : μD > 0 (Los accidentes antes son mayores que después, el programa es eficaz)

Resultados: n = 10 diferencias efectivas, x = 9 signos positivos. La cadena de signos es: + + + + - - + + + + +

4.2.1 Prueba U (2 muestras indep.)

Existen dos pruebas: la U y la H.

Prueba U (Wilcoxon) - Alternativa no param. de t bimuestral. Se quiere probar si las medias de dos muestras son significativamente iguales. Se busca probar si las muestras vienen de poblaciones idénticas (Misma distribución: misma forma, μ y varianza)

Pasos qnorm para las absicas

- Unimos las muestras y las ordenamos de menor a mayor. (Rango=Sum de la posic.)
- A cada valor se le indica a que muestra pertenece (I, II) y se le asigna un rango (posición). Si dos valores son iguales, se asigna un promedio de sus rangos.
- Sumar los rangos de cada muestra R1 y R2. se comparan y se elije el R1 menor.
- Se define el estadístico:

$$U_i = n_1 \cdot n_2 + \frac{n_i \cdot (n_i + 1)}{2} - R_i$$

Si las n1 y n2 son > 8, Ui tiene una dist. normal. gralm. prueba 2 colas

$$z = \frac{U_i - u_{U_i}}{\sigma_{U_i}} \qquad \mu_{U1} = \frac{n_1 \cdot n_2}{2}$$

$$\sigma_{U1} = \sqrt{\frac{n1 \cdot n2 \cdot (n1 + n2 + 1)}{12}}$$

Ejemplo (diámetro de arenas):

- Se sospecha q ambos difieren en su diametro

▪ **Arena I** (n1 = 15): 0.63, 0.17, 0.35, 0.49, 0.18, 0.43, 0.12, 0.20, 0.47, 1.36, 0.51, 0.84, 0.32, 0.40, 0.45.

▪ **Arena II** (n2 = 14): 1.13, 0.54, 0.96, 0.26, 0.39, 0.88, 0.92, 0.53, 1.01, 0.48, 0.89, 1.07, 1.11, 0.58.

2) 0.12 (I) → Rango 1 0.17 (I) → Rango 2 0.20 (I) → Rango 4
0.26 (II) → Rango 5 3) $\sum R$

4.2.2 Prueba H (3 o mas muestras indep.)

Prueba H (Kruskal Wallis). Alternativa no paramétrica de **Anova**. Comparo que **k** medias poblacionales (de k muestras) sean significativamente iguales. **H0:** u1=u2=...=uk

- Unimos las k muestras y las ordenamos de forma creciente.
- A cada valor se le indica a que muestra pertenece (I, II,k) y se le asigna un rango (posición). Si dos valores son iguales, se asigna un promedio de sus rangos.
- Sumamos los rangos de cada muestra (R1, R2, ..., Rk)
- Aplicamos la fórmula H, si n1>5. Aceptamos o rechazamos H0

$$H = \frac{12}{n \cdot (n + 1)} \cdot \sum_{i=1}^k \frac{(R_i)^2}{(n_i)} - 3 \cdot (n + 1)$$

Distribucion chi cuadrado con **k-1 grados de libertad**. **k** el numero de poblaciones. **n** es la suma de todos los tamaños muestr

Caso Práctico (corrosión en cables):

Se evalúa la eficacia de tres tratamientos preventivos anticorrosión midiendo la profundidad máxima de las cavidades (en milésimas de pulgada) en piezas de cable sometidas a un ensayo acelerado:

- Método A** (n1 = 6): 77, 54, 67, 74, 71, 66
- Método B** (n2 = 7): 60, 41, 59, 65, 62, 64, 52
- Método C** (n3 = 5): 49, 52, 69, 47, 56

H0 : Las poblaciones de los tres tratamientos son idénticas (μA = μB = μC). H1 : Al menos uno de los tratamientos difiere en su localización central (distinta eficacia)

Valor	Grupo	Rango	Valor	Grupo	Rango
41	B	1	60	B	9
47	C	2	62	B	10
49	C	3	64	B	11
52	B	4.5	65	B	12
52	C	4.5	66	A	13
54	A	6	67	A	14
56	C	7	69	C	15
59	B	8	71	A	16
			74	A	17
			77	A	18

4.3 Pruebas de aleatoreidad — Prueba de corridas

Sirven para comprobar si el orden de una muestra o proceso puede considerarse **aleatorio**. Se analiza si los valores se suceden sin un patrón sistemático. Una **corrida o racha** es una secuencia de una o más letras iguales consecutivas.

$$a \ a \ | \ b \ b \ | \ a \ b \ b \ b \ \longrightarrow \ 4 \text{ corridas}$$

Hipotesis

H0:el arreglo o secuencia es aleatorio

H1:el arreglo lo no es aleatorio ⇒prueba bilateral

H1:hay demasiadas corridas ⇒prueba unilateral derecha

H1:hay muy pocas corridas ⇒prueba unilateral izquierda

Pasos

- Construir la cadena de letras.** -Si los datos son **binarios** — éxito/frasco, 1/0, caro/barato—, se construye directamente una cadena de letras a y b. -Si los datos son **numéricos**:

- Calcular la mediana.
- Asignar a a cada observación superior a la mediana.
- Asignar b a cada observación inferior a la mediana.
- Los valores iguales a la mediana se omiten.
- Mantener el orden original de los datos.

- Contar las cantidades.** n1=cantidad de letras a; n2=cantidad de letras b; u=cantidad total de corridas
- Calcular los parámetros de la distribución de corridas**

$$\mu_u = \frac{2n_1n_2}{n_1 + n_2} + 1 \qquad \sigma_u = \sqrt{\frac{2n_1n_2(2n_1n_2 - n_1 - n_2)}{(n_1 + n_2)^2(n_1 + n_2 - 1)}}$$

- Aproximacion normal.** si n1>10 y n2>10 la dist. del num de corridas u se aproxima a una dist. normal, aplico estadístico z

$$Z_{\text{calc}} = \frac{u - \mu_u}{\sigma_u}$$

Interpretaciones

- u grande: demasiados cambios entre a y b; alternancia excesiva.
- u chico: pocas alternancias; los valores iguales tienden a agruparse.
- u cercano a μu: comportamiento compatible con aleatoriedad.

Se usa en control de calidad para dar aleatoreidad a procesos

Dato	.261	.258	.249	.251	.247	.256	.250	.247	.255	.243
Signo	a	a	b	a	b	a	(Empate)	b	a	b

H0 : la secuencia es aleatoria H1 : hay demasiadas corridas (u > μu)

5.1 Metodos de los minimos cuadrados

Se requiere analizar la **relación** entre dos **variables cuantitativas**, para determinar si están asociadas, y si una puede predecir el valor de otra. **El coefic. de corr. no sirve:** no explica una variable respecto de otra

Regresion lineal

1) Tenemos un diagrama de dispersión donde hay dos variables relacionadas: - La independiente o **explicativa “x”** ej: edad. - La dependiente o **explicada “y”** ej: tensión arterial

2) Queremos encontrar la recta que mejor ajuste los valores, y que pueda ser utilizada para predecir los valores: - Para esto usamos el **método de los mínimos cuadrados**, que elige la recta de regresión que minimiza los errores de las diferencias verticales.

3) La recta que mejor se ajusta es: y=α + β.x , que será estimada por:

$$\hat{y} = a + b \cdot x$$

a y b (parámetros muestrales) son estimadores de α y β (parámetros poblacionales)

$$e_i = y_i - \hat{y}_i$$

diferencias verticales ← (regresión y sobre x)

No es viable la suma de los errores, pq se cancelan los (+) con los (–)

4) Se busca **minimizar la suma de los cuadrados de las diferencias** entre los valores reales y los valores estimados ⇒ **a y b se elegirán con: SCE**

$$\sum_{i=1}^n [y_i - (a + b \cdot x_i)]^2$$

Al cuadrado para que los errores no se cancelen, no utilizamos el valor absoluto debido a un problema de amiguedad en el f(x)' = 0

5) Para minimizar la suma debemos hacer las **derivadas parciales** de los coeficientes **a y b, e igualarlos a 0**. Esto es debido a que la función es convexa entonces al igualar a 0 se encuentra el **mínimo** de la función

$$\sum_{i=1}^n y_i = a \cdot n + b \cdot \sum_{i=1}^n x_i$$

$$\sum_{i=1}^n y_i \cdot x_i = a \cdot \sum_{i=1}^n x_i + b \cdot \sum_{i=1}^n (x_i)^2$$

6) Formamos un Sist de Ecuaciones Normales con las derivadas:

$$\begin{bmatrix} n & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n (x_i)^2 \end{bmatrix} \begin{pmatrix} a \\ b \end{pmatrix} = \begin{bmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n (y_i \cdot x_i) \end{bmatrix}$$

Resolviendo el SEN por determinantes **obtenemos los valores de a y b que mejor se ajustan a la recta**. Se puede calcular a con **intercept(x,y)** y b con **slope(x,y)**

5.2 Inferencias basadas en min cuadrados

Una vez que calculamos a y b para nuestra muestra, la inferencia basada en min cuadrados nos permitirán saber que tan confiable es ese modelo para toda la poblacion y no para una muestra en particular. La inferencia sirve para pasar de los estimadores muestrales a y b a conclusiones sobre los parametros poblacionales α y β.

Sxy (varianza de xy), Sxx(varianza de x) me van a permitir estimar la pendiente b y la ordenada al origen a. Con **Syy(varianza de y)** voy a poder calcular la varianza residual muestral

$$(1) \text{ Calc.-->Sxy, Sxx, Syy} \qquad (2) \bar{y} = \sum_n \frac{y_i}{n} \quad \bar{x} = \sum_n \frac{x_i}{n}$$

$$(3) b = \frac{S_{xy}}{S_{xx}} \qquad a = \bar{Y} - b\bar{X}$$

(4)

$$s_e^2 = \frac{S_{xx} \cdot S_{yy} - S_{xy}^2}{n(n - 2) \cdot S_{xx}} \qquad \mathbf{n-2 \ gl} \qquad s_e = \sqrt{s_e^2}$$

s_e² → Varianza residual muestral; s_e → Error estandar de estimacion; n-->cant. puntos

Intervalos de conf. α y β

$$\alpha : t = \frac{a - \alpha}{s_e} \cdot \sqrt{\frac{n \cdot S_{xx}}{S_{xx} + (n \cdot \bar{x})^2}} \qquad \beta : t = \frac{b - \beta}{s_e} \cdot \sqrt{\frac{S_{xx}}{n}}$$

→ Se compara con el t.crit

$$a - t_{\frac{\alpha}{2}} s_e \sqrt{\frac{n S_{xx}}{S_{xx} + (n \bar{x})^2}} < \alpha < a + t_{\frac{\alpha}{2}} s_e \sqrt{\frac{n S_{xx}}{S_{xx} + (n \bar{x})^2}}$$

$$b - t_{\frac{\alpha}{2}} s_e \sqrt{\frac{n}{S_{xx}}} < \beta < b + t_{\frac{\alpha}{2}} s_e \sqrt{\frac{n}{S_{xx}}}$$

Errores máximos de estimación de a y b

Las pruebas de hipótesis con β son muy importantes, pq indica el cambio promedio de Y cuando X aumenta 1 unidad. Si β=0: y no depende de x (**recta horizontal**), si β ≠ 0 : y depende de x por lo que existe relacion lineal.

Habiendo comprobado q β ≠ 0 osea que existe relacion lineal, podemos utilizar dicha recta ajustada para realizar estimaciones. Podemos ver q pasa en un punto específico X0

5.3 Regresion curvilinea

Ahora que pasa si al graficar el diagrama de dispersion vemos que los datos no siguen una trayectoria recta? queremos ajustar con linea rec-

ta pero el modelo no va a ser el mas adecuado ya q no representa la naturaleza del fenomeno. Es por esto q usamos un modelo curvilineo. Para lograr este modelo y que se comporte de manera lineal debemos aplicar una transformacion matematica a los datos originales y así poder aplicar el metodo de los minimos cuadrados que ya veniamos trabajando.

Exponencial

$$y = \alpha \cdot \beta^x \Rightarrow \log_{10}(y) = \log_{10}(\alpha \cdot \beta^x) \Rightarrow \log_{10}(y) = \log_{10}(\alpha) + x \cdot \log_{10}(\beta) \\ y^* = \log_{10}(y), \quad a = \log_{10}(\alpha), \quad b = \log_{10}(\beta) \\ \Rightarrow y^* = a + b \cdot x \quad \alpha = 10^a \quad \beta = 10^b$$

Potencial

$$y = \alpha \cdot x^\beta \Rightarrow \log_{10}(y) = \log_{10}(\alpha) + \beta \cdot \log_{10}(x) \\ \Rightarrow y^* = \log_{10}(y), \quad x^* = \log_{10}(x), \quad a = \log_{10}(\alpha), \quad B = \beta \\ \Rightarrow y^* = a + Bx^* \quad \alpha = 10^a \quad \beta = 10^B$$

Reciprocos

$$y = \frac{1}{\alpha + \beta \cdot x} \Rightarrow \frac{1}{y} = \alpha + \beta \cdot x$$

$$\Rightarrow y^* = \frac{1}{y} \quad a = \alpha \quad b = \beta \quad \Rightarrow y^* = \alpha + \beta x$$

5.4 Ajuste polinomico

Si no sabemos cómo es la relación entre x e y (luego de haber probado con regresion curvilinea y regresion lineal), se busca el mejor ajuste a través de un polinomio de grado p (grado mínimo para no sobreajust.)

(1) Para estimar los p+1 coeficientes óptimos (denotados en la muestra como b0, b1, . . . , bp), aplicamos el método de **Mínimos Cuadrados Ordinarios**. El objetivo es encontrar aquellos estimadores que minimicen de forma conjunta la **Suma de Cuadrados de Error (SCE)**, definida como:

$$S(b_0, \dots, b_p) = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n [y_i - \hat{y}_i]^2 = \sum_{i=1}^n \left[y_i - (b_0 + b_1 x_i + b_2 x_i^2 + \dots + b_p x_i^p) \right]^2$$

(2) Derivamos e igualamos a 0 los p+1 valor (b0,b1,b2,...)

$$\frac{\partial S}{\partial b_0} = \sum_{i=1}^n \underbrace{2}_{\text{Baja el exp.}} \cdot \underbrace{\left[y_i - (b_0 + b_1 x_i + \dots + b_p x_i^p) \right]}_{\text{Lo de adentro intacto}} \cdot \underbrace{(-1)}_{\text{Deriv. resp. } b_0} = 0$$

$$\frac{\partial S}{\partial b_k} = \sum_{i=1}^n \underbrace{2}_{\text{Baja el exp.}} \cdot \underbrace{\left[y_i - (b_0 + b_1 x_i + \dots + b_p x_i^p) \right]}_{\text{Lo de adentro intacto}} \cdot \underbrace{(-x_i^k)}_{\text{Deriv. resp. } b_k} = 0$$

$$\underbrace{b_0 \sum_{i=1}^n x_i^0 + b_1 \sum_{i=1}^n x_i^{k+1} + \dots + b_p \sum_{i=1}^n x_i^{k+p}}_{\text{Fila de incógnitas}} = \underbrace{\sum_{i=1}^n (x_i^k y_i)}_{\text{Término indep.}}$$

(3) Armamos sist. ec. y matriz

$$k = 0 : nb_0 + b_1 \sum x_i + b_2 \sum x_i^2 + \dots + b_p \sum x_i^p = \sum y_i$$

$$k = 1 : b_0 \sum x_i + b_1 \sum x_i^2 + b_2 \sum x_i^3 + \dots + b_p \sum x_i^{p+1} = \sum (x_i y_i)$$

$$k = 2 : b_0 \sum x_i^2 + b_1 \sum x_i^3 + b_2 \sum x_i^4 + \dots + b_p \sum x_i^{p+2} = \sum (x_i^2 y_i)$$

$$\begin{bmatrix} \sum x_i & \sum x_i^2 & \sum x_i^3 & \dots & \sum x_i^p \\ \sum x_i^2 & \sum x_i^3 & \sum x_i^4 & \dots & \sum x_i^{p+1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sum x_i^p & \sum x_i^{p+1} & \sum x_i^{p+2} & \dots & \sum x_i^{2p} \end{bmatrix} \begin{bmatrix} b_0 \\ b_1 \\ b_2 \\ \vdots \\ b_p \end{bmatrix} = \begin{bmatrix} \sum y_i \\ \sum (x_i y_i) \\ \sum (x_i^2 y_i) \\ \vdots \\ \sum (x_i^p y_i) \end{bmatrix}$$

5.5 Metodo de la varianza residual

Para evitar el sobreajuste, se calcula la **varianza residual**:

$$\sigma_{\text{res}}^2 = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n - (p + 1)}$$

Donde:

- n es la cantidad de puntos de la muestra.
- p es el grado del polinomio.
- p+1 es la cantidad de coeficientes estimados.
- n – p – 1 son los **grados de libertad del modelo**.
- y_i – ŷ_i es el residuo: diferencia entre el valor observado y el estimado.

Se comienza por :

- una recta, grado 1
- se sigue parábola, grado 2,
- luego polinomio, grado 3
- polinomio de grados superiores si fuera necesario

Para cada uno se calcula la varianza residual y se compara los re-

sultados. La suma de cuadrados de error vista en el numerador de la formula tiende a disminuir porque la curva se adapta mejor a los puntos. Tambien disminuyen los grados de libertad, porque se estiman mas coeficientes

Para la seleccion: Se selecciona el grado en el q se observa la mayor caida. Despues de este punto aumentar el grado puede ser innecesario ya q puede aumentar el riesgo de sobreajuste

Ej:

Dada una muestra de $n = 10$ mediciones industriales, se evalúa el ajuste de polinomios de grados sucesivos obteniéndose los siguientes resultados reales:

Grado (p)	SCE	GL (n-p-1)	s ²	¿Se justifica?
1 (Lineal)	57.655	8	7.207	Modelo Base
2 (Cuadrático)	53.059	7	7.580	No, la varianza aumentó
3 (Cúbico)	6.124	6	1.021	Si, salto decreciente masivo
4 (Cuártico)	4.959	5	0.992	No, reducción insignificante

5.6 Correlacion

coeficiente correlacion: El coeficiente de correlación sirve para indicar relaciones lineales y comportamientos entre dos variables. Indica asociacion, no causalidad. Se denota comúnmente como r (correlación de Pearson) y varía en cualquier valor entre -1 y 1:

Si $r = 1 \rightarrow$ Si una variable aumenta, la otra también

Si $r = -1 \rightarrow$ Si una aumenta, la otra disminuye

Si $r = 0 \rightarrow$ No hay relación lineal, puede haber de otro tipo

$$r = \frac{s_{xy}}{s_x \cdot s_y} \quad (2)$$

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot \sum_{i=1}^n (y_i - \bar{y})^2}} \quad (3)$$

6.1 Diseños completamente aleatorios

La prueba ANOVA busca evaluar si las k medias poblacionales $\mu_1, \mu_2, \dots, \mu_k$ son todas iguales entre sí:

$H_0 : \mu_1 = \mu_2 = \dots = \mu_k$ (Todas las medias poblacionales son iguales)

$H_1 : \text{Al menos una media } \mu_i \text{ es distinta (Existe al menos un par } \mu_i \neq \mu_j \text{ para } i \neq j)$

Suponemos poblaciones normales con misma varianza, observaciones independientes. Podemos construir una matriz con k filas y n columnas

Primero considero el diseño completamente aleatorio con tamaños muestrales iguales. Tengo k tratamientos y cada uno tiene la misma cantidad n de observaciones. Las unidades experimentales se asignan aleatoriamente a cada tratamiento.

Tratamiento / Muestra	Obs. 1	Obs. 2	...	Obs. j	...	Obs. n	Total (T _i)	Media (ȳ _i)
Muestra 1	y ₁₁	y ₁₂	...	y _{1j}	...	y _{1n}	T ₁	ȳ ₁
Muestra 2	y ₂₁	y ₂₂	...	y _{2j}	...	y _{2n}	T ₂	ȳ ₂
...	...	...	...	...	...	...	...	...
Muestra i	y _{i1}	y _{i2}	...	y _{ij}	...	y _{in}	T _i	ȳ _i
...	...	...	...	...	...	...	...	...
Muestra k	y _{k1}	y _{k2}	...	y _{kj}	...	y _{kn}	T _k	ȳ _k
Total / Gran Media							T _{..}	ȳ _{..}

Efecto tratamiento (α) Interpretacion. Si $\bar{y}_{i.}$ (media muestra 1) tienen un valor mas grande que $\bar{y}_{..}$ (media global o gran media) poniendo como ejemplo los detergente quiere decir q ese detergente es positivo o mejor. Decir q las medias son iguales, los efectos serian 0.

Para el calculo final del estadistico se realizan los sig calculos

1) vamos a definir un valor constante que es la suma de los elementos de la matriz elevado al cuadrado, multiplicado por 1/k.n

$$C = \frac{1}{k \cdot n} \left(\sum_{i=1}^k \sum_{j=1}^n y_{ij} \right)^2$$

o simplemente haciendo-->

$$C = \frac{(T_{..})^2}{k \cdot n}$$

C= termino de correccion

2) vamos a calcular la suma de cuadrados total SST, tomando cada elemento de la matriz y elevando al cuadrado y sumando todo y restando el valor de “C” que calculamos recién. Es el primer miembro de la expresion.

$$SST = \sum_{i=1}^k \sum_{j=1}^n \left(y_{ij} \right)^2 - C$$

3) vamos a calcular una sumatoria llamada **suma de cuadrados de tratamientos**. Pertenece al ultimo termino de mi expresion. T_i es la suma de todos los elementos de una fila de la matriz

$$SS(Tr) = n \sum_{i=1}^k (\bar{y}_{i.} - \bar{y}_{..})^2$$

o

$$SS(Tr) = \frac{1}{n} \sum_{i=1}^k (T_{i.})^2 - C$$

4) podemos calcular la suma de cuadrados de error SSE con el SST y SS(Tr) calculados anteriormente

$$SSE = SST - SS(Tr)$$

5) finalmente defino el estadistico F , para zona critica

$$F = \frac{\frac{SS(Tr)}{k-1}}{\frac{SSE}{k \cdot (n-1)}} = \frac{\hat{\sigma}_H^2}{\hat{\sigma}_W^2}$$

media cuad. tratamiento(MS(Tr)) $\searrow$ media cuad.error (MSE) $\nearrow \longrightarrow$

n1=k-1 gl $\longrightarrow$ n2=k(n-1) gl

$\hat{\sigma}_H^2 \longrightarrow$ Estima varianza a lo alto; $\hat{\sigma}_W^2 \longrightarrow$ Estima varianza a lo ancho; k= n° tratamientos

Fuentes de Variación	Grados de Libertad	Suma de Cuadrados	Media Cuadrada	F
Tratamientos	k-1	SS(Tr)	MS(Tr)=SS(Tr)/(k-1)	MS(Tr)/MSE
Error	k.(n-1)	SSE	MSE=SSE/k.(n-1)	
Total	n.k-1	SST		

PARA k=4; n=12 Error=total-tratamientos = (n.k - 1) - (k - 1) = nk - 1 - k + 1 = nk - k = k(n - 1)

6.2 Tamaños muestrales distintos

cada fila tiene distintas cantidad de columnas

Tratamiento	Obs. 1	Obs. 2	...	Obs. j	...	Obs. n _i	Tamaño (n _i)	Total (T _i)	Media (ȳ _i)
Muestra 1	y ₁₁	y ₁₂	...	y _{1j}	...	y _{1n₁}	n ₁	T ₁	ȳ ₁
Muestra 2	y ₂₁	y ₂₂	...	y _{2j}	...	—	n ₂	T ₂	ȳ ₂
...	...	...	...	...	...	...	...	...	...
Muestra k	y _{k1}	y _{k2}	...	y _{kj}	...	—	n _k	T _k	ȳ _k
Total Global							N = ∑ n _i	T _{..}	ȳ _{..}

Se deben hacer los siguientes cambios:

1. Cambiar **n** por **n_i** en: SST, SS(Tr) , C y T

2. Cambiar **k.n** por **N** en: C (N es = ∑ni)

Se usa **n_i** (**tamaño de cada muestra**) en lugar de **n** (**tamaño de todas las muestras**)

$$\nu 1 := k - 1 = \qquad \nu := N - 1 = \qquad \nu 2 := \nu - \nu 1$$

$$C = \frac{T^2}{N} \quad \text{donde } N = \sum_{i=1}^k n_i \qquad SST = \sum_{i=1}^k \sum_{j=1}^{n_i} y_{ij}^2 - C$$

$$SS(Tr) = \sum_{i=1}^k \frac{T_i^2}{n_i} - C \qquad SSE = SST - SS(Tr)$$

Fuente de Variación	gl	Suma de Cuadrados	Media Cuadrada (MS)	F _{calc}
Tratamientos	k - 1	SS(Tr)	MS(Tr) = $\frac{SS(Tr)}{k-1}$	$\frac{MS(Tr)}{MSE}$
Error Aleatorio	N - k	SSE	MSE = $\frac{SSE}{N-k}$	
Total	N - 1	SST		

6.3 Diseño en bloques aleatorios

El experimentador tiene a disposicion mediciones relativas a “a” tratamientos distribuidos en b bloques. Vamos a considerar el caso en q hay una observacion en cada tratamiento de cada bloque.

Tratamiento	Bloque 1	Bloque 2	...	Bloque b	Total (T _i)	Media (ȳ _i)	Efecto (α _i)
Tratamiento 1	y ₁₁	y ₁₂	...	y _{1b}	T ₁	ȳ ₁	α ₁ = ȳ ₁ - ȳ _{..}
Tratamiento 2	y ₂₁	y ₂₂	...	y _{2b}	T ₂	ȳ ₂	α ₂ = ȳ ₂ - ȳ _{..}
...	...	...	...	...	...	...	...
Tratamiento a	y _{a1}	y _{a2}	...	y _{ab}	T _a	ȳ _a	α _a = ȳ _a - ȳ _{..}
Total Bloque	T _{.1}	T _{.2}	...	T _{.b}	T _{..}	ȳ _{..}	
Media Bloque	ȳ _{.1}	ȳ _{.2}	...	ȳ _{.b}			
Efecto Bloque	β ₁	β ₂	...	β _b			

El modelo matemático aditivo sin interacción es:

$$y_{ij} = \mu + \alpha_i + \beta_j + \epsilon_{ij} \quad \text{para } i = 1, \dots, a; \quad j = 1, \dots, b$$

Con las restricciones $\sum_{i=1}^a \alpha_i = 0$ y $\sum_{j=1}^b \beta_j = 0$, donde:

- μ: Gran media general.
- α_i = ȳ_{i.} - ȳ_{..}: Efecto fijo del *i*-ésimo tratamiento.
- β_j = ȳ_{.j} - ȳ_{..}: Efecto fijo del *j*-ésimo bloque.
- ϵ_{ij} ~ iid N(0, σ²): Error aleatorio.

$$C = \frac{T^2}{a \cdot b} \qquad SST = \sum_{i=1}^a \sum_{j=1}^b y_{ij}^2 - C$$

$$SS(Tr) = \frac{1}{b} \sum_{i=1}^a T_i^2 - C \quad \text{con } a - 1 \text{ gl}$$

$$SS(BI) = \frac{1}{a} \sum_{j=1}^b T_{.j}^2 - C \quad \text{con } b - 1 \text{ gl}$$

$$SSE = SST - SS(Tr) - SS(BI) \quad \text{con } (a - 1)(b - 1) \text{ gl}$$

Fuentes de Variación	Grados de Libertad	Suma de Cuadrados	Media Cuadrada	F
Tratamientos	a-1	SS(Tr)	MS(Tr)=SS(Tr)/(a-1)	F _{Tr} = $\frac{MS(Tr)}{MSE}$
Bloques	b-1	SS(BI)	MS(BI)=SS(BI)/(b-1)	F _{BI} = $\frac{MS(BI)}{MSE}$
Error	(a-1).(b-1)	SSE	MSE=SSE/((a-1).(b-1)	
Total	a.b-1	SST		

para llegar al error hicimos: Error = total-tratamientos-bloques