

UNIDAD 4 — No Param.

Prueba del Signo (1 muestra o apareadas)

Alternativa no paramétrica a t-Unimuestral. Reemplazar cada valor por +/- según sea mayor/menor a la media o mediana (se ignora si es igual); prob. $p = 0.5$ siempre. x =cant. de signos +, n =total de signos. Se calcula $P(X \geq x)$ (dbinom) y si es $\leq \alpha$ se rechaza H_0 .

Ej: Octanaje de nafta, $n = 15$ ($\mu_0 = 98$): 1 empate se descarta $\rightarrow n = 14$, $x = 12$ signos +. $H_0 : \bar{\mu} = 98$, $H_1 : \bar{\mu} > 98$. p -valor = $P(X \geq 12) = 0.0065 < \alpha = 0.01 \Rightarrow$ Rechaza H_0 .

Ej: Accidentes antes/después (pareada), $n = 10$ plantas: $x = 9$ signos + (antes>después). $H_0 : \bar{\mu}_D = 0$, $H_1 : \bar{\mu}_D > 0$. p -valor = $P(X \geq 9) = 0.0107 < \alpha = 0.05 \Rightarrow$ Rechaza H_0 (programa eficaz).

Prueba U (Wilcoxon, 2 muestras indep.)

Alternativa no paramétrica a t-bimuestral. Unir y ordenar ambas muestras; asignar rango (posición, promedio si hay empate); sumar R_1, R_2 y elegir el R_i menor.

$$U_i = n_1 n_2 + \frac{n_i(n_i + 1)}{2} - R_i$$

Si $n_1, n_2 > 8$: U_i aprox. normal (2 colas).

$$z = \frac{U_i - \mu_{U_i}}{\sigma_{U_i}}$$

$$\mu_{U1} = \frac{n_1 n_2}{2}$$

$$\sigma_{U1} = \sqrt{\frac{n_1 n_2 (n_1 + n_2 + 1)}{12}}$$

Prueba H (Kruskal-Wallis, $k \geq 3$ indep.)

Alternativa no paramétrica a ANOVA. $H_0 : \mu_1 = \dots = \mu_k$. Unir las k muestras, ordenar creciente, rango (promedio en empates), sumar R_i por grupo.

$$H = \frac{12}{n(n+1)} \sum_{i=1}^k \frac{R_i^2}{n_i} - 3(n+1)$$

Válido si $n_i > 5$. $H \sim \chi^2_{k-1}$. n =suma de

todos los tamaños muestrales.

Ej: Corrosión en cables, 3 métodos ($n_1=6, n_2=7, n_3=5, N=18$):

Método	n_i	R_i
A	6	84
B	7	55.5
C	5	31.5

$H = 6.66 > \chi^2_{crit}(2) = 5.991 \Rightarrow$ Rechaza H_0 (A el menos eficaz, C el mejor).

Pruebas de aleatoriedad (corridas)
 H_0 : secuencia aleatoria. H_1 : no aleatoria (bil.) / demasiadas corridas (unil. der.) / muy pocas corridas (unil. izq.). Corrida=letras iguales consecutivas. Binario: cadena a/b directa. Numérico: a si $>$ mediana, b si $<$, se omiten los iguales, se mantiene el orden.

$$\mu_u = \frac{2n_1 n_2}{n_1 + n_2} + 1$$

$$\sigma_u = \sqrt{\frac{2n_1 n_2 (2n_1 n_2 - n_1 - n_2)}{(n_1 + n_2)^2 (n_1 + n_2 - 1)}}$$

Si $n_1, n_2 > 10$: $Z_{calc} = (u - \mu_u)/\sigma_u$. u grande=alternancia excesiva; u chico=valores agrupados; $u \approx \mu_u$ =compatible con aleatoriedad.

UNIDAD 5 — Regresión

Método de los mínimos cuadrados
 $\hat{y} = a + bx$ estima $y = \alpha + \beta x$; $e_i = y_i - \hat{y}_i$ (dif. verticales). Minimizar $\sum [y_i - (a + bx_i)]^2$.

$$\begin{aligned} \sum y_i &= an + b \sum x_i \\ \sum y_i x_i &= a \sum x_i + b \sum x_i^2 \\ \begin{bmatrix} n & \sum x_i \\ \sum x_i & \sum x_i^2 \end{bmatrix} \begin{pmatrix} a \\ b \end{pmatrix} &= \begin{bmatrix} \sum y_i \\ \sum y_i x_i \end{bmatrix} \\ a &= \text{intercept}(x, y), b = \text{slope}(x, y). \end{aligned}$$

Correlación

$$r = \frac{s_{xy}}{s_x \cdot s_y} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \cdot \sum (y_i - \bar{y})^2}}$$

$-1 \leq r \leq 1$. $r = 1$: recta pend. positiva perfecta. $r = -1$: recta pend. negativa perfecta.

va perfecta. $r = 0$: no asociación lineal (puede haber relación no lineal). r mide relación entre 2 variables; no permite explicar una en función de la otra (no es causalidad).

Inferencias basadas en mín. cuadrados

$$b = \frac{S_{xy}}{S_{xx}} \quad a = \bar{Y} - b\bar{X}$$
$$s_e^2 = \frac{S_{xx} S_{yy} - S_{xy}^2}{n(n-2) S_{xx}} \quad (\nu = n-2) \quad s_e = \sqrt{s_e^2}$$

IC:

$$a \pm t_{\alpha/2, s_e} \sqrt{\frac{n S_{xx}}{S_{xx} + (n\bar{x})^2}}$$

$$b \pm t_{\alpha/2, s_e} \sqrt{\frac{n}{S_{xx}}}$$

$H_0 : \beta = 0$ vs $H_1 : \beta \neq 0$ (X influye linealmente en Y ? si $\beta = 0$, Y no depende de X). Estimación puntual: $\hat{y}_0 = a + bx_0$.

Regresión curvilínea (linealizar)

Exponencial $y = \alpha \beta^x \Rightarrow y^* = \log_{10} y = a + bx$, $\alpha = 10^a$, $\beta = 10^b$. Potencial $y = \alpha x^\beta \Rightarrow y^* = \log_{10} y$, $x^* = \log_{10} x$: $y^* = a + Bx^*$.

Recíproca $y = \frac{1}{\alpha + \beta x} \Rightarrow y^* = \frac{1}{y} = \alpha + \beta x$.

Ajuste polinómico

Grado p , coef. $b_0, \dots, b_p$; minimizar $\sum [y_i - (b_0 + b_1 x_i + \dots + b_p x_i^p)]^2$ y armar sistema de $p+1$ ecuaciones normales (matriz de sumas de potencias de x).

Método de la varianza residual

$$\sigma_{res}^2 = \frac{\sum (y_i - \hat{y}_i)^2}{n - (p + 1)}$$

Se prueba grado 1 (recta), 2 (parábola), 3, ... y se elige el grado donde se observa la mayor caída de σ_{res}^2 ; subir más el grado aumenta el riesgo de sobreajuste. Ej: $n = 10$ mediciones:

p	SCE	gl	s^2
1 (Lineal)	57.655	8	7.207
2 (Cuadr.)	53.059	7	7.580
3 (Cúbico)	6.124	6	1.021
4 (Cuárt.)	4.959	5	0.992

Mayor caída en $p = 3$ (salto de 7.58 a 1.02) $\Rightarrow$ se elige polinomio cúbico.

Regresión múltiple

Incorpora $x_1, \dots, x_k$ variables independientes para explicar Y ; se estima un plano (o hiperplano) de regresión en vez de una recta.

UNIDAD 6 — ANOVA

Diseño completamente aleatorio (1 vía)

$H_0 : \mu_1 = \dots = \mu_k$; H_1 : al menos una distinta. k tratamientos, n obs. c/u. $\alpha_i = \bar{y}_i - \bar{y}..$ (si H_0 cierta, todos $\alpha_i = 0$).

$$C = \frac{T_{..}^2}{kn} \quad SST = \sum \sum y_{ij}^2 - C$$

$$SS(Tr) = \frac{1}{n} \sum T_{i.}^2 - C = n \sum (\bar{y}_{i.} - \bar{y}..)^2$$

$$SSE = SST - SS(Tr)$$

$$F = \frac{SS(Tr)/(k-1)}{SSE/[k(n-1)]}$$

Fuente	gl	SC	MC
Tratam.	$k - 1$	$SS(Tr)$	$MS(Tr)$
Error	$k(n - 1)$	SSE	MSE
Total	$nk - 1$	SST	

Ej: 4 laboratorios de estaño, $k = 4$, $n = 12$, $N = 48$:

Fuente	gl	SC	MC	F
Labs.	3	0.0130	0.00433	2.87
Error	44	0.0679	0.00154	
Total	47	0.0809		

$F_{crit}(3, 44) = 2.82$. Como $2.87 > 2.82 \Rightarrow$ Rechaza H_0 (evidencia marginal, sugiere aumentar n).

Diseño en bloques aleatorios

$y_{ij} = \mu + \alpha_i + \beta_j + \epsilon_{ij}$, $\sum \alpha_i = 0$, $\sum \beta_j = 0$; $\epsilon_{ij} \sim iid N(0, \sigma^2)$. $a=n^o$ tratamientos, $b=n^o$ bloques.

$$C = \frac{T_{..}^2}{ab} \quad SST = \sum \sum y_{ij}^2 - C$$

$$SS(Tr) = \frac{1}{b} \sum T_{i.}^2 - C \quad (a-1 \text{ gl})$$

$$SS(Bl) = \frac{1}{a} \sum T_{.j}^2 - C \quad (b-1 \text{ gl})$$

$$SSE = SST - SS(Tr) - SS(Bl) \quad [(a-1)(b-1) \text{ gl}]$$

$$F_{Tr} = \frac{MS(Tr)}{MSE} \quad F_{Bl} = \frac{MS(Bl)}{MSE}$$

Fuente	gl	SC
Tratam.	$a - 1$	$SS(Tr)$
Bloques	$b - 1$	$SS(Bl)$
Error	$(a-1)(b-1)$	SSE
Total	$ab - 1$	SST

Ej: Detergentes ($a = 3$) $\times$ Lavarropas ($b = 3$):

Fuente	gl	SC	F_{calc}
Deterg.	2	600	120
Lavarr.	2	150	30
Error	4	10	
Total	8	760	

$F_{crit}(2, 4; 0.01) = 18$. Como $120 > 18$ y $30 > 18 \Rightarrow$ Rechaza ambas H_0 (detergentes y lavarropas influyen).

Tamaños muestrales distintos (n_i)

Cambios respecto al diseño 1 vía: usar n_i (no n) en $SST, SS(Tr)$ y T ; usar $N = \sum n_i$ (no $k \cdot n$) en C .

$$C = \frac{T_{..}^2}{N} \quad SST = \sum \sum y_{ij}^2 - C$$

$$SS(Tr) = \sum \frac{T_{i.}^2}{n_i} - C$$

$$SSE = SST - SS(Tr)$$

gl: Tratamientos $k-1$, Error $N-k$, Total $N-1$.

Ej: Aflatoxina en 2 marcas, $k = 2$, $n_1 = 8$, $n_2 = 6$, $N = 14$:

Fuente	gl	SC	F_{calc}
Marcas	1	11.734	1.047
Error	12	134.515	
Total	13	146.249	

$F_{crit}(1, 12) = 4.747$. Como $1.047 < 4.747 \Rightarrow$ No se rechaza H_0 (las marcas no difieren).