

Metodos de los minimos cuadrados

Se requiere analizar la **relación** entre dos **variables cuantitativas**, para determinar si están asociadas, y si una puede predecir el valor de otra. **El coef. de corr. no sirve:** no explica una variable respecto de otra

Regresion lineal

1) Tenemos un diagrama de dispersión donde hay dos variables relacionadas:

- La independiente o **explicativa “x”** ej: edad
- La dependiente o **explicada “y”** ej: tensión arterial

2) Queremos encontrar la recta que mejor ajuste los valores, y pueda ser utilizada para predecir los valores:


- Para esto usamos el **método de los mínimos cuadrados**, que elige la recta de regresión que minimiza los errores de las diferencias verticales.

3) La recta que mejor se ajusta es: $y = \alpha + \beta \cdot x$, que será estimada por:

$$\hat{y} = a + b \cdot x$$

a y b (parámetros muestrales) son estimadores de α y β (parámetros poblacionales)

$$e_i = y_i - \hat{y}_i \quad \text{diferencias verticales} \leftarrow (\text{regresión y sobre } x)$$



No es viable la suma de los errores,
pq se cancelan los (+) con los (-)

4) Se busca **minimizar la suma de los cuadrados de las diferencias** entre los valores reales y los valores estimados
 $\Rightarrow$ a y b se elegirán con:

$$\sum_{i=1}^n [y_i - (a + b \cdot x_i)]^2 \quad \text{Al cuadrado para que los errores no se cancelen, no utilizamos el valor absoluto debido a un problema de amiguedad en el } f(x)' = 0$$

5) Para minimizar la suma debemos hacer las **derivadas parciales** de los coeficientes a y b, e igualarlos a 0. Esto es debido a que la función es convexa entonces al igualar a 0 se encuentra el mínimo de la función

$$\sum_{i=1}^n y_i = a \cdot n + b \sum_{i=1}^n x_i \quad \sum_{i=1}^n y_i \cdot x_i = a \sum_{i=1}^n x_i + b \sum_{i=1}^n (x_i)^2$$

6) Formamos un Sist de Ecuaciones Normales con las derivadas:

$$\begin{bmatrix} n & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n (x_i)^2 \end{bmatrix} \begin{pmatrix} a \\ b \end{pmatrix} = \begin{bmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n (y_i \cdot x_i) \end{bmatrix}$$

Resolviendo el SEN por determinantes **obtenemos los valores de a y b** que mejor se ajustan a la recta
 Se puede calcular a con **intercept(x,y)** y b con **slope(x,y)**