

CONCEPTOS BÁSICOS



Población:

- **Definición:** Es el conjunto completo de todos los elementos o individuos que se desea estudiar.
- **Ejemplo:** Si se desea estudiar la altura de todos los estudiantes de una universidad, todos los estudiantes de esa universidad constituyen la población.

Marco Muestral:

- **Definición:** Es la lista o subconjunto de elementos de la población de donde se seleccionará la muestra.
- En ciertos casos, el marco muestral puede coincidir con la población. Se dice que el marco muestral representa perfectamente a la población.

Muestra:

- **Definición:** Es un subconjunto del marco muestral que se selecciona para el estudio. La muestra debe ser representativa de la población para que los resultados del estudio sean generalizables.
- **Ejemplo:** Si se seleccionan 100 estudiantes de la universidad para medir su altura y hacer inferencias sobre la altura de todos los estudiantes de la universidad, esos 100 estudiantes constituyen la muestra.

Diferencias entre Marco Muestral, Muestra y Población:

Escenario: Encuesta sobre hábitos alimenticios en una ciudad.

1. **Población:** Todos los habitantes de la ciudad.
Es el grupo completo que queremos estudiar y del que queremos sacar conclusiones.
2. **Marco muestral:** Una lista de todos los habitantes de la ciudad registrados en el padrón de un municipio de la ciudad.
Es el conjunto accesible y definido del cual se puede extraer la muestra.
3. **Muestra:** 500 habitantes seleccionados al azar del padrón municipal.
Es el grupo específico de individuos que realmente serán encuestados para representar a la población.

Variable Aleatoria:

- **Definición:** Una variable aleatoria es una función que asigna un valor numérico a cada uno de los posibles resultados de un experimento aleatorio.
- **Rango:** El conjunto de todos los valores numéricos que se asignan a cada resultado.
- **Tipos:**
 - **Discreta:** Toma un número finito o contable de valores (por ejemplo, el número de caras al lanzar una moneda tres veces). Si podemos contar la cantidad de puntos del rango es discreta, ej: $R = \{0, 1, 2, 3\}$ Hay 4 puntos
 - **Continúa:** Toma cualquier valor en un intervalo continuo (por ejemplo, la altura de una persona). Si no podemos contar la cantidad de puntos del rango, es decir el rango tiene un número incontable de valores, ej: $0 < R < 500$.

Dominio o Espacio Muestral (S):

- **Definición:** Es el conjunto de todos los posibles resultados de un experimento aleatorio.
- **Ejemplo:** Al lanzar un dado, el espacio muestral es $\{1, 2, 3, 4, 5, 6\}$.

Punto Muestral:

- **Definición:** Es un único resultado posible del espacio muestral.
- **Ejemplo:** En el lanzamiento de un dado, cada uno de los números $\{1, 2, 3, 4, 5, 6\}$ es un punto muestral.

Media - Mediana - Moda

Media: Es la suma de todos los valores de un conjunto de datos dividida por el número total de valores. Es sensible a valores extremos (outliers), esto significa que su valor puede verse significativamente afectado por la presencia de datos que son mucho mayores o mucho menores que el resto del conjunto.

Mediana: Es el valor que divide el conjunto de datos en dos mitades iguales cuando los datos están ordenados de menor a mayor. Si el número de datos es impar, la mediana es el valor central. Si el número de datos es par, la mediana es el promedio de los dos valores centrales. Es menos sensible a valores extremos que la media.

Moda: Es el valor o valores que aparecen con mayor frecuencia en el conjunto de datos. Puede haber: Una única moda (distribución unimodal). Dos modas (distribución bimodal). Más de dos modas (distribución multimodal). Si todos los valores tienen la misma frecuencia, no hay moda.

Robustez y Eficiencia de un estimador

La **robustez** se refiere a la capacidad de un estimador para no verse afectado por valores atípicos o extremos.

La **eficiencia** se refiere a la precisión del estimador en condiciones ideales (como distribuciones simétricas).
Un estimador es más eficiente que otro cuando su dispersión es menor.

¿Cuál es más eficiente entre media o mediana?

La media porque su distribución tiene menos dispersión que la distribución de la mediana. También hay que tener en cuenta la robustez (capacidad de un estimador para no verse afectado por valores atípicos o datos extremos). En este sentido, la mediana es más robusta que la media, ya que no se ve influenciada por valores atípicos, mientras que la media puede distorsionarse cuando hay datos extremos.

1, 2, 2, 3, 6, 8, 12, 16

MEDIA

Valor medio del conjunto de datos

$$1+2+2+3+6+8+12+16 = 50$$

$$50/8 = 6,25$$

MEDIANA

Valor ubicado en el centro del conjunto de datos

1, 2, 2, 3, 6, 8, 12, 16

$$9/2 = 4,50$$

MODA

Valor que más se repite en el conjunto de datos

1, 2, 2, 3, 6, 8, 12, 16

Varianza y Desviación Estándar

Tanto la varianza como la desviación estándar son medidas de dispersión que indican cuánto se alejan los datos de la media (promedio). La diferencia clave es que la desviación estándar está en las mismas unidades que los datos originales, mientras que la varianza está en unidades cuadradas.

Varianza:

Es una medida que describe la **dispersión promedio al cuadrado** de los datos respecto a la media. Una varianza alta indica que los datos están más dispersos alrededor de la media, mientras que una varianza baja indica que los datos están más agrupados.

Se calcula el promedio entre los datos, y luego se hace la diferencia entre cada valor con el promedio, esto elevado al cuadrado, por cada valor del conjunto. Ej: (Se suele anotar como sigma para la varianza poblacional σ^2 , y con S^2 para la varianza muestral)

POBLACION: $\sigma^2 = \frac{\sum (x - \bar{x})^2}{n}$

MUESTRA: $S^2 = \frac{\sum (x - \bar{x})^2}{n-1}$

Varianza es la desviación estándar al cuadrado: σ^2

Desviación estándar: Es una medida que describe la dispersión promedio de los datos respecto a la media. Se mide en las mismas unidades que las medidas originales. No hay que darle mucha bola a la varianza, solo es un paso intermedio contra la desviación estándar. (σ)

Ejemplo:

Imagina que tienes las siguientes edades de un grupo de personas: 20, 25, 30, 35, 40.

La media (promedio) es 30.

La varianza sería el promedio de $((20-30)^2 + (25-30)^2 + (30-30)^2 + (35-30)^2 + (40-30)^2) / 5$, que resulta en 50.

La desviación estándar sería la raíz cuadrada de 50, aproximadamente 7.07. Esto significa que, **en promedio, las edades se desvían 7.07 años de la media de 30 años.**

La **varianza** mide la dispersión de los datos respecto a la media y se calcula como el promedio de los cuadrados de las diferencias. Aunque la **desviación estándar** es más intuitiva porque tiene las mismas unidades que los datos, la **varianza** es útil porque:

- **Facilita** cálculos en modelos estadísticos (como en regresión y estimaciones).
- Se suma fácilmente en **combinaciones de variables aleatorias** (a diferencia de la desviación estándar).
- Es clave en **optimización** y teoría de **probabilidades** (por ejemplo, en **Mínimos Cuadrados**).

Se eleva al cuadrado para evitar que las diferencias se cancelen y para dar más peso a valores extremos.

UNIDAD I: CONCEPTOS

TEMA A) POBLACIONES Y MUESTRAS

Muestra aleatoria quiere decir que todos los posibles resultados (subconjuntos finitos n) de una población finita N tienen la misma probabilidad de ser elegidos. (todas las variables aleatorias tienen la misma distribución que la población original)

Una muestra aleatoria es vista como un conjunto de variables aleatorias independientes e idénticamente distribuidas

La idea principal es usar esta muestra aleatoria para hacer inferencias (**deducir o concluir**) sobre los parámetros de la población, como la media (μ) o la desviación estándar (σ). Para hacer estas inferencias, se <http://www.youtube.com> utilizan estadísticas (valores) calculadas a partir de las muestras, como la media muestral ($\bar{X}$) o la desviación estándar muestral (s)

La muestra no tiene que ser siempre aleatoria. Si tengo una preferencia en la selección de la muestra produce un sesgo en la inferencia.

¿La media muestral es la media poblacional? Únicamente en el caso en que la muestra sea toda la población, pero no tomo la muestra del tamaño de la población pq medir toda la población es caro, trabajoso y a veces imposible..

DISTRIBUCIONES

Las **distribuciones** son descripciones de cómo se distribuyen los valores de una variable en un conjunto de datos. Una distribución muestra la frecuencia o probabilidad de ocurrencia de los valores posibles de una variable.

Tipos de distribuciones

1. **Distribución de frecuencias:** Describe cuántas veces ocurre cada valor o rango de valores en un conjunto de datos.
 - Ejemplo: Una tabla que muestra cuántas personas tienen edades en diferentes rangos.
2. **Distribución de probabilidad:** Representa la probabilidad de que una variable aleatoria tome ciertos valores.
 - Ejemplo: La probabilidad de obtener un número específico al lanzar un dado.

1 A - 1 y 2) DISTRIBUCIÓN MUESTRAL DE LA MEDIA (σ conocida)

Si de alguna población de parámetros conocidos se extraen n muestras es difícil que la medias de tales muestras coincidan.

Si calculas la media de cada muestra de una población, y luego calculas la media de todas esas medias muestrales ($\mu_{\bar{x}}$) que has obtenido, este valor será igual (o muy cercano) a la media de la población original (μ).

La varianza de las medias muestrales es igual a la varianza de la población (σ^2) dividida por el tamaño de la muestra (n). A medida que el tamaño de la muestra (n) aumenta, la varianza de la distribución muestral disminuye (significa que las medias muestrales estarán más cerca de la media poblacional).

Si el tamaño de la muestra es suficientemente grande (generalmente se considera $n \geq 30$), la distribución muestral de la media se aproxima a una distribución normal, independientemente de la forma de la distribución de la población original. Este es el resultado del Teorema del Límite Central. Y si la muestra es menor a 30, la distribución de las medias dependerá de la distribución original de la población.

$$\sigma_{\bar{x}}^2 = \frac{\sigma^2}{n} \quad \text{como esta es la varianza, la desviación estándar es: } \frac{s}{\sqrt{n}} \quad s = \text{sigma}$$

Para muestras tomadas de poblaciones finitas (Poblaciones pequeñas) de tamaño N , hay que hacer una corrección, siendo N el tamaño de la población y n el tamaño de la muestra, quedando la varianza de esta distribución así:

$$\sigma_{\bar{x}}^2 = \frac{\sigma^2}{n} \cdot \frac{N - n}{N - 1}$$

INTERVALOS DE CONFIANZA PARA LA MEDIA (" σ " conocida)

Si la **media** proviene de una muestra grande ($n > 30$, aún suponiendo que no se conozca la varianza de la misma) es posible definir una variable aleatoria (estadístico) llamada **media estandarizada** cuyos valores están dados por:

$$Z = \frac{\bar{X} - \mu}{\frac{s}{\sqrt{n}}} \quad \text{donde sigma "}\sigma\text{" (desv estándar poblacional) se cambia por "s" (desv estándar muestral) ya que en la realidad difícilmente se conoce de antemano la desviación estándar de una población, y que tiene una distribución normal estándar.}$$

La distribución normal es una campana de gauss (el área bajo la curva vale 1). Que sea Estándar quiere decir que la campana de Gauss tiene media $\mu = 0$, desviación estándar $\sigma = 1$ y varianza = 1.

La media estandarizada determina cuán lejos está la media muestral de la media poblacional en una escala estándar, ayudando a evaluar si una muestra es representativa o si es inusual (expresándola en términos de desviaciones estándar).

Supongamos que piden una confianza del 90%, como esta debe ser a ambos lados de la "campana" deben quedar colas con áreas de 5%. Esto implica la siguiente desigualdad que define el intervalo de confianza:

$$-z_{5\%} \leq \frac{\bar{x} - \mu}{\frac{s}{\sqrt{n}}} \leq z_{5\%}$$

Y despejando μ :

$$\bar{x} - z_{5\%} \cdot \frac{s}{\sqrt{n}} \leq \mu \leq \bar{x} + z_{5\%} \cdot \frac{s}{\sqrt{n}}$$

TEOREMA CENTRAL DEL LÍMITE (para tener idea, no lo toma como tema)

Esta propiedad establece que, independientemente de la forma de la población original, la distribución de las medias muestrales tiende a seguir una distribución normal (Z) a medida que el tamaño de la muestra aumenta.

1 A-1 y 2) DISTRIBUCIÓN MUESTRAL DE LA MEDIA (σ desconocida)

Si se supone que la muestra no es grande (n menor que 30) pero que proviene de una población normal, se puede probar el siguiente teorema:


Si $\bar{x}$ es la media de una muestra aleatoria de tamaño n tomada de una población normal que tiene media μ y varianza σ^2 , entonces:

$$t = \frac{\bar{x} - \mu}{\frac{s}{\sqrt{n}}}$$

Es el valor de una variable aleatoria (estadístico) con distribución t-Student y parámetro $v=n-1$ (grados de libertad), siendo n el tamaño de la muestra.

Los **grados de libertad** son los valores que puedes elegir libremente en un cálculo, antes de que las restricciones (como la media) fijen los demás valores.

La varianza depende de los grados de libertad v . Cuando este valor tiende a infinito (n grande) la varianza de la distribución tiende a 1 y la t-Student se convierte en normal estándar. Mientras más grande es v es como que la curva tiene menos dispersión. La t student es parecida a la distribución normal ya que ambas son acampanadas y simétricas.



Ejemplo:

$t = -3.192$ sugiere que la media de la muestra está mucho más baja de lo esperado (3.192 desviaciones estándar por debajo).

1 A-3) TEOREMA DE CHEBYSHEV (No hay ni un ejercicio de esto, poco probable que lo tome)

(SI NO CONOZCO LA DISTRIBUCIÓN DE LA POBLACIÓN, DIRECTAMENTE USO CHEBYSHEV)

Cuando la muestra es pequeña ($n < 30$) y se supone que la población **no** está normalmente distribuida, no es

posible utilizar la distribución de probabilidad normal ni la t-Student para construir un intervalo de confianza. En este caso no se pueden usar los estadísticos z ni t que vimos más arriba.

El Teorema de Chebyshev establece: La proporción de las medias en un conjunto de datos que se sitúa dentro de las desviaciones estándar de la media no es menor de $1-1/k^2$, siendo $k \geq 1$.

$$P(|x_m - \mu| \leq k \cdot \sigma_{x_m}) \leq 1 - \frac{1}{k^2}$$

$\sigma_{x_m} \rightarrow$ desviación estándar de la distribución de medias

Haciendo operaciones matemáticas para despejar μ el intervalo queda:

$$x_m - k \cdot \frac{s}{\sqrt{n}}$$

extremo inferior del intervalo de confianza

$$x_m + k \cdot \frac{s}{\sqrt{n}}$$

extremo superior del intervalo de confianza

Esta fórmula construye un intervalo de confianza para la media, pero en vez de hablar de un estadístico como t o z, utilizamos un valor k.

Lo malo del chebysehv es que para los mismos tamaños de muestra da intervalos de confianza más grande que el estadístico t (teniendo la misma cantidad de muestras) y todavía más grande hecho con el z de la distribución normal. (Es decir que los datos están más dispersos, es menos preciso)

Pero lo bueno es que se puede usar sin saber de qué distribución viene la población.

TABLA DE RESUMEN PARA ESTIMACIÓN DE INTERVALOS DE CONFIANZA PARA LA MEDIA DE UNA POBLACIÓN.

Población	Tamaño de la muestra	σ conocida	σ desconocida
Normalmente Distribuida	Grande ($n \geq 30$)	$\bar{x} \pm z_{\alpha} \cdot \sigma_{\bar{x}}$	$\bar{x} \pm z_{\alpha} \cdot s_{\bar{x}}$
	Chica ($n < 30$)	$\bar{x} \pm z_{\alpha} \cdot \sigma_{\bar{x}}$	$\bar{x} \pm t_{\alpha} \cdot s_{\bar{x}}$
No Normalmente Distribuida	Grande ($n \geq 30$)	$\bar{x} \pm z_{\alpha} \cdot \sigma_{\bar{x}}$	$\bar{x} \pm z_{\alpha} \cdot s_{\bar{x}}$
	Chica ($n < 30$)	$\bar{x} \pm k \cdot \sigma_{\bar{x}}$ donde $1-1/k^2$ se define por medio del Teorema de Chebyshev	$\bar{x} \pm k \cdot s_{\bar{x}}$ donde $1-1/k^2$ se define por medio del Teorema de Chebyshev

IMPORTANTE!!

A la hora de elegir el estadístico tengo q preguntarme:

- 1) La población es grande (mayor a 30) o chica (menor a 30)

- 2) La población está normalmente distribuida o no
- 3) La varianza es conocida o desconocida

Entonces para encontrar el intervalo de confianza de la media:

- Cualquiera sea la distribución puedo usar chebyshev
- Si viene de normal y la muestra es chica y no conozco la desviación estándar uso t
- Si la muestra es grande, en cualquier circunstancia puedo usar la distribución normal, es decir uso el estadístico z

TEMA B: ESTIMACIÓN

1 B-1) DISTRIBUCIÓN MUESTRAL DE LA VARIANZA

Al estudiar la distribución muestral de la varianza, **una de las primeras apreciaciones es que no puede ser negativa**, luego es evidente que no puede responder a una distribución normal ya que implica una campana de gauss con valores positivos y negativos. **Es por ella que se usa una distribución Chi Cuadrado**

Si s^2 es la varianza de una muestra aleatoria de tamaño n tomada de una población normal cuya varianza es σ^2 , entonces:

$$\chi^2 = (n-1) \cdot \frac{s^2}{\sigma^2}$$


Es un valor de una variable aleatoria (estadístico) que tiene la distribución chi-cuadrado con parámetro $v=n-1$ que va a servir para elaborar intervalos de confianza.

También es importante **encontrar la razón de dos muestras tomadas aleatoriamente**. Sirve en pruebas **para determinar si dos muestras provienen de poblaciones con varianzas iguales**, en dicho caso la razón debe ser cercana a 1.

Si s_1^2 y s_2^2 son las varianzas de muestras aleatorias independientes de tamaño n_1 y n_2 , respectivamente, tomadas de dos poblaciones normales, entonces:

$$F = \frac{s_1^2}{s_2^2}$$

es una variable aleatoria que tiene la distribución **F(Fisher)** con parámetros $v_1 = n_1 - 1$ (grados de libertad del numerador) y $v_2 = n_2 - 1$ (grados de libertad del denominador)



1 B-2) INFERENCIAS RELATIVAS A MEDIAS

Estimación Puntual:

Es la elección de un estadístico a partir de los datos muestrales, que se utiliza como mejor aproximación al valor real de un parámetro desconocido en la población. Por ejemplo, usar la media muestral ($\bar{x}$) para estimar la media poblacional (μ). Acertar con este tipo de estimaciones es casi imposible, por lo que siempre se añade cierto error máximo de estimación $E = \bar{x} - \mu$ (diferencia entre la estimación y la cantidad que se supone estima)

Estimador Insesgado:


Un estadístico es un estimador insesgado si, al repetir el ensayo con muchas muestras, la media de las medias muestrales, acierta en el valor real que queremos estimar. No hay una desviación sistemática. Ej: Si calculo la media de muchas muestras de sandías de mi granja, siendo muestras representativas, es decir que tomo tanto sandías grandes, medianas y pequeñas. Por lo tanto la media de las medias muestrales tenderá a la media poblacional.

Estimador Sesgado:

El método de estimación, en promedio, no da el valor real del parámetro poblacional. Hay una desviación sistemática en una dirección particular (sobreestimación o subestimación). Ej: Si calculo la media únicamente de muestras que tienen sandías grandes, la media de las medias muestrales no tenderá a la media poblacional.

La eficiencia se mide sabiendo si un estimador es insesgado y que tan pequeña es la varianza de cada estimador. Un estimador es más eficiente que otro cuando su dispersión es menor.


Ej: Si tenemos 2 tiradores que disparan a dos blancos como en la imagen, el que tira al blanco de la derecha tiene un mejor arma, ya que las balas están menos dispersas, por lo tanto solo deberíamos compensar ese error en la mira. El de la izquierda no tiene un error corregible, el de la derecha si. Por lo tanto la de la derecha tiene un sesgo.



ESTIMACIÓN POR INTERVALOS DE CONFIANZA

Por lo dicho anteriormente, las probabilidades de estimar puntualmente en precisa el valor de un parámetro, con todas sus cifras decimales, es prácticamente nula. (ya que sería un integral con extremos iguales), por

esto es preferible determinar un intervalo dentro del cuál podamos afirmar (con cierta certeza, es decir, con cierto nivel de confianza) que el valor real de la media poblacional μ se encuentre en el intervalo.



Por ejemplo, si tomo un alumno cualquiera la probabilidad de que pese exactamente 62 kg es 0. Si quiero saber la probabilidad de que un alumno pese 62 kg tengo que hacer la integral desde 62 hasta 62 y esa área da 0. Uno puede pesar 62.01, otro 62.12 y así. La estimación puntual no es muy buena. Interesa estimar por intervalo, por ej. los alumnos que pesen 60 kg a 64 kg y ahí sí va a haber un área bajo la

curva pq los extremos de la integral van ser diferentes.

El intervalo se construye en base a la media muestral (Estimador puntual, osea la raya en medio de la campana). El área bajo la curva es el nivel de confianza que tengo, y la suma de lo sombreado es el nivel de significancia (alpha).

$$E = z_{\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}}$$

con probabilidad $1 - \alpha$

Como dijimos anteriormente: $E = x_m - u$

z → Indica que es una distribución normal

$\frac{\alpha}{2}$ → Es una probabilidad de cola

$z_{\frac{\alpha}{2}}$ → En conjunto z y $\frac{\alpha}{2}$, es la abscisa que me deja un área $\frac{\alpha}{2}$ a la derecha o a la izquierda de la curva normal.

$\alpha \rightarrow$ Me indica el nivel de significancia

$1 - \alpha \rightarrow$ Me indica el nivel de confianza o la probabilidad de que esté dentro de ese valor.

Los valores $\bar{x} - E$ y $\bar{x} + E$ (media muestral + el error y media muestral – el error) se los denomina **Límites de Confianza** (Las abscisas)

Para ilustrar esto, supongamos una muestra grande ($n \geq 30$) con μ y σ^2 conocidos entonces se puede asegurar con una confianza del $(1-\alpha)100\%$ que el intervalo

$$\left(\bar{x} - z_{\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}}, \bar{x} + z_{\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}} \right) \quad \text{Contiene a } \mu.$$

Este es un **Intervalo de Confianza** para μ , con un **Nivel de Confianza** $1 - \alpha$.

Para determinar el estadístico en casos de n chico o n grande, etc, miramos la tabla de [Distribución de la Media Muestral](#). (Link a la tabla)

Si la población es normal, n es chico y no se conoce σ :

$$t = \frac{\bar{x} - \mu}{\frac{s}{\sqrt{n}}}$$

t es una variable aleatoria con distribución t-Student con $v=n-1$ grados de libertad.

Luego, el error máximo de estimación será: $E = t_{\frac{\alpha}{2}} \cdot \frac{s}{\sqrt{n}}$

Con una confianza del $(1-\alpha)100\%$ de que el error sea menor que esa cantidad.

Mientras mayor sea el nivel de significancia (α) entonces menor va a ser el nivel de confianza ($1-\alpha$) y menor va a ser el intervalo de confianza (los extremos van a ser más chicos) . Mientras menor sea el intervalo de confianza entonces es más preciso, hay menos dispersión de valores.

Puedo determinar el tamaño que debe tener la muestra para obtener un error máximo determinado y con un nivel de significancia determinado. Determinar n sirve para presupuestar: evaluar costos, tiempo etc.

$$E = z_{\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}} \quad n = \left(z_{\frac{\alpha}{2}} \cdot \frac{\sigma}{E} \right)^2$$

UNIDAD II: PRUEBAS DE HIPÓTESIS

TEMA A: HIPÓTESIS

2-A-1 HIPÓTESIS NULA Y PRUEBA DE SIGNIFICANCIA

2-A-2 HIPÓTESIS RELATIVAS A UNA MEDIA.

Sirve para decidir si una afirmación respecto a un parámetro es verdadera o falsa, es decir **probar una hipótesis** respecto a un parámetro .

El proceso de decisión podría conducir a resultados erróneos, sin embargo, es posible respaldar nuestra decisión con un cierto nivel de significación asociado a la prueba.

El error tipo I es la probabilidad de rechazar algo correcto. Y el error tipo II es la probabilidad de aceptar algo incorrecto.

	Se Acepta H	Se Rechaza H
H es Verdadera	Decisión Correcta	Error de Tipo I
H es Falsa	Error de Tipo II	Decisión Correcta

La potencia de una prueba estadística es la probabilidad de rechazar la hipótesis nula cuando la hipótesis alternativa es verdadera. Matemáticamente, se expresa como: $(1 - B)$

Ej:

Error de Tipo 1: Falso Positivo

Se produce cuando **rechazamos la hipótesis nula (H_0)** cuando en realidad era verdadera.

Ejemplo: Un test de COVID-19

- H_0 : La persona **NO** tiene COVID.
- H_1 : La persona **tiene** COVID.
- Si la prueba de COVID da **positivo**, pero en realidad la persona NO está infectada, hemos cometido un **error de tipo 1**.

- ♦ **Consecuencia:** Una persona sana recibe un tratamiento innecesario.

Error de Tipo 2 (β): Falso Negativo

Se produce cuando **no rechazamos la hipótesis nula (H_0)** cuando en realidad era falsa.

Ejemplo: Un test de embarazo

- H_0 : La persona **NO** está embarazada.
- H_1 : La persona **está** embarazada.
- Si la prueba de embarazo da **negativo**, pero en realidad la persona SÍ está embarazada, hemos cometido un **error de tipo 2**.

- ♦ **Consecuencia:** No se detecta un embarazo cuando realmente existe.

Hipótesis Nula (H_0): Es una hipótesis opuesta a lo que se quiere probar. Por ejemplo, si se quiere determinar de dos sistemas de riego cuál es el de menor costo, se formula la hipótesis de que los dos sean

igualmente costosos. Una **Hipótesis Nula Simple** es la que fija exactamente el valor de un parámetro de la población, sin permitir otros valores posibles. Ej: Quiere decir que toma un único valor, ej: $\mu = 20 \text{ min}$, o $\mu_0 = \mu$. Es decir que μ no es mayor o menor a algo (No toma rangos de valores)

Orden de resolución de un problema:

1 – Se formula una Hipótesis Nula simple y una Hipótesis Alterna apropiada que se acepta cuando la Hipótesis Nula debe ser rechazada.

En el ejemplo de la pintura (clase 3), la hipótesis nula es $\mu = 20 \text{ min}$ y la alternativa $\mu > 20 \text{ min}$. Esta clase de alternativa se llama Unilateral (porque da un alfa hacia una de las colas. En el caso de la pintura es de cola derecha ya que toleraba como máximo una media de 20.75, me preocupa que no haya de más, que la media no sea mayor a 20.75). Un caso de prueba alternativa Bilateral sería el de un fraccionador de café que desea verificar si en cada frasco de 100 gr hay en realidad 100 gr. La alternativa bilateral es $\mu \neq 100$. Al fraccionador no le conviene menos de 100 gr porque puede perder mercado ni más de 100 gr por la pérdida económica. En el caso que yo fuese el comprador de bolsitas de azúcar la prueba que se hace sería unilateral de cola izquierda ya que me preocuparía que hayan menos de 100 gr de café.

2 - Se especifica la probabilidad de un Error de Tipo I si es posible, conveniente o necesario, se puede especificar también las probabilidades de Errores Tipo II, para alternativas particulares.

La probabilidad de un Error Tipo I se denomina **Nivel de Significación** y se fija comúnmente en $\alpha=0.05$ ó $\alpha=0.01$. No conviene muy chico α porque β se hace muy grande. α es un error de tipo 1 y β un error de tipo 2

3 – Con base en la distribución muestral de un estadístico apropiado, se construye un criterio para probar la Hipótesis Nula contra la alternativa determinada. *(Siempre pruebo la H_0 , NUNCA H_1)*
Por ejemplo, si ya sé que puedo usar el estadístico z, dibujo mi campana gauss y calculo la abscisa que marca la zona de aceptación y la zona de rechazo.

4 – Se calcula, a partir de los datos, el valor del estadístico sobre el cual se basa la decisión .
Calculamos el estadístico y nos fijamos si cae en la zona de aceptación o de rechazo.

5 - Se decide rechazar la Hipótesis Nula, aceptarla o abstenerse de tomar una decisión. Según donde haya caído el estadístico se acepta la hipótesis nula o se rechaza (y se acepta la hipótesis alterna)

Aceptar H_0 no significa que sea verdadera, sino que los datos no nos permiten rechazarla con confianza. Es por eso que en estadística se prefiere decir que "no se rechaza H_0 " en lugar de "se acepta H_0 "

TEMA B: CARACTERÍSTICAS DE OPERACIÓN.

2 B-1) CURVAS CARACTERÍSTICAS DE OPERACIÓN (Análisis de las curvas)


La curva roja es la curva del μ original del problema (Error Tipo 1), y la azul la del μ que cambia (Error Tipo 2).

Ej: Si el secado de pintura tiene una media de $\mu=20 \text{ min}$ (curva roja) según el vendedor, pero nosotros al realizar una prueba obtenemos que en realidad tiene una media de $\mu=21 \text{ min}$ (curva azul)

Análisis para cola derecha

En una prueba de cola derecha a medida que crece μ (se va para derecha) entonces Beta (error tipo II)


disminuye. Y a medida que μ disminuye (se va para la izquierda) entonces Beta aumenta.



Si rechazamos H_0 (con un nivel de significancia del 5%), existe un 5% de probabilidad de que sea un error tipo 1.


Análisis para cola izquierda

En una prueba de cola izquierda a medida que disminuye μ (se va para la izq) entonces Beta (error tipo II) disminuye. Y a medida que μ aumenta (se va para la derecha) entonces Beta aumenta.




Análisis para dos colas

Si aumenta μ entonces beta aumenta pero cuando ya pasa la mitad empieza a disminuir. Entonces disminuye para los μ chico, disminuye para los μ grande y alcanza un máximo cuando los μ de ambas curvas sean iguales donde Beta va a valer $1 - \alpha$.



En caso de que la curva azul esté más a la derecha o más a la izquierda, se analizan como en las fotos de abajo



Apunte para entender: ¡¡IMPORTANTE!!

Tomar una decisión de forma arbitraria, significa que se eligió un valor para la media sin una justificación basada en datos o en un criterio específico

Medidas absolutas y normalizadas:

Absolutas: Cuando se trabaja con las mismas medidas del problema (Ej: Si habla de 30 metros se usan esos metros). Ej: Si medimos la altura de 5 personas en cm: 160,165,170,175,180 → La **media** es:

$$\mu = \frac{160 + 165 + 170 + 175 + 180}{5} = 170 \text{ cm}$$

Esto es una **medida absoluta**, porque está en cm.

Normalizadas: Son aquellas que **eliminan las unidades originales** y permiten comparar datos en diferentes escalas (En una distribución normal estándar). Se obtienen utilizando la media 0 y la desviación estándar 1 (Distribución normal estándar). Para los límites no es necesario normalizar el Z. Si hay que calcular un estadístico a veces es necesario normalizarlo, ej con el Z se normaliza con z-score.

qnorm devuelve el cuantil (percentil) de probabilidad. (Un valor “x” de la función). Tiene parámetros (p, μ, σ) siendo p la probabilidad (Ej: $p = 0.9$ es decir 90%).

Ej: Si queremos encontrar el percentil 95 de una distribución normal con $\mu=50$ y $\sigma=10$. `qnorm(0.95, 50, 10)` x tal que el 95% de los valores están por debajo de él. (El percentil 95 es un valor “x” tal que el 95% de los valores de la distribución están a la izquierda del mismo)

Sirve para determinar los **valores críticos** de la función que serían los **límites (abscisas)**. La probabilidad p es el nivel de significancia ($p=\alpha$). Si quiero calcular para dos colas es $p = \alpha/2$:

- Cola izq `qnorm( $\alpha/2, \mu, \sigma$ )`
- Cola derecha: `qnorm( $1 - \alpha/2, \mu, \sigma$ )`.

$z05i := \text{qnorm}\left(\frac{\alpha}{2}, 0, 1\right)$	$z05i = -1.96$	Cola izquierda	$\text{qnorm}\left(0.025, 1600, \frac{120}{\sqrt{100}}\right) = 1.576 \times 10^3$
$z05d := \text{qnorm}\left(1 - \frac{\alpha}{2}, 0, 1\right)$	$z05d = 1.96$	Cola derecha	$\text{qnorm}\left(0.025, 1600, \frac{120}{\sqrt{100}}\right) = 1.576 \times 10^3$
Datos:			

Si es con una distribución de medias $\sigma = \frac{s}{\sqrt{n}}$, siendo n el tamaño de la muestra.

Se suele trabajar con distribuciones de medias muestrales en temas como:

- Estimación de parámetros (media de la población).
- Pruebas de hipótesis sobre la media.
- Construcción de intervalos de confianza para la media.

$x = 0, 0.01 \dots 5$ (Se define un intervalo de valores que va a tomar la función densidad de probabilidad)

Si las medidas están estandarizadas, (Se transformó la media con z-score), entonces dnorm y pnorm usarían Z como parámetro x

dnorm tiene parámetros $\text{dnorm}(x, \mu, \sigma)$. Se usa para calcular la densidad de probabilidad es decir **qué valores son más probables** dentro de una distribución. Este valor **no es una probabilidad**, sino la altura de la curva de la distribución normal en x. Ej: Si evaluamos $\text{dnorm}(x, 170, 10)$, veremos que los valores más altos de densidad están cerca de 170 cm, lo que significa que la mayoría de las personas tienen alturas cercanas a 170 cm. (En general se usa para graficar)

pnorm tiene parámetros $\text{pnorm}(x, \mu, \sigma)$. y se usa para calcular la probabilidad acumulada hasta el punto x.

rnorm devuelve N muestras random de tamaño n. Tiene parámetros $\text{rnorm}(n, \mu, \sigma)$, siendo n la cantidad de valores aleatorios que quieras generar.

Los **estadísticos** sirven para predecir dónde se encuentra un parámetro (ej: distintas medias) dentro de una función.

ANÁLISIS PARA MUESTRAS DE MAYOR TAMAÑO

Si las muestras son cada vez más grandes:

- Las curvas que marcan el error tipo II se hacen cada vez más pendientes (una pendiente cada vez mayor a medida que aumenta el n). Por lo tanto, disminuye el error tipo II
- La función densidad de probabilidad de la distribución de medias (campana de gauss) se hace más flaca.
- Disminuye la dispersión. Por lo tanto, el intervalo de confianza es más ajustado.
- Siempre voy a hacer una mejor apreciación cuando es mayor el tamaño de la muestra.

2 B-3) HIPÓTESIS RELATIVA A DOS MEDIAS

Se consideran dos poblaciones con medias μ_1 y μ_2 y varianzas σ_1^2 y σ_2^2 . **Se quieren comparar las medias de**

dos poblaciones distintas. Se quiere probar la hipótesis nula $\mu_1 - \mu_2 = \delta$, siendo δ una constante, que se determina en base a muestras aleatorias independientes de tamaños n_1 y n_2 .

Se harán pruebas de la hipótesis nula contra las alternas $\mu_1 - \mu_2 < \delta$ o $\mu_1 - \mu_2 > \delta$ o $\mu_1 - \mu_2 \neq \delta$. Donde δ suele ser 0. La prueba **dependerá** de las diferencias entre las media muestrales $\bar{x}_1 - \bar{x}_2$ y si ambas provienen de poblaciones normales, se define el estadístico:

$$z = \frac{(\bar{x}_1 - \bar{x}_2) - \delta}{\sqrt{\sigma_{\bar{x}_1}^2 + \sigma_{\bar{x}_2}^2}}$$

$\sigma_{\bar{x}_1}$ es la desviación estándar de la media de la muestra 1 y $\sigma_{\bar{x}_2}$ es la desviación estándar de la media de la muestra 2.

Se forma una nueva población dada por la diferencia entre las medias muestrales, y tiene una distribución que viene dada por el cuadro

Si las distribuciones de dos variables aleatorias independientes tienen las medias μ_1 y μ_2 y las varianzas σ_1^2 y σ_2^2 , entonces la **distribución de su suma o diferencia (nueva población)** tiene la media $\mu_1 + \mu_2$ (o $\mu_1 - \mu_2$) y la varianza $\sigma_1^2 + \sigma_2^2$.

Se sabe que:

$$\sigma_{\bar{x}_1}^2 = \frac{\sigma_1^2}{n_1} \quad \sigma_{\bar{x}_2}^2 = \frac{\sigma_2^2}{n_2}$$

es decir la varianza de la diferencia de medias es:

$$\sigma_{\bar{x}_1 - \bar{x}_2}^2 = \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}$$

Luego el estadístico es:

$$z = \frac{[\bar{x}_1 - \bar{x}_2] - \delta}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$$

Este estadístico es aún válido para muestras grandes (n_1 y n_2 mayores que 30) con sigma desconocida sustituyendo σ_1 y σ_2 por s_1 y s_2 .

Cuando n_1 , n_2 o ambos son pequeños y se desconocen las varianzas de las poblaciones, se puede fundamentar la hipótesis nula $\mu_1 - \mu_2 = \delta$ en un estadístico adecuado **t**, con tal de suponer a **ambas poblaciones normales** con $\sigma_1 = \sigma_2 (= \sigma)$. En estas condiciones se llega a la llamada:

"Prueba t bimuestral"

$$t = \frac{[(\bar{x}_1 - \bar{x}_2) - \delta]}{\sqrt{(n_1 - 1) \cdot (s_1)^2 + (n_2 - 1) \cdot (s_2)^2}} \cdot \sqrt{\frac{n_1 \cdot n_2 \cdot (n_1 + n_2 - 2)}{n_1 + n_2}} \quad \text{con } v = n_1 + n_2 - 2.$$

Al aplicar la prueba t-bimuestral se deben vigilar que las muestras sean independientes. Por ejemplo, no puede utilizarse cuando se trabaja con datos de "antes y después".

Prueba para t unimuestral

La **Prueba Unimuestral** verifica que una media poblacional sea significativamente igual a una media esperada. Únicamente aplico el estadístico y verifico si cayó en zona de aceptación.

(Ej de hipótesis: $H_0: u = u_0$ donde u_0 es la media esperada)

Problema: Los siguientes datos integran una muestra aleatoria de 15 mediciones de octanaje de cierto tipo de nafta:

99.0	102.3	99.8	100.5	99.7	96.2	99.1	102.5
103.3	97.4	100.4	98.9	98.3	98.0	101.6	

Si las 2 poblaciones no son independientes, sino que están relacionadas entonces no se aplica la prueba t bimuestral sino que se aplica otra prueba tomando como muestra la diferencia entre las 2 poblaciones con su signo. A esta prueba t se la conoce como:

"Prueba t para Muestras Apareadas"

La **Prueba t para muestras Apareadas** verifica que la media poblacional sea significativamente igual a una media esperada a través de la media muestral x_m , donde x_m es media de la diferencia de muestras

(Ej de hipótesis: $H_0: u = 0$, $H_1: u > 0$ o puede ser un $H_0: u = u_0$ si nos da u_0 esperada)

45 y 36	73 y 60	46 y 44	124 y 119	33 y 35
57 y 51	83 y 77	34 y 29	26 y 24	17 y 11

Por cada par se calcula a través de la diferencia entre ellas la nueva media y desviación muestral:
(Primero $45 - 36 = 9$, $73 - 60 = 13$...)

$$\bar{x}_m := \frac{9 + 13 + 2 + 5 - 2 + 6 + 6 + 5 + 2 + 6}{10} = 5.2$$

$$s := \sqrt{\frac{(9^2 + 13^2 + 2^2 + 5^2 + 2^2 + 6^2 + 6^2 + 5^2 + 2^2 + 6^2) - 10 \cdot (5.2)^2}{9}} = 4.077$$

Luego aplicó el estadístico **t unimuestral**:

$$t = \frac{\bar{x}_m - \mu}{\frac{s}{\sqrt{n}}} \quad \text{Aceptando o rechazando la hipótesis}$$

Para muestras independientes grandes	
varianza conocida	varianza desconocida
$z = \frac{(XM - YM) - \delta}{\sqrt{\frac{(\sigma_1)^2}{n_1} + \frac{(\sigma_2)^2}{n_2}}}$	$z = \frac{(XM - YM) - \delta}{\sqrt{\frac{(s_1)^2}{n_1} + \frac{(s_2)^2}{n_2}}}$
Para muestras independientes chicas y varianza desconocida	
$t = \frac{(XM - YM) - \delta}{\sigma_{est} \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} = \frac{(XM - YM) - \delta}{\sqrt{(n_1 - 1)(s_1)^2 + (n_2 - 1)(s_2)^2}} \sqrt{\frac{n_1 \cdot n_2 (n_1 + n_2 - 2)}{n_1 + n_2}}$	
Las variables deben ser independientes entre sí . Caso contrario se debe aplicar una comparación que se basa en diferencias pareadas , conocida como prueba t pareada	
Se debe tomar una variable aleatoria D que sea la diferencia entre las 2 variables dependientes originales y la prueba se basa en: $H_0 >> \mu_D = 0$ DM = Media de D Sd = desviación estándar de D	
$\frac{DM - \mu_D}{\frac{s_D}{\sqrt{n}}}$	

UNIDAD III: VARIANZA Y PROPORCIONES

TEMA A: VARIANZA

3 A-1) ESTIMACIÓN DE LA VARIANZA

La varianza muestral s^2 es un estimador insesgado de la varianza poblacional σ^2 (siempre y cuando pongamos $n-1$ y no n en la fórmula de la varianza). Pero, la **desviación estándar muestral es un estimador sesgado de la desviación estándar**. Para muestras grandes, este sesgo es chico, pero en muestras chicas puede ser significativo. Por esto **se recurre al estimador R (Rango muestral)**, que es un **estimador insesgado de la desviación estándar**.

El rango muestral se calcula como el valor más grande de una muestra menos el más pequeño:

$$R = X_{\max} - X_{\min}$$

Se puede demostrar que si se tiene una población normal y se toman muestras de tamaño n , **el rango tiene una distribución normal con media $d_2 \cdot \sigma$ y con desviación estándar $d_3 \cdot \sigma$** , donde d_2 y d_3 son constantes que dependen del tamaño de la muestra y que se obtienen de la tabla de abajo:

d_2	1.128	1.693	2.054	2.326	2.534	2.704	2.847	2.970	3.078
d_3	0.853	0.888	0.880	0.864	0.848	0.833	0.830	0.808	0.797
N	2	3	4	5	6	7	8	9	10

Luego R/d_3 es un estimador insesgado de σ .

El rango se emplea fundamentalmente en **Control de Calidad**.

En **muestras aleatorias chicas** (menores que 30) de poblaciones normales **se puede determinar un estadístico, el cual tiene una distribución chi cuadrado con $n-1$ grados de libertad**. Este **me permite elaborar un intervalo de confianza para la desviación estándar**.

$$\chi^2 = \frac{(n-1) \cdot s^2}{\sigma^2} \quad \text{con } v = n-1 \text{ grados de libertad}$$

Obtenemos el intervalo de confianza para la varianza.

$$\frac{(n-1) \cdot s^2}{\left(\chi^2\right)_{1-\frac{\alpha}{2}}} < \sigma^2 < \frac{(n-1) \cdot s^2}{\left(\chi^2\right)_{\frac{\alpha}{2}}}$$

Si tomo la raíz cuadrada en los tres miembros, obtengo el intervalo de confianza para la desviaciones estándar.

Ahora si el tamaño de la muestra es grande (mayor a 30), la distribución de la desviación estándar se puede aproximar con una distribución normal con media σ y desviación estándar $\frac{\sigma}{\sqrt{2 \cdot n}}$. También con muestras grandes se puede observar que la distribución chi cuadrado se aproxima a la normal, al darle valores de n mayores que 30 se puede estimar con una normal.

$$Z = \frac{s - \sigma}{\frac{\sigma}{\sqrt{2 \cdot n}}} \quad \text{Estadístico Z (distribución normal estándar) con media } \sigma \text{ y desviación estándar } \frac{\sigma}{\sqrt{2 \cdot n}}$$

Obtenemos el intervalo de confianza para la desviación estándar.

$$\frac{s}{1 + \frac{z_{\frac{\alpha}{2}}}{\sqrt{2 \cdot n}}} < \sigma < \frac{s}{1 - \frac{z_{\frac{\alpha}{2}}}{\sqrt{2 \cdot n}}}$$

De igual forma para una muestra de gran tamaño se puede usar la chi cuadrado pero sería innecesario.

Para estimar la desviaciones estándar poblacional con la desviación estándar muestral utilizamos en muestras pequeñas R/d3 y para muestras grandes raíz cuadrada de $S^2 = \frac{\sum (x - \bar{x})^2}{n-1}$. En muestras chicas el intervalo de confianza de la desv estándar poblacional se utiliza CHI CUADRADO, y en muestra grande Z.

3 A-2) HIPÓTESIS REFERIDA A UNA VARIANZA

Se quiere probar la hipótesis nula de que la varianza de una población es igual a una determinada, contra una alternativa unilateral o bilateral adecuada. Si me interesa que la desviación no sea mayor a x valor entonces será prueba de cola derecha. Si me interesa que la desviación sea por lo menos x entonces será prueba de cola izq. Y si necesito que la desviación estándar esté entre dos valores entonces será bilateral.

Los datos conocidos son: la desviación estándar de referencia σ_0 y la desviación estándar muestral s.

La H_0 es $\sigma = \sigma_0$ (Se quiere verificar si la desv. estándar poblacional es significativamente igual a una esperada, a través de la desv. muestral)

Nunca se va a probar si la desviación estándar o varianza son más chicas. Por lo tanto siempre es de cola derecha

Para muestras aleatorias extraídas de una población normal con varianza σ^2 , se utiliza chi cuadrado:

$$\chi^2 = \frac{(n-1) \cdot s^2}{(\sigma_0)^2}$$

siendo sigma cero el sigma de la hipótesis nula que se plantea

Recordar que si la población que se muestrea tiene un tamaño relativo grande ($n \geq 30$) la hipótesis nula se puede probar con:

$$z = \frac{s - \sigma_0}{\frac{\sigma_0}{\sqrt{2 \cdot n}}}$$

es decir, se puede usar el estadístico z en vez del chi cuadrado

TEMA B: PROPORCIONES

3 B-1) ESTIMACIÓN DE PROPORCIONES

Por ej que de la población de Mendoza tomó una muestra de tamaño 100 y le pregunto a cada uno si bebe vino o no. De la muestra de tamaño 100 encontré que 35 toman vino. Sin embargo, no podría concluir que la proporción de los mendocinos que toman vino es del 35% ya que a esta conclusión la estoy sacando de una sola muestra y probablemente no sea muy representativa. Pero estadísticamente, con el pivote en esa estimación puntual, puedo establecer un intervalo de confianza que me permita decir con una confianza del 95 o 99% que entre el X1% e X2% (valores de ejemplo) de la proporción de población de Mendoza bebe vino, basándome en una muestra de 100 personas.

Por ejemplo, podría decir que entre 30 y 40 está la proporción de personas que beben vino en Mendoza basado en una muestra de tamaño 100 con un nivel de confianza del 95%. Quiere decir que si yo repitiera 1000 veces el experimento en 950 ocasiones estaría ubicado dentro del intervalo de 30 y 40.

La información que suele disponerse al estimar la proporción es el número de veces x , que un evento ocurre en n ensayos, ocasiones u observaciones.

La estimación puntual de la proporción poblacional p (prop real) suele ser x/n (proporción muestral, es un estimador insesgado de p , es decir: $p=x/n$).

Se quiere estimar p que es un parámetro poblacional a través de x/n .

Para n ensayos que satisfacen la distribución binomial, se verifica $\mu = n \cdot p$ es la media y $\sigma = \sqrt{n \cdot p \cdot (1 - p)}$ la desviación estándar, y si se divide por n , se encuentra la media y la desviación estándar de la proporción de éxitos (es decir la proporción muestral)

Ya que x y x/n son variables discretas, un intervalo de confianza de exactamente $(1 - \alpha) \cdot 100\%$ es difícil de lograr. Como x y x/n son variables discretas el intervalo de confianza que se va a lograr no es un intervalo exacto como cuando se tenían distribuciones continuas en los casos anteriores.

DISTRIBUCIÓN BINOMIAL


La distribución binomial es una distribución de probabilidad discreta que cuenta el número de éxitos en una secuencia de n ensayos de Bernoulli independientes entre sí, con una probabilidad fija p de ocurrencia de "éxito" entre los ensayos. La **probabilidad de "fracaso"** está dada por **$q=1-p$**


Se puede asegurar con probabilidad de aproximadamente $(1 - \alpha) \cdot 100\%$ que se cumple la siguiente desigualdad:

$$x_0(p) < x < x_1(p) \quad \text{siendo los límites del intervalo.}$$

Para transformar esta desigualdad en un intervalo de confianza para p , se recurre a un método gráfico.

Hay gráficos que se utilizan para ver los extremos del intervalo (gráfico que muestra en **clase 5 min 36 aprox**, donde te fijas tu valor de x/n (trazas una línea vertical) y eligir las curvas dependiendo del tamaño de muestra que se tenga (trazas dos rectas horizontales donde se intersecta la línea vertical anteriormente marcada y la curva), si entras con los x/n de abajo entonces usas los valores de p de la izq y si entras por los x/n de arriba usas los valores de p de la derecha).





Sino como regla práctica para que una distribución binomial se acerque a la normal basta con que $n \cdot p$ y $(1-p) \cdot n$ sean a la vez mayores que 5. Si ambos no son mayores que 5 tengo que aplicar la solución gráfica. La regla permite encontrar los valores de p de manera analítica y no gráfica. Este método analítico se refiere a la distribución binomial que cuando se cumple esas condiciones, la binomial se puede estimar a través de la normal estándar. El valor 5 es un umbral que se ha establecido en base a la experiencia ya que ha demostrado funcionar bien para que la campana sea simétrica.

$$Z = \frac{x - n \cdot p}{\sqrt{n \cdot p \cdot (1-p)}}$$

Luego trabajando con el estadístico Z se obtiene

$$\frac{x}{n} - z_{\frac{\alpha}{2}} \cdot \sqrt{\frac{\frac{x}{n} \cdot \left(1 - \frac{x}{n}\right)}{n}} < p < \frac{x}{n} + z_{\frac{\alpha}{2}} \cdot \sqrt{\frac{\frac{x}{n} \cdot \left(1 - \frac{x}{n}\right)}{n}}$$

lo que permite lograr este intervalo de confianza para p en muestras de gran tamaño, con un nivel de confianza $(1-\alpha) \cdot 100\%$. Vemos que ese intervalo de confianza para p que quedó usa x/n como pivote (como base sobre la cual se construye el intervalo) y le resta y le suma un error de estimación.

Hacer una estimación del intervalo de confianza sirve para que por ej: viene el cliente y me pide que le estime esta proporción pero con este intervalo de confianza (+ - 5% por ej.) . Este dato a mi me va a servir

pq mientras el cliente pida más finito el intervalo (bien ajustado, que no le escape en más de + - 5%) voy a tener que aumentar el tamaño de la muestra. Que el cliente quiera un resultado más ajustado implica una muestra más grande y un precio más alto. Mientras más finito pida el cliente el intervalo de confianza más caro le tengo que cobrar. Con el cliente se transa el error de estimación, si lo quiere chico sale más caro, ahora si quiere un error de estimación más laxa entonces la prueba va a salir más barata pero que no espere que tenga tanta exactitud.

Error Máximo de Estimación:

$$E = z_{\frac{\alpha}{2}} \cdot \sqrt{\frac{\frac{x}{n} \cdot \left(1 - \frac{x}{n}\right)}{n}}$$

Notar que el Error Máximo de Estimación es el segundo término de ambos extremos del intervalo de la fórmula que usamos recién

La fórmula E puede servir para determinar el **tamaño muestral** que es necesario para alcanzar un grado deseado de precisión.

$$n = p \cdot (1 - p) \cdot \left(\frac{z_{\frac{\alpha}{2}}}{E} \right)^2$$
 Donde E es fijado por el cliente. El alfa (nivel de confianza) es un acuerdo o convención entre el cliente y el proveedor (puede ser 0.01 o 0.05)

Esta fórmula no se puede utilizar a menos que se tenga información de p (en base a datos auxiliares, digamos una muestra previa). Por ejemplo que digan que la proporción real no excede de 0.127. Si yo no tengo idea de la proporción p, me tengo que poner en la situación más desfavorable

Si no se conoce, se sabe que p.(1-p) es a lo sumo 1/4, correspondiente a p=1/2. Luego:

$$n = \frac{1}{4} \cdot \left(\frac{z_{\frac{\alpha}{2}}}{E} \right)^2$$

La demostración es: si no se tiene ni la más remota idea de cuanto puede ser la proporción que hay, entonces hay que ponerse en la situación más desfavorable para el análisis. Entonces se sabe que p.(1-p) (fórmula de la varianza muestral, despejar la desviación estándar y dividir por n)

p.(1-p), luego distribuyo

$$p - p^2$$

, luego derivó e igualó a cero para encontrar los puntos críticos

$$1 - 2 \cdot p = 0$$

se puede ver que el valor de p que maximiza ese producto es 1/2, ya que al derivar e igualar a 0 encontramos el punto máximo de la función (El más alto).

$$p = \frac{1}{2}$$

O sea que la peor de las situaciones se daría si p vale 1/2. Se asume el **peor caso posible** (Que es que la muestra sea MUY grande) para garantizar que el tamaño de muestra sea suficiente para cualquier escenario. Entonces:

$$n = p \cdot (1 - p) \cdot \left(\frac{z_{\frac{\alpha}{2}}}{E} \right)^2$$
 En p.(1-p) reemplazo p por lo peor, es decir 1/2 y eso da 1/4 quedando


La
$$n = \frac{1}{4} \cdot \left(\frac{z_{\frac{\alpha}{2}}}{E} \right)^2$$
 varia

Notar en la formula que si el cliente pidio un E muy chiquito entonces n va a ser grande (ya que E esta en el denominador). Si pide reducir el error a la mitad, el tamaño de la muestra tiene que ser 4 veces más. Cuanto más exigente el cliente se pone con el error más cara es la encuesta.

Explicación:

Al ser cuadrática negativa, es una función CÓNCAVA por lo que cuando igualó derivada a 0 es el MÁXIMO de la función.

$$x/n = 35/100 = 0.35$$



Tomo el peor de los casos ($p=0.5$) cuando no conozco p , ya que mi muestra va a tener que ser lo suficientemente grande para asegurar que el intervalo de confianza cumpla con la precisión que quiere el cliente.

Cuando p está cerca de 0 o 1, se necesita una **muestra más pequeña** para estimar p con precisión.

Entonces esas fórmulas son para saber el tamaño de la muestra para hacer una investigación estadística, con un error de estimación E que me pide el cliente y alfa acordado entre ambas partes. La primera se usa si se tiene información de p y la segunda se usa si no se conoce p .

En definitiva las fórmulas sirven para poder decirle al cliente cuánto le va a costar. Nos permite encontrar el tamaño de la muestra a recabar.

Aumentar el tamaño de la muestra reduce el **margen de error** (es decir, hace que el intervalo de confianza sea más estrecho) manteniendo el mismo nivel de confianza.

Mantener el mismo tamaño de muestra pero aumentar el **nivel de confianza** hará que el intervalo de confianza se haga más amplio, porque estás buscando mayor seguridad de que el valor real esté

3 B-2) HIPÓTESIS RELATIVA A UNA PROPORCIÓN esto le tomaron a Albornoz

Igual que hipótesis relativa a una varianza y media (Se hace la prueba de hipótesis para un parámetro0 (proporción 0) y el parámetro1 (proporción 1) a verificar si es significativamente igual a p_0 , los parametros pueden ser media, varianza o prop). Se considerarán casos de grandes muestras. Se probará la hipótesis nula $p = p_0$ contra las alternativas $p < p_0$, $p > p_0$ ó $p \neq p_0$ (p_0 es la proporción de la hipótesis nula) mediante la aplicación del siguiente estadístico:

$$z = \frac{x - n \cdot p_0}{\sqrt{n \cdot p_0 \cdot (1 - p_0)}}$$

Ejemplo: En un estudio diseñado para investigar si ciertos detonadores empleados en explosivos en una mina de carbón cumplen con los requerimientos de que al menos el 90% encenderá el explosivo a ser detonado, se encontró que 174 de 200 funcionaron adecuadamente. Probar la hipótesis nula de que $p=0.90$ contra la hipótesis alterna $p<0.90$ con un nivel de significancia de 0.05.


- 1 - Hipótesis Nula $p = 0.90$,
Hipótesis Alternativa $p < 0.90$ (unilateral, cola izquierda),
- 2 - Nivel de significancia: $\alpha = 0.05$.

$$\alpha := 0.05$$

$$z_{0.05} := \text{qnorm}(\alpha, 0, 1) = -1.645$$

- 3 - Criterio

$$t := -3, -2.99 \dots 3$$



- 4 - Cálculos

Conforme a los datos

$$x := 174 \quad \text{número de "éxitos"}$$

$$n := 200 \quad \text{tamaño de la muestra (grande)}$$

$$p_0 := 0.9 \quad \text{proporción de la hipótesis nula}$$

$$z := \frac{x - n \cdot p_0}{\sqrt{n \cdot p_0 \cdot (1 - p_0)}} = -1.414 \quad \text{estadístico para la prueba}$$

HIPÓTESIS RELATIVA A VARIAS PROPORCIONES esto le tomaron a Albornoz

Se prueba si dos o más poblaciones binomiales tienen el mismo parámetro p . Se quiere demostrar si las proporciones entre distintas poblaciones son significativamente iguales o si son significativamente diferentes.

$$p = x/n$$

Se prueba la Hipótesis Nula: (Que todas las proporciones de las poblaciones binomiales sean significativamente iguales)

$$p_1 = p_2 = \dots = p_k = p$$

Contra la Hipótesis Alternativa de que no lo sean. Bastaría con que uno de ellos fuese **significativamente distinto** para que la Hipótesis Nula no se cumpla.

Se necesitan muestras aleatorias de tamaño $n_1, n_2, \dots, n_k$ de las k poblaciones. Luego, si los números correspondientes de éxitos son $x_1, x_2, \dots, x_k$ respectivamente, la prueba que se utiliza se fundamenta en el hecho que:

1. **Método 1:** Para grandes muestras la distribución muestral de:

$z_i = \frac{x_i - n_i \cdot p_i}{\sqrt{n_i \cdot p_i \cdot (1 - p_i)}}$ Z_i es aproximadamente la **distribución normal estándar**. Este estadístico puede formarse en cada una de las poblaciones siendo x_i el número de éxitos de la población i , n_i el tamaño de la muestra extraída de la población i , p_i es la proporción de la población i .

- El **cuadrado** de una variable aleatoria con distribución normal estándar, es otra variable aleatoria con **distribución chi-cuadrado con 1 grado de libertad**.
- La **suma** de k variables aleatorias independientes cuyas distribuciones son chi-cuadrado con 1 grado de libertad, es otra variable aleatoria chi-cuadrado con k grados de libertad.

en consecuencia:

$$\chi^2 = \sum_{i=1}^k \frac{(x_i - n_i \cdot p_i)^2}{n_i \cdot p_i \cdot (1 - p_i)}$$
 es una variable con distribución chi-cuadrado con $v=k$ grados de libertad.


Dado que las p_i son todas iguales por hipótesis nula y $p_n = x_n / n_n$, se pueden sustituir por:

$$\hat{p} = \frac{x_1 + x_2 + \dots + x_k}{n_1 + n_2 + \dots + n_k}$$

Ya que en la hipótesis nula se pretende demostrar que todas las proporciones son iguales entonces puedo hacer una probabilidad única (formulita de arriba) que sería la suma de todos los éxitos dividido la suma de todos los tamaños muestrales. Esto daría una probabilidad estimada (p sombrero)

Entonces la Hipótesis Nula se debe rechazar si las diferencias entre las x_i y las $n_i \cdot \hat{p}$ son grandes (lo cual nos conduce a una prueba de hipótesis unilateral de cola derecha. Si esas diferencias son chicas entonces el **chi cuadrado va a ser chico**, por lo tanto el chi cuadrado se corre a la izquierda y vamos a estar en zona de aceptación. A medida que el chi cuadrado sea más chico voy a estar en zona de aceptación)

La región crítica es $\chi^2 > \chi^2_\alpha$ y el número de



grados de libertad es $k-1$. La pérdida de un grado de libertad surge de reemplazar a p por su estimación $\hat{p}$. Entonces vuelvo a calcular el chi cuadrado pero ahora en vez de p uso $\hat{p}$ (que es p sombrero) y un grado de libertad $k-1$

$$\chi^2 = \sum_{i=1}^k \frac{(x_i - n_i \cdot p_{est})^2}{n_i \cdot p_{est} \cdot (1 - p_{est})}$$

Estadístico de prueba χ^2 relativo a diferencia entre proporciones

2. Método 2: Surge con el fin de simplificar el cálculo de χ^2 con el método 1, entonces se disponen los datos en forma tabular:

Para calcular χ^2 conviene disponer los datos de la siguiente manera:

	Muestra 1	Muestra 2	...	Muestra k	Total
éxitos	x_1	x_2	...	x_k	x
fallas	$n_1 - x_1$	$n_2 - x_2$	...	$n_k - x_k$	$n - x$
Total	n_1	n_2	...	n_k	n

El elemento correspondiente al renglón i y a la columna j se denomina frecuencia observada en la celda $o_{i,j}$ con $i = 1, 2$ y $j = 1, 2, \dots, k$.

Como antes, $\hat{p} = x/n$. Luego, el número esperado de éxitos $e_{1,j}$ y fracasos $e_{2,j}$ para la j -ésima muestra se estima con:

$$e_{1j} = n_j \cdot \hat{p} = \frac{n_j \cdot x}{n}$$

(Éxitos) n_j = tamaño de cada muestra (n_1, n_2 , etc) es por columna,
 x = total de todos los éxitos de todas las muestras
 n = tamaño total de todas las muestras (suma de n_j).

$$e_{2j} = n_j \cdot (1 - \hat{p}) = \frac{n_j \cdot (n - x)}{n} \quad (\text{Fracasos})$$

$e_{1,j}$ y $e_{2,j}$ se denominan frecuencias esperadas en celdas para $j = 1, 2, \dots, k$.

Cada celda es una frecuencia observada, luego se calculan las frecuencias esperadas. Multiplicando el total de la fila por el total de la columna dividido el gran total

En esta notación el estadístico χ^2 (con $p_i = \hat{p}$)

$$\chi^2 = \sum_{i=1}^2 \sum_{j=1}^k \frac{(o_{i,j} - e_{i,j})^2}{e_{i,j}}$$

con $v = k-1$ grados de libertad

Calcular el estadístico chi cuadrado con lo que vimos recién de valores observados y esperados es lo mismo que aplicar la fórmula del chi cuadrado que se vió más arriba.

En el caso particular de comparar únicamente dos poblaciones entre sí ($k=2$), se pueden plantear hipótesis alternativas específicas respecto a las dos proporciones (por ejemplo, $p_1 > p_2$, o viceversa). De cualquier

forma, en esta situación se demuestra que el estadístico 2 puede simplificarse a:

$$z = \frac{\frac{x_1}{n_1} - \frac{x_2}{n_2}}{\sqrt{\hat{p} \cdot (1 - \hat{p}) \cdot \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} \quad \text{donde} \quad p = \frac{x_1 + x_2}{n_1 + n_2} \quad \underline{\text{Z con dist normal estándar.}}$$

3 B-3) TABLAS R X C (TABLAS DE CONTINGENCIA) esto le tomaron a Albornoz

La diferencia con el método anterior (ambos métodos: el de las matrices y el de la formulita) es que ahora puedo tener más resultados dentro de la muestra. Antes solo tenía dos resultados (en el ej de recién serían desmoronado/fracaso o intacto/éxito). El cuadro que teníamos antes se agranda en cantidad de filas, donde r son filas (rows) y c columnas (columns). Por ejemplo, ahora podría encuestar a 100 personas de Mendoza, Bs As y Córdoba sobre qué equipos son que pueden ser Boca, River o San Lorenzo y podría probar la hipótesis de que si esas proporciones se mantienen en todas las provincias.

Estas tablas organizan los datos de acuerdo con dos criterios de clasificación: las filas representan un criterio y las columnas otro. A diferencia de las tablas simples, permiten más de dos categorías en cada criterio.

Hago lo mismo que con el método anterior. Obtengo las frecuencias observadas en la celdas ($o_{i,j}$) y después calculo las frecuencias esperadas en cada celda ($e_{i,j}$). Sólo es necesario calcular $(r-1) \cdot (c-1)$ de las $e_{i,j}$, las restantes se pueden deducir a partir de los totales de filas y columnas.

	A	B	C	Xi	
Funciona	40	23	12	75	
Roto	32	20	30	82	
Reaco	11	27	40	78	
Nj	83	70	82	235	Suma de X o de Nj
	$e_{11} = 83.75/235 = 26.4$	e_{21}	e_{31}	Fórmula (Siempre es esta) $N_j \cdot X_i / \text{Suma de } N_j$	
	$e_{12} = 83.82/235 = 28.9$	$e_{22} =$	e_{32}		
	$e_{13} = 83 - e_{11} - e_{12} = 27.7$	e_{23}	$e_{33} = 82.78/235$		

Luego, el estadístico para el análisis de la tabla $r \times c$ es:

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(o_{i,j} - e_{i,j})^2}{e_{i,j}} \quad v = (r-1) \cdot (c-1) \text{ grados de libertad.}$$

Los grados de libertad: Los grados de libertad en una tabla de contingencia indican cuántas celdas de la tabla pueden variar libremente una vez que se conocen los totales de las filas y columnas. Este número es crucial porque afecta la forma de la distribución χ^2 y, por lo tanto, los valores críticos que se utilizan para determinar si el resultado de la prueba es estadísticamente significativo.

Aprovechamiento en el programa de entrenamiento

		Debajo del Promedio	Promedio	Sobre el Promedio	Total
Éxito en el puesto (Clasificación en el empleo)	Deficiente	23	60	29	112
	Promedio	28	79	60	167
	Muy buena	9	49	63	121
	Total	60	188	152	400

$$O = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 23 & 60 & 29 \\ 0 & 28 & 79 & 60 \\ 0 & 9 & 49 & 63 \end{pmatrix}$$

Observados:

$$e = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 16.8 & 52.64 & 42.56 \\ 0 & 25.05 & 78.49 & 63.46 \\ 0 & 18.15 & 56.87 & 45.98 \end{pmatrix}$$

Esperados:

Se rechaza la Hipótesis Nula si el valor de χ^2 excede a χ^2_{α}

¿Cuándo las muestras son independientes?

Cuando los grupos que comparas **no están relacionados**. Por ejemplo:

- ✓ Encuestas diferentes cada año con personas distintas.
- ✓ Comparación de preferencias en diferentes ciudades.
- ✓ Distribución de ventas en distintas sucursales de una empresa.

¿Cuándo las muestras NO son independientes?

Cuando las mismas personas u objetos se miden más de una vez. Por ejemplo:

- ✗ Medir la misma persona antes y después de un tratamiento.
- ✗ Encuestar a los mismos clientes cada año.
- ✗ Evaluar los mismos estudiantes antes y después de un curso.

En este método como en el anterior las muestras tienen que ser independientes obligatoriamente.

3 B-4) BONDAD DE AJUSTE

Si desconozco qué distribución tienen ciertos datos, hago una prueba de Bondad de Ajuste para verificar si

los datos siguen una distribución estimada.

La prueba trata de comparar una distribución de frecuencias observadas de un conjunto de datos con una distribución esperada o teórica (como la normal, Poisson, chi-cuadrado, etc.)

Hipótesis nula: Los datos siguen la distribución teórica que se está probando (por ejemplo, normal, Poisson, etc.). **Hipótesis Alternativa:** No siguen esa distribución.

Ej: Le llegan mensajes a una empresa, y se quieren ver cuántos mensajes le llegan en un intervalo de 5 min.
 H_0 = Que los datos sigan una distribución de Poisson. H_1 = No sigue esa distribución.

Como ejemplo se analizan 400 intervalos de 5 minutos en el control de tráfico aéreo en cuanto a la recepción de mensajes de radio, comparándola con una distribución de Poisson con $\lambda=4.6$.

En los primeros 3 intervalos ningún auto, en los próximos 15 intervalos que paso 1 solo, en los próximos 47 intervalos que pasaron 2, etc....

Sumo la columna de frecuencias observadas y me da 400. Hay que demostrar en este ejercicio que si los datos siguen una distribución de Poisson con λ de 4.6

Si multiplico la columna de nro de mensajes en intervalos de 5min por la de frecuencia observadas y lo divido por n. Me da un valor aproximado de 4.6 (Como la media ponderada) $\rightarrow$ Tasa de ocurrencia
 $(0 \times 3 + 1 \times 15 + 2 \times 47 + \dots + 13 \times 1) / 400 = 4.6$ (aproximado). En 3, 4 y 5 esta la mayor cantidad de frecuencias observadas.

Número de mensajes en interv. de 5 min.	Frecuencias observadas	Probabilidad de Poisson	Frecuencias esperadas
0	3	0.010	4.0
1	15	0.046	18.4
2	47	0.107	42.8
3	76	0.163	65.2
4	68	0.187	74.8
5	74	0.173	69.2
6	46	0.132	52.8
7	39	0.087	34.8
8	15	0.050	20.0
9	9	0.025	10.0
10	5	0.012	4.8
11	2	0.005	2.0
12	2	0.002	0.8
13	1	0.001	0.4

1. Se dividen los datos en **filas** (por ejemplo, intervalos en el caso de una distribución continua).

2. Se anotan las frecuencias observadas de cada categoría.

3. Se calcula la probabilidad de cada fila (para cada distribución es distinto).

4. Se calculan las frecuencias esperadas (probabilidad de cada fila por el tamaño total de la muestra).

5. Nos fijamos si algún valor dan menos que 5 en las frecuencias esperadas. Si es así lo juntamos con el valor que tiene abajo/arriba y hacemos lo mismo con las observadas.

Cantidad total de la muestra: n = suma de cantidad de filas

Se usa el estadístico para ver si las diferencias entre lo que observamos y lo que esperamos son solo por casualidad:

$$\chi^2 = \sum_{i=1}^k \frac{(o_i - e_i)^2}{e_i}$$

Con $k - m - 1$ grados de libertad. Siendo k el número de términos de la fórmula (cantidad de categorías, cantidad de filas agrupadas) y m el número de parámetros en la distribución supuesta (en el caso de Poisson, tiene solo parámetro λ

entonces sería $m = 1$, por ejemplo que hubiésemos tenido una distribución normal entonces $m=2$ ya que tiene dos parámetros: media y desviación estándar).

Dibujamos la abscisa según el nivel de significancia, y con el estadístico me fijo si se acepta o rechaza.

Si las diferencias entre las **observadas** y las **esperadas** son chicas, el valor del estadístico será chico, lo cual da un indicio de si se acepta la hipótesis nula. En caso contrario se rechaza.

Vamos a tomar un ejemplo para una Distribución Normal.

Problema II: La siguiente tabla indica la cifra promedio de accidentes por mil horas-hombre de la muestra de 50 firmas, obtenidas de una industria específica. Probar la hipótesis nula de que las frecuencias observadas en esta muestra siguen una distribución normal, utilizando un nivel de significancia de 0.05.

Cifra promedio de accidentes por mil horas-hombre	Número de firmas
1.5 – 1.7	3
1.8 – 2.0	12
2.1 – 2.3	14
2.4 – 2.6	9
2.7 – 2.9	7
3.0 – 3.2	5
Total	50

Después de haber agrupado queda $k = 4$, $m = 2$ por (media y desviación estándar).

1 - Hipótesis Nula: variable aleatoria que tiene distribución Normal.
Hipótesis Alternativa: No la tiene.

2 - Nivel de significancia: $\alpha = 0.05$.

$$k := 4 \quad m := 2 \quad \nu := k - m - 1 = 1$$

$$\alpha := 0.05 \quad \chi_{0.05} := \text{qchisq}(0.95, \nu) = 3.841$$

3 - Criterio: Se rechaza la Hipótesis Nula si $\chi^2 > 3.841$

Calculamos la Media y Desviación estándar.

$$TF := \sum NF \quad \text{total de firmas}$$

$$MP := \frac{\sum_{k=0}^5 (PM_k \cdot NF_k)}{TF} = 2.32 \quad \text{Media ponderada}$$

$$s := \sqrt{\frac{\sum_{k=0}^5 [(PM_k)^2 \cdot (NF_k)] - MP^2 \cdot TF}{TF}} = 0.42 \quad \text{desviación estándar}$$

El área va de menos a más ya que son adyacentes a los intervalos.

$$\int_{1.45}^{1.75} \text{dnorm}(t, MP, s) dt = 0.068$$

Cifra promedio de accidentes por mil horas-hombre (fronteras de clase)	fronteras de clase (en unidades normales estándar)	Probabilidad de estar en cada categoría	Frecuencia esperada =50.p
1.45 – 1.75	-2.07 a -1.35	0.07	3.5
1.75 – 2.05	-1.36 a -0.64	0.17	8.5
2.05 – 2.35	-0.64 a 0.07	0.27	13.5
2.35 – 2.65	0.07 a 0.78	0.26	13.0
2.65 – 2.95	0.78 a 1.50	0.15	7.5
2.95 – 3.25	1.50 a 2.21	0.05	2.5

En base a esto sacamos lo siguiente:

Cifra promedio de accidentes por mil horas-hombre	Frecuencias observadas, f_o	Frecuencias esperadas, f_e	$(f_o - f_e)^2 / f_e$
1.5 – 1.7	3 15	3.5 12	0.75
1.8 – 2.0	12 15	8.5 12	
2.1 – 2.3	14	13.5	0.02
2.4 – 2.6	9	13.0	1.23 ¹⁷
2.7 – 2.9	7 12	7.5 10	0.40
3.0 – 3.2	5 12	2.5 10	
		$\chi^2 =$	2.40

Y por último calculamos CHI CUADRADO:

Y ahora se calcula el estadístico χ^2 :

$$\chi^2 = \frac{(15 - 12)^2}{12} + \frac{(14 - 13.5)^2}{13.5} + \frac{(9 - 13)^2}{13} + \frac{(12 - 10)^2}{10} = 2.40$$

2.40 es menor que el chi cuadrado de 3.841 entonces se acepta hipótesis nula, es igual a una dist. normal con un nivel de confianza de 95%

UNIDAD IV: PRUEBAS NO PARAMÉTRICAS

La mayoría de los procedimientos de prueba de hipótesis analizados anteriormente se fundamentan en la suposición de que las muestras aleatorias se seleccionan de poblaciones normales. Incluso aunque existan ligeras desviaciones respecto a la normalidad, gran parte de estas pruebas seguirá siendo confiable, más aún para tamaños de muestra relativamente grandes. A estos procedimientos se los suele denominar

métodos paramétricos. (Ya que siempre terminamos **suponiendo** que los datos vienen de poblaciones normales, donde tenemos leves desviaciones (En casos donde asumimos normalidad pero no la alcanza), y si no se cumplen ciertas condiciones de los métodos, dan resultados incorrectos)

Cuando no se posee conocimiento alguno respecto a las distribuciones de las poblaciones anteriores, no se pueden usar los métodos paramétricos. Por esto, se han desarrollado procedimientos de prueba alternativos, llamados métodos no paramétricos o de distribución libre, que permiten realizar inferencias exactas sobre los parámetros poblacionales a pesar de que las suposiciones fundamentales de los métodos estándar no puedan cumplirse en su totalidad.

Al margen de su flexibilidad, las pruebas no paramétricas tienen asociadas ciertas desventajas:

1. **Demanda una cantidad elevada de información para su aplicación**, lo que en muchos escenarios resulta no ser óptimo.
2. **No se hace uso de toda la información proporcionada por la muestra**, por lo que, **en casos donde pueden aplicarse métodos paramétricos y no paramétricos, los no paramétricos resultarán ser menos eficientes que el procedimiento paramétrico correspondiente.**

Como consecuencia, para lograr la misma potencia que la prueba paramétrica, una prueba no paramétrica requerirá siempre un tamaño muestral mayor.

Son también conocidas como pruebas de distribución libre. Sirven para cuando no conocemos la distribución de la población, lo que significa que no conocemos sus parámetros ni los podemos estimar.

En lugar de hacer suposiciones sobre esa distribución, utilizamos métodos que se basan en el orden o la clasificación de los datos.

Por ejemplo, en lugar de calcular promedios y desviaciones estándar, se pueden utilizar pruebas de rangos, medianas o pruebas de signos para analizar los datos.

Ejemplos de poblaciones con distribución desconocida o no normal:

- ① **Salarios en una empresa** → Suelen ser asimétricos, con muchos empleados ganando poco y pocos con salarios muy altos (**distribución sesgada a la derecha**).
- ② **Tiempo de espera en un hospital** → Puede seguir una **distribución exponencial**, donde la mayoría espera poco tiempo, pero algunos casos tardan mucho más.
- ③ **Puntuaciones de satisfacción en encuestas (1-5 estrellas)** → No necesariamente siguen una curva normal, ya que los datos pueden estar agrupados en los extremos (mucha gente vota 1 o 5, pero pocos votan 3).
- ④ **Ventas diarias de una tienda** → Pueden ser muy variables según el día, mostrando una **distribución multimodal** (varios picos en los datos).

¿Cuándo usar pruebas no paramétricas?

- ✓ **Cuando la distribución de los datos es desconocida o no normal.**
- ✓ **Cuando la muestra es pequeña y no se puede verificar la normalidad.**
- ✓ **Cuando los datos son ordinales** (ej., encuestas de satisfacción).
- ✓ **Cuando hay valores atípicos** que afectarían pruebas paramétricas.

TEMA A: TESTS

4 A-1) PRUEBA DEL SIGNO (hipótesis relativa a varias medias, comparo que 1 media poblacional (Es decir la media de 1 muestra) sea significativamente igual a una media esperada $\mu = \mu_0$)

Es una alternativa no paramétrica de la prueba t unimuestral, de la prueba t para muestras apareadas y las correspondientes pruebas para muestras de gran tamaño ([link a esa parte](#)). (Esa parte es de hipótesis relativa a dos medias) (Casos de 1 muestra)

Se aplica cuando muestreo una población simétrica (misma probabilidad ser mayor o menor a la media)

La hipótesis nula $H_0: \mu = \mu_0$ ejemplo: $\mu_0 = 98$ (Octanaje con media 98) y la alternativa $\mu > \mu_0$

Donde cada valor muestral se compara con μ_0 , si es mayor se coloca un signo +, si es menor un signo -, y si es igual no se pone nada. Quedando una cadena de signos: (x es la cantidad de signos positivos). Se considera siempre una probabilidad $p = 0.5$ para realizar una distribución binomial. Cadena ej: +++-+-

Se establece un nivel de significancia: Ej: 0.01 y luego el criterio

Criterio: La hipótesis nula se rechaza si la probabilidad de obtener x o mas es menor o igual a 0.01 (nivel de significancia)

99.0	102.3	99.8	100.5	99.7	96.2	99.1	102.5
103.3	97.4	100.4	98.9	98.3	98.0	101.6	

2. Nivel de significancia: $\alpha = 0.01$.

3. Criterio: Se denota con x a los signos positivos. Se rechaza la hipótesis nula si la probabilidad de obtener x o más signos es menor o igual que 0.01.

4. Cálculos: de las comparaciones de 98 con los valores muestrales, surge:

++++-++++-++++ x=12 n=14 (ya que uno de los valores es 98)

La probabilidad que esto suceda en una distribución binomial está dada por:

$$\sum_{k=12}^{14} \text{dbinom}(k, 14, 0.5) = 6.47 \times 10^{-3}$$

$P(x \geq 12)$

0.00647

La probabilidad se calcula con la sumatoria de **dbinom(x, n, 0.5)** que va de x a n (el profe en el ej pone $k = x$): esto **permite calcular la probabilidad de que el número de éxitos (x) esté dentro de un rango específico (Entre 12 y 14)**.

Para casos de **muestras apareadas**: La única diferencia es que la condición de la **hipótesis alternativa** es respecto a la suma o resta de las muestras apareadas. En este ejemplo, se coloca + si el primer valor menos el segundo valor es mayor a cero. (Osea si el primer valor es mayor al segundo, sino da menor a 0). Caso contrario se pone un -

45 y 36 73 y 60 46 y 44 124 y 119 33 y 35
57 y 51 83 y 77 34 y 29 26 y 24 17 y 11

1. Hipótesis Nula: $\mu_1 - \mu_2 = 0$ ($p=1/2$).

Hipótesis Alternativa: $\mu_1 - \mu_2 > 0$ ($p>1/2$).

2. Nivel de significancia: $\alpha = 0.05$.

3. Criterio: Se denota con x a los signos positivos.

Se rechaza la hipótesis nula si la probabilidad de obtener x o más signos es menor o igual que 0.05.

4. Cálculos: reemplazando cada par de valores por un signo + o - según el primero sea mayor que el segundo y viceversa.

++++-+++++

$x := 9$ $n := 10$

La probabilidad que esto suceda en una distribución binomial está dada por:

$$\sum_{k=9}^{10} \text{dbinom}(k, n, 0.5) = 0.011 \quad P(x \geq 9)$$

5- Decisión: dado que $0.011 < 0.05$ Se Rechaza la Hipótesis Nula. Luego, el programa de seguridad es eficaz.

se compara la sumatoria de dbinom con el nivel de significancia

El 1/2 (o 0.5) en la prueba de signo significa que, bajo la hipótesis nula (H_0), cada valor tiene la **misma probabilidad (50%) de ser mayor o menor** que la mediana de referencia μ_0 . Es como lanzar una moneda: hay igual chance de obtener "+" o "-".

Por eso, el número total de signos positivos sigue una **distribución binomial** con $p=0.5$, y se usa esa probabilidad para calcular si los resultados son significativos o no. 🚀

¿Qué significa que la población sea simétrica?

Para aplicar la prueba de signo, la **población de la que se toma la muestra debe ser simétrica**. Esto significa que los valores tienen la **misma probabilidad de estar por encima o por debajo de la media**.

♦ Ejemplo de población simétrica:

- Una distribución **uniforme** en el intervalo $[40, 60]$.
- Una distribución **normal** (aunque si es normal, es mejor usar pruebas paramétricas como la t de Student).

♦ Ejemplo de población NO simétrica:

- **Distribución sesgada a la derecha** (Ej. ingresos salariales, donde hay pocos valores muy altos).
- **Distribución sesgada a la izquierda** (Ej. tiempos de vida de focos, donde la mayoría dura bastante y pocos se queman rápido).

Si la población **no es simétrica**, la prueba de signo **puede dar resultados incorrectos**, y en su lugar es mejor usar la **prueba de Wilcoxon**.

Resumen rápido

- ♦ La prueba de signo cuenta cuántos valores están por encima o por debajo de μ_0 .
- ♦ Asume que cada valor tiene **50% de probabilidad** de estar arriba o abajo.
- ♦ Se basa en la **distribución binomial con $p=0.5$** .
- ♦ Funciona bien **si la población es simétrica**.

4 A-2) PRUEBAS DE SUMA DE RANGOS esto le tomaron a Sarmiento

Existen dos pruebas: la **U** y la **H**.

La **U** es una alternativa no paramétrica de la prueba **t bimuestral** (link) (2 muestras)

PRUEBA U o de Wilcoxon (hipótesis relativa a varias medias, comparo que 2 medias poblacionales sean significativamente iguales $\mu_1 = \mu_2$)

Se quiere ver si las medias de dos muestras son significativamente iguales. Se busca probar si las muestras vienen de poblaciones idénticas (H_0). Entonces:

Para ello se consideran los datos de ambas muestras y se consideran como si fueran una sola muestra y se los ordena de forma creciente. Luego, a cada valor se le indica con un número romano a que muestra pertenecen. Si el primer valor es de la muestra 1 se le coloca I, si el n-ésimo valor es de la muestra 2 se le coloca II y así con cada uno. También a cada valor se le asigna un rango (suponiendo que tenemos 2 muestras, una muestra tenía 14 elementos y la otra 15, tendremos 29 rangos) entonces al primer valor se le coloca rango 1, al segundo rango 2, y así con cada una.

0.12	0.17	0.18	0.2	0.26	0.32	0.35	0.39	0.4	0.43	0.45	0.47	0.48
I	I	I	I	II	I	I	II	I	I	I	I	II
0.49	0.51	0.53	0.54	0.58	0.63	0.84	0.88	0.89	0.92	0.96	1.01	1.07
I	I	II	II	II	I	I	II	II	II	II	II	II
1.11	1.13	1.36										
II	II	I										

La Muestra1 tiene los valores con rangos R1: 1, 2, 3, 4, 6, 7, 9, 10, 11, 12, 14, 15, 19, 20, 29.

La Muestra2 tiene los valores con rangos R2: 5, 8, 13, 16, 17, 18, 21, 22, 23, 24, 25, 26, 27, 28.

Si hay valores repetidos en las muestras, en lugar de darles un rango individual, se les asigna el promedio de los rangos que les corresponderían.

Por ejemplo:

- Si dos valores iguales ocupan las posiciones 3 y 4 (rango), en lugar de asignarles 3 y 4, ambos reciben $(3+4)/2 = 3.5$.
- Si tres valores iguales ocupan las posiciones 9, 10 y 11, cada uno recibe $(9+10+11)/3 = 10$.

En resumen, cuando hay repeticiones, se asigna el rango promedio de esas posiciones.

Luego, se comparan las sumas de los rangos de las muestras, para que la diferencia en la cantidad de datos de cada muestra no afecte el resultado.

Entonces la suma de rangos son para la muestra 1: $R_1=162$ y para la muestra 2: $R_2=273$ y queda por ver si la diferencia es demasiado grande como para rechazar la Hipótesis Nula.

Se definen dos estadísticos:

$$U1 = n1 \cdot n2 + \frac{n1 \cdot (n1 + 1)}{2} - R1$$

$$U2 = n1 \cdot n2 + \frac{n2 \cdot (n2 + 1)}{2} - R2$$

$$Ui = n1 \cdot n2 + \frac{ni \cdot (ni + 1)}{2} - Ri$$

n_i = TAMAÑO DE LA MUESTRA. R es la sumatoria de la muestra

De ellos se elige el estadístico U, que es el correspondiente al rango más pequeño, de los dos.

Puede comprobarse que la media y la varianza de la distribución muestral (de $U1$, en este caso) son:

$$\mu_{U1} = \frac{n1 \cdot n2}{2}$$

$$\sigma_{U1} = \sqrt{\frac{n1 \cdot n2 \cdot (n1 + n2 + 1)}{12}}$$

Si ambos tamaños de muestra ($n1$ y $n2$) son mayores a 8 ($n1$ y $n2 > 8$) el estadístico $U1$ sigue una distribución normal. Esto permite usarlo para comprobar si las dos muestras vienen de poblaciones iguales o si hay diferencias entre ellas:

$$Z = \frac{U1 - \mu_{U1}}{\sigma_{U1}} \quad Z = \frac{Ui - \mu_{Ui}}{\sigma_{Ui}}$$

Donde μ_{U1} es la media de $U1$ y σ_{U1} es la desviación estándar de $U1$. En caso de muestras pequeñas, se aplica la prueba basándose en tablas especiales.

Acá generalmente va a ser una prueba de dos colas donde:

Hipótesis Nula: las poblaciones son idénticas ($\mu_1 = \mu_2$)

Hipótesis Alternativa: $\mu_1 > \mu_2$ (dos colas)

Luego hay que ver si el estadístico calculado cae en la zona de aceptación o rechazo que está marcada por las abscisas calculadas y se concluye si hay o no diferencia significativa entre ambas medias.

Para muestras grandes ($n1$ y $n2$ mayores que 10) es una dist normal, para pequeñas se usan tablas específicas de la dist de U

PRUEBA H (O DE KRUSKAL-WALLIS) (Comparo que k medias poblacionales (de k muestras) sean significativamente iguales $u1=u2=uk$)

Es una generalización de la Prueba U que permite probar la Hipótesis Nula de que k muestras aleatorias independientes provienen de poblaciones idénticas. Con la prueba del signo es con una muestra (t unimuestral), con la prueba U solo podía tener dos muestras (como t bimuestral), ahora (con la prueba K) puedo tener k muestras

Pasos de resolución:

1. Combinamos todos los datos de diferentes muestras, los ordenamos y les asignamos rangos.
2. Sumamos los rangos para cada muestra por separado ($R1, R2 \dots Rn$)
3. Aplico la formula H

Se utiliza el estadístico H , que tiene una distribución chi cuadrado con $k-1$ grados de libertad siendo k el número de poblaciones que estoy comparando. Si todos los tamaños de las muestras son mayores a 5 ($n_i > 5$)

$$H = \frac{12}{n \cdot (n+1)} \cdot \sum_{i=1}^k \frac{(R_i)^2}{n_i} - 3 \cdot (n+1)$$

n es la sumatoria de todos los tamaños muestrales
 k es el número de muestras o tratamientos
 R_i es el rango de la i -ésima muestra
 n_i es el tamaño de la i -ésima muestra

$$n = n_1 + n_2 + \dots + n_k$$

cuando $n_i > 5$ para toda i y cuando H_0 es verdadera, la distribución muestral de H es aproximada con la distribución chi-cuadrada con $k-1$ grados de libertad.

UTILIZAMOS UN CHI CUADRADO COMO ESTADÍSTICO PORQUE LAS GRANDES DIFERENCIAS TIRAN PARA LA DERECHA ENTONCES ES UNA PRUEBA DE COLA DERECHA. Por lo tanto si una muestra está muy alejada de otra muestra. Se irá hacia la zona de rechazo de chi cuadrado

Problema: Un experimento para comparar tres métodos preventivos contra la corrosión produjo las siguientes profundidades máximas de las cavidades (en milésimo de pulgada) en piezas de alambre que fueron sometidas a los tratamientos respectivos:

Método A: 77, 54, 67, 74, 71, 66

Método B: 60, 41, 59, 65, 62, 64, 52

Método C: 49, 52, 69, 47, 56

Con un nivel de significación de 0.05, probar la Hipótesis Nula que las tres muestras provienen de poblaciones idénticas.

1. Hipótesis Nula: las poblaciones son idénticas ($\mu_1 = \mu_2 = \mu_3$)

Hipótesis Alternativa: las poblaciones son distintas.

2. Nivel de significancia: 0.05


$$\alpha := 0.05$$

$$k := 3$$

$$\chi_{0.05} := qchisq(1 - \alpha, k - 1) = 5.991$$

3. Criterio: se rechaza H_0 si $\chi > \chi_{0.05}$

$t := 0, 0.01 \dots 10$



4. Cálculos:

$n_1 := 6$ $n_2 := 7$ $n_3 := 5$

Se ordenan los datos como si fueran una sola muestra, preservando el origen

41 47 49 52 52 54 56 59 60 62 64 65 66 67 69 71 74 77
B C C B C A C B B B B A A C A A A

Los rangos son:

Método A: 6, 13, 14, 16, 17, 18

R1= 84

Método B: 1, 4.5, 8, 9, 10, 11, 12

R2= 55.5

Método C: 2, 3, 4.5, 7, 15

R3= 31.5

$R_1 := 84$


$R_2 := 55.5$

$R_3 := 31.5$

$nn := n_1 + n_2 + n_3$

$$H := \frac{12}{nn \cdot (nn + 1)} \cdot \sum_{i=1}^k \frac{(R_i)^2}{n_i} - 3 \cdot (nn + 1) = 6.666$$

Y verifico entonces el estadístico donde cae



4 A-3) PRUEBAS DE ALEATORIEDAD

Es necesario saber que seguridad hay de que **una muestra** sea aleatoria. Por ejemplo en el caso que este diseñando pruebas de ruleta de juegos quisiera que los resultados no tuviesen una tendencia pq si alguien la capta empezaría a perder plata. Esta prueba es siempre a 2 colas (Ver el resumen del final de la unidad)

Prueba de corridas

Se basa en el orden en que fueron obtenidos los datos, con más precisión, se fundamenta en el número de **corridas** exhibidas en los resultados muestrales. Dada una sucesión de dos símbolos (por ejemplo, cara y cruz de una moneda) una corrida es la sucesión de símbolos idénticos contenidos entre símbolos diferentes. Por ejemplo:

A A B B A A B B B A B B B A A A A B B B
 1 2 3 4 5 6 7 8

En el esquema se aprecian un total de 8 corridas.

Las corridas me van a determinar si hay falta de aleatoriedad. Muchas corridas indican falta de aleatoriedad (ABABABAB) y pocas corridas también indican falta de aleatoriedad (AAAAABBBBB). Entonces la aleatoriedad se mide a partir del parametro corridas.

Notar que en este ejemplo aunque la tendencia sea aproximadamente $\frac{1}{2}$ ya que A es $\frac{9}{20}$ y B $\frac{11}{20}$ se puede notar cierto patrón, se puede observar una falta de aleatoriedad. Es como si hubiese una mano mágica.

Esto puede servir para determinar el grado de aleatoriedad. La sospecha de falta de aleatoriedad está en el orden de aparición.

Si una sucesión contiene n_1 símbolos del primer tipo y n_2 del segundo tipo (Siendo n_1 y $n_2 > 10$) entonces la distribución muestral del número de corridas u , puede aproximarse mediante una distribución muestral con:

$$\mu_u = \frac{2 \cdot n_1 \cdot n_2}{n_1 + n_2} + 1 \quad \sigma_u = \sqrt{\frac{2 \cdot n_1 \cdot n_2 \cdot (2 \cdot n_1 \cdot n_2 - n_1 - n_2)}{(n_1 + n_2)^2 \cdot (n_1 + n_2 - 1)}}$$

La prueba de Hipótesis Nula de que el arreglo de los símbolos es aleatoria , puede fundamentarse en el

estadístico:

$$Z = \frac{u - \mu_u}{\sigma_u} \text{ que tiene aproximadamente la distribución normal.}$$

Acá vamos a tener que:

Hipótesis Nula: El arreglo es aleatorio

Hipótesis Alternativa: No lo es (cola izquierda).

Por último verifico en qué zona cayó la probabilidad para tomar una decisión.

También se puede utilizar la **prueba de secuencias** para probar la aleatoriedad de muestras que constan de **datos numéricos contando secuencias por encima y por debajo de la mediana**. Si la mediana es por ej 0.25, entonces a cada valor de las muestras le asignó una “a” si es mayor a la media, y “b” si no lo es. Luego calculo la cantidad de corridas u , calculo:

$$\mu_u = \frac{2 \cdot n_1 \cdot n_2}{n_1 + n_2} + 1 \quad \sigma_u = \sqrt{\frac{2 \cdot n_1 \cdot n_2 \cdot (2 \cdot n_1 \cdot n_2 - n_1 - n_2)}{(n_1 + n_2)^2 \cdot (n_1 + n_2 - 1)}}$$

Y luego calculo el estadístico Z de arriba.

Por último verifico en qué zona cayó la probabilidad para tomar una decisión.

Una aplicación muy común de esta prueba es el Control de Calidad para evaluar la uniformidad y aleatoriedad de ciertos procesos.

El procedimiento típico involucra los siguientes pasos:

1) **Si la muestra es booleana (éxito o fracaso):**

a) Armo la cadena de letras y corridas (eeefffeefeefeffe)

2) **Si la muestra es numérica:**

a) **Calcular la mediana:** Se determina la mediana de los datos.

b) **Asignar a y b:** Se etiquetan las observaciones como "a" si están por encima de la mediana y como "b" si están por debajo.

3) **Contar corridas (Rachas):** Se cuentan la cantidad de secuencias consecutivas de "a" y "b", de "c" y "s", o de lo que tengamos.

4) **Aplicar la prueba:** Se calculan los parámetros para utilizar (media de corridas y desv estándar de corridas), luego aplico el estadístico Z

5) **Verificar Resultado:** Se analiza dónde quedó el Z con respecto a los valores críticos (Siempre es bilateral) para verificar si se cumple la hipótesis nula de aleatoriedad.

Es bilateral ya que hay aleatoriedad por el lado derecho cuando el número de corridas u es grande, es decir cuando se va alternando muy rápidamente. Hay aleatoriedad por el lado izquierdo cuando u es chico. En este problema es u es chico.

Prueba de dos colas: Se usa cuando solo quieres verificar si hay aleatoriedad o no, sin importar en qué dirección.

Prueba de una cola:

- **Cola izquierda:** Si los datos están demasiado **agrupados** (pocas alternancias, **u pequeño**).
- **Cola derecha:** Si los datos están demasiado **dispersos** (muchas alternancias, **u grande**).

Problema: El siguiente arreglo se refiere al número de piezas defectuosas d y no defectuosas n en el orden dado producidas por cierta máquina:

n n n n n d d d d d n n n n n n n n n n n d d n n d d d d


probar la aleatoriedad con un nivel de confianza de 0.01.

1. Hipótesis Nula: El arreglo es aleatorio
Hipótesis Alternativa: No hay aleatoriedad (cola izquierda)
2. Nivel de significancia: $\alpha = 0.01$.

Criterio: Se rechaza la hipótesis nula si $z < z_{0.01}$.

$\alpha := 0.01$ Nivel de significancia

$z_{01} := \text{qnorm}(\alpha, 0, 1) = -2.326$ $t := -3, -2.99 .. 3$




4. Cálculos:

$$u := 6 \quad \underline{n1} := 10 \quad \underline{n2} := 17$$

$$\mu_u := \frac{2 \cdot n1 \cdot n2}{n1 + n2} + 1 = 13.593$$

$$\sigma_u := \sqrt{\frac{2 \cdot n1 \cdot n2 \cdot (2 \cdot n1 \cdot n2 - n1 - n2)}{(n1 + n2)^2 \cdot (n1 + n2 - 1)}} = 2.37$$

$$\left(\underline{z} := \frac{u - \mu_u}{\sigma_u} = -3.204 \right) \quad \text{Estadístico}$$



5- Decisión: dado que $-3.204 (z) < -2.326 (z_{01})$ Se Rechaza la Hipótesis Nula. Luego, el arreglo no es aleatorio. En realidad **el número total de corridas es mucho menor que el esperado** y existe una fuerte tendencia a que las partes defectuosas aparezcan aglomeradas, la razón de esto seguramente la descubrirá un ingeniero familiarizado con el proceso.

PRUEBAS DE KOLMOGOROV-SMIRNOV

Se utilizan para diferencias entre distribuciones acumuladas. La prueba unimuestral es una prueba de Bondad de Ajuste (técnica estadística utilizada para evaluar si una muestra de datos proviene de una población con una distribución de probabilidad específica). Es más eficiente que la prueba χ^2 en muestras pequeñas. No se aplica a distribuciones discretas. Para una sola muestra se encarga de comparar valores observados contra valores esperados o teóricos de una distribución continua en particular, por lo tanto es una prueba de bondad de ajuste. Es generalmente más eficiente que la prueba chi-cuadrada cuando el tamaño de la muestra es pequeño.

Entonces dado un nivel de significación alfa se busca los valores críticos de ese D deseable de la tabla, comparada con el D que se calculo en el desarrollo de la prueba verifico si: si es menor digo que la

distribuciones son significativamente iguales sino digo que no son significativamente iguales. Se basa en la diferencia absoluta máxima D entre los valores de la distribución acumulada observada y la teórica. Para decidir si esta diferencia absoluta máxima es razonable, con un respecto a un nivel de significación α asociado a la prueba, se buscan los valores críticos de D preestablecidos en una tabla, usando el tamaño de muestra y el nivel de significancia

De manera sencilla:

La **prueba de Kolmogorov-Smirnov (KS)** se usa para comparar distribuciones. Puede aplicarse en dos casos:

- 1) **KS Unimuestral:** Verifica si una muestra sigue una distribución teórica específica (ej. normal, exponencial, etc.). Es una **prueba de bondad de ajuste**.
- 2) **KS Bimuestral:** Compara si **dos muestras** provienen de la misma distribución.

¿Cómo funciona?

- ♦ Se calcula la **diferencia máxima (DDD)** entre la **distribución acumulada observada** y la **distribución teórica o de otra muestra**.
- ♦ Se compara con un **valor crítico** (según el tamaño de la muestra y el nivel de significancia α).
- ♦ **Decisión:**
 - Si $D_{\text{calculado}} < D_{\text{critico}} \rightarrow$ Las distribuciones son **iguales**.
 - Si $D_{\text{calculado}} > D_{\text{critico}} \rightarrow$ **Las distribuciones son diferentes**.

¿Por qué usar KS?

- ✓ Funciona mejor que **Chi-cuadrado** en muestras pequeñas.
- ✓ Se aplica solo a **distribuciones continuas** (no discretas).

 **Ejemplo:** Queremos saber si las alturas de 30 personas siguen una distribución normal. Aplicamos la prueba KS y comparamos con la distribución normal teórica. 

Problema: Se desea comprobar si los agujeros en una placa de hojalata electrolítica están uniformemente distribuidos a través de la placa. Por ello se han tomado distancias (en pulgadas) de 10 agujeros a partir de un extremo de una larga tira de 30 pulgadas de ancho, dando los siguientes resultados:

4.8 14.8 28.2 23.1 4.4 28.7 19.5 2.4 25.0 6.2

Probar esta hipótesis nula con un nivel de significación de 0.05

1. Hipótesis nula:

$$F(x) = \begin{cases} 0 & \text{para } x \leq 0 \\ x/30 & \text{para } 0 < x < 30 \\ 1 & \text{para } x > 30 \end{cases}$$

Hipótesis alterna: no están uniformemente distribuidos

2. Nivel de significación: $\alpha = 0.05$

0.410 SALE DE LA TABLA

TAMAÑO DE LA MUESTRA (N)	NIVEL DE SIGNIFICANCIA PARA $D = \text{MAX} [F_0(X) - S_n(X)]$				
	.20	.15	.10	.05	.01
1	.900	.925	.950	.975	.995
2	.684	.726	.776	.842	.929
3	.565	.597	.642	.708	.828
4	.494	.525	.564	.624	.733
5	.446	.474	.510	.565	.669
6	.410	.436	.470	.521	.618
7	.381	.405	.438	.486	.577
8	.358	.381	.411	.457	.543
9	.339	.360	.388	.432	.514
10	.322	.342	.368	.410	.490
11	.307	.326	.352	.391	.468
12	.295	.313	.338	.375	.450
13	.284	.302	.325	.361	.433
14	.274	.292	.314	.349	.418
15	.266	.283	.304	.338	.404
16	.258	.274	.295	.328	.392
17	.250	.266	.286	.318	.381
18	.244	.259	.278	.309	.371
19	.237	.252	.272	.301	.363
20	.231	.246	.264	.294	.356
25	.210	.220	.240	.270	.320
30	.190	.200	.220	.240	.290
35	.180	.190	.210	.230	.270
	<u>1.07</u>	<u>1.14</u>	<u>1.22</u>	<u>1.36</u>	<u>1.63</u>

3. Criterio: Se rechaza H_0 si $D > 0.410$, donde D es la diferencia máxima entre la distribución acumulada observada y la supuesta bajo la Hipótesis Nula.

4. Cálculos: Se construye el siguiente gráfico que muestra la distribución acumulada observada y la supuesta.
Para cada valor potencial Dat , la prueba de Kolmogorov-Smirnov compara la proporción de valores menores que Dat con el número esperado predicho por la distribución.


$Dat := (4.8 \ 14.8 \ 28.2 \ 23.1 \ 4.4 \ 28.7 \ 19.5 \ 2.4 \ 25 \ 6.2)^T$ Datos

$n := \text{rows}(Dat) = 10$ $i := 0 \dots n - 1$

$O := \frac{\text{sort}(Dat)}{30}$ valores observados ordenados

$A_i := 3 \cdot i$ Vector auxiliar

$E_i := \int_0^{A_i} \text{dunif}(t, 0, 30) dt$ valores esperados




UNIDAD V: AJUSTE DE CURVAS

Se requiere analizar la relación entre dos variables cuantitativas.

Los dos objetivos fundamentales de este análisis serán:

- Determinar si dichas variables están asociadas y en qué sentido se da dicha asociación (es decir, si los valores de una de las variables tienden a aumentar –o disminuir– al aumentar los valores de la otra: ej edad y altura)
- Estudiar si los valores de una variable pueden ser utilizados para predecir el valor de la otra.

El **coeficiente de correlación** (entre -1 y 1) mide la relación entre dos variables, pero no permite explicar una en función de la otra. Para eso, es necesario un modelo que establezca la relación entre ellas. Para tal propósito se recurrirá a la **técnica de regresión**.



Coeficiente de correlación alta en ambos casos → Coeficiente de correlación es distinto del Beta (pendiente).

Se considera únicamente la relación entre dos variables: la variable independiente o explicativa “x” y la variable dependiente o explicada “y”. Esto no va a ser aplicable en el caso en que los datos no tengan una

relación lineal.

5 B-3) COEFICIENTE DE CORRELACIÓN → Resumen tincho MEJOREN ESTO, LO SUELE TOMAR POR ARRIBA PERO HAY DISTINTOS TIPOS DE COEFICIENTES DE CORRELACION, ESTE ES UNO PARA RELACIONES LINEALES UNICAMENTE.

Se lo tomó a la Alma Quinteros junto a regresión

El coeficiente de correlación sirve para indicar **relaciones lineales** y **comportamientos** entre dos variables. Se denota comúnmente como **r** (correlación de Pearson) y varía en cualquier valor entre -1 y 1:

- Si $r = 1$ → Relación positiva perfecta (si una variable aumenta, la otra también).
- Si $r = -1$ → Relación negativa perfecta (si una aumenta, la otra disminuye).
- Si $r = 0$ → No hay relación lineal (**pero puede haber otro tipo de relación**)
- Si toma un valor como 0.5 o -0.5 → la relación es moderada (positiva o negativa).

Este coeficiente implica asociación, no implica **causalidad**: una variable no necesariamente causa cambios en la otra. Ej:

Si encontramos que hay una correlación alta entre el consumo de helado y los ataques de tiburón, no significa que comer helado **cause** ataques de tiburón. Probablemente haya una **tercera variable** (como la temperatura, ya que en verano la gente come más helado y también nada más en el mar).

★ Si la correlación r es positiva (cercana a 1) → La pendiente de la recta de regresión es positiva, es decir, cuando una variable aumenta, la otra también aumenta.

★ Si la correlación r es negativa (cercana a -1) → La pendiente de la recta de regresión es negativa, es decir, cuando una variable aumenta, la otra disminuye.

★ Si r está cerca de 0 → No hay una relación lineal clara, la pendiente puede no tener sentido o ser casi 0.

💡 Ejemplos:

- $r = 0.9$ → A más horas de estudio, mayor nota (pendiente positiva 📈).
- $r = -0.8$ → A más velocidad, menor tiempo de viaje (pendiente negativa 📉).
- $r = 0.05$ → Casi sin relación, la pendiente no es útil.

Así que sí, pendiente positiva ↔ r positivo, pendiente negativa ↔ r negativo. 🚀

$$r = \frac{S_{xy}}{\sqrt{S_{xx}S_{yy}}}$$

TEMA A: REGRESIÓN SIMPLE

5 A-1) LA RECTA DE REGRESIÓN (Regresión Lineal) esto le tomaron a Centeleghe

A partir de una muestra para los que se dispone de los valores de dos variables relacionadas, se realiza el diagrama de dispersión. Tenemos una variable independiente (explicativa “x”) y otra variable dependiente (explicada “y”)

Queremos encontrar la recta que mejor ajuste los valores, y que pueda ser utilizada para predecir los valores. Para esto se utiliza el método de los mínimos cuadrados, que elige como recta de regresión a aquella que minimiza las distancias verticales de las observaciones a la recta que mejor se ajusta de y a partir de los de x. La ecuación de la recta de regresión (la que mejor se ajusta) es $\alpha + \beta \cdot x$ (alfa ordenada al origen y beta

pendiente). Entonces, si se predice y por medio de la ecuación:


$$\hat{y} = a + b \cdot x$$

a y b (parámetros muestrales) son estimadores de α y β (parámetros poblacionales). Siendo a la ordenada al origen y b la pendiente.

sea e_i el error de predecir el valor de y correspondiente a la x_i es:

$$e_i = y_i - \hat{y}_i$$

diferencias verticales



El error sería la diferencia entre el “ y sub i ” y el “ y sub i sombrero”. Es decir, el error es la diferencia entre el valor real observado y el valor estimado en un punto específico del conjunto de datos

Se quiere determinar a y b de modo que estos errores sean lo más pequeños posibles. Ya que no se pueden minimizar cada uno de los e_i por separado, se intenta:

$$\sum_{i=1}^n e_i$$

Tan cercano a cero como sea posible.

Esto no es aconsejable ya que errores positivos y negativos se compensarán, y la estimación de la recta no será precisa. Por lo tanto, se busca minimizar la suma de los cuadrados de las diferencias entre los valores reales y los valores predichos por el modelo, por lo que a y b se elegirán con:

$$\sum_{i=1}^n [y_i - (a + b \cdot x_i)]^2$$

sea mínimo

Se eleva al cuadrado para que los errores negativos y positivos no se cancelen. Si los datos estuvieran perfectamente alineados, el error sería 0, pero como no lo están, siempre habrá un error. La mejor recta será aquella que tenga el menor error posible, es decir, la que minimiza la suma de los errores al cuadrado.

Para que pueda lograr la ecuación de la recta donde el resultado de la suma de cuadrados de error es mínimo, se tiene que cumplir una condición necesaria: Que exista un **mínimo relativo**. Para verificar esto las derivadas parciales con respecto a “ a ” y “ b ” deben anularse, obteniendo un sistema de ecuaciones lineales. “ n ” es el tamaño de “ x ” $\rightarrow n = \text{length}(x)$. Así podemos calcular el valor de a y b

Cuando derivas y con el 0 encuentras el mínimo debido a que el error es una función cuadrática, por lo que es una función CONVEXA. Por eso no tiene máximos y solo un mínimo.

$$2 \cdot \sum_{i=1}^n [y_i - (a + b \cdot x_i)] \cdot (-1) = 0 \quad \text{derivada respecto de } a \quad 2 \cdot \sum_{i=1}^n [y_i - (a + b \cdot x_i)] \cdot (-x_i) = 0 \quad \text{derivada respecto de } b$$

También se podría usar el valor absoluto para eliminar el problema del signo, pero el problema de la función valor absoluto es que la derivada cuando $x = 0$ es ambigua (No existe), mientras que en la función cuadrática no hay puntos de ambigüedad y anda todo perfecto)

Cuando derivo respecto de b, y me queda el $-x_i$, hago distributiva de la $-x_i$ con los términos y después hago distributiva de la sumatoria en los términos. Por eso me queda de la siguiente manera:

$$\sum_{i=1}^n y_i = a \cdot n + b \cdot \sum_{i=1}^n x_i \qquad \sum_{i=1}^n y_i \cdot x_i = a \cdot \sum_{i=1}^n x_i + b \cdot \sum_{i=1}^n (x_i)^2$$

Esto es un conjunto de ecuaciones lineales con incógnitas **a** y **b**, denominadas Ecuaciones Normales.

Resolviendo por determinantes:

Para resolver por determinantes coloco para el DENOMINADOR los valores que se encuentran del lado derecho de la igualdad (Termino 1 y termino 2). AMBOS EL DENOMINADOR ES IGUAL. Multiplico a_{11} x a_{22} y le resto a_{21} x a_{12} .

Para el NUMERADOR de a, cambio la PRIMERA COLUMNA por los valores INDEPENDIENTES (Los que están a la izquierda de la igualdad). Para el NUMERADOR de b cambio la SEGUNDA COLUMNA por los valores INDEPENDIENTES. Para ambos lo mismo multiplico a_{11} x a_{22} y le resto a_{21} x a_{12} .

$$a = \frac{\sum_{i=1}^n y_i \cdot \sum_{i=1}^n (x_i)^2 - \sum_{i=1}^n y_i \cdot x_i \cdot \sum_{i=1}^n x_i}{n \cdot \sum_{i=1}^n (x_i)^2 - \left(\sum_{i=1}^n x_i \right)^2} \qquad b = \frac{n \cdot \sum_{i=1}^n x_i \cdot y_i - \sum_{i=1}^n x_i \cdot \sum_{i=1}^n y_i}{n \cdot \sum_{i=1}^n (x_i)^2 - \left(\sum_{i=1}^n x_i \right)^2}$$


Calculando los valores de a y b, obtenemos la **ecuación predictora**, **$y = a + b \cdot x$**

MATHCAD te saca con $\text{intercept}(x,y)$ el estimador a y $\text{slope}(x,y)$ el estimador b

5 A-2) INFERENCIAS BASADAS EN ESTIMADORES DE MÍNIMOS CUADRADOS

Si se asume que la relación entre las variables es lineal, pero en realidad los datos en el diagrama de dispersión siguen una curva (por ejemplo, una parábola), entonces ajustar una recta a esos datos no representará bien la relación real. Desde el método de mínimos cuadrados, el ajuste lineal sería válido en términos matemáticos (minimiza la suma de los errores cuadrados), pero no tendría sentido en la práctica, **porque no sería el mejor ajuste**. AJUSTAR UNA FUNCIÓN LINEAL PARA ESTIMAR UNA FUNCIÓN CUADRÁTICA ESTÁ MAL, NO INTERPRETA LO QUE ESTÁ REALMENTE OCURRIENDO. PRIMERO MIRAR EL DIAGRAMA DE DISPERSIÓN

Se asume que se parte de una regresión lineal, donde los valores de y_i se distribuyen en forma normal, con media igual a $\alpha + \beta x_i$. Los errores son valores de variables aleatorias independientes con media 0 y varianza común igual a σ^2 .



Esto refleja que son muchas muestras, entonces los valores de x_1, x_2, x_i , resultan ser diferentes para cada muestra. $y = \alpha + \beta x$ es la única recta poblacional. Cada una de las distribuciones x_1, x_2, x_n tiene varianza σ^2 . En cada uno puedo hacer un intervalo de confianza para a y para b .

En resumen: Para cada lectura de X , tengo varios valores de Y . Cada una de las X tiene una función de densidad de probabilidad. Cada una de esas funciones tiene un máximo. Y eso va a ser la recta $y = \alpha + \beta x$

Se definen notaciones especiales: S_{xx} , S_{yy} y S_{xy} (no tienen ningún significado estadístico). Se utilizarán para

$$S_{xx} = n \cdot \sum_{i=1}^n (x_i)^2 - \left(\sum_{i=1}^n x_i \right)^2 = n \cdot s_x^2 \cdot (n-1)$$

donde s_x es simplemente la varianza de las x

$$S_{yy} = n \cdot \sum_{i=1}^n (y_i)^2 - \left(\sum_{i=1}^n y_i \right)^2 = n \cdot s_y^2 \cdot (n-1)$$

donde s_y es simplemente la varianza de las y

$$S_{xy} = n \cdot \sum_{i=1}^n x_i \cdot y_i - \sum_{i=1}^n x_i \cdot \sum_{i=1}^n y_i = n \cdot s_{xy} \cdot (n-1)$$

donde s_{xy} es simplemente la varianza de las x e y

en base a esto, se redefinen las ecuaciones normales, quedando:

$$b = \frac{S_{xy}}{S_{xx}} \quad a = \bar{y} - b \cdot \bar{x} \quad \text{donde } \bar{x} \text{ e } \bar{y} \text{ son, respectivamente las medias de las } x \text{ y de las } y.$$

Luego queremos estimar la varianza “sigma cuadrado” que es la misma para todas las funciones de densidad de probabilidad.

$$s_e^2 = \frac{1}{n-2} \cdot \sum_{i=0}^{n-1} [y_i - (a + b \cdot x_i)]^2$$

$$s_e^2 = \frac{S_{xx} \cdot S_{yy} - S_{xy}^2}{n \cdot (n-2) \cdot S_{xx}}$$

donde s_e se denomina Error Estándar de Estimación, también la suma de los cuadrados dada por $s_e^2 \cdot (n-2)$ recibe el nombre de Suma de Cuadrados Residual Suma de Cuadrados de Error.

Se puede demostrar que tanto “a” como “b” presentan una distribución normal, cuyas medias (μ_a y μ_b) coinciden con los parámetros α y β . La estimación, $s_e^2 \cdot (n-2)$ se denomina Suma de Cuadrados de Error.

Luego, se pueden obtener estos estadísticos t-student con n-2 grados de libertad, que permiten establecer un intervalo de confianza para a y b:

$$t = \frac{a - \alpha}{s_e} \cdot \sqrt{\frac{n \cdot S_{xx}}{S_{xx} + (n \cdot \bar{x})^2}} \quad y \quad t = \frac{b - \beta}{s_e} \cdot \sqrt{\frac{S_{xx}}{n}}$$


Los intervalos de confianza $-t_{\alpha/2} < t < t_{\alpha/2}$ son:

$$a - t_{\frac{\alpha}{2}} \cdot s_e \cdot \sqrt{\frac{n \cdot S_{xx}}{S_{xx} + (n \cdot \bar{x})^2}} < \alpha < a + t_{\frac{\alpha}{2}} \cdot s_e \cdot \sqrt{\frac{n \cdot S_{xx}}{S_{xx} + (n \cdot \bar{x})^2}}$$


$$b - t_{\frac{\alpha}{2}} \cdot s_e \cdot \sqrt{\frac{n}{S_{xx}}} < \beta < b + t_{\frac{\alpha}{2}} \cdot s_e \cdot \sqrt{\frac{n}{S_{xx}}}$$

Errores máximos de estimación de a y b

Intervalo de confianza para ALFA con un nivel de significancia alfa:
Influye en la ORDENADA AL ORIGEN



Intervalo de confianza para BETA con un nivel de significancia alfa:
Influye en la PENDIENTE



Las pruebas sobre β (la pendiente) son muy importantes porque nos dicen si X realmente influye en Y.

- β representa cuánto cambia Y en promedio cuando X aumenta en 1 unidad.
- Si β es muy chico (cercano a 0), quiere decir que los valores de Y varían muy poco (casi nula) con respecto a los de X
- Si $\beta = 0$, la recta es horizontal, lo que significa que X no afecta a Y (no hay relación lineal entre ellas).

Para calcular un intervalo de confianza en un determinado punto.

Otro problema es estimar $\alpha + \beta \cdot x$, es decir la media de la distribución de las y (μ_y), para un valor dado de x.

Si x se hace igual a un valor fijo x_0 se desea estimar $\alpha + \beta \cdot x_0$ y sería razonable emplear $a + b \cdot x_0$ (con a y b obtenidos por el método de los mínimos cuadrados).

Puede verificarse que este estimador es insesgado, y que tiene la varianza:

$$\sigma^2 \left[\frac{1}{n} + \frac{n(x_0 - \bar{x})^2}{S_{XX}} \right]$$

Y estaría dado de esta manera:

y que los límites de confianza del $(1-\alpha) \cdot 100\%$ para $\alpha + \beta \cdot x_0$ están dados por

$$(a + b \cdot x_0) \pm t_{\frac{\alpha}{2}} \cdot s_e \cdot \sqrt{\frac{1}{n} + \frac{n \cdot (x_0 - \bar{x})^2}{S_{xx}}} \quad \text{con } v = n-2 \text{ g.d.l.}$$

Ejemplo

Problema: En relación al ejemplo anterior, construir un intervalo de confianza del 95% para el coeficiente de evaporación cuando la velocidad del aire es de 190 cm/seg.

$$a := 0.05 \quad v := n - 2 = 8 \quad t_{0.025} := qt\left(1 - \frac{\alpha}{2}, v\right) = 2.306$$

$$x_0 := 190$$

$$E := t_{0.025} \cdot s_e \cdot \sqrt{\frac{1}{n} + \frac{n \cdot (x_0 - \text{mean}(x))^2}{S_{xx}}} = 0.116$$

$$(a + b \cdot x_0) - E = 0.661 \quad \text{Extremo inferior del intervalo}$$

$$(a + b \cdot x_0) + E = 0.894 \quad \text{Extremo superior del intervalo}$$

$$0.661 < \alpha + \beta \cdot x_0 < 0.893 \quad \text{Intervalo de confianza}$$

Algo así sería el intervalo de confianza:



Las mejores predicciones las podemos hacer en el medio del intervalo (menor error), las peores en los extremos (mayor error)

5 A-2) REGRESIÓN CURVILÍNEA (logaritmo)

Cuando la relación entre X e Y no es lineal, se cuenta con dos alternativas:

1. Desarrollar un modelo de regresión no lineal
2. Transformar los datos para que se adapten al modelo lineal.

Esta segunda es la más sencilla. Se transforma la ecuación predictora para que los parámetros (α y β) sean

lineales, y así para poder tratar el modelo con las técnicas antes vistas y construir el sistema de ecuaciones normales.

Tener en cuenta que cuando cálculo A y B finales, es decir, calcular a y b con intercept y slope (o por determinantes más lento) el valor que después transformó en A y B. Son los valores que tengo que reemplazar en la función ORIGINAL.

Exponencial $\rightarrow A \cdot B^x$

Potencial $\rightarrow A \cdot x^B$

Recíproca $\rightarrow 1/A + B \cdot x$

Una vez obtenidos los valores de las estimaciones para los coeficientes de regresión transformados, éstos deberán retransformarse a su forma original (deshaciendo todas las operaciones efectuadas para linealizarlos), obteniéndose, así, sus verdaderas aproximaciones.

Ejemplos de ecuaciones predictoras no lineales:

Forma funcional que relaciona y con x	Transformación propia	Forma de la regresión lineal simple
Exponencial: $y = \beta_0 e^{\beta_1 x}$	$y^* = \ln y$	Hacer la regresión de y^* contra x
Potencia: $y = \beta_0 x^{\beta_1}$	$y^* = \log y ; x^* = \log x$	Hacer la regresión de y^* contra x^*
Recíproca: $y = \beta_0 + \beta_1 \left(\frac{1}{x}\right)$	$x^* = \frac{1}{x}$	Hacer la regresión de y contra x^*
Hiperbólica: $y = \frac{x}{\beta_0 + \beta_1 x}$	$y^* = \frac{1}{y}; x^* = \frac{1}{x}$	Hacer la regresión de y^* contra x^*

Ejemplo: Si al graficar los puntos (x_i, y_i) , los datos crecen(exponencial) o decrecen(logarítmica), esto indica que la curva de regresión es exponencial o logarítmica. Suponiendo que decrecen la **ecuación predictora** es: $y = \alpha \cdot \beta^x$, tomando logaritmos en ambos miembros se obtiene la **ecuación predictora transformada**:

$$\log(y) = \log(\alpha) + x \cdot \log(\beta)$$

Vemos que ahora la **ecuación predictora** es lineal. Entonces se debe calcular las **ecuaciones normales** (Con determinantes) para obtener los valores de “a” y “b”, y se calcula el error.

Luego se deben revertir los pasos de la linealidad, obteniendo la regresión curvilínea. En este caso la operación inversa es la exponenciación. Por lo tanto se utiliza la base del logaritmo, y por definición “la base elevada al argumento es igual al resultado”, entonces: $\log_{10}(a) \rightarrow a$ es el argumento, 10 es la base.

Por lo tanto:

$$\begin{pmatrix} A \\ B \end{pmatrix} := \begin{pmatrix} 10^a \\ 10^b \end{pmatrix} = \begin{pmatrix} 99.941 \\ 0.958 \end{pmatrix}$$

Problema: Las cifras siguientes son datos sobre el porcentaje de llantas radiales producidas por cierto fabricante que aún pueden usarse después de recorrer cierto número de millas:

Miles de Millas recorridas (x)	1	2	5	10	20	30	40	50
Porcentaje útil (y)	98.2	91.7	81.3	64.0	36.4	32.6	17.1	11.3
Log(y)	1.992	1.9624	1.910	1.806	1.561	1.5132	1.2330	1.0531

+

- Graficar los datos proporcionados en escala semilogaritmica para advertir si es razonable que la relación es exponencial.
- Ajustar una curva exponencial aplicando el método de mínimos cuadrados a las parejas de puntos $[x_i, \log(y_i)]$.
- Emplear los resultados de la parte b) para estimar qué porcentaje de las llantas radiales del fabricante durarán menos de 25000 millas

a) Se crean los vectores:

$$x := (1 \ 2 \ 5 \ 10 \ 20 \ 30 \ 40 \ 50)^T$$


$$y := (98.2 \ 91.7 \ 81.3 \ 64 \ 36.4 \ 32.6 \ 17.1 \ 11.3)^T$$

$$Ly := \log(y)$$


$$n := \text{length}(x)$$

$$i := 0 .. n - 1$$

Lineal



Semilogaritmico



El patrón global (del segundo gráfico) es **lineal** y esto justifica el ajuste mediante una curva exponencial.

b) Para formar las ecuaciones normales:

$$\sum_i x_i = 158 \quad \sum_i (x_i)^2 = 5.53 \times 10^3 \quad \sum_i Ly_i = 13.031 \quad \sum_i (x_i \cdot Ly_i) = 212.121$$

$$\sum_i Ly_i = n \cdot \log(a) + \log(b) \cdot \sum_i (x_i)$$

$$\sum_i (x_i \cdot Ly_i) = \log(a) \cdot \sum_i (x_i) + \log(b) \cdot \sum_i (x_i)^2$$

$$13.031 = 8 \cdot \log(a) + 158 \cdot \log(b)$$

Ecuaciones normales

$$13.031 = 8 \cdot \log(a) + 158 \cdot \log(b)$$

Ecuaciones normales

$$212.121 = 158 \cdot \log(a) + 5.53 \times 10^3 \cdot \log(b)$$

$$\log(a) = \frac{\begin{vmatrix} 13.031 & 158 \\ 212.121 & 5.53 \times 10^3 \end{vmatrix}}{\begin{vmatrix} 8 & 158 \\ 158 & 5.53 \times 10^3 \end{vmatrix}} = 2$$

$$\log(b) = \frac{\begin{vmatrix} 8 & 13.031 \\ 158 & 212.121 \end{vmatrix}}{\begin{vmatrix} 8 & 158 \\ 158 & 5.53 \times 10^3 \end{vmatrix}} = -0.019$$

$$A := 10^2 = 100$$

$$B := 10^{-0.019} = 0.957$$

Mucho más simple, utilizando Mathcad:


$$\text{in} := \text{intercept}(x, Ly) = 2$$

Ordenada al origen


$$\text{sl} := \text{slope}(x, Ly) = -0.019$$

Pendiente

Lineal



Semilogaritmico



LA GRAFICA ES HACIA ABAJO PORQUE LA BASE DE X ES MENOR A 1

Utilizando la última expresión para $x=25$:

$$A \cdot B^{25} = 33.497$$

Vale decir, el 33.5% durarán menos de 25000 millas.

EN RESUMEN UNA VEZ QUE LO PASAS A LA ECUACIÓN PREDICTORA TRANSFORMADA (EN EL CASO DE EXPONENCIACIÓN QUE LE PONEMOS LOS LOGARITMOS DE MODO QUE QUEDARÍA $\text{LOG}(Y) = \text{LOG}(A) + X \text{LOG}(B)$) SE TRABAJA COMO SI FUERA UNA LINEAL. AL FINAL QUE HACEMOS TODO PARA OBTENER A Y B (DETERMINANTES) ESOS 2 VALORES LOS VOLVEMOS A PONER EN SU FORMA NORMAL. 10 ELEVADO A LA A Y 10 ELEVADO A LA B. ASÍ OBTENEMOS A Y B. EN LUGAR DE HACER EL PROCEDIMIENTO DE DETERMINANTES LOS CALCULAMOS CON INTERCEPT Y SLOPE (INTERCEPT(X,LOG(Y)) Y SLOPE(X,LOG(Y))).

PARA FUNCION POTENCIAL:

- ✓ Gráfica curva que se dispara rápido → Exponencial.
- ✓ Gráfica curva que crece pero suavemente → Potencial.

PARA DIFERENCIAR!!!

A simple vista no se sabe si es potencial o exponencial. Para **potencial** aplico $\log(y)$ vs $\log(x)$ (**logaritmo completo**) y se observa una línea recta. Para **exponencial** aplico $\log(y)$ y x normal sin modificar (**semilogarítmico**) y se observa una línea recta

La potencial es de la siguiente manera:

$$y = \alpha x^\beta$$

De manera que cuando aplico logaritmo (en base 10, no natural) queda así:

$$\log(y) = \log(\alpha) + \beta \cdot \log(x)$$

De esta manera cuando trabajo con esta función (trabajando como una regresión lineal) y cálculo a y b (Calculados con intercept y slope para que sea más sencillo). Únicamente a a le aplicó la transformación a la original. De manera que queda de la siguiente manera:


$$a := \text{intercept}(\log(x), \log(y)) = 0.396$$

$$b := \text{slope}(\log(x), \log(y)) = 2.989$$

$$A := 10^a = 2.488$$

$$B := b$$

Entonces quedaría así:



PARA FUNCIÓN RECÍPROCA


$$y = 1/(\alpha + \beta \cdot x)$$

Valor de x_i normal y el valor de y_i es $1/y_i \rightarrow [x_i, 1/y_i]$.


Así quedaría $\rightarrow$

$$\frac{1}{y} = \alpha + \beta x$$

Para saber que es recíproca le clavo al eje y le clavo $1/y_i \rightarrow$ Así
De esto:



A esto:




Calculando con intercept y slope →

$$\begin{aligned} \underline{a} &:= \text{intercept}\left(x, \frac{1}{y}\right) = 4.396 \\ \underline{b} &:= \text{slope}\left(x, \frac{1}{y}\right) = 3.901 \end{aligned}$$

A Y B NO SE MODIFICAN ENTONCES YA QUE ESTÁN IGUALES.

Así queda la predicción de la función $1/A + B X$



TEMA B: Regresión Múltiple.


5 B-1) AJUSTE POLINÓMICO (esto le tomaron a Guarnier y a Peretti)

Peretti: vos en ajuste polinómico tenés regresión simple y regresión múltiple. A él directamente le tomaron regresión múltiple. También le preguntó de mínimos cuadrados por qué se empleaban los errores cuadrados y él respondió que se hace pq hay errores positivos y negativos y si hacemos la sumatoria total de todos los errores entonces los negativos se van a ir compensando con los positivos y va a quedar un número más chico del error que realmente es, entonces se toma los errores cuadrados.

La idea es que no se tiene ninguna indicación de la forma. Se probó ajustar exponencialmente y no se dio, se probó ajustar potencialmente y tampoco, se probó reciprocamente y tampoco dio. Entonces lo que se propone para el ajuste es una función polinómica de grado p cuya ecuación predictora está debajo.

Observación:

Dato de color: Pero si se analizan los errores horizontalmente, ¿la recta del mejor ajuste va a ser la misma? No, va a ser otra recta que tiene la regresión de x sobre y . NORMALMENTE SE TRABAJA CON LOS ERRORES VERTICALES Y NO HORIZONTALES.



Si no sabemos cómo es la relación entre y y x (que consiste en la minimización de los errores verticales respecto a la recta del mejor ajuste. Eso pasa entonces cuando se consideran los errores horizontales en vez de los verticales), suponemos que es estable y podemos aproximarla con una **Serie de Taylor**. Tomando los primeros términos, obtenemos una **regresión polinomial** (Se busca el mejor ajuste de grado mínimo), que ajusta los datos con un polinomio de grado p .

Vale decir, los datos se ajustan a un **polinomio** o ecuación predictora de la forma

$$y = \beta_0 + \beta_1 \cdot x + \beta_2 \cdot x^2 + \dots + \beta_p \cdot x^p$$

notar que si el polinomio es de grado 1 estaríamos en un ajuste lineal, si es de grado dos en un ajuste cuadrático y así ...

donde el grado se determina por observación de los datos o por un método más riguroso como el siguiente: dado un conjunto de datos que consta de n puntos (x_i, y_i) se estiman los coeficientes $\beta_0, \beta_1, \beta_2, \dots, \beta_p$ del polinomio de p -ésimo grado, minimizando:

$$\sum_{i=1}^n \left[y_i - (\beta_0 + \beta_1 \cdot x + \beta_2 \cdot x^2 + \dots + \beta_p \cdot x^p) \right]^2$$

Esa fórmula es la suma de cuadrados de error (que está elevada al cuadrado para eliminar el signo). Hay que lograr que esta suma de cuadrados de error sea mínima y para ellos se deriva parcialmente y se iguala a 0. Se van a tener que hacer $p+1$ derivadas donde la primera derivada es respecto a β_0 la otra respecto a β_1 y así ...

derivando parcialmente con respecto a $\beta_0, \beta_1, \beta_2, \dots, \beta_p$, igualando estas derivadas parciales a cero, se obtienen las $p+1$ (debido a que hay $\beta + 1$ de términos) ecuaciones normales, y se arma el SEN (sistema de ecuaciones normales):

$$\begin{bmatrix} n & \sum_i x_i & \dots & \sum_i (x_i)^p \\ \sum_i x_i & \sum_i (x_i)^2 & \dots & \sum_i (x_i)^{p+1} \\ \dots & \dots & \dots & \dots \\ \sum_i (x_i)^p & \sum_i (x_i)^{p+1} & \dots & \sum_i (x_i)^{2 \cdot p} \end{bmatrix} \cdot \begin{pmatrix} b_0 \\ b_1 \\ \dots \\ b_p \end{pmatrix} = \begin{bmatrix} \sum_i y_i \\ \sum_i (y_i \cdot x_i) \\ \dots \\ \sum_i [y_i \cdot (x_i)^p] \end{bmatrix}$$

Un ejemplo de esto para un polinomio de grado 3 es: $y_i = b_0 + b_1 \cdot x + b_2 \cdot x^2 + b_3 \cdot x^3$

En caso de que pidan un polinomio de grado 3 $y_i = b_0 + b_1 \cdot x + b_2 \cdot x^2 + b_3 \cdot x^3$ La cantidad de coeficientes del polinomio determina el tamaño de la matriz.

$$\begin{bmatrix} n & \sum x_i & \sum x_i^2 & \sum x_i^3 \\ \sum x_i & \sum x_i^2 & \sum x_i^3 & \sum x_i^4 \\ \sum x_i^2 & \sum x_i^3 & \sum x_i^4 & \sum x_i^5 \\ \sum x_i^3 & \sum x_i^4 & \sum x_i^5 & \sum x_i^6 \end{bmatrix} \cdot \begin{bmatrix} b_0 \\ b_1 \\ b_2 \\ b_3 \end{bmatrix} = \begin{bmatrix} y_i \\ y_i \cdot x_i \\ y_i \cdot x_i^2 \\ y_i \cdot x_i^3 \end{bmatrix}$$

A B Y

$$B = A^{-1} \cdot Y$$

La matriz A se pasa con el exponente inverso para resolverse

¿Cuándo tengo que parar en el ajuste? En este ejercicio yo tenía 9 puntos y con el pudiera haber hecho un polinomio de grado 9 que hubiese pasado por todos los puntos. Eso no está muy bien porque escapa de la realidad, yo debería tener un polinomio de un grado no tan alto y que no necesariamente pase por todos los puntos. Entonces en qué grado de polinomio me quedo? Para resolver esta situación se recurre a un indicador objetivo que se llama **varianza residual**

Resumen de Ajuste Polinómico:

1. Concepto General

El ajuste polinómico se usa cuando no tenemos información previa sobre la relación entre x y y. Si otros modelos (exponencial, potencial, recíproco) no funcionan, se prueba con un polinomio de grado p para encontrar la mejor aproximación.

Un polinomio de grado p tiene la siguiente forma:

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \dots + \beta_p x^p$$

- Si $p=1$, es una regresión lineal.

- Si $p=2$, es una regresión cuadrática.
- Si $p=3$, es una regresión cúbica, y así sucesivamente.

2. ¿Cómo se determinan los coeficientes $\beta_0, \beta_1, \dots, \beta_p$?

Se emplea el método de mínimos cuadrados, que minimiza la diferencia entre los valores reales y_i y los valores predichos por el polinomio.

Se minimiza la suma de cuadrados del error (SCE):

$$E = \sum_{i=1}^n [y_i - (\beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \dots + \beta_p x_i^p)]^2$$

- Se derivan parcialmente E respecto a cada β_j se iguala a 0.
- Se obtiene un Sistema de Ecuaciones Normales (SEN), que se resuelve para encontrar los coeficientes.
- ES UNA MATRIZ SIMÉTRICA

$$\begin{bmatrix} n & \sum_i x_i & \dots & \sum_i (x_i)^p \\ \sum_i x_i & \sum_i (x_i)^2 & \dots & \sum_i (x_i)^{p+1} \\ \dots & \dots & \dots & \dots \\ \sum_i (x_i)^p & \sum_i (x_i)^{p+1} & \dots & \sum_i (x_i)^{2 \cdot p} \end{bmatrix} \cdot \begin{pmatrix} b_0 \\ b_1 \\ \dots \\ b_p \end{pmatrix} = \begin{bmatrix} \sum_i y_i \\ \sum_i (y_i \cdot x_i) \\ \dots \\ \sum_i [y_i \cdot (x_i)^p] \end{bmatrix}$$

Ejemplo para $p=3$:

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3$$

Tendremos **4 ecuaciones normales** para determinar $\beta_0, \beta_1, \beta_2, \beta_3$.

En caso de que pidan un polinomio de grado 3

$$y_i = b_0 + b_1 \cdot x_i + b_2 \cdot x_i^2 + b_3 \cdot x_i^3$$

La cantidad de coeficientes del polinomio determina el tamaño de la matriz.

$$\begin{bmatrix} n & \sum x_i & \sum x_i^2 & \sum x_i^3 \\ \sum x_i & \sum x_i^2 & \sum x_i^3 & \sum x_i^4 \\ \sum x_i^2 & \sum x_i^3 & \sum x_i^4 & \sum x_i^5 \\ \sum x_i^3 & \sum x_i^4 & \sum x_i^5 & \sum x_i^6 \end{bmatrix} \cdot \begin{bmatrix} b_0 \\ b_1 \\ b_2 \\ b_3 \end{bmatrix} = \begin{bmatrix} y_i \\ y_i \cdot x_i \\ y_i \cdot x_i^2 \\ y_i \cdot x_i^3 \end{bmatrix}$$

A B Y

$$B = A^{-1} \cdot Y$$

La matriz A se pasa con el exponente inverso para resolverse

Ejercicio resuelto:

Cantidad de aditivo (en gr.)	0	1	2	3	4	5	6	7	8
Tiempo de secado (en seg.)	12.0	10.5	10.0	8.0	7.0	8.0	7.5	8.5	9.0


- Dibujar el diagrama de dispersión de modo que permita advertir si es razonable una relación parabólica.
- Ajustar un polinomio de segundo grado por el método de mínimos cuadrados.
- Emplear el resultado de b) para predecir el valor del tiempo de secado cuando se han utilizado 6.5 gr. del aditivo.

$$x := (0 \ 1 \ 2 \ 3 \ 4 \ 5 \ 6 \ 7 \ 8)^T$$

$$y := (12.0 \ 10.5 \ 10.0 \ 8.0 \ 7.0 \ 8.0 \ 7.5 \ 8.5 \ 9.0)^T$$

$i := 0 \dots \text{length}(x) - 1$

a)




b)

+

Calculo los valores de Beta

$$b := \begin{bmatrix} \text{length}(x) & \sum_i x_i & \sum_i (x_i)^2 \\ \sum_i x_i & \sum_i (x_i)^2 & \sum_i (x_i)^3 \\ \sum_i (x_i)^2 & \sum_i (x_i)^3 & \sum_i (x_i)^4 \end{bmatrix}^{-1} \begin{bmatrix} \sum_i y_i \\ \sum_i (x_i \cdot y_i) \\ \sum_i [(x_i)^2 \cdot y_i] \end{bmatrix} = \begin{pmatrix} 12.185 \\ -1.847 \\ 0.183 \end{pmatrix}$$

Y me da así la predicción de la función:



3. ¿Cómo se elige el grado p del polinomio?

El grado p se elige de dos formas:

1. Observación de los datos: Se prueban diferentes valores de p y se elige el que mejor ajuste sin sobreajustar.
2. Método riguroso: Se usa un indicador matemático como:
 - Varianza residual: Evalúa la dispersión del error.
 - Coeficiente de determinación R²: Mide qué tan bien el modelo explica los datos.

● ¿Por qué no elegir p=n-1?

Si hay n puntos, un polinomio de grado n-1 pasaría exactamente por todos, pero esto genera sobreajuste.

4. ¿Qué es el sobreajuste?

El sobreajuste (overfitting) ocurre cuando el modelo se ajusta demasiado a los datos de entrenamiento, capturando ruido en vez de la tendencia real.

🌸 Ejemplo:

Si tienes 9 puntos y ajustas un polinomio de grado 9, la función pasará por todos los puntos, pero el modelo será muy complejo y tendrá mal desempeño con nuevos datos.

✓ Solución:

Se elige un grado menor que equilibre precisión y simplicidad, evitando que el modelo sea demasiado sensible a pequeñas variaciones en los datos.

5 B-2) AJUSTE POLINOMIAL MEDIANTE LA VARIANZA RESIDUAL esto le tomaron a Guarnier y a Peretti

Cuando se ajusta un polinomio a un conjunto de parejas de datos, se suele empezar ajustando con una línea recta (regresión lineal) y se calcula la varianza residual, después se ajusta un polinomio de segundo grado y se calcula la varianza residual para este. A partir del polinomio de segundo grado se van comparando los valores de las varianzas residuales. Este proceso se repite, hasta que la varianza residual produce “el salto decreciente más significativo” (tiene un valor mucho más bajo que el anterior). Y a partir de ahí por más que se siga iterando y aumentando el grado del polinomio es al pedo pq la aproximación va a ser prácticamente igual de buena.

Cada una de estas varianzas residuales está dada por:

$$\sigma_{\text{res}}^2 = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n - p}$$

grados de libertad

Esta sumatoria indica la suma de cuadrados de errores

con $\hat{y}$ determinada por la ecuación del polinomio.

Los grados de libertad se determinan restando el número de puntos considerados y los coeficientes estimados (cantidad de β de la ecuación).

En este caso se toma la sumatoria de y_i (que son los puntos que saco del problema) - el polinomio con los respectivos coeficientes de Beta₀, Beta₁, etc previamente calculados. Ej:

$$\sum_i \frac{(y_i - b_0 - b_1 \cdot x_i)^2}{n - 2}$$

Lineal:

$$\sum_i \frac{[y_i - b_0 - b_1 \cdot x_i - b_2 \cdot (x_i)^2]^2}{n - 3}$$

Cuadrática:

$$\sum_i \frac{[y_i - b_0 - b_1 \cdot x_i - b_2 \cdot (x_i)^2 - b_3 \cdot (x_i)^3]^2}{n - 4}$$

Cúbica:

Cuando tenemos x puntos, el polinomio de grado x pasará por todos los puntos y tendrá una varianza residual nula porque vamos a tener una suma de cuadrados de error igual a 0. Por lo general a medida que vaya aumentando el grado del polinomio va a ir disminuyendo el error.

Peretir es un método para obtener un error que se está cometiendo después de haber realizado el ajuste. Cuando se hace un ajuste por serie de Taylor de un polinomio (en serie de Taylor cada iteración que se hace se eleva un grado más el grado del polinomio y ahí queda una mejor aproximación a los puntos que tienes que hacer) y con la varianza residual lo que se hace es la medición del error que se comete luego de cada iteración. También me pregunto hasta cuando tenía que hacerlo y dijo que era hasta dar un salto significativo en el valor que obtienes y ahí denota que decreció mucho el error y a partir de ahí por más que se siga iterando y aumentando el grado del polinomio es al pedo porque la aproximación va a ser prácticamente igual de buena.

Resumen de Ajuste Polinómico mediante la varianza muestral:

Cuando se ajusta un polinomio a un conjunto de datos, **se comienza con un ajuste lineal** y se va aumentando el grado del polinomio, observando la **varianza residual** para determinar el grado óptimo del polinomio.

La varianza residual es una medida del **error** en el ajuste del modelo. Cuantifica qué tan bien el polinomio se ajusta a los datos, comparando los valores reales y_i con los valores predichos $\hat{y}_i$.

$$\sigma^2 = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n - p}$$

Donde:

- y_i son los valores reales.
- $\hat{y}_i$ son los valores predichos por el polinomio.
- n es el número total de puntos.
- p es el grado del polinomio + 1 (porque hay $p + 1$ coeficientes β).
- $n - p$ son los **grados de libertad**.

¿Cómo usamos este valor de **varianza residual**?

Comenzamos con un ajuste lineal ($p=1$) y calculamos la varianza residual.

Probamos con un polinomio de grado 2, calculamos la varianza residual y la comparamos con la anterior.

Seguimos aumentando el grado del polinomio y registrando la varianza residual en cada paso.

Detenemos el proceso cuando se observa un “salto decreciente significativo”, es decir, cuando el error baja considerablemente en una iteración y en las siguientes iteraciones apenas mejora.

Ejemplo:

Problema: Dado el siguiente conjunto de datos:

x	.5	1.5	2.5	5.5	6.5	9.5	10.5	12.5	14.5	15.5
y	3	7	12.5	14.5	16	14.5	16	16	21	23

encontrar el polinomio de mejor ajuste.

Se intenta en primer lugar, el ajuste **lineal**. Para ello se determinan y resuelven las ecuaciones normales:

$x := 0$ $y := 0$

$\underline{x} := (.5 \ 1.5 \ 2.5 \ 5.5 \ 6.5 \ 9.5 \ 10.5 \ 12.5 \ 14.5 \ 15.5)^T$

$\underline{n} := \text{length}(x)$ $i := 0..n - 1$

$\underline{y} := (3 \ 7 \ 12.5 \ 14.5 \ 16 \ 14.5 \ 16 \ 16 \ 21 \ 23)^T$

Se intenta en primer lugar, el ajuste **lineal**.

$$\begin{pmatrix} b_0 \\ b_1 \end{pmatrix} := \begin{bmatrix} n & \sum_i x_i \\ \sum_i x_i & \sum_i (x_i)^2 \end{bmatrix}^{-1} \cdot \begin{bmatrix} \sum_i y_i \\ \sum_i (y_i \cdot x_i) \end{bmatrix} = \begin{pmatrix} 6.578 \\ 0.984 \end{pmatrix}$$

Luego se calcula la varianza residual

$$\text{var_res}_1 := \frac{\sum_i (y_i - b_0 - b_1 \cdot x_i)^2}{n - 2} = 7.207$$

El segundo ajuste es **cuadrático**

$$\begin{pmatrix} b_0 \\ b_1 \\ b_2 \end{pmatrix} := \begin{bmatrix} n & \sum_i x_i & \sum_i (x_i)^2 \\ \sum_i x_i & \sum_i (x_i)^2 & \sum_i (x_i)^3 \\ \sum_i (x_i)^2 & \sum_i (x_i)^3 & \sum_i (x_i)^4 \end{bmatrix}^{-1} \cdot \begin{bmatrix} \sum_i y_i \\ \sum_i (y_i \cdot x_i) \\ \sum_i [y_i \cdot (x_i)^2] \end{bmatrix} = \begin{pmatrix} 5.399 \\ 1.5 \\ -0.033 \end{pmatrix}$$

$$\text{var_res}_2 := \frac{\sum_i \left[y_i - b_0 - b_1 \cdot x_i - b_2 \cdot (x_i)^2 \right]^2}{n - 3} = 7.58$$

El Tercer ajuste es **cúbico**

$$\begin{pmatrix} b_0 \\ b_1 \\ b_2 \\ b_3 \end{pmatrix} := \begin{bmatrix} n & \sum_i x_i & \sum_i (x_i)^2 & \sum_i (x_i)^3 \\ \sum_i x_i & \sum_i (x_i)^2 & \sum_i (x_i)^3 & \sum_i (x_i)^4 \\ \sum_i (x_i)^2 & \sum_i (x_i)^3 & \sum_i (x_i)^4 & \sum_i (x_i)^5 \\ \sum_i (x_i)^3 & \sum_i (x_i)^4 & \sum_i (x_i)^5 & \sum_i (x_i)^6 \end{bmatrix}^{-1} \cdot \begin{bmatrix} \sum_i y_i \\ \sum_i (x_i \cdot y_i) \\ \sum_i [y_i \cdot (x_i)^2] \\ \sum_i [y_i \cdot (x_i)^3] \end{bmatrix} = \begin{pmatrix} 0.497 \\ 5.793 \\ -0.714 \\ 0.028 \end{pmatrix}$$

$$\text{var_res}_3 := \frac{\sum_i \left[y_i - b_0 - b_1 \cdot x_i - b_2 \cdot (x_i)^2 - b_3 \cdot (x_i)^3 \right]^2}{n - 4} = 1.021$$


Y así hasta llegar a un polinomio de grado 9, que pasará por todos los puntos (varianza residual nula).

Una tabla con las *varianzas residuales* para cada ajuste es la siguiente (hasta el orden cuártico):

Lineal	Cuadrático	Cúbico	Cuártico
7.207	7.58	1.021	0.992

Se ve que el salto mayor se produce entre el ajuste cuadrático y el cúbico, por lo tanto el mejor estimador lo constituye el ajuste cúbico.

Al elegir el cúbico.



5 B) REGRESIÓN MÚLTIPLE esto le tomaron a Guarnier y Peretti

En la regresión simple había una única variable independiente (x) porque se trabajaba en el **plano**, ahora hay más, nos limitamos a 2 variables independientes para trabajar en el espacio. Entonces no se encuentra una línea sino que se encuentra un plano.

Las curvas obtenidas se utilizan para:

- **Predecir** valores de y usando varias x.
- **Optimizar**, encontrando valores de x que hagan y lo más grande o pequeña posible.

En la **regresión múltiple**, se tiene **n** variables independientes x_i (predictoras) y 1 dependiente y_i es decir, **coordenadas:** $(X_{1i}, X_{2i}, \dots, X_{ni}, y_i)$ donde otra vez se supone que las x_i se conocen sin error, mientras que las y son valores de variables aleatorias. Nos vamos a limitar solo a 2 variables independientes para poder graficar en el espacio. Por lo que $n = 2$.

Se aplica el método de los mínimos cuadrados para obtener estimaciones de los coeficientes constantes: β_0 , β_1 y β_2 .

Para esto, se minimiza la **suma de los cuadrados del error**, es decir:

$$\sum_{i=1}^n [y_i - (\beta_0 + \beta_1 \cdot x_{1i} + \beta_2 \cdot x_{2i})]^2 \quad (\text{lo que está en corchetes es la ecuación predictora})$$

Se aplican las derivadas parciales (respecto de los coeficientes) a la fórmula de arriba, se igualan a 0, obteniendo el siguiente sistema de ecuaciones normales:

$$\begin{bmatrix} n & \sum_{i=1}^n x_{1i} & \sum_{i=1}^n x_{2i} \\ \sum_{i=1}^n x_{1i} & \sum_{i=1}^n (x_{1i})^2 & \sum_{i=1}^n (x_{1i} \cdot x_{2i}) \\ \sum_{i=1}^n x_{2i} & \sum_{i=1}^n (x_{1i} \cdot x_{2i}) & \sum_{i=1}^n (x_{2i})^2 \end{bmatrix} \cdot \begin{pmatrix} b_0 \\ b_1 \\ b_2 \end{pmatrix} = \begin{bmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n (y_i \cdot x_{1i}) \\ \sum_{i=1}^n (y_i \cdot x_{2i}) \end{bmatrix}$$

Donde b_0 , b_1 y b_2 son estimadores de mínimos cuadrados para β_0 , β_1 y β_2 . (Ejemplo)

Peretti: en regresión lineal es cuando se encuentra un polinomio en 2d, pero en regresión múltiple hay una variable más pq estoy trabajando en el **espacio** (no en el plano), entonces no se encuentra una línea sino que se encuentra un plano. El profe le hizo mucho hincapié en la ecuación modelo de ese plano (le preguntó cuales son variables, cuales son constantes (b_0 , b_1 , ...), como se hace para minimizar el error y el respondio que también se aplica el método de los mínimos cuadrados)

UNIDAD VI: ANÁLISIS DE VARIANZA

6 A-1) DISEÑOS COMPLETAMENTE ALEATORIOS esto le tomaron a Guarnier (ANOVA). +2.

Interesa probar la hipótesis de que las medias de k poblaciones son todas iguales.

Se supone que el experimentador cuenta con los resultados de k muestras aleatorias independientes, cada una de tamaño n , de k diferentes poblaciones (datos relativos a k tratamientos, k grupos, k métodos de producción, etc.).

Un tratamiento es algo que se aplica a un grupo para ver su efecto.

	n1	n2	...			n	Medias
Muestra 1	y_{11}	y_{12}		y_{1i}		y_{1n}	$\bar{y}_1$
Muestra 2	y_{21}	y_{22}		y_{2i}	...	y_{2n}	$\bar{y}_2$
.....	...	...			...		
Muestra i	y_{i1}	y_{i2}		y_{ii}	...	y_{in}	$\bar{y}_i$
.....	...	...			...		
Muestra k	y_{k1}	y_{k2}		y_{ki}	...	y_{kn}	$\bar{y}_k$
							$\bar{y}_.$

y_{11} : Primer durazno de la Parcela 1 tratado con el Fertilizante A (el primer índice, genéricamente i , indica tratamiento). El segundo, j , la posición del elemento extraído de la muestra)

y_{ij} : i -ésimo durazno de la Parcela j -ésima tratado con el i -ésimo Fertilizante.

Donde $\bar{y}_1$ es la media aritmética de la muestra 1 y $\bar{y}_.$ es la media global (media de medias).

Se realiza una prueba de hipótesis considerando que las distintas muestras tienen medias iguales (hipótesis nula), donde se supone que las muestras vienen de poblaciones **con distribuciones normales**, y **tienen la misma varianza σ^2** . Si desconozco qué distribución tienen las poblaciones voy a tener que hacer

una **prueba de bondad de ajuste** para verificar si las muestras tienen distribución normal y en todas las misma varianza.

Cada observación y_{ij} se puede escribir como la media de la muestra μ_i más un error aleatorio ϵ_{ij} . Para dar uniformidad a las ecuaciones, se reescribe μ_i en la media general μ (media de las medias) más el efecto del tratamiento $\alpha_i = \mu_i - \mu$, quedando: $\alpha_i = \mu_i - \mu \rightarrow \alpha_i = \bar{y}_i - \bar{y}_\cdot \rightarrow$ Si da + hay un efecto positivo y si da - hay un efecto negativo

$y_{ij} = \mu + \alpha_i + \epsilon_{ij}$ para $i=1,2,\dots,k; j=1,2,\dots,n$ **$\epsilon_{ij} = \mu$ es 0 y σ^2 común**

ϵ_{ij} a esto se le llama ruido

La suma de los efectos de los tratamientos α_i es 0 porque algunos aumentan la media y otros la reducen, equilibrándose entre sí.

La Hipótesis Nula se puede expresar diciendo que los efectos de los tratamientos $\alpha_1 = \alpha_2 = \dots = \alpha_k = 0$. Ya que si todas las medias fueran iguales, los efectos serían 0. Por otro lado, la Hipótesis Alternativa de que al menos dos de las medias son distintas equivale a que al menos un α_i sea distinto de 0.

Para probar la Hipótesis Nula, se comparan las estimaciones de σ^2 (una en base a la observación de las medias muestrales y la otra con la variación dentro de la muestra).

Ya que cada muestra viene de una población con varianza σ^2 , la varianza se puede estimar de cualquiera de las muestras:

$$s_i^2 = \frac{1}{n-1} \cdot \sum_{j=1}^n (y_{ij} - \bar{y}_i)^2$$

Esta fórmula permite estimar la varianza de la muestra i.

y entonces para estimar la varianza sigma cuadrado se deben promediar estas k varianzas:

$$\hat{\sigma}_W^2 = \frac{1}{k} \cdot \sum_{i=1}^k s_i^2 = \frac{1}{k \cdot (n-1)} \cdot \sum_{i=1}^k \sum_{j=1}^n (y_{ij} - \bar{y}_i)^2$$

cada una de las varianzas muestrales s_i^2 está basada en $(n-1)$ grados de libertad y entonces $\hat{\sigma}_W^2$ está basada en $k \cdot (n-1)$ grados de libertad.

$\hat{\sigma}_W^2$ es la varianza a lo ancho ($W = \text{width}$)

Por otro lado, la varianza de las k medias muestrales está dada por:

$$s_{\bar{x}}^2 = \frac{1}{k-1} \cdot \sum_{i=1}^k (\bar{y}_i - \bar{y}_{..})^2$$

y si la hipótesis es verdadera, esta expresión da una estimación de σ^2/n y así una estimación de σ^2 , pero basada en la diferencia entre las medias, está dada por:

$$\hat{\sigma}_H^2 = n \cdot s_{\bar{x}}^2 = \frac{n}{k-1} \cdot \sum_{i=1}^k (\bar{y}_i - \bar{y}_{..})^2 \quad \text{basada en } (k-1) \text{ grados de libertad.}$$

Para entender sigma de h y de w. SIGMA DE W mide como varían los datos dentro de cada grupo (Y luego se saca el promedio de esas varianzas. Si da bajo es que con cada uno de los fertilizantes utilizados crecen de manera similar ese conjunto. Pero SIGMA DE H hace la COMPARACIÓN con los otros fertilizantes, si da un número alto quiere decir que hay algunos métodos más eficientes que otros. ES POR ESO QUE SIGMA DE W UTILIZA LA MEDIA DE SU RESPECTIVO GRUPO Y SIGMA DE H UTILIZA LA MEDIA TOTAL

σ_H^2 : Varianza entre grupos (o varianza debida a los tratamientos).

σ_W^2 : Varianza dentro de los grupos (o varianza debida al error aleatorio).

1. Varianza entre grupos: Representa la variabilidad debida a las diferencias entre las medias de los grupos.

Si los grupos son significativamente diferentes, σ_H^2 será grande.

Se calcula como la variabilidad de las medias de los grupos respecto a la media global.

2. Varianza dentro de los grupos: Representa la variabilidad dentro de cada grupo, es decir, las diferencias entre las observaciones individuales y la media de su grupo.

Captura el ruido o error aleatorio que no puede ser explicado por los tratamientos.

Se calcula como el promedio de las varianzas dentro de cada grupo.

De manera fácil de ver.

Sigma de W que es a lo ancho se refiere a la varianza de cada muestra pero para que ese estimador sea un estimador de la varianza poblacional tenemos que sumar las varianzas de cada una de las muestras y dividirla por la cantidad de muestras (promedio de cada una de las varianzas muestrales).

Sigma de H es la varianza respecto entre las muestras, por eso calculo la varianza de cada muestra respecto de la media global. Y luego multiplico esa varianza por la cantidad de columnas que hay en la muestra.

Con esas dos estimaciones (W y H), puedo obtener F, ya que el cociente de varianzas tiene distribución F.

Si H_0 es cierta, se puede demostrar que $\hat{\sigma}_W^2$ y $\hat{\sigma}_H^2$ son estimaciones independientes de σ^2 y por ello:

$$F = \hat{\sigma}_H^2 / \hat{\sigma}_W^2$$

Es una variable aleatoria con distribución F con $v_1 = k-1$ (grados de libertad del numerador) y $v_2 = k \cdot (n-1)$ (grados de libertad del denominador) grados de libertad.

Cabe esperar que la varianza entre muestras ($\hat{\sigma}_H^2$) exceda la varianza dentro de las muestras ($\hat{\sigma}_W^2$), y cuando la Hipótesis Nula es falsa, por eso H_0 será rechazada si $F > F_{\alpha}$.

Es notable el hecho de que las dos estimaciones en cuestión [excepto para los divisores $(k-1)$ y $k(n-1)$] pueden obtenerse “partiendo” o analizando la varianza total de las $n \cdot k$ observaciones en dos partes. La varianza muestral de las $n \cdot k$ observaciones está dada por:

$$s^2 = \frac{1}{k \cdot n - 1} \sum_{i=1}^k \sum_{j=1}^n (y_{ij} - \bar{y})^2$$

se puede probar el siguiente teorema respecto del numerador, llamado Suma de Cuadrados Total:

$$\sum_{i=1}^k \sum_{j=1}^n (y_{ij} - \bar{y})^2 = \sum_{i=1}^k \sum_{j=1}^n (y_{ij} - \bar{y}_i)^2 + n \cdot \sum_{i=1}^k (\bar{y}_i - \bar{y})^2$$

y como:

$$\sum_{j=1}^n (y_{ij} - \bar{y}_i) = 0$$

la suma de las desviaciones de las observaciones con respecto a la media de ese grupo es cero.

se verifica la relación anterior y se acostumbra a denotar:

$$C = \frac{1}{k \cdot n} \left(\sum_{i=1}^k \sum_{j=1}^n y_{ij} \right)^2$$

C es la suma de todos los elementos de la matriz elevado al cuadrado y luego se lo multiplica por $1/kn$

a) Suma de Cuadrados Total, SST:

$$SST = \sum_{i=1}^k \sum_{j=1}^n (y_{ij} - \bar{y})^2$$

SST se calcula tomando cada elemento de la matriz elevándolo al cuadrado y sumándolo y luego a esa sumatoria se le resta el valor de C

$$SST = \sum_{i=1}^k \sum_{j=1}^n (y_{ij})^2 - C$$

b) Suma de Cuadrados de Tratamiento SS(Tr):

$$SS(Tr) = (k-1) \cdot \hat{\sigma}_H^2 = n \cdot \sum_{i=1}^k (\bar{y}_i - \bar{y})^2$$

cada T_i es la suma de todos los elementos de una fila de la matriz

$$SS(Tr) = \frac{1}{n} \cdot \sum_{i=1}^k (T_i)^2 - C$$

c) Suma de Cuadrados de Error, **SSE**:

$$SSE = k \cdot (n-1) \cdot \hat{\sigma}_W^2 = \sum_{i=1}^k \sum_{j=1}^n (y_{ij} - \bar{y}_i)^2$$

$$SSE = SST - SS(Tr)$$

Como la suma de cuadrados total es la suma de cuadrados de error más la suma de cuadrados de tratamiento entonces $SSE = SST - SS(Tr)$

Luego, **F** se puede escribir así:

$$F = \frac{\frac{SS(Tr)}{k-1}}{\frac{SSE}{k \cdot (n-1)}}$$

los resultados obtenidos son resultados en la siguiente tabla ANOVA:

Fuentes de Variación	Grados de Libertad	Suma de Cuadrados	Media Cuadrada	F
Tratamientos	k-1	SS(Tr)	MS(Tr)=SS(Tr)/(k-1)	MS(Tr)/MSE
Error	k.(n-1)	SSE	MSE=SSE/k.(n-1)	
Total	n.k-1	SST		

Por ejemplo que se quiera probar si las medias de k muestras sean significativamente igual (Hipótesis Nula) con $\alpha=0.05$ a través de una Tabla de análisis de varianza. Entonces:

- 1) Se plantea la Hipótesis nula y la alterna. En este caso que la H_0 es que las medias son iguales (y nulas) y la H_1 que son diferentes.
- 2) Calculamos el F crítico con los grados de libertad del numerador (k-1) y grados de libertad del denominador (k.(n-1)), y el nivel de significancia $\alpha=0.05$.

k := 4	número de tratamientos
n := 12	tamaño de la muestra
$\nu_1 := k - 1 = 3$	grados de libertad del numerador
$\nu_2 := k \cdot (n - 1) = 44$	grados de libertad del denominador
F05 := qF(1 - α, ν_1, ν_2) = 4.261	F crítico

Ese 4.261 sería la abscisa que deja a la derecha un área del 5% (en caso de que sea prueba de cola derecha). Entonces ya tenemos la zona de aceptación y de rechazo

3) Ahora calculamos C, SST, SS(Tr) y SSE:

$$\begin{aligned} n &:= \text{cols}(y) = 12 && \text{Tamaño de las muestras} \\ nk &:= \text{rows}(y) = 4 && \text{Número de tratamientos} \\ i &:= 1..k & j &:= 1..n && \text{Índices} \\ C &:= \frac{1}{k \cdot n} \cdot \left(\sum_{i=1}^k \sum_{j=1}^n y_{i,j} \right)^2 = 2.847 && \text{Término de corrección} \\ T_i &:= \sum_{j=1}^n y_{i,j} && \text{Vector de suma de filas} \end{aligned}$$

$$SST := \sum_{i=1}^k \sum_{j=1}^n (y_{i,j})^2 - C = 0.081$$

Suma de cuadrados total

$$SS_{Tr} := \frac{1}{n} \cdot \sum_{i=1}^k (T_i)^2 - C = 0.013$$

Suma de cuadrados de tratamientos

$$SSE := SST - SS_{Tr} = 0.0679$$

Suma de cuadrados de error

$$MS_{Tr} := \frac{SS_{Tr}}{k - 1} = 0.0043$$

Media cuadrática de tratamientos

$$MSE := \frac{SSE}{k \cdot (n - 1)} = 0.0015$$

Media cuadrática del error

4) Con eso ya puedo calcular el estadístico F

$$F := \frac{0.0043}{0.0015} = 2.87$$

Estadístico


5) Si el F calculado es más chico (está a la izq) que el F crítico se acepta la H0. En caso contrario se rechaza y por lo tanto las medias son significativamente diferentes.

****Valores de la tabla**** Grados de libertad laboratorio → Cantidad de laboratorios - 1
 Grados de libertad Total → Cantidad de celdas - 1
 Grados de libertad Error → Total - laboratorio

La tabla queda

Fuentes de Variación	Grados de Libertad	Suma de Cuadrados	Media Cuadrada	F
Laboratorios	3	0.0130	0.0043	2.87
Error	44	0.0679	0.0015	
Total	47	0.0809		

Como el estadístico F (azul) quedó en zona de aceptación, se acepta la Hipótesis nula:



Para estimar los parámetros μ (media), α_1 , α_2 , α_3 y α_4 (efectos):

$$\mu = \frac{1}{n \cdot k} \sum_{i=1}^k \sum_{j=1}^n y_{ij} = \bar{\bar{y}}$$

Donde se debería cumplir que: $y_i - u = 0$, siendo u la sumatoria de los y_i

para un i dado:

$$\sum_{j=1}^n -2 \cdot (y_{ij} - \mu - \alpha_i) = 0 \quad \sum_{j=1}^n \alpha_i = \sum_{j=1}^n y_{ij} - \sum_{j=1}^n \mu$$

$$n \cdot \alpha_i = \sum_{j=1}^n y_{ij} - n \cdot \bar{\bar{y}} \quad \alpha_i = \bar{y}_i - \bar{\bar{y}}$$

Ejemplo:

													Total
Lab. A	.25	.27	.22	.30	.27	.28	.32	.24	.31	.26	.21	.28	3.21
Lab. B	.18	.28	.21	.23	.25	.20	.27	.19	.24	.22	.29	.16	2.72
Lab. C	.19	.25	.27	.24	.18	.26	.28	.24	.25	.20	.21	.19	2.76
Lab. D	.23	.30	.28	.28	.24	.34	.20	.18	.24	.28	.22	.21	3.00
Total													11.69

$$\mu = \frac{11.69}{48} = 0.244$$

$$\alpha_1 = \frac{3.21}{12} - \frac{11.69}{48} = 0.024$$

siendo 3.21 la sumatoria de los elementos del Lab. A

$$\alpha_2 = \frac{2.72}{12} - \frac{11.69}{48} = -0.017$$

siendo 2.72 la sumatoria de los elementos del Lab. B

$$\alpha_3 = \frac{2.76}{12} - \frac{11.69}{48} = -0.0135$$

siendo 2.76 la sumatoria de los elementos del Lab. C

$$\alpha_4 = \frac{3.00}{12} - \frac{11.69}{48} = 0.006$$

siendo 3 la sumatoria de los elementos del Lab. D

TAMAÑOS MUESTRALES DISTINTOS

La alternativa que se va a ver ahora permite que los tamaños muestrales del experimento puedan ser distintos. Ahora cada fila puede tener distinta cantidad de columnas

El Análisis de Varianza descripto, se aplica a criterios de clasificación en que cada muestra tiene el mismo número de observaciones. Si no es así, y los tamaños muestrales son $n_1, n_2, \dots, n_k$ se tiene que sustituir $N = \sum n_i$ por $n.k$ en todo lo anterior, quedando el siguiente esquema de partida:

							Medias
Muestra 1	y_{11}	y_{12}		y_{1i}		y_{1n_1}	$\bar{y}_1$
Muestra 2	y_{21}	y_{22}		y_{2i}	...	y_{2n_2}	$\bar{y}_2$
.....	...	...			...		
Muestra i	y_{i1}	y_{i2}		y_{ii}	...	y_{in_i}	$\bar{y}_i$
.....	...	...			...		
Muestra k	y_{k1}	y_{k2}		y_{ki}	...	y_{kn_k}	$\bar{y}_k$
							$\bar{y}_.$

									Total
Marca A	0.5	0.0	3.2	1.4	0.0	1.0	8.6	2.9	17.6
Marca B	4.7	6.2	0.0	10.5	2.1	0.8			24.3
Total									41.9

Se obtiene la varianza dentro de la muestra:

$$s_i^2 = \frac{1}{n_i - 1} \cdot \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_i)^2$$

Notar el n sub i en el imite de la sumatoria va diciendo que longitud tiene cada muestra (cada fila). Antes iba desde 1 hasta n mientras que ahora va desde 1 hasta n_1 , desde 1 hasta n_2 y así ...

y

$$\hat{\sigma}_W^2 = \frac{1}{k} \cdot \sum_{i=1}^k s_i^2 = \sum_{i=1}^k \sum_{j=1}^{n_i} \frac{(y_{ij} - \bar{y}_i)^2}{k \cdot (n_i - 1)}$$

la varianza de las k medias muestrales es:

$$s_{\bar{y}}^2 = \sum_{i=1}^k \frac{(\bar{y}_i - \bar{y}_{..})^2}{k - 1}$$

y

$$\hat{\sigma}_H^2 = \sum_{i=1}^k n_i \cdot \frac{(\bar{y}_i - \bar{y}_{..})^2}{k - 1}$$

con lo cual se determina:

$$F = \frac{\hat{\sigma}_H^2}{\hat{\sigma}_W^2}$$

La varianza muestral de las N observaciones está dada por:

$$s^2 = \sum_{i=1}^k \sum_{j=1}^{n_i} \frac{(y_{ij} - \bar{y}_{..})^2}{N - 1} \quad N = k \cdot \left(\sum_i n_i \right)$$

Con N-1 gl TOTALES

Donde N es la suma de los tamaños de cada muestra ($n_1 + n_2 \dots + n_k$), multiplicado por k (cantidad de muestras)

se puede demostrar que:

$$\sum_{i=1}^k \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_{..})^2 = \sum_{i=1}^k \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_i)^2 + \sum_{i=1}^k n_i \cdot (\bar{y}_i - \bar{y}_{..})^2$$

$$SST = SSE + SS(Tr)$$

Con:

$$SST = \sum_{i=1}^k \sum_{j=1}^{n_i} (y_{ij})^2 - C \quad SS(Tr) = \sum_{i=1}^k \frac{(T_i)^2}{n_i} - C$$

siendo:

$$C = \frac{1}{N} \cdot \left(\sum_{i=1}^k \sum_{j=1}^{n_i} y_{ij} \right)^2 \quad T_i = \left(\sum_{j=1}^{n_i} y_{ij} \right)$$

Problema: El contenido de aflatoxina, en partes por millón, de algunas muestras de crema de mani se prueba y se consiguen los siguientes resultados:

									Total
Marca A	0.5	0.0	3.2	1.4	0.0	1.0	8.6	2.9	17.6
Marca B	4.7	6.2	0.0	10.5	2.1	0.8			24.3
Total									41.9

- a) Emplear Análisis de Varianza para probar si las dos marcas difieren en contenido de aflatoxina, con un nivel de significancia $\alpha=0.05$.
- b) Probar la misma hipótesis usando la prueba t-bimuestral.

1. Hipótesis nula: las dos marcas difieren en contenido de aflatoxina
Hipótesis alternativa: No difieren

2. Nivel de significancia: $\alpha = 0.05$ $\alpha := 0.05$

Criterio se acepta la H_0 si $F < 2.816$

$$y1 := (0.5 \ 0 \ 3.2 \ 1.4 \ 0 \ 1.0 \ 8.6 \ 2.9)^T$$

$$y2 := (4.7 \ 6.2 \ 0 \ 10.5 \ 2.1 \ 0.8)^T$$

$$n_1 := \text{length}(y1) \quad n_2 := \text{length}(y2) \quad N := n_1 + n_2 = 14 \quad k := 2$$

$$\nu_1 := k - 1 = 1 \quad \nu := N - 1 = 13 \quad \nu_2 := \nu - \nu_1 = 12 \quad \text{g. de libertad}$$

$$F_{05} := qF(1 - \alpha, \nu_1, \nu_2) = 4.747 \quad t := 0, 0.01 \dots 10$$

Cálculos:

$$T_1 := \sum_{j=1}^{n_1} y_{1j} \quad T_2 := \sum_{j=1}^{n_2} y_{2j}$$

$$C := \frac{1}{N} \cdot \left(\sum_{j=1}^{n_1} y_{1j} + \sum_{j=1}^{n_2} y_{2j} \right)^2 = 125.401$$

$$SST := \sum_{j=1}^{n_1} (y_{1j})^2 + \sum_{j=1}^{n_2} (y_{2j})^2 - C = 146.249$$

$$SS_{Tr} := \sum_{i=1}^k \frac{(T_i)^2}{n_i} - C = 11.734$$

$$MS_{Tr} := \frac{SS_{Tr}}{\nu_1} = 11.734$$

$$SSE := SST - SS_{Tr} = 134.515$$

$$MSE := \frac{SSE}{\nu_2} = 11.21$$

$$F := \frac{MS_{Tr}}{MSE} = 1.047$$

Estadístico

+

Fuentes de Variación	Grados de Libertad	Suma de Cuadrados	Media Cuadrada	F
Tratamientos	1	11.74	11.74	1.05
Error	12	134.51	11.21	
Total	13	146.25		

Dado que $1.05 < 4.75$ (valor de F, de Tablas, con $\alpha=0.05$, $\nu_1=1$ y $\nu_2=12$) se Acepta la Hipótesis Nula, luego dos marcas NO difieren en el contenido de

CUANDO TENEMOS 2 MUESTRAS PODEMOS HACERLO CON T-BIMUESTRAL, ESTE SES UTILIZA PARA MUESTRAS CHICAS Y DISTRIBUCION NORMAL. CON MAS MUESTRAS NO SE PUEDE.

DISEÑO EN BLOQUES ALEATORIOS esto le tomaron a uno que rindió con Sarmiento

Se supondrá que el experimentador tiene a su disposición mediciones relativas a **a** tratamientos distribuidos en **b** bloques. Primero se observará el caso en que hay exactamente una observación de cada tratamiento en cada bloque. Si y_{ij} denota la observación relativa al i -ésimo tratamiento y al j -ésimo bloque, $\bar{y}_{i\cdot}$ la media de las b observaciones para el i -ésimo tratamiento, $\bar{x}_{\cdot j}$ la media de las a observaciones en el j -ésimo bloque e $\bar{y}_{\cdot\cdot}$ la gran media de las $a \cdot b$ observaciones, se emplea el siguiente esquema en esta clase de clasificación con dos criterios:

	B ₁	B ₂		B _j		B _b	Medias
Tratamiento 1	y ₁₁	y ₁₂		y _{1j}		y _{1b}	$\bar{y}_{1\cdot}$
Tratamiento 2	y ₂₁	y ₂₂		y _{2j}	...	y _{2b}	$\bar{y}_{2\cdot}$
.....	...	...			...		
Tratamiento i	y _{i1}	y _{i2}		y _{ij}	...	y _{ib}	$\bar{y}_{i\cdot}$
.....	...	...			...		
Tratamiento a	y _{a1}	y _{a2}		y _{aj}	...	y _{ab}	$\bar{y}_{k\cdot}$
Medias	$\bar{y}_{\cdot 1}$	$\bar{y}_{\cdot 2}$		$\bar{y}_{\cdot j}$		$\bar{y}_{\cdot b}$	$\bar{y}_{\cdot\cdot}$

Al esquema se lo llama aleatorio, siempre que los tratamientos sean asignados al azar dentro de cada bloque.

Cuando se usa un punto en lugar de un subíndice, esto significa que la media se obtiene sumando sobre él.

El modelo que se supondrá para el análisis con una observación por “celda” está dado por:

$$y_{ij} = \mu + \alpha_i + \beta_j + \epsilon_{ij} \quad \text{para } i=1,2,\dots,a; j=1,2,\dots,b$$

ahora la observacion por celda es de esa forma, donde para cualquier elemento de la matriz hay una media global + efecto de la fila + efecto de la columna + el ruido. En cada medida esta presente la media gobal y el impacto q ocasionan la fila y la columna.

aquí μ es la gran media, α_i es el efecto de i -ésimo tratamiento, β_j el efecto del j -ésimo bloque y los ϵ_{ij} son valores de variables aleatorias independientes normalmente distribuidas que tienen media cero y varianza común σ^2 . Se restringen los parámetros imponiendo las condiciones que:

$$\sum_{i=1}^a \alpha_i = 0 \quad \sum_{j=1}^b \beta_j = 0$$

En el análisis de clasificación con dos criterios, cada tratamiento es representado una vez dentro de cada bloque, el objetivo principal consiste en probar la significancia de las diferencias entre las $\bar{y}_{i\cdot}$, o sea, probar la Hipótesis Nula: $\alpha_1 = \alpha_2 = \dots = \alpha_k = 0$.

Más aún, quizás convenga probar si la división en bloques ha sido eficaz, esto es probar que la Hipótesis Nula: $\beta_1 = \beta_2 = \dots = \beta_k = 0$ puede rechazarse.

En cualquier caso, la Hipótesis alterna establece que al menos uno de los efectos no es cero.

Como en el análisis con un criterio, se fundará la prueba de significancia mediante comparaciones de σ^2 (una basada en la variación entre tratamientos, la otra basada en la variación entre bloques y la última que mide el error experimental). Nótese que sólo el último es una estimación de σ^2 cuando cualquiera (o ambas) las Hipótesis Nulas no son válidas.

Las sumas de cuadrados requeridas están dadas por el siguiente teorema:

$$\sum_{i=1}^a \sum_{j=1}^b (y_{ij} - \bar{y}_{..})^2 = \sum_{i=1}^a \sum_{j=1}^b (y_{ij} - \bar{y}_{i.} - \bar{y}_{.j} + \bar{y}_{..})^2 + \dots$$

$$+ b \cdot \sum_{i=1}^a (\bar{y}_{i.} - \bar{y}_{..})^2 + a \cdot \sum_{j=1}^b (\bar{y}_{.j} - \bar{y}_{..})^2$$

$$SST = SSE + SS(Tr) + SS(BI)$$

En la práctica se usan las siguientes fórmulas:

$$SST = \sum_{i=1}^a \sum_{j=1}^b (y_{ij})^2 - C \quad SS(Tr) = \frac{1}{b} \cdot \sum_{i=1}^a (T_{i.})^2 - C$$

$$SST(BI) = \frac{1}{a} \cdot \sum_{j=1}^b T_{.j}^2 - C \quad C = \frac{1}{a \cdot b} \cdot T_{..}^2$$

donde:

C es el término de corrección

$T_{i.}$ es la suma de las b observaciones para el i-ésimo tratamiento

$T_{.j}$ es la suma de las a observaciones para el j-ésimo bloque

$T_{..}$ es la suma de todas las observaciones

Empleando esta sumas de cuadrados, se puede rechazar la Hipótesis Nula de que las α_i son todas nulas, con un nivel de significancia α si:

$$F_{Tr} = \frac{MS(Tr)}{MSE} = \frac{\frac{SS(Tr)}{a-1}}{\frac{SSE}{(a-1) \cdot (b-1)}}$$

excede F_{α} con (a-1) y (a-1).(b-1) grados de libertad. La Hipótesis Nula de que todas las β_j son todas nulas, con un nivel de significancia α si:

$$F_{BI} = \frac{MS(BI)}{MSE} = \frac{\frac{SS(BI)}{b-1}}{\frac{SSE}{(a-1) \cdot (b-1)}}$$

excede F_{α} con $(b-1)$ y $(a-1) \cdot (b-1)$ grados de libertad. Nótese que las medias de los cuadrados $MS(Tr)$, $MS(BI)$ y MSE se definen otra vez como las correspondientes sumas de cuadrados divididas entre sus grados de libertad.

La siguiente tabla resume todo el procedimiento:

Fuentes de Variación	Grados de Libertad	Suma de Cuadrados	Media Cuadrada	F
Tratamientos	a-1	SS(Tr)	$MS(Tr)=SS(Tr)/(a-1)$	$F_{Tr} = MS(Tr)/MSE$
Bloques	b-1	SS(BI)	$MS(BI)=SS(BI)/(b-1)$	$F_{BI} = MS(BI)/MSE$
Error	$(a-1) \cdot (b-1)$	SSE	$MSE=SSE/(a-1) \cdot (b-1)$	
Total	a.b-1	SST		

Con diseño en bloques aleatorios se sacan dos conclusiones de una misma prueba.

Ejemplo:

Ejemplo: Se diseñó un experimento para estudiar el rendimiento de cuatro detergentes diferentes. Las siguientes lecturas de “blancura” se obtuvieron con un equipo especialmente diseñado para 12 cargas de lavado , distribuidas en tres modelos de lavadoras:

	Lavadora 1	Lavadora 2	Lavadora 3	Totales
Detergente A	45	43	51	139
Detergente B	47	46	52	145
Detergente C	48	50	55	153
Detergente D	42	37	49	128
Totales	182	176	207	565

Considerando los detergentes como **tratamientos** y las lavadoras como **bloques**, obtener la Tabla de Análisis de Varianza y probar, con un nivel de significación 0.01, si existen diferencias entre los detergentes y/o entre las lavadoras.

- Hipótesis Nula: $\alpha_1 = \alpha_2 = \alpha_3 = \alpha_4 = 0$, $\beta_1 = \beta_2 = \beta_3 = 0$
Hipótesis Alternativa: no todas las α y tampoco las β iguales a 0.

2 - Nivel de significancia: $\alpha = 0.01$.

$$\alpha := 0.01$$

$$y := \begin{pmatrix} 45 & 43 & 51 & 139 \\ 47 & 46 & 52 & 145 \\ 48 & 50 & 55 & 153 \\ 42 & 37 & 49 & 128 \\ 182 & 176 & 207 & 565 \end{pmatrix}$$

$$a := \text{rows}(y) - 1 = 4$$

$$b := \text{cols}(y) - 1 = 3$$

3- Criterio: Se rechaza H_0 si $F > 9.78$ (este valor corresponde a $F_{0.01}$ con $v_1 = 3$ y $v_2 = 6$)

O si $F > 10.9$ (este valor corresponde a $F_{0.01}$ con $v_1 = 2$ y $v_2 = 6$)

$$v_1 := a - 1 = 3$$

$$v_2 := b - 1 = 2$$

$$v := a \cdot b - 1$$

$$v_3 := v - v_1 - v_2 = 6$$

$$F_{Tr01} := qF(1 - \alpha, v_1, v_3) = 9.78$$

F crítico para tratamiento

$$F_{Bl01} := qF(1 - \alpha, v_2, v_3) = 10.925$$

F crítico para bloques

4 Cálculos:

$i := 0 .. a - 1$ $j := 0 .. b - 1$ índices

$$T_punto_i := (y)^{\langle b+1 \rangle} \quad T_punto_i^T = (139 \ 145 \ 153 \ 128 \ 565)$$

$$T_j_punto := (y^T)^{\langle a+1 \rangle} \quad T_j_punto^T = (182 \ 176 \ 207 \ 565)$$

$$T_punto_punto := y_{a+1, b+1} = 565$$

$$C := \frac{T_punto_punto^2}{a \cdot b} = 26602.083$$

$$SST := \sum_{i=1}^a \sum_{j=1}^b (y_{i,j})^2 - C = 264.917$$

$$SS_Tr := \frac{1}{b} \cdot \sum_{i=1}^a (T_punto_i)^2 - C = 110.917$$

$$SS_Bl := \frac{1}{a} \cdot \sum_{j=1}^b (T_j_punto_j)^2 - C = 135.167$$

$$SSE := SST - SS_Tr - SS_Bl = 18.833$$

Fuentes de Variación	Grados de Libertad	Suma de Cuadrados	Media Cuadrada	F
Detergentes	3	111	37.0	11.6
Lavadoras	2	135	67.5	21.1
Error	6	19	3.2	
Total	11	265		