

La **varianza** mide la dispersión de los datos respecto a la media y se calcula como el promedio de los cuadrados de las diferencias. Aunque la **desviación estándar** es más intuitiva porque tiene las mismas unidades que los datos, la **varianza** es útil porque:

- **Facilita** cálculos en modelos estadísticos (como en regresión y estimaciones).
- Se suma fácilmente en **combinaciones de variables aleatorias** (a diferencia de la desviación estándar).
- Es clave en **optimización** y teoría de **probabilidades** (por ejemplo, en **Mínimos Cuadrados**).

Se eleva al cuadrado para evitar que las diferencias se cancelen y para dar más peso a valores extremos.

UNIDAD I: CONCEPTOS

TEMA A) POBLACIONES Y MUESTRAS

Muestra aleatoria quiere decir que todos los posibles resultados (subconjuntos finitos n) de una población finita N tienen la misma probabilidad de ser elegidos. (todas las variables aleatorias tienen la misma distribución que la población original)

Una muestra aleatoria es vista como un conjunto de variables aleatorias independientes e idénticamente distribuidas

La idea principal es usar esta muestra aleatoria para hacer inferencias (**deducir o concluir**) sobre los parámetros de la población, como la media (μ) o la desviación estándar (σ). Para hacer estas inferencias, se <http://www.youtube.com> utilizan estadísticas (valores) calculadas a partir de las muestras, como la media muestral ($\bar{X}$) o la desviación estándar muestral (s)

La muestra no tiene que ser siempre aleatoria. Si tengo una preferencia en la selección de la muestra produce un sesgo en la inferencia.

¿La media muestral es la media poblacional? Únicamente en el caso en que la muestra sea toda la población, pero no tomo la muestra del tamaño de la población pq medir toda la población es caro, trabajoso y a veces imposible..

DISTRIBUCIONES

Las **distribuciones** son descripciones de cómo se distribuyen los valores de una variable en un conjunto de datos. Una distribución muestra la frecuencia o probabilidad de ocurrencia de los valores posibles de una variable.

Tipos de distribuciones

1. **Distribución de frecuencias:** Describe cuántas veces ocurre cada valor o rango de valores en un conjunto de datos.
 - Ejemplo: Una tabla que muestra cuántas personas tienen edades en diferentes rangos.
2. **Distribución de probabilidad:** Representa la probabilidad de que una variable aleatoria tome ciertos valores.
 - Ejemplo: La probabilidad de obtener un número específico al lanzar un dado.

1 A - 1 y 2) DISTRIBUCIÓN MUESTRAL DE LA MEDIA (σ conocida)

Si de alguna población de parámetros conocidos se extraen n muestras es difícil que la medias de tales muestras coincidan.

Si calculas la media de cada muestra de una población, y luego calculas la media de todas esas medias muestrales ($\mu_{\bar{x}}$) que has obtenido, este valor será igual (o muy cercano) a la media de la población original (μ).

La varianza de las medias muestrales es igual a la varianza de la población (σ^2) dividida por el tamaño de la muestra (n). A medida que el tamaño de la muestra (n) aumenta, la varianza de la distribución muestral disminuye (significa que las medias muestrales estarán más cerca de la media poblacional).

Si el tamaño de la muestra es suficientemente grande (generalmente se considera $n \geq 30$), la distribución muestral de la media se aproxima a una distribución normal, independientemente de la forma de la distribución de la población original. Este es el resultado del Teorema del Límite Central. Y si la muestra es menor a 30, la distribución de las medias dependerá de la distribución original de la población.

$$\sigma_{\bar{x}}^2 = \frac{\sigma^2}{n} \quad \text{como esta es la varianza, la desviación estándar es: } \frac{s}{\sqrt{n}} \quad s = \text{sigma}$$

Para muestras tomadas de poblaciones finitas (Poblaciones pequeñas) de tamaño N , hay que hacer una corrección, siendo N el tamaño de la población y n el tamaño de la muestra, quedando la varianza de esta distribución así:

$$\sigma_{\bar{x}}^2 = \frac{\sigma^2}{n} \cdot \frac{N - n}{N - 1}$$

INTERVALOS DE CONFIANZA PARA LA MEDIA (" σ " conocida)

Si la **media** proviene de una muestra grande ($n > 30$, aún suponiendo que no se conozca la varianza de la misma) es posible definir una variable aleatoria (estadístico) llamada **media estandarizada** cuyos valores están dados por:

$$Z = \frac{\bar{X} - \mu}{\frac{s}{\sqrt{n}}} \quad \text{donde sigma "}\sigma\text{" (desv estándar poblacional) se cambia por "s" (desv estándar muestral) ya que en la realidad difícilmente se conoce de antemano la desviación estándar de una población, y que tiene una distribución normal estándar.}$$

La distribución normal es una campana de gauss (el área bajo la curva vale 1). Que sea Estándar quiere decir que la campana de Gauss tiene media $\mu = 0$, desviación estándar $\sigma = 1$ y varianza = 1.

La media estandarizada determina cuán lejos está la media muestral de la media poblacional en una escala estándar, ayudando a evaluar si una muestra es representativa o si es inusual (expresándola en términos de desviaciones estándar).

Supongamos que piden una confianza del 90%, como esta debe ser a ambos lados de la "campana" deben quedar colas con áreas de 5%. Esto implica la siguiente desigualdad que define el intervalo de confianza:

$$-z_{5\%} \leq \frac{\bar{x} - \mu}{\frac{s}{\sqrt{n}}} \leq z_{5\%}$$

Y despejando μ :

$$\bar{x} - z_{5\%} \cdot \frac{s}{\sqrt{n}} \leq \mu \leq \bar{x} + z_{5\%} \cdot \frac{s}{\sqrt{n}}$$

TEOREMA CENTRAL DEL LÍMITE (para tener idea, no lo toma como tema)

Esta propiedad establece que, independientemente de la forma de la población original, la distribución de las medias muestrales tiende a seguir una distribución normal (Z) a medida que el tamaño de la muestra aumenta.

1 A-1 y 2) DISTRIBUCIÓN MUESTRAL DE LA MEDIA (σ desconocida)

Si se supone que la muestra no es grande (n menor que 30) pero que proviene de una población normal, se puede probar el siguiente teorema:


Si $\bar{x}$ es la media de una muestra aleatoria de tamaño n tomada de una población normal que tiene media μ y varianza σ^2 , entonces:

$$t = \frac{\bar{x} - \mu}{\frac{s}{\sqrt{n}}}$$

Es el valor de una variable aleatoria (estadístico) con distribución t-Student y parámetro $v=n-1$ (grados de libertad), siendo n el tamaño de la muestra.

Los **grados de libertad** son los valores que puedes elegir libremente en un cálculo, antes de que las restricciones (como la media) fijen los demás valores.

La varianza depende de los grados de libertad v . Cuando este valor tiende a infinito (n grande) la varianza de la distribución tiende a 1 y la t-Student se convierte en normal estándar. Mientras más grande es v es como que la curva tiene menos dispersión. La t student es parecida a la distribución normal ya que ambas son acampanadas y simétricas.



Ejemplo:

$t = -3.192$ sugiere que la media de la muestra está mucho más baja de lo esperado (3.192 desviaciones estándar por debajo).

1 A-3) TEOREMA DE CHEBYSHEV (No hay ni un ejercicio de esto, poco probable que lo tome)

(SI NO CONOZCO LA DISTRIBUCIÓN DE LA POBLACIÓN, DIRECTAMENTE USO CHEBYSHEV)

Cuando la muestra es pequeña ($n < 30$) y se supone que la población **no** está normalmente distribuida, no es

posible utilizar la distribución de probabilidad normal ni la t-Student para construir un intervalo de confianza. En este caso no se pueden usar los estadísticos z ni t que vimos más arriba.

El Teorema de Chebyshev establece: La proporción de las medias en un conjunto de datos que se sitúa dentro de las desviaciones estándar de la media no es menor de $1-1/k^2$, siendo $k \geq 1$.

$$P(|x_m - \mu| \leq k \cdot \sigma_{x_m}) \leq 1 - \frac{1}{k^2}$$

$\sigma_{x_m} \rightarrow$ desviación estándar de la distribución de medias

Haciendo operaciones matemáticas para despejar μ el intervalo queda:

$$x_m - k \cdot \frac{s}{\sqrt{n}}$$

extremo inferior del intervalo de confianza

$$x_m + k \cdot \frac{s}{\sqrt{n}}$$

extremo superior del intervalo de confianza

Esta fórmula construye un intervalo de confianza para la media, pero en vez de hablar de un estadístico como t o z, utilizamos un valor k.

Lo malo del chebysehv es que para los mismos tamaños de muestra da intervalos de confianza más grande que el estadístico t (teniendo la misma cantidad de muestras) y todavía más grande hecho con el z de la distribución normal. (Es decir que los datos están más dispersos, es menos preciso)

Pero lo bueno es que se puede usar sin saber de qué distribución viene la población.

TABLA DE RESUMEN PARA ESTIMACIÓN DE INTERVALOS DE CONFIANZA PARA LA MEDIA DE UNA POBLACIÓN.

Población	Tamaño de la muestra	σ conocida	σ desconocida
Normalmente Distribuida	Grande ($n \geq 30$)	$\bar{x} \pm z_{\alpha} \cdot \sigma_{\bar{x}}$	$\bar{x} \pm z_{\alpha} \cdot s_{\bar{x}}$
	Chica ($n < 30$)	$\bar{x} \pm z_{\alpha} \cdot \sigma_{\bar{x}}$	$\bar{x} \pm t_{\alpha} \cdot s_{\bar{x}}$
No Normalmente Distribuida	Grande ($n \geq 30$)	$\bar{x} \pm z_{\alpha} \cdot \sigma_{\bar{x}}$	$\bar{x} \pm z_{\alpha} \cdot s_{\bar{x}}$
	Chica ($n < 30$)	$\bar{x} \pm k \cdot \sigma_{\bar{x}}$ donde $1-1/k^2$ se define por medio del Teorema de Chebyshev	$\bar{x} \pm k \cdot s_{\bar{x}}$ donde $1-1/k^2$ se define por medio del Teorema de Chebyshev

IMPORTANTE!!

A la hora de elegir el estadístico tengo q preguntarme:

- 1) La población es grande (mayor a 30) o chica (menor a 30)

- 2) La población está normalmente distribuida o no
- 3) La varianza es conocida o desconocida

Entonces para encontrar el intervalo de confianza de la media:

- Cualquiera sea la distribución puedo usar chebyshev
- Si viene de normal y la muestra es chica y no conozco la desviación estándar uso t
- Si la muestra es grande, en cualquier circunstancia puedo usar la distribución normal, es decir uso el estadístico z

TEMA B: ESTIMACIÓN

1 B-1) DISTRIBUCIÓN MUESTRAL DE LA VARIANZA

Al estudiar la distribución muestral de la varianza, **una de las primeras apreciaciones es que no puede ser negativa**, luego es evidente que no puede responder a una distribución normal ya que implica una campana de gauss con valores positivos y negativos. **Es por ella que se usa una distribución Chi Cuadrado**

Si s^2 es la varianza de una muestra aleatoria de tamaño n tomada de una población normal cuya varianza es σ^2 , entonces:

$$\chi^2 = (n-1) \cdot \frac{s^2}{\sigma^2}$$


Es un valor de una variable aleatoria (estadístico) que tiene la distribución chi-cuadrado con parámetro $v=n-1$ que va a servir para elaborar intervalos de confianza.

También es importante **encontrar la razón de dos muestras tomadas aleatoriamente**. Sirve en pruebas **para determinar si dos muestras provienen de poblaciones con varianzas iguales**, en dicho caso la razón debe ser cercana a 1.

Si s_1^2 y s_2^2 son las varianzas de muestras aleatorias independientes de tamaño n_1 y n_2 , respectivamente, tomadas de dos poblaciones normales, entonces:

$$F = \frac{s_1^2}{s_2^2}$$

es una variable aleatoria que tiene la distribución **F(Fisher)** con parámetros $v_1 = n_1 - 1$ (grados de libertad del numerador) y $v_2 = n_2 - 1$ (grados de libertad del denominador)



1 B-2) INFERENCIAS RELATIVAS A MEDIAS

Estimación Puntual:

Es la elección de un estadístico a partir de los datos muestrales, que se utiliza como mejor aproximación al valor real de un parámetro desconocido en la población. Por ejemplo, usar la media muestral ($\bar{x}$) para estimar la media poblacional (μ). Acertar con este tipo de estimaciones es casi imposible, por lo que siempre se añade cierto error máximo de estimación $E = \bar{x} - \mu$ (diferencia entre la estimación y la cantidad que se supone estima)

Estimador Insesgado:


Un estadístico es un estimador insesgado si, al repetir el ensayo con muchas muestras, la media de las medias muestrales, acierta en el valor real que queremos estimar. No hay una desviación sistemática. Ej: Si calculo la media de muchas muestras de sandías de mi granja, siendo muestras representativas, es decir que tomo tanto sandías grandes, medianas y pequeñas. Por lo tanto la media de las medias muestrales tenderá a la media poblacional.

Estimador Sesgado:

El método de estimación, en promedio, no da el valor real del parámetro poblacional. Hay una desviación sistemática en una dirección particular (sobreestimación o subestimación). Ej: Si calculo la media únicamente de muestras que tienen sandías grandes, la media de las medias muestrales no tenderá a la media poblacional.

La eficiencia se mide sabiendo si un estimador es insesgado y que tan pequeña es la varianza de cada estimador. Un estimador es más eficiente que otro cuando su dispersión es menor.


Ej: Si tenemos 2 tiradores que disparan a dos blancos como en la imagen, el que tira al blanco de la derecha tiene un mejor arma, ya que las balas están menos dispersas, por lo tanto solo deberíamos compensar ese error en la mira. El de la izquierda no tiene un error corregible, el de la derecha si. Por lo tanto la de la derecha tiene un sesgo.



ESTIMACIÓN POR INTERVALOS DE CONFIANZA

Por lo dicho anteriormente, las probabilidades de estimar puntualmente en precisa el valor de un parámetro, con todas sus cifras decimales, es prácticamente nula. (ya que sería un integral con extremos iguales), por

esto es preferible determinar un intervalo dentro del cuál podamos afirmar (con cierta certeza, es decir, con cierto nivel de confianza) que el valor real de la media poblacional μ se encuentre en el intervalo.



Por ejemplo, si tomo un alumno cualquiera la probabilidad de que pese exactamente 62 kg es 0. Si quiero saber la probabilidad de que un alumno pese 62 kg tengo que hacer la integral desde 62 hasta 62 y esa área da 0. Uno puede pesar 62.01, otro 62.12 y así. La estimación puntual no es muy buena. Interesa estimar por intervalo, por ej. los alumnos que pesen 60 kg a 64 kg y ahí sí va a haber un área bajo la

curva pq los extremos de la integral van ser diferentes.

El intervalo se construye en base a la media muestral (Estimador puntual, osea la raya en medio de la campana). El área bajo la curva es el nivel de confianza que tengo, y la suma de lo sombreado es el nivel de significancia (alpha).

$$E = z_{\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}}$$

con probabilidad $1 - \alpha$

Como dijimos anteriormente: $E = x_m - u$

z → Indica que es una distribución normal

$\frac{\alpha}{2}$ → Es una probabilidad de cola

$z_{\frac{\alpha}{2}}$ → En conjunto z y $\frac{\alpha}{2}$, es la abscisa que me deja un área $\frac{\alpha}{2}$ a la derecha o a la izquierda de la curva normal.

$\alpha \rightarrow$ Me indica el nivel de significancia

$1 - \alpha \rightarrow$ Me indica el nivel de confianza o la probabilidad de que esté dentro de ese valor.

Los valores $\bar{x} - E$ y $\bar{x} + E$ (media muestral + el error y media muestral – el error) se los denomina **Límites de Confianza** (Las abscisas)

Para ilustrar esto, supongamos una muestra grande ($n \geq 30$) con μ y σ^2 conocidos entonces se puede asegurar con una confianza del $(1-\alpha)100\%$ que el intervalo

$$\left(\bar{x} - z_{\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}}, \bar{x} + z_{\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}} \right) \quad \text{Contiene a } \mu.$$

Este es un **Intervalo de Confianza** para μ , con un **Nivel de Confianza** $1 - \alpha$.

Para determinar el estadístico en casos de n chico o n grande, etc, miramos la tabla de **Distribución de la Media Muestral**. (Link a la tabla)

Si la población es normal, n es chico y no se conoce σ :

$$t = \frac{\bar{x} - \mu}{\frac{s}{\sqrt{n}}}$$

t es una variable aleatoria con distribución t-Student con $v=n-1$ grados de libertad.

Luego, el error máximo de estimación será: $E = t_{\frac{\alpha}{2}} \cdot \frac{s}{\sqrt{n}}$

Con una confianza del $(1-\alpha)100\%$ de que el error sea menor que esa cantidad.

Mientras mayor sea el nivel de significancia (α) entonces menor va a ser el nivel de confianza ($1-\alpha$) y menor va a ser el intervalo de confianza (los extremos van a ser más chicos) . Mientras menor sea el intervalo de confianza entonces es más preciso, hay menos dispersión de valores.

Puedo determinar el tamaño que debe tener la muestra para obtener un error máximo determinado y con un nivel de significancia determinado. Determinar n sirve para presupuestar: evaluar costos, tiempo etc.

$$E = z_{\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}} \quad n = \left(z_{\frac{\alpha}{2}} \cdot \frac{\sigma}{E} \right)^2$$