

UNIDAD III: VARIANZA Y PROPORCIONES

TEMA A: VARIANZA

3 A-1) ESTIMACIÓN DE LA VARIANZA

La varianza muestral s^2 es un estimador insesgado de la varianza poblacional σ^2 (siempre y cuando pongamos $n-1$ y no n en la fórmula de la varianza). Pero, la **desviación estándar muestral es un estimador sesgado de la desviación estándar**. Para muestras grandes, este sesgo es chico, pero en muestras chicas puede ser significativo. Por esto **se recurre al estimador R (Rango muestral)**, que es un **estimador insesgado de la desviación estándar**.

El rango muestral se calcula como el valor más grande de una muestra menos el más pequeño:

$$R = X_{\max} - X_{\min}$$

Se puede demostrar que si se tiene una población normal y se toman muestras de tamaño n , **el rango tiene una distribución normal con media $d_2 \cdot \sigma$ y con desviación estándar $d_3 \cdot \sigma$** , donde d_2 y d_3 son constantes que dependen del tamaño de la muestra y que se obtienen de la tabla de abajo:

d_2	1.128	1.693	2.054	2.326	2.534	2.704	2.847	2.970	3.078
d_3	0.853	0.888	0.880	0.864	0.848	0.833	0.830	0.808	0.797
N	2	3	4	5	6	7	8	9	10

Luego R/d_3 es un estimador insesgado de σ .

El rango se emplea fundamentalmente en Control de Calidad.

En **muestras aleatorias chicas** (menores que 30) de poblaciones normales **se puede determinar un estadístico, el cual tiene una distribución chi cuadrado con $n-1$ grados de libertad**. Este me permite elaborar un intervalo de confianza para la desviación estándar.

$$\chi^2 = \frac{(n-1) \cdot s^2}{\sigma^2} \quad \text{con } v = n-1 \text{ grados de libertad}$$

Obtenemos el intervalo de confianza para la varianza.

$$\frac{(n-1) \cdot s^2}{\left(\chi^2\right)_{1-\frac{\alpha}{2}}} < \sigma^2 < \frac{(n-1) \cdot s^2}{\left(\chi^2\right)_{\frac{\alpha}{2}}}$$

Si tomo la raíz cuadrada en los tres miembros, obtengo el intervalo de confianza para la desviaciones estándar.

Ahora **si el tamaño de la muestra es grande** (mayor a 30), **la distribución de la desviación estándar se puede**

aproximar con una distribución normal con media σ y desviación estándar $\frac{\sigma}{\sqrt{2 \cdot n}}$. También con muestras grandes se puede observar que la distribución chi cuadrado se aproxima a la normal, al darle valores de n mayores que 30 se puede estimar con una normal.

$$Z = \frac{s - \sigma}{\frac{\sigma}{\sqrt{2 \cdot n}}}$$

Estadístico Z (distribución normal estándar) con media σ y desviación estándar $\frac{\sigma}{\sqrt{2 \cdot n}}$

Obtenemos el intervalo de confianza para la desviación estándar.

$$\frac{s}{1 + \frac{Z_{\alpha/2}}{\sqrt{2 \cdot n}}} < \sigma < \frac{s}{1 - \frac{Z_{\alpha/2}}{\sqrt{2 \cdot n}}}$$

De igual forma para una muestra de gran tamaño se puede usar la chi cuadrado pero sería innecesario.

Para estimar la desviaciones estándar poblacional con la desviación estándar muestral utilizamos en muestras pequeñas R/d3 y para muestras grandes raíz cuadrada de $S^2 = \frac{\sum (x - \bar{x})^2}{n-1}$. En muestras chicas el intervalo de confianza de la desv estándar poblacional se utiliza CHI CUADRADO, y en muestra grande Z.

3 A-2) HIPÓTESIS REFERIDA A UNA VARIANZA

Se quiere probar la hipótesis nula de que la varianza de una población es igual a una determinada, contra una alternativa unilateral o bilateral adecuada. Si me interesa que la desviación no sea mayor a x valor entonces será prueba de cola derecha. Si me interesa que la desviación sea por lo menos x entonces será prueba de cola izq. Y si necesito que la desviación estándar esté entre dos valores entonces será bilateral.

Los datos conocidos son: la desviación estándar de referencia σ_0 y la desviación estándar muestral s.

La H_0 es $\sigma = \sigma_0$ (Se quiere verificar si la desv. estándar poblacional es significativamente igual a una esperada, a través de la desv. muestral)

Nunca se va a probar si la desviación estándar o varianza son más chicas. Por lo tanto siempre es de cola derecha

Para muestras aleatorias extraídas de una población normal con varianza σ^2 , se utiliza chi cuadrado:

$$\chi^2 = \frac{(n-1) \cdot s^2}{(\sigma_0)^2}$$

siendo sigma cero el sigma de la hipótesis nula que se plantea

Recordar que si la población que se muestrea tiene un tamaño relativo grande ($n \geq 30$) la hipótesis nula se puede probar con:

$$Z = \frac{s - \sigma_0}{\frac{\sigma_0}{\sqrt{2 \cdot n}}}$$

es decir, se puede usar el estadístico z en vez del chi cuadrado

TEMA B: PROPORCIONES

3 B-1) ESTIMACIÓN DE PROPORCIONES

Por ej que de la población de Mendoza tomó una muestra de tamaño 100 y le pregunto a cada uno si bebe vino o no. De la muestra de tamaño 100 encontré que 35 toman vino. Sin embargo, no podría concluir que la proporción de los mendocinos que toman vino es del 35% ya que a esta conclusión la estoy sacando de una sola muestra y probablemente no sea muy representativa. Pero estadísticamente, con el pivote en esa estimación puntual, puedo establecer un intervalo de confianza que me permita decir con una confianza del 95 o 99% que entre el $X_1\%$ e $X_2\%$ (valores de ejemplo) de la proporción de población de Mendoza bebe vino, basándome en una muestra de 100 personas.

Por ejemplo, podría decir que entre 30 y 40 está la proporción de personas que beben vino en Mendoza basado en una muestra de tamaño 100 con un nivel de confianza del 95%. Quiere decir que si yo repitiera 1000 veces el experimento en 950 ocasiones estaría ubicado dentro del intervalo de 30 y 40.

La información que suele disponerse al estimar la proporción es el número de veces x , que un evento ocurre en n ensayos, ocasiones u observaciones.

La estimación puntual de la proporción poblacional p (prop real) suele ser x/n (proporción muestral, es un estimador insesgado de p , es decir: $p=x/n$).

Se quiere estimar p que es un parámetro poblacional a través de x/n .

Para n ensayos que satisfacen la distribución binomial, se verifica $\mu = n \cdot p$ es la media y $\sigma = \sqrt{n \cdot p \cdot (1 - p)}$ la desviación estándar, y si se divide por n , se encuentra la media y la desviación estándar de la proporción de éxitos (es decir la proporción muestral)

Ya que x y x/n son variables discretas, un intervalo de confianza de exactamente $(1 - \alpha) \cdot 100\%$ es difícil de lograr. Como x y x/n son variables discretas el intervalo de confianza que se va a lograr no es un intervalo exacto como cuando se tenían distribuciones continuas en los casos anteriores.

DISTRIBUCIÓN BINOMIAL

La distribución binomial es una distribución de probabilidad discreta que cuenta el número de éxitos en una secuencia de n ensayos de Bernoulli independientes entre sí, con una probabilidad fija **p de ocurrencia de "éxito"** entre los ensayos. La **probabilidad de "fracaso"** está dada por **$q=1-p$**


Se puede asegurar con probabilidad de aproximadamente $(1 - \alpha) \cdot 100\%$ que se cumple la siguiente desigualdad:


$$x_0(p) < x < x_1(p) \quad \text{siendo los límites del intervalo.}$$

Para transformar esta desigualdad en un intervalo de confianza para p , se recurre a un método gráfico.

Hay gráficos que se utilizan para ver los extremos del intervalo (gráfico que muestra en **clase 5 min 36 aprox**, donde te fijas tu valor de x/n (trazas una línea vertical) y elegir las curvas dependiendo del tamaño de muestra que se tenga (trazas dos rectas horizontales donde se intersecta la línea vertical anteriormente marcada y la curva), si entras con los x/n de abajo entonces usas los valores de p de la izq y si entras por los x/n de arriba usas los valores de p de la derecha).

$\alpha = 0.05$





Sino como regla práctica para que una distribución binomial se acerque a la normal basta con que $n \cdot p$ y $(1-p) \cdot n$ sean a la vez mayores que 5. Si ambos no son mayores que 5 tengo que aplicar la solución gráfica. La regla permite encontrar los valores de p de manera analítica y no gráfica. Este método analítico se refiere a la distribución binomial que cuando se cumple esas condiciones, la binomial se puede estimar a través de la normal estándar. El valor 5 es un umbral que se ha establecido en base a la experiencia ya que ha demostrado funcionar bien para que la campana sea simétrica.

$$Z = \frac{x - n \cdot p}{\sqrt{n \cdot p \cdot (1-p)}}$$

Luego trabajando con el estadístico Z se obtiene

$$\frac{x}{n} - z_{\frac{\alpha}{2}} \cdot \sqrt{\frac{\frac{x}{n} \cdot \left(1 - \frac{x}{n}\right)}{n}} < p < \frac{x}{n} + z_{\frac{\alpha}{2}} \cdot \sqrt{\frac{\frac{x}{n} \cdot \left(1 - \frac{x}{n}\right)}{n}}$$

lo que permite lograr este intervalo de confianza para p en muestras de gran tamaño, con un nivel de confianza $(1-\alpha) \cdot 100\%$. Vemos que ese intervalo de confianza para p que quedó usa x/n como pivote (como base sobre la cual se construye el intervalo) y le resta y le suma un error de estimación.

Hacer una estimación del intervalo de confianza sirve para que por ej: viene el cliente y me pide que le estime esta proporción pero con este intervalo de confianza (+ - 5% por ej.) . Este dato a mi me va a servir

pq mientras el cliente pida más finito el intervalo (bien ajustado, que no le escape en más de + - 5%) voy a tener que aumentar el tamaño de la muestra. Que el cliente quiera un resultado más ajustado implica una muestra más grande y un precio más alto. Mientras más finito pida el cliente el intervalo de confianza más caro le tengo que cobrar. Con el cliente se transa el error de estimación, si lo quiere chico sale más caro, ahora si quiere un error de estimación más laxa entonces la prueba va a salir más barata pero que no espere que tenga tanta exactitud.

Error Máximo de Estimación:

$$E = z_{\frac{\alpha}{2}} \cdot \sqrt{\frac{\frac{x}{n} \cdot \left(1 - \frac{x}{n}\right)}{n}}$$

Notar que el Error Máximo de Estimación es el segundo término de ambos extremos del intervalo de la fórmula que usamos recién

La fórmula E puede servir para determinar el **tamaño muestral** que es necesario para alcanzar un grado deseado de precisión.

$$n = p \cdot (1 - p) \cdot \left(\frac{z_{\frac{\alpha}{2}}}{E} \right)^2$$
 Donde E es fijado por el cliente. El alfa (nivel de confianza) es un acuerdo o convención entre el cliente y el proveedor (puede ser 0.01 o 0.05)

Esta fórmula no se puede utilizar a menos que se tenga información de p (en base a datos auxiliares, digamos una muestra previa). Por ejemplo que digan que la proporción real no excede de 0.127. Si yo no tengo idea de la proporción p, me tengo que poner en la situación más desfavorable

Si no se conoce, se sabe que p.(1-p) es a lo sumo 1/4, correspondiente a p=1/2. Luego:

$$n = \frac{1}{4} \cdot \left(\frac{z_{\frac{\alpha}{2}}}{E} \right)^2$$

La demostración es: si no se tiene ni la más remota idea de cuanto puede ser la proporción que hay, entonces hay que ponerse en la situación más desfavorable para el análisis. Entonces se sabe que p.(1-p) (fórmula de la varianza muestral, despejar la desviación estándar y dividir por n)

p.(1-p), luego distribuyo

$$p - p^2$$

, luego derivó e igualó a cero para encontrar los puntos críticos

$$1 - 2 \cdot p = 0$$

se puede ver que el valor de p que maximiza ese producto es 1/2, ya que al derivar e igualar a 0 encontramos el punto máximo de la función (El más alto).

$$p = \frac{1}{2}$$

O sea que la peor de las situaciones se daría si p vale 1/2. Se asume el **peor caso posible** (Que es que la muestra sea MUY grande) para garantizar que el tamaño de muestra sea suficiente para cualquier escenario. Entonces:

$$n = p \cdot (1 - p) \cdot \left(\frac{z_{\frac{\alpha}{2}}}{E} \right)^2$$
 En p.(1-p) reemplazo p por lo peor, es decir 1/2 y eso da 1/4 quedando


La
$$n = \frac{1}{4} \cdot \left(\frac{z_{\frac{\alpha}{2}}}{E} \right)^2$$
 varia

Notar en la formula que si el cliente pidio un E muy chiquito entonces n va a ser grande (ya que E esta en el denominador). Si pide reducir el error a la mitad, el tamaño de la muestra tiene que ser 4 veces más. Cuanto más exigente el cliente se pone con el error más cara es la encuesta.

Explicación:

Al ser cuadrática negativa, es una función CÓNCAVA por lo que cuando igualó derivada a 0 es el MÁXIMO de la función.

$$x/n = 35/100 = 0.35$$



Tomo el peor de los casos ($p=0.5$) cuando no conozco p , ya que mi muestra va a tener que ser lo suficientemente grande para asegurar que el intervalo de confianza cumpla con la precisión que quiere el cliente.

Cuando p está cerca de 0 o 1, se necesita una **muestra más pequeña** para estimar p con precisión.

Entonces esas fórmulas son para saber el tamaño de la muestra para hacer una investigación estadística, con un error de estimación E que me pide el cliente y alfa acordado entre ambas partes. La primera se usa si se tiene información de p y la segunda se usa si no se conoce p .

En definitiva las fórmulas sirven para poder decirle al cliente cuánto le va a costar. Nos permite encontrar el tamaño de la muestra a recabar.

Aumentar el tamaño de la muestra reduce el **margen de error** (es decir, hace que el intervalo de confianza sea más estrecho) manteniendo el mismo nivel de confianza.

Mantener el mismo tamaño de muestra pero aumentar el **nivel de confianza** hará que el intervalo de confianza se haga más amplio, porque estás buscando mayor seguridad de que el valor real esté

3 B-2) HIPÓTESIS RELATIVA A UNA PROPORCIÓN esto le tomaron a Albornoz

Igual que hipótesis relativa a una varianza y media (Se hace la prueba de hipótesis para un parámetro 0 (proporción 0) y el parámetro 1 (proporción 1) a verificar si es significativamente igual a p_0 , los parámetros pueden ser media, varianza o prop). Se considerarán casos de grandes muestras. Se probará la hipótesis nula $p = p_0$ contra las alternativas $p < p_0$, $p > p_0$ ó $p \neq p_0$ (p_0 es la proporción de la hipótesis nula) mediante la aplicación del siguiente estadístico:

$$z = \frac{x - n \cdot p_0}{\sqrt{n \cdot p_0 \cdot (1 - p_0)}}$$

Ejemplo: En un estudio diseñado para investigar si ciertos detonadores empleados en explosivos en una mina de carbón cumplen con los requerimientos de que al menos el 90% encenderá el explosivo a ser detonado, se encontró que 174 de 200 funcionaron adecuadamente. Probar la hipótesis nula de que $p=0.90$ contra la hipótesis alterna $p<0.90$ con un nivel de significancia de 0.05.


- 1 - Hipótesis Nula $p = 0.90$,
Hipótesis Alternativa $p < 0.90$ (unilateral, cola izquierda),
- 2 - Nivel de significancia: $\alpha = 0.05$.

$$\alpha := 0.05$$

$$z_{0.05} := \text{qnorm}(\alpha, 0, 1) = -1.645$$

3 - Criterio

$$t := -3, -2.99 \dots 3$$



4 - Cálculos

Conforme a los datos

$$x := 174 \quad \text{número de "éxitos"}$$

$$n := 200 \quad \text{tamaño de la muestra (grande)}$$

$$p_0 := 0.9 \quad \text{proporción de la hipótesis nula}$$

$$z := \frac{x - n \cdot p_0}{\sqrt{n \cdot p_0 \cdot (1 - p_0)}} = -1.414 \quad \text{estadístico para la prueba}$$

HIPÓTESIS RELATIVA A VARIAS PROPORCIONES esto le tomaron a Albornoz

Se prueba si dos o más poblaciones binomiales tienen el mismo parámetro p . Se quiere demostrar si las proporciones entre distintas poblaciones son significativamente iguales o si son significativamente diferentes.

$$p = x/n$$

Se prueba la Hipótesis Nula: (Que todas las proporciones de las poblaciones binomiales sean significativamente iguales)

$$p_1 = p_2 = \dots = p_k = p$$

Contra la Hipótesis Alternativa de que no lo sean. Bastaría con que uno de ellos fuese **significativamente distinto** para que la Hipótesis Nula no se cumpla.

Se necesitan muestras aleatorias de tamaño $n_1, n_2, \dots, n_k$ de las k poblaciones. Luego, si los números correspondientes de éxitos son $x_1, x_2, \dots, x_k$ respectivamente, la prueba que se utiliza se fundamenta en el hecho que:

1. **Método 1:** Para grandes muestras la distribución muestral de:

$z_i = \frac{x_i - n_i \cdot p_i}{\sqrt{n_i \cdot p_i \cdot (1 - p_i)}}$ Z_i es aproximadamente la **distribución normal estándar**. Este estadístico puede formarse en cada una de las poblaciones siendo x_i el número de éxitos de la población i , n_i el tamaño de la muestra extraída de la población i , p_i es la proporción de la población i .

- El **cuadrado** de una variable aleatoria con distribución normal estándar, es otra variable aleatoria con **distribución chi-cuadrado con 1 grado de libertad**.
- La **suma** de k variables aleatorias independientes cuyas distribuciones son chi-cuadrado con 1 grado de libertad, es otra variable aleatoria chi-cuadrado con k grados de libertad.

en consecuencia:

$$\chi^2 = \sum_{i=1}^k \frac{(x_i - n_i \cdot p_i)^2}{n_i \cdot p_i \cdot (1 - p_i)}$$
 es una variable con distribución chi-cuadrado con $v=k$ grados de libertad.


Dado que las p_i son todas iguales por hipótesis nula y $p_n = x_n / n_n$, se pueden sustituir por:

$$\hat{p} = \frac{x_1 + x_2 + \dots + x_k}{n_1 + n_2 + \dots + n_k}$$

Ya que en la hipótesis nula se pretende demostrar que todas las proporciones son iguales entonces puedo hacer una probabilidad única (formulita de arriba) que sería la suma de todos los éxitos dividido la suma de todos los tamaños muestrales. Esto daría una probabilidad estimada (p sombrero)

Entonces la Hipótesis Nula se debe rechazar si las diferencias entre las x_i y las $n_i \cdot \hat{p}$ son grandes (lo cual nos conduce a una prueba de hipótesis unilateral de cola derecha. Si esas diferencias son chicas entonces el **chi cuadrado va a ser chico**, por lo tanto el chi cuadrado se corre a la izquierda y vamos a estar en zona de aceptación. A medida que el chi cuadrado sea más chico voy a estar en zona de aceptación)

La región crítica es $\chi^2 > \chi^2_\alpha$ y el número de



grados de libertad es $k-1$. La pérdida de un grado de libertad surge de reemplazar a p por su estimación $\hat{p}$. Entonces vuelvo a calcular el chi cuadrado pero ahora en vez de p uso $\hat{p}$ (que es p sombrero) y un grado de libertad $k-1$

$$\chi^2 = \sum_{i=1}^k \frac{(x_i - n_i \cdot p_{est})^2}{n_i \cdot p_{est} \cdot (1 - p_{est})}$$

Estadístico de prueba χ^2 relativo a diferencia entre proporciones

2. Método 2: Surge con el fin de simplificar el cálculo de χ^2 con el método 1, entonces se disponen los datos en forma tabular:

Para calcular χ^2 conviene disponer los datos de la siguiente manera:

	Muestra 1	Muestra 2	...	Muestra k	Total
éxitos	x_1	x_2	...	x_k	x
fallas	$n_1 - x_1$	$n_2 - x_2$	...	$n_k - x_k$	$n - x$
Total	n_1	n_2	...	n_k	n

El elemento correspondiente al renglón i y a la columna j se denomina frecuencia observada en la celda $o_{i,j}$ con $i = 1, 2$ y $j = 1, 2, \dots, k$.

Como antes, $\hat{p} = x/n$. Luego, el número esperado de éxitos $e_{1,j}$ y fracasos $e_{2,j}$ para la j -ésima muestra se estima con:

$$e_{1j} = n_j \cdot \hat{p} = \frac{n_j \cdot x}{n}$$

(Éxitos) n_j = tamaño de cada muestra (n_1, n_2 , etc) es por columna,
 x = total de todos los éxitos de todas las muestras
 n = tamaño total de todas las muestras (suma de n_j).

$$e_{2j} = n_j \cdot (1 - \hat{p}) = \frac{n_j \cdot (n - x)}{n} \quad (\text{Fracasos})$$

$e_{1,j}$ y $e_{2,j}$ se denominan frecuencias esperadas en celdas para $j = 1, 2, \dots, k$.

Cada celda es una frecuencia observada, luego se calculan las frecuencias esperadas. Multiplicando el total de la fila por el total de la columna dividido el gran total

En esta notación el estadístico χ^2 (con $p_i = \hat{p}$)

$$\chi^2 = \sum_{i=1}^2 \sum_{j=1}^k \frac{(o_{i,j} - e_{i,j})^2}{e_{i,j}}$$

con $v = k-1$ grados de libertad

Calcular el estadístico chi cuadrado con lo que vimos recién de valores observados y esperados es lo mismo que aplicar la fórmula del chi cuadrado que se vió más arriba.

En el caso particular de comparar únicamente dos poblaciones entre sí ($k=2$), se pueden plantear hipótesis alternativas específicas respecto a las dos proporciones (por ejemplo, $p_1 > p_2$, o viceversa). De cualquier

forma, en esta situación se demuestra que el estadístico 2 puede simplificarse a:

$$z = \frac{\frac{x_1}{n_1} - \frac{x_2}{n_2}}{\sqrt{\hat{p} \cdot (1 - \hat{p}) \cdot \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} \quad \text{donde} \quad p = \frac{x_1 + x_2}{n_1 + n_2} \quad \underline{\text{Z con dist normal estándar.}}$$

3 B-3) TABLAS R X C (TABLAS DE CONTINGENCIA) esto le tomaron a Albornoz

La diferencia con el método anterior (ambos métodos: el de las matrices y el de la formulita) es que ahora puedo tener más resultados dentro de la muestra. Antes solo tenía dos resultados (en el ej de recién serían desmoronado/fracaso o intacto/éxito). El cuadro que teníamos antes se agranda en cantidad de filas, donde r son filas (rows) y c columnas (columns). Por ejemplo, ahora podría encuestar a 100 personas de Mendoza, Bs As y Córdoba sobre qué equipos son que pueden ser Boca, River o San Lorenzo y podría probar la hipótesis de que si esas proporciones se mantienen en todas las provincias.

Estas tablas organizan los datos de acuerdo con dos criterios de clasificación: las filas representan un criterio y las columnas otro. A diferencia de las tablas simples, permiten más de dos categorías en cada criterio.

Hago lo mismo que con el método anterior. Obtengo las frecuencias observadas en la celdas ($o_{i,j}$) y después calculo las frecuencias esperadas en cada celda ($e_{i,j}$). Sólo es necesario calcular $(r-1) \cdot (c-1)$ de las $e_{i,j}$, las restantes se pueden deducir a partir de los totales de filas y columnas.

	A	B	C	Xi	
Funciona	40	23	12	75	
Roto	32	20	30	82	
Reaco	11	27	40	78	
Nj	83	70	82	235	Suma de X o de Nj
	$e_{11} = 83.75/235 = 26.4$	e_{21}	e_{31}	Fórmula (Siempre es esta) $N_j \cdot X_i / \text{Suma de } N_j$	
	$e_{12} = 83.82/235 = 28.9$	$e_{22} =$	e_{32}		
	$e_{13} = 83 - e_{11} - e_{12} = 27.7$	e_{23}	$e_{33} = 82.78/235$		

Luego, el estadístico para el análisis de la tabla $r \times c$ es:

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(o_{i,j} - e_{i,j})^2}{e_{i,j}} \quad v = (r-1) \cdot (c-1) \text{ grados de libertad.}$$

Los grados de libertad: Los grados de libertad en una tabla de contingencia indican cuántas celdas de la tabla pueden variar libremente una vez que se conocen los totales de las filas y columnas. Este número es crucial porque afecta la forma de la distribución χ^2 y, por lo tanto, los valores críticos que se utilizan para determinar si el resultado de la prueba es estadísticamente significativo.

Aprovechamiento en el programa de entrenamiento

		Debajo del Promedio	Promedio	Sobre el Promedio	Total
Éxito en el puesto (Clasificación en el empleo)	Deficiente	23	60	29	112
	Promedio	28	79	60	167
	Muy buena	9	49	63	121
	Total	60	188	152	400

$$O = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 23 & 60 & 29 \\ 0 & 28 & 79 & 60 \\ 0 & 9 & 49 & 63 \end{pmatrix}$$

Observados:

$$E = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 16.8 & 52.64 & 42.56 \\ 0 & 25.05 & 78.49 & 63.46 \\ 0 & 18.15 & 56.87 & 45.98 \end{pmatrix}$$

Esperados:

Se rechaza la Hipótesis Nula si el valor de χ^2 excede a χ^2_{α}

¿Cuándo las muestras son independientes?

Cuando los grupos que comparas **no están relacionados**. Por ejemplo:

- ✓ Encuestas diferentes cada año con personas distintas.
- ✓ Comparación de preferencias en diferentes ciudades.
- ✓ Distribución de ventas en distintas sucursales de una empresa.

¿Cuándo las muestras NO son independientes?

Cuando las mismas personas u objetos se miden más de una vez. Por ejemplo:

- ✗ Medir la misma persona antes y después de un tratamiento.
- ✗ Encuestar a los mismos clientes cada año.
- ✗ Evaluar los mismos estudiantes antes y después de un curso.

En este método como en el anterior las muestras tienen que ser independientes obligatoriamente.

3 B-4) BONDAD DE AJUSTE

Si desconozco qué distribución tienen ciertos datos, hago una prueba de Bondad de Ajuste para verificar si

los datos siguen una distribución estimada.

La prueba trata de comparar una distribución de frecuencias observadas de un conjunto de datos con una distribución esperada o teórica (como la normal, Poisson, chi-cuadrado, etc.)

Hipótesis nula: Los datos siguen la distribución teórica que se está probando (por ejemplo, normal, Poisson, etc.). **Hipótesis Alternativa:** No siguen esa distribución.

Ej: Le llegan mensajes a una empresa, y se quieren ver cuántos mensajes le llegan en un intervalo de 5 min.
 H_0 = Que los datos sigan una distribución de Poisson. H_1 = No sigue esa distribución.

Como ejemplo se analizan 400 intervalos de 5 minutos en el control de tráfico aéreo en cuanto a la recepción de mensajes de radio, comparándola con una distribución de Poisson con $\lambda=4.6$.

En los primeros 3 intervalos ningún auto, en los próximos 15 intervalos que paso 1 solo, en los proximos 47 intervalos que pasaron 2, etc....

Sumo la columna de frecuencias observadas y me da 400. Hay que demostrar en este ejercicio que si los datos siguen una distribución de Poisson con lambda de 4.6

Si multiplico la columna de nro de mensajes en intervalos de 5min por la de frecuencia observadas y lo divido por n. Me da un valor aproximado de 4.6 (Como la media ponderada) → Tasa de ocurrencia
($0 \times 3 + 1 \times 15 + 2 \times 47 + \dots + 13 \times 1$) / 400 = 4.6 (aproximado). En 3, 4 y 5 esta la mayor cantidad de frecuencias observadas.

Número de mensajes en interv. de 5 min.	Frecuencias observadas	Probabilidad de Poisson	Frecuencias esperadas
0	3	0.010	4.0
1	15	0.046	18.4
2	47	0.107	42.8
3	76	0.163	65.2
4	68	0.187	74.8
5	74	0.173	69.2
6	46	0.132	52.8
7	39	0.087	34.8
8	15	0.050	20.0
9	9	0.025	10.0
10	5	0.012	4.8
11	2	0.005	2.0
12	2	0.002	0.8
13	1	0.001	0.4

1. Se dividen los datos en **filas** (por ejemplo, intervalos en el caso de una distribución continua).

2. Se anotan las frecuencias observadas de cada categoría.

3. Se calcula la probabilidad de cada fila (para cada distribución es distinto).

4. Se calculan las frecuencias esperadas (probabilidad de cada fila por el tamaño total de la muestra).

5. Nos fijamos si algún valor dan menos que 5 en las frecuencias esperadas. Si es así lo juntamos con el valor que tiene abajo/arriba y hacemos lo mismo con las observadas.

Cantidad total de la muestra: n = suma de cantidad de filas

Se usa el estadístico para ver si las diferencias entre lo que observamos y lo que esperamos son solo por casualidad:

$$\chi^2 = \sum_{i=1}^k \frac{(o_i - e_i)^2}{e_i}$$

Con $k - m - 1$ grados de libertad. Siendo k el número de términos de la fórmula (cantidad de categorías, cantidad de filas agrupadas) y m el número de parámetros en la distribución supuesta (en el caso de Poisson, tiene solo parámetro λ

entonces sería $m = 1$, por ejemplo que hubiésemos tenido una distribución normal entonces $m=2$ ya que tiene dos parámetros: media y desviación estándar).

Dibujamos la abscisa según el nivel de significancia, y con el estadístico me fijo si se acepta o rechaza.

Si las diferencias entre las **observadas** y las **esperadas** son chicas, el valor del estadístico será chico, lo cual da un indicio de si se acepta la hipótesis nula. En caso contrario se rechaza.

Vamos a tomar un ejemplo para una Distribución Normal.

Problema II: La siguiente tabla indica la cifra promedio de accidentes por mil horas-hombre de la muestra de 50 firmas, obtenidas de una industria específica. Probar la hipótesis nula de que las frecuencias observadas en esta muestra siguen una distribución normal, utilizando un nivel de significancia de 0.05.

Cifra promedio de accidentes por mil horas-hombre	Número de firmas
1.5 – 1.7	3
1.8 – 2.0	12
2.1 – 2.3	14
2.4 – 2.6	9
2.7 – 2.9	7
3.0 – 3.2	5
Total	50

Después de haber agrupado queda $k = 4$, $m = 2$ por (media y desviación estándar).

1 - Hipótesis Nula: variable aleatoria que tiene distribución Normal.
Hipótesis Alternativa: No la tiene.

2 - Nivel de significancia: $\alpha = 0.05$.

$$k := 4 \quad m := 2 \quad \nu := k - m - 1 = 1$$

$$\alpha := 0.05 \quad \chi_{0.05} := qchisq(0.95, \nu) = 3.841$$

3 - Criterio: Se rechaza la Hipótesis Nula si $\chi^2 > 3.841$

Calculamos la Media y Desviación estándar.

$$TF := \sum NF \quad \text{total de firmas}$$

$$MP := \frac{\sum_{k=0}^5 (PM_k \cdot NF_k)}{TF} = 2.32 \quad \text{Media ponderada}$$

$$s := \sqrt{\frac{\sum_{k=0}^5 [(PM_k)^2 \cdot (NF_k)] - MP^2 \cdot TF}{TF}} = 0.42 \quad \text{desviación estándar}$$

El área va de menos a más ya que son adyacentes a los intervalos.

$$\int_{1.45}^{1.75} \text{dnorm}(t, MP, s) dt = 0.068$$

Cifra promedio de accidentes por mil horas-hombre (fronteras de clase)	fronteras de clase (en unidades normales estándar)	Probabilidad de estar en cada categoría	Frecuencia esperada =50.p
1.45 – 1.75	-2.07 a -1.35	0.07	3.5
1.75 – 2.05	-1.36 a -0.64	0.17	8.5
2.05 – 2.35	-0.64 a 0.07	0.27	13.5
2.35 – 2.65	0.07 a 0.78	0.26	13.0
2.65 – 2.95	0.78 a 1.50	0.15	7.5
2.95 – 3.25	1.50 a 2.21	0.05	2.5

En base a esto sacamos lo siguiente:

Cifra promedio de accidentes por mil horas-hombre	Frecuencias observadas, f_0	Frecuencias esperadas, f_e	$(f_0 - f_e)^2 / f_e$
1.5 – 1.7	3 15	3.5 12	0.75
1.8 – 2.0	12	8.5	
2.1 – 2.3	14	13.5	0.02
2.4 – 2.6	9	13.0	1.23
2.7 – 2.9	7 12	7.5 10	0.40
3.0 – 3.2	5	2.5	
		$\chi^2 =$	2.40

Y por último calculamos CHI CUADRADO:

Y ahora se calcula el estadístico χ^2 :

$$\chi^2 = \frac{(15 - 12)^2}{12} + \frac{(14 - 13.5)^2}{13.5} + \frac{(9 - 13)^2}{13} + \frac{(12 - 10)^2}{10} = 2.40$$

2,40 es menor que el chi cuadrado de 3.841 entonces se acepta hipótesis nula, es igual a una dist. normal con un nivel de confianza de 95%