

PRUEBAS NO PARAMÉTRICAS

Si se piensa que los métodos fundamentados en la suposición de normalidad son completamente eficientes (100%) esto sirve de patrón para evaluar a otros. La medida de eficiencia más utilizada se basa en el tamaño de la muestra que se requiere para producir resultados de igual precisión con un método y con el de referencia de 100%. Por ejemplo, al estimar la media de una población normal, el método más eficiente exige emplear la media muestral $\bar{x}$.

Si se desea valer de la mediana en lugar de la media, la varianza de la distribución muestral de la mediana es casi $1.57 \sigma^2/n$, luego la eficiencia de la mediana es $1/1.57$ o aproximadamente del 64%. Vale decir, la mediana basada en una muestra de tamaño 100 da una estimación tan confiable como la media de tamaño 64, para evaluar la media poblacional (μ) de una normal.

En el mundo real, los datos rara vez se comportan como la "Campana de Gauss" (distribución normal) perfecta que vemos en los libros.

Para entender por qué la mediana suele ser la "voz de la razón", debemos analizar tres conceptos clave: la **sensibilidad a valores extremos**, la **asimetría** y la **representatividad**.

1. La sensibilidad: El "Efecto Bill Gates"

La media aritmética es un estimador **no robusto**. Esto significa que un solo valor extremadamente alto o bajo puede "arrastrar" el promedio hacia él, distorsionando la realidad de la mayoría.

Ejemplo clásico: Imagina una cafetería con 9 clientes que ganan 1.000 € al mes. El salario promedio es 1.000 €.


De repente, entra **Elon Musk** (quien gana, supongamos, 1.000.000 € al mes).

- **La Media:** Sube a más de 100.000 €. Si lees el periódico, diría: *"El cliente promedio de esta cafetería es rico"*. **Es mentira.**
- **La Mediana:** Sigue siendo 1.000 €. La mediana te dice: *"La mitad de la gente gana 1.000 € o menos"*. **Es la verdad.**

2. Asimetría en datos económicos (Skewness)

Los salarios y los precios de las viviendas no se distribuyen de forma simétrica. Tienen lo que llamamos **asimetría positiva** (cola a la derecha).

- **Límite inferior:** Existe un suelo natural (el salario mínimo es 0 o un valor legal, el precio de una casa no puede ser negativo).
- **Límite superior:** No hay techo. Hay un pequeño grupo de personas o propiedades con valores astronómicos.



En una distribución con asimetría positiva, el orden siempre es:

$$\text{Moda} < \text{Mediana} < \text{Media}$$

La media se ve "atraída" por la cola larga de los ricos o las mansiones, mientras que la mediana se queda en el centro de la densidad de la población.

En cambio la eficiencia del estimador rango para la desviación estándar (σ) de una población normal decrece cuando el tamaño de la muestra crece. La eficiencia es del 100 % para $n=2$; 96% para $n=5$; 81% para $n=15$.

La principal ventaja de las pruebas no paramétricas consiste en que pueden realizarse inferencias exactas cuando las suposiciones fundamentales de los métodos estándar no pueden cumplirse en su totalidad. La desventaja estriba en que exigen demasiada información y tienen una eficiencia menor cuando las exigencias se satisfacen.

PRUEBA DEL SIGNO

Es una alternativa no paramétrica de la prueba t unimuestral, de la prueba t para muestras apareadas y las correspondientes pruebas para muestras de gran tamaño.

Se aplica cuando se muestreo una población simétrica, de tal manera que la probabilidad de obtener un valor mayor o menor son ambas iguales a $\frac{1}{2}$.

Para probar la Hipótesis Nula $\mu = \mu_0$, contra una alternativa apropiada en base a una muestra de tamaño n , **se reemplaza cada valor muestral por un signo + si $\mu > 0$ ó - si $\mu < 0$ y se ignora en caso que $\mu = \mu_0$** . Después se prueba la Hipótesis Nula que los signos + y - son los resultados de ensayos binomiales con $p=1/2$.

Problema: Los siguientes datos integran una muestra aleatoria de **15** mediciones de octanaje de cierto tipo de nafta:

99.0	102.3	99.8	100.5	99.7	96.2	99.1	102.5
103.3	97.4	100.4	98.9	98.3	98.0	101.6	

probar la Hipótesis Nula que **$\mu = 98.0$** contra la Hipótesis alternativa $\mu > 98.0$ con un nivel de significancia de **0.01**.

1. Hipótesis Nula: $\mu = 98.0$ ($p=1/2$).

Hipótesis Alternativa: $\mu > 98.0$ ($p>1/2$).

2. Nivel de significancia: $\alpha=0.01$.

3. Criterio: Se denota con x a los signos positivos. Se rechaza la hipótesis nula si la probabilidad de obtener x o más signos es menor o igual que 0.01.

4. Cálculos: de las comparaciones de 98 con los valores muestrales, surge:

++++ - +++ - ++++ $x=12$ $n=14$ (ya que uno de los valores es 98)

$$P(x \geq 12) = C_{14}^{12} \left(\frac{1}{2}\right)^{14} + C_{14}^{13} \left(\frac{1}{2}\right)^{14} + C_{14}^{14} \left(\frac{1}{2}\right)^{14} = 106 \cdot \left(\frac{1}{2}\right)^{14} = 0.0065$$

o bien, por tablas:

$$1 - B(14, 11, 1/2) = 1 - 0.9935 = 0.0065$$

5- Decisión: dado que $0.0065 < 0.01$ **Se Rechaza la Hipótesis Nula**. Luego, el octanaje promedio excede la media de 98.0.

La siguiente función Matlab realiza las operaciones anteriores.

function signo(h0,alfa)

```
load octano.txt -ascii;
```

```
% Prueba del Signo
```

```
%
```

```
% Entrada: octano, vector de datos(externo)
```

```
% h0, real, media correspondiente a la Hipotesis Nula
```

```
% alfa, real, nivel de significacion
```

```
% Salida: prueba, logico, 1, si se cumple Ho, o si no
```

```
%
```

```
n=length(octano);n1=n;posi=0;nega=0;
```

```
for i=1:n,
```

```
    if (octano(i)<h0), nega=nega+1;end
```

```
    if (octano(i)>h0), posi=posi+1;end
```

```
    if (octano(i)==h0), n1=n1-1;end
```

```
end
```

```
proba=0;
```

```
for i=posi:n1,
```

```
    proba=proba+factorial(n1)/(factorial(i)*factorial(n1-i))*(1/2)^n1;
```

```
end
```

```
proba > alfa
```

Ejecutando:

```
>> signo(98,0.01)
ans =
0
```

La prueba de signo se puede emplear también como alternativa no paramétrica de la prueba t para muestras apareadas o también para la prueba correspondiente para muestras de gran tamaño. En tales problemas, cada par de valores muestrales se reemplaza por un signo + si el primer valor es mayor que el segundo y con signo – en caso contrario y si son iguales, se descarta.

Problema: Conforme a un ejemplo anterior, el cual trataba de un programa de seguridad industrial, con la prueba de signo verificar si el programa es eficaz. Los datos eran:

45 y 36	73 y 60	46 y 44
124 y 119	33 y 35	
	57 y 51	83 y 77
34 y 29	26 y 24	17 y 11

1. Hipótesis Nula: $\mu_1 - \mu_2 = 0$ ($p=1/2$).

Hipótesis Alternativa: $\mu_1 - \mu_2 > 0$ ($p>1/2$).

2. Nivel de significancia: $\alpha=0.05$.

3. Criterio: Se denota con x a los signos positivos. Se rechaza la hipótesis nula si la probabilidad de obtener x o más signos es menor o igual que 0.05.

Cálculos: reemplazando cada par de valores por un signo + o – según el primero sea mayor que el segundo y viceversa.

++++ - +++++ $x=9$ $n=10$

$$P(x \geq 9) = 1 - 0.9893 = 0.0107$$

5- Decisión: dado que $0.0107 < 0.01$ **Se Rechaza la Hipótesis Nula**. Luego, el programa de seguridad es eficaz.

PRUEBAS DE SUMA DE RANGOS

Existen dos pruebas: la **U** y la **H**. La primera es una alternativa no paramétrica de la prueba t bimuestral.

A manera de ejemplo de aplicación de la **Prueba U** (o de Wilcoxon), suponer que en un estudio de rocas sedimentarias se obtuvieron los siguientes diámetros (en milímetros) de dos tipos de arena:

Arena I: 0.63 0.17 0.35 0.49 0.18 0.43 0.12 0.20 0.47 1.36 0.51 0.84 0.32 0.40 0.45

Arena II: 1.13 0.54 0.96 0.26 0.39 0.88 0.92 0.53 1.01 0.48 0.89 1.07 1.11 0.58

Las medias de las dos muestras son 0.46 y 0.76, respectivamente. El problema estriba en decidir si la diferencia es significativa.

Se consideran los datos como si fueran una sola muestra y se los ordena en forma creciente:

	0.12	0.17	0.18	0.2	0.26	0.32	0.35	0.39	0.4	0.43	0.45	0.47	
0.48													
	I	I	I	I	II	I	I	II	I	I	I	I	II
	0.49	0.51	0.53	0.54	0.58	0.63	0.84	0.88	0.89	0.92	0.96	1.01	
1.07													
	I	I	II	II	II	I	I	II	II	II	II	II	
	1.11	1.13	1.36										
	II	II	I										

asignando a los datos en este orden los rangos 1, 2, ..., 29: Se encuentra que los valores de la primera muestra tienen los rangos: 1, 2, 3, 4, 6, 7, 9, 10, 11, 12, 14, 15, 19, 20, 29 mientras que los de la segunda muestra 5, 8, 13, 16, 17, 18, 21, 22, 23, 24, 25, 26, 27, 28.

No hay nexo entre los valores pertenecientes a los distintas muestras, pero si lo hubiese, se asignaría a cada una de las observaciones relacionadas la media de los rangos que tienen conjuntamente [por caso, si el tercero y cuarto valores fuesen idénticos se asignaría a cada uno el rango $(3+4)/2=3.5$, y si el 9no., 10mo. y 11mo. fueran iguales, se asignaría a cada uno el rango $(9+10+11)/3=10$].

La Hipótesis Nula que se desea probar es que las dos muestras provienen de poblaciones idénticas, habiendo razón en tal caso para establecer que las medias de los rangos asignados a los valores de las dos muestras deberían ser más o menos iguales.

En lugar de las medias, se pueden comparar también las sumas de los rangos asignados a los valores de las dos muestras, con ello se toma en cuenta de manera apropiada una posible diferencia de los tamaños. La suma de rangos son $R_1=162$ y $R_2=273$ y queda por ver si la diferencia es demasiado grande como para rechazar la Hipótesis Nula.

Se definen dos estadísticos:

$$U_1 = n_1 \cdot n_2 + \frac{n_1 \cdot (n_1 + 1)}{2} - R_1 \quad U_2 = n_1 \cdot n_2 + \frac{n_2 \cdot (n_2 + 1)}{2} - R_2$$

o también el estadístico U , que es el correspondiente al rango más pequeño, de los dos.

Según la Hipótesis Nula de que las dos muestras provienen de poblaciones idénticas, puede comprobarse que la media y la varianza de la distribución muestral (de U_1 , en este caso) son:

$$\mu_{U_1} = \frac{n_1 \cdot n_2}{2} \quad \sigma_{U_1} = \sqrt{\frac{n_1 \cdot n_2 \cdot (n_1 + n_2 + 1)}{12}}$$


Si existen rangos iguales estas formas dan sólo aproximaciones, pero el número de rangos iguales es pequeño, por lo tanto las aproximaciones suelen ser buenas.

Estudios numéricos han demostrado que la distribución muestral de U_1 puede

aproximarse mediante una distribución normal con n_1 y n_2 ambos mayores que 8, la Hipótesis Nula (provenir de dos poblaciones idénticas) se puede fundamentar en el estadístico:

$$z = \frac{U_1 - \mu_{U_1}}{\sigma_{U_1}}$$

en caso de muestras pequeñas, se aplica la prueba basándose en tablas especiales.



Obsérvese que cuando se prueba H_0 contra la alternativa $\mu_1 > \mu_2$, se rechaza H_0 si $z < z_\alpha$ dado que los valores pequeños de U_1 corresponden a valores grandes de R_1 .

Asimismo, si la Hipótesis Alternativa es $\mu_1 < \mu_2$, se rechaza H_0 si $z > z_\alpha$ dado que para U_1 grande corresponde R_1 bajo.

Problema: De acuerdo a los datos de la propuesta anterior, mediante la prueba U , con un nivel de significancia de 0.01, verificar la Hipótesis Nula de que las dos muestras provienen de poblaciones iguales contra la Hipótesis Alternativa que tienen medias distintas.

1. Hipótesis Nula: las poblaciones son idénticas ($\mu_1 = \mu_2$)

Hipótesis Alternativa: $\mu_1 \neq \mu_2$ (dos colas)

2. Nivel de significancia: $\alpha = 0.01$. $z_\alpha = 2.575$

3. Criterio: Se rechaza H_0 si $z_\alpha > 2.575$ ó $z_\alpha < -2.575$

4. Cálculos: $n_1=15$, $n_2=14$, $R_1=162$, $R_2=273$

$$\mu_{U_1} = 15 \cdot \frac{14}{2} = 105 \quad \sigma_{U_1} = \sqrt{\frac{15 \cdot 14 \cdot (15 + 14 + 1)}{12}} = 22.9$$

$$z = \frac{168 - 105}{22.9} = 2.75$$

5- Decisión: dado que $z > z_{\alpha}$ **Se Rechaza la Hipótesis Nula**. Luego, existe diferencia en las dimensiones de los promedios reales de los dos tipos de arena.

La siguiente función Matlab, permite calcular el estadístico correspondiente a la prueba.

```
function Wilcoxon

% Prueba no parametrica U o de Wicoxon
%
% Entrada: muestra1, vector de datos correspondiente a la muestra 1(externo)
% muestra2, vector de datos correspondiente a la muestra 2(externo)
% alfa, real, nivel de significacion
% Salida: z, real, estadistico para la prueba
%
% Lectura de datos
load muestra1.txt -ascii;load muestra2.txt -ascii;
n1=length(muestra1);n2=length(muestra2);
% Construye una matriz con las dos muestras, en la segunda columna
% se mantiene la pista de donde proviene
k=1; for i=1:n1, A(k,1)=muestra1(i);A(k,2)=1;k=k+1; end
for i=1:n2, A(k,1)=muestra2(i);A(k,2)=2;k=k+1; end
% ordena segun valores de la primera columna
k=1;while k<n1+n2,
    if A(k,1)>A(k+1,1), temp=A(k,1);A(k,1)=A(k+1,1);A(k+1,1)=temp;
        temp=A(k,2);A(k,2)=A(k+1,2);A(k+1,2)=temp; k=1;
    else, k=k+1;
    end
end
% Verificacion de elementos iguales
cont=1; ref=0;
for i=2:n1+n2
    if A(i-1,1)==A(i,1),
        cont=cont+1;
        ref=i;
    end
end
ref=ref-cont+1; s=0;
for i=ref:ref+cont-1, s=s+i; end
prom=s/cont;
R1=0;R2=0;i=2;
while i<=n1+n2,
    if A(i-1,1)~=A(i,1),
        if A(i-1,2)==1,R1=R1+(i-1);end
        if A(i-1,2)==2,R2=R2+(i-1);
```

```

end
else,
  i1=i-1;
  for k=1:cont-1,
    if A(i1,2)==1,R1=R1+prom;i1=i1+1; end
    if A(i1,2)==2,R2=R2+prom;i1=i1+1; end
  end
  i=i+cont-1;
end
i=i+1;
end
if A(n1+n2,2)==1,R1=R1+n1+n2;end
if A(n1+n2,2)==2,R2=R2+n1+n2;end
uu1=n1*n2+n1*(n1+1)/2-min(R1,R2);mu1=n1*n2/2;
sig=sqrt(n1*n2*(n1+n2+1)/12);
z=(uu1-mu1)/sig

```

Ejecutando:

```

>> wilcoxon
z =
    2.7495

```

PRUEBA H (o de Kruskal-Wallis)

Es una generalización de la Prueba U que permite probar la Hipótesis Nula de que k muestras aleatorias independientes provienen de poblaciones idénticas.

Se clasifican las observaciones conjuntamente, y si R_i es la suma de los rangos ocupados por las n_i observaciones de la i -ésima muestra y $n_1 + n_2 + \dots + n_k = n$. La prueba se funda en el estadístico:

$$H = \frac{12}{n \cdot (n+1)} \cdot \sum_{i=1}^k \frac{(R_i)^2}{(n_i)} - 3 \cdot (n+1)$$

cuando $n_i > 5$ para toda i y cuando H_0 es verdadera, la distribución muestral de H es aproximada con la distribución chi-cuadrada con $k-1$ grados de libertad.

Problema: Un experimento para comparar tres métodos preventivos contra la corrosión produjo las siguientes profundidades máximas de las cavidades (en milésimo de pulgada) en piezas de alambre que fueron sometidas a los tratamientos respectivos:

Método A: 77, 54, 67, 74, 71, 66
 Método B: 60, 41, 59, 65, 62, 64, 52
 Método C: 49, 52, 69, 47, 56

Con un nivel de significación de 0.05, probar la Hipótesis Nula que las tres muestras provienen de poblaciones idénticas.

1. Hipótesis Nula: las poblaciones son idénticas ($\mu_1 = \mu_2 = \mu_3$)
Hipótesis Alternativa: las poblaciones son distintas.
2. Nivel de significancia: $\alpha = 0.05$. $\chi^2_{\alpha} = 5.991$ con $v = k - 1 = 3 - 1 = 2$ g.d.l
3. Criterio: Se rechaza H_0 si $\chi^2_{\alpha} > 5.991$
4. Cálculos: $n_1 = 6$, $n_2 = 7$, $n_3 = 5$
Se ordenan los datos como si fueran una sola muestra, preservando el origen

41 47 49 52 52 54 56 59 60 62 64 65 66 67 69 71 74 77
B C C B C A C B B B B A A C A A A

Los rangos son:

Método A: 6, 13, 14, 16, 17, 18	$R_1 = 84$
Método B: 1, 4.5, 8, 9, 10, 11, 12	$R_2 = 55.5$
Método C: 2, 3, 4.5, 7, 15	$R_3 = 31.5$

$$H = \frac{12}{18 \cdot (18 + 1)} \cdot \left(\frac{84^2}{6} + \frac{55.5^2}{7} + \frac{31.5^2}{5} \right) - 3 \cdot (18 + 1) = 6.66$$

5- Decisión: dado que $H > 5.991$ **Se Rechaza la Hipótesis Nula**. Luego, los tres métodos no tienen igual eficacia.

PRUEBAS DE ALEATORIEDAD

Es necesario saber que seguridad hay de que una muestra sea aleatoria. Una de las pruebas se basa en el orden en que fueron obtenidos los datos, con más precisión, se fundamenta en el número de **corridas** exhibidas en los resultados muestrales.

Dada una sucesión de dos símbolos (por ejemplo, cara y cruz de una moneda) una **corrida** es la sucesión de símbolos idénticos contenidos entre símbolos diferentes o ninguno de todos. Por ejemplo:

A A B B A A B B B A B B B A A A A B B B
1 2 3 4 5 6 7 8

en el esquema se aprecian un total de 8 corridas.

Esto puede servir para determinar el grado de aleatoriedad. Si sólo hubieran habido 2 corridas consistentes de 10 lados A seguidos por 10 lados B (**2 corridas**), sería sospechoso del mismo modo que lo serían la aparición alternada 1 a 1 de los lados (**20 corridas**). La sospecha de falta de aleatoriedad está en el orden de aparición.

Si una sucesión contiene n_1 símbolos del primer tipo y n_2 del segundo tipo (ni n_1 ni n_2 menores que 10) entonces la distribución muestral del número de corridas u , puede aproximarse mediante una distribución muestral con:

$$\mu_u = \frac{2 \cdot n_1 \cdot n_2}{n_1 + n_2} + 1 \quad \sigma_u = \sqrt{\frac{2 \cdot n_1 \cdot n_2 \cdot (2 \cdot n_1 \cdot n_2 - n_1 - n_2)}{(n_1 + n_2)^2 \cdot (n_1 + n_2 - 1)}}$$

De esta manera, la prueba de Hipótesis Nula de que el arreglo de los símbolos (y de aquí la muestra) es aleatoria, puede fundamentarse en el estadístico:

$$z = \frac{u - \mu_u}{\sigma_u}$$

que tiene aproximadamente la distribución normal.

Problema: El siguiente arreglo se refiere al número de piezas defectuosas d y no defectuosas n en el orden dado producidas por cierta máquina:

n n n n n d d d d n n n n n n n n n d d n n d d d d

probar la aleatoriedad con un nivel de confianza de 0.01.

1. Hipótesis Nula: El arreglo es aleatorio
Hipótesis Alternativa: No lo es.
2. Nivel de significancia: $\alpha = 0.01$. $z_\alpha = 2.575$
3. Criterio: Se rechaza H_0 si $z_\alpha > 2.575$ ó $z_\alpha < -2.575$
4. Cálculos: $n_1 = 10$, $n_2 = 17$, $u = 6$

$$\mu_u = \frac{2 \cdot 10 \cdot 17}{10 + 17} + 1 = 13.59 \quad \sigma_u = \sqrt{\frac{2 \cdot 10 \cdot 17 \cdot (2 \cdot 10 \cdot 17 - 10 - 17)}{(10 + 17)^2 \cdot (10 + 17 - 1)}} = 2.37$$

$$z = \frac{6 - 13.59}{2.37} = -3.2$$

5. Decisión: dado que $z < -2.575$ Se Rechaza la Hipótesis Nula. Luego, el arreglo no es aleatorio. En realidad el número total de corridas es mucho menor que el esperado y existe una fuerte tendencia a que las partes defectuosas aparezcan aglomeradas, la razón de esto seguramente la descubrirá un ingeniero familiarizado con el proceso.

También se puede utilizar la prueba de secuencias para probar la aleatoriedad de muestras que constan de datos numéricos contando secuencias **por encima** y **por debajo** de la mediana.

Si con **a** se denota una observación **por encima** de la mediana de la muestra y con **b** se denota una observación **por debajo** de la mediana, se puede emplear la sucesión de letras **a** y **b** para probar la aleatoriedad del método indicado.

Una aplicación muy común de esta prueba es el Control de Calidad, donde las media de pequeñas muestras sucesivas se exhiben en orden cronológico sobre una gráfica.

Problema: Un ingeniero está preocupado debido a que están realizando demasiadas modificaciones al ajustar un torno automático. Dados los siguientes diámetros medios (en pulgadas) de 40 ejes maquinados sucesivamente en el torno:

.261 .258 .249 .251 .247 .256 .250 .247 .255 .243 .252 .250
 .253 .247 .251 .243 .258 .251 .245 .250 .248 .252 .254 .250
 .247 .253 .251 .246 .249 .252 .247 .250 .253 .247 .249 .253
 .246 .251 .249 .253

emplear el nivel de significación 0.01 para probar la hipótesis nula de aleatoriedad contra la alterna de que existe un patrón que se repite con frecuencia.

1. Hipótesis Nula: El arreglo es aleatorio

Hipótesis Alterna: No lo es. Existe un patrón de repetición.

2. Nivel de significancia: $\alpha=0.01$. $z_{\alpha} = 2.33$

3. Criterio: Se rechaza H_0 si $z_{\alpha} > 2.33$

4. Cálculos: La mediana de las 40 mediciones es 0.250. Con este valor como referencia se construye el siguiente cuadro:

a a b a b a b a b a a b a b a a b b a a b a a b b a b a b b a b a b a

$n_1=19$, $n_2=16$, $u=27$

$$\mu_u = \frac{2 \cdot 19 \cdot 16}{19 + 16} + 1 = 18.37 \quad \sigma_u = \sqrt{\frac{2 \cdot 19 \cdot 16 \cdot (2 \cdot 19 \cdot 16 - 19 - 16)}{(19 + 16)^2 \cdot (19 + 16 - 1)}} = 2.89$$

$$z = \frac{27 - 18.37}{2.89} = 2.986$$

5. Decisión: dado que $z > 2.33$ **Se Rechaza la Hipótesis Nula**. Luego, se acepta la alternativa, esto es el Arreglo no es aleatorio.

Todo este proceso se puede realizar con la siguiente función Matlab:

```
function z=corridas
% Prueba de la mediana para determinar aleatoriedad de la toma
```

```

% de datos presentes en el archivo ascii datos.txt
% Entradas: u, vector, obtenido del archivo ascii "datos.txt"
% Salida: z, real, Estadístico

% Retoma el valor de la secuencia y calcula la mediana de la misma
load datos.txt;u=datos;
m=median(u);
% Se calcula el numero de valores por encima y por debajo de la mediana y
% se eliminan los elementos iguales a ella
encima=0;debajo=0;
k=1;
for i=1:length(u)
    if u(i)~=m, v(k)=u(i);k=k+1;; end
    if u(i)>m,encima=encima+1; end
    if u(i)<m,debajo=debajo+1; end
end
% Se rehace el vector sin los elementos iguales a la media
for i=1:length(v),v(i)=v(i)-m;end
% Se calcula el numero de corridas en la variable C
C=1;
for i=1:length(v)-1
    if sign(v(i))~=sign(v(i+1));C=C+1;end
end
% Se calcula la media y la desviacion estandar de las corridas
media=2*encima*debajo/(encima+debajo)+1;
desv1=2*encima*debajo*(2*encima*debajo-encima-debajo);
desv2=(encima+debajo)^2*(encima+debajo-1);
desv=sqrt(desv1/desv2);
% Calculo del estadístico
z=(C-media)/desv;

```

Si se ejecuta la misma:

```

>> corridas
ans =
    2.9834

```

PRUEBAS DE KOLMOGOROV-SMIRNOV

Se utilizan para diferencias entre distribuciones acumuladas. La prueba unimuestral es una prueba de Bondad de Ajuste. Es más eficiente que la prueba χ^2 en muestras pequeñas. No se aplica a distribuciones discretas.

La prueba unimuestral se funda en la diferencia absoluta máxima D entre los valores de la distribución acumulada de una muestra aleatoria de tamaño n y una distribución teórica determinada. Para decidir si esta diferencia es mayor de la razonablemente esperada con un nivel de significación α , se buscan los valores críticos de D en Tablas apropiadas.

Problema: Se desea comprobar si los agujeros en una placa de hojalata electrolítica están uniformemente distribuidos a través de la placa. Por ello se han tomado distancias (en

pulgadas) de 10 agujeros a partir de un extremo de una larga tira de 30 pulgadas de ancho, dando los siguientes resultados:

4.8 14.8 28.2 23.1 4.4 28.7 19.5 2.4 25.0 6.2

Probar esta hipótesis nula con un nivel de significación de 0.05

1. Hipótesis nula:


$$F(x) = \begin{cases} 0 & \text{para } x \leq 0 \\ x/30 & \text{para } 0 < x < 30 \\ 1 & \text{para } x \geq 30 \end{cases}$$

Hipótesis alterna: no están uniformemente distribuidos

2. Nivel de significación 0.05

3. Criterio: Se rechaza H_0 si $D > 0.410$, donde D es la diferencia máxima entre la distribución acumulada observada y la supuesta bajo la Hipótesis Nula.

4. Cálculos: Se construye el siguiente gráfico que muestra la distribución acumulada observada y la supuesta.



5. Decisión: Ya que $0.193 < 0.410$ (valor de Tabla) **No se Rechaza la Hipótesis Nula**. Luego, los agujeros están significativamente uniformemente distribuidos.

La función Matlab `kolmogorov` permite realizar esta prueba:

`function kolmogorov(A)`

```
% Prueba de Kolmogorov-Smirnov sobre problema de placa de hojalata de ancho A
% con datos presentes en el archivo ascii kolmo.txt
% Entradas: u, vector, obtenido del archivo ascii "kolmo.txt"
% Salida: D, real, Estadístico
```

```
load kolmo.txt;u=kolmo;
% Se ordena los valores en forma creciente y se dividen los elemto por A
% distribucion acumulada observada
u=sort(u)/A;
% distribucion acumulada teorica
for i=1:length(u),T(i)=i/length(u);end
% diferencias "hasta" distribucion teorica
difer1=abs(T-u);
for i=1:length(u)-1,difer2(i)=abs(T(i)-u(i+1));end
% diferencias "desde" distribucion teorica
difer2(length(u))=abs(1-u(length(u)));
% El valor de D se calcula como el mayor de los elementos de ambos vectores
D=max(max(difer1),max(difer2))
```

Ejecutando:

```
>> kolmogorov(30)
D =
    0.1933
```