


UNIDAD V: AJUSTE DE CURVAS

Se requiere analizar la relación entre dos variables cuantitativas.

Los dos objetivos fundamentales de este análisis serán:

- Determinar si dichas variables están asociadas y en qué sentido se da dicha asociación (es decir, si los valores de una de las variables tienden a aumentar –o disminuir- al aumentar los valores de la otra: ej edad y altura)
- Estudiar si los valores de una variable pueden ser utilizados para predecir el valor de la otra.

El **coeficiente de correlación** (entre -1 y 1) mide la relación entre dos variables, pero no permite explicar una en función de la otra. Para eso, es necesario un modelo que establezca la relación entre ellas. Para tal propósito se recurrirá a la **técnica de regresión**.



Coeficiente de correlación alta en ambos casos → Coeficiente de correlación es distinto del Beta (pendiente).

Se considera únicamente la relación entre dos variables: la variable independiente o explicativa “x” y la variable dependiente o explicada “y”. Esto no va a ser aplicable en el caso en que los datos no tengan una relación lineal.

5 B-3) COEFICIENTE DE CORRELACIÓN → Resumen tincho MEJOREN ESTO, LO SUELE TOMAR POR ARRIBA PERO HAY DISTINTOS TIPOS DE COEFICIENTES DE CORRELACION, ESTE ES UNO PARA RELACIONES LINEALES UNICAMENTE.

Se lo tomó a la Alma Quinteros junto a regresión

El coeficiente de correlación sirve para indicar **relaciones lineales** y **comportamientos** entre dos variables. Se denota comúnmente como **r** (correlación de Pearson) y varía en cualquier valor entre -1 y 1:

- Si $r = 1$ → Relación positiva perfecta (si una variable aumenta, la otra también).
- Si $r = -1$ → Relación negativa perfecta (si una aumenta, la otra disminuye).
- Si $r = 0$ → No hay relación lineal (**pero puede haber otro tipo de relación**)
- Si toma un valor como 0.5 o -0.5 → la relación es moderada (positiva o negativa).

Este coeficiente implica asociación, no implica **causalidad**: una variable no necesariamente causa cambios en la otra. Ej:

Si encontramos que hay una correlación alta entre el consumo de helado y los ataques de tiburón, no significa que comer helado **cause** ataques de tiburón. Probablemente haya una **tercera variable** (como la temperatura, ya que en verano la gente come más helado y también nada más en el mar).

- ★ Si la correlación r es positiva (cercana a 1) → La pendiente de la recta de regresión es **positiva**, es decir, cuando una variable aumenta, la otra también aumenta.
- ★ Si la correlación r es negativa (cercana a -1) → La pendiente de la recta de regresión es **negativa**, es decir, cuando una variable aumenta, la otra disminuye.
- ★ Si r está cerca de 0 → No hay una relación lineal clara, la pendiente puede no tener sentido o ser casi 0.

💡 Ejemplos:

- $r = 0.9$ → A más horas de estudio, mayor nota (pendiente positiva 📈).
- $r = -0.8$ → A más velocidad, menor tiempo de viaje (pendiente negativa 📉).
- $r = 0.05$ → Casi sin relación, la pendiente no es útil.

Así que sí, pendiente positiva ↔ r positivo, pendiente negativa ↔ r negativo. 🚀

$$r = \frac{S_{xy}}{\sqrt{S_{xx}S_{yy}}}$$

TEMA A: REGRESIÓN SIMPLE

5 A-1) LA RECTA DE REGRESIÓN (Regresión Lineal) esto le tomaron a Centeleghe

A partir de una muestra para los que se dispone de los valores de dos variables relacionadas, se realiza el diagrama de dispersión. Tenemos una variable independiente (explicativa “x”) y otra variable dependiente (explicada “y”)


Queremos encontrar la recta que mejor ajuste los valores, y que pueda ser utilizada para predecir los valores. Para esto se utiliza el método de los mínimos cuadrados, que elige como recta de regresión a aquella que minimiza las distancias verticales de las observaciones a la recta que mejor se ajusta de y a partir de los de x.

La ecuación de la recta de regresión (la que mejor se ajusta) es $\alpha + \beta \cdot x$ (alfa ordenada al origen y beta pendiente). Entonces, si se predice y por medio de la ecuación:

$\hat{y} = a + b \cdot x$ a y b (parámetros muestrales) son estimadores de α y β (parámetros poblacionales) Siendo a la ordenada al origen y b la pendiente. ¿

sea e_i el error de predecir el valor de y correspondiente a la x_i es:

$$e_i = y_i - \hat{y}_i \quad \text{diferencias verticales}$$



El error sería la diferencia entre el “y sub i” y el “y sub i sombrero”. Es decir, el error es la diferencia entre el valor real observado y el valor estimado en un punto específico del conjunto de datos

Se quiere determinar a y b de modo que estos errores sean lo más pequeños posibles. Ya que no se pueden minimizar cada uno de los e_i por separado, se intenta:

$$\sum_{i=1}^n e_i$$

Tan cercano a cero como sea posible.

Esto no es aconsejable ya que errores positivos y negativos se compensarán, y la estimación de la recta no será precisa. Por lo tanto, se busca minimizar la suma de los cuadrados de las diferencias entre los valores reales y los valores predichos por el modelo, por lo que a y b se elegirán con:

$$\sum_{i=1}^n [y_i - (a + b \cdot x_i)]^2 \quad \text{sea } \underline{\text{mínimo}}$$

Se eleva al cuadrado para que los errores negativos y positivos no se cancelen. Si los datos estuvieran perfectamente alineados, el error sería 0, pero como no lo están, siempre habrá un error.

La mejor recta será aquella que tenga el menor error posible, es decir, la que minimiza la suma de los errores al cuadrado.

Para que pueda lograr la ecuación de la recta donde el resultado de la suma de cuadrados de error es mínimo, se tiene que cumplir una condición necesaria: Que exista un **mínimo relativo**. Para verificar esto las derivadas parciales con respecto a “a” y “b” deben anularse, obteniendo un sistema de ecuaciones lineales. “n” es el tamaño de “x” $\rightarrow n = \text{length}(x)$. Así podemos calcular el valor de a y b

Cuando derivas y con el 0 encuentras el mínimo debido a que el error es una función cuadrática, por lo que es una función CONVEXA. Por eso no tiene máximos y solo un mínimo.

$$2 \cdot \sum_{i=1}^n [y_i - (a + b \cdot x_i)] \cdot (-1) = 0 \quad \text{derivada respecto de a} \quad 2 \cdot \sum_{i=1}^n [y_i - (a + b \cdot x_i)] \cdot (-x_i) = 0 \quad \text{derivada respecto de b}$$

También se podría usar el valor absoluto para eliminar el problema del signo, pero el problema de la función valor absoluto es que la derivada cuando $x = 0$ es ambigua (No existe), mientras que en la función cuadrática no hay puntos de ambigüedad y anda todo perfecto)

Cuando derivo respecto de b, y me queda el $-x_i$, hago distributiva de la $-x_i$ con los términos y después hago distributiva de la sumatoria en los términos. Por eso me queda de la siguiente manera:

$$\sum_{i=1}^n y_i = a \cdot n + b \cdot \sum_{i=1}^n x_i \quad \sum_{i=1}^n y_i \cdot x_i = a \cdot \sum_{i=1}^n x_i + b \cdot \sum_{i=1}^n (x_i)^2$$

Esto es un conjunto de ecuaciones lineales con incógnitas a y b, denominadas Ecuaciones Normales.

Resolviendo por determinantes:

Para resolver por determinantes coloco para el DENOMINADOR los valores que se encuentran del lado derecho de la igualdad (Termino 1 y termino 2). AMBOS EL DENOMINADOR ES IGUAL. Multiplico a_{11} x a_{22} y le resto a_{21} x a_{12} .

Para el NUMERADOR de a, cambio la PRIMERA COLUMNA por los valores INDEPENDIENTES (Los que están a la izquierda de la igualdad. Para el NUMERADOR de b cambio la SEGUNDA COLUMNA por los valores INDEPENDIENTES. Para ambos lo mismo multiplico a_{11} x a_{22} y le resto a_{21} x a_{12} .

$$a = \frac{\sum_{i=1}^n y_i \cdot \sum_{i=1}^n (x_i)^2 - \sum_{i=1}^n y_i \cdot x_i \cdot \sum_{i=1}^n x_i}{n \cdot \sum_{i=1}^n (x_i)^2 - (\sum_{i=1}^n x_i)^2} \quad b = \frac{n \cdot \sum_{i=1}^n x_i \cdot y_i - \sum_{i=1}^n x_i \cdot \sum_{i=1}^n y_i}{n \cdot \sum_{i=1}^n (x_i)^2 - (\sum_{i=1}^n x_i)^2}$$


Calculando los valores de a y b , obtenemos la **ecuación predictora**, $y = a + b.x$

MATHCAD te saca con $\text{intercept}(x,y)$ el estimador a y $\text{slope}(x,y)$ el estimador b

5 A-2) INFERENCIAS BASADAS EN ESTIMADORES DE MÍNIMOS CUADRADOS

Si se asume que la relación entre las variables es lineal, pero en realidad los datos en el diagrama de dispersión siguen una curva (por ejemplo, una parábola), entonces ajustar una recta a esos datos no representará bien la relación real. Desde el método de mínimos cuadrados, el ajuste lineal sería válido en términos matemáticos (minimiza la suma de los errores cuadrados), pero no tendría sentido en la práctica, porque no sería el mejor ajuste. AJUSTAR UNA FUNCIÓN LINEAL PARA ESTIMAR UNA FUNCIÓN CUADRÁTICA ESTÁ MAL, NO INTERPRETA LO QUE ESTÁ REALMENTE OCURRIENDO. PRIMERO MIRAR EL DIAGRAMA DE DISPERSIÓN

Se asume que se parte de una regresión lineal, donde los valores de y_i se distribuyen en forma normal, con media igual a $\alpha + \beta x_i$. Los errores son valores de variables aleatorias independientes con media 0 y varianza común igual a σ^2 .



Esto refleja que son muchas muestras, entonces los valores de x_1, x_2, x_i , resultan ser diferentes para cada muestra. $y = \alpha + \beta x$ es la única recta poblacional. Cada una de las distribuciones x_1, x_2, x_n tiene varianza σ^2 . En cada uno puedo hacer un intervalo de confianza para a y para b .

En resumen: Para cada lectura de X , tengo varios valores de Y . Cada una de las X tiene una función de densidad de probabilidad. Cada una de esas funciones tiene un máximo. Y eso va a ser la recta $y = \alpha + \beta x$

Se definen notaciones especiales: S_{xx} , S_{yy} y S_{xy} (no tienen ningún significado estadístico). Se utilizarán

para

$$S_{xx} = n \cdot \sum_{i=1}^n (x_i)^2 - \left(\sum_{i=1}^n x_i \right)^2 = n \cdot s_x^2 \cdot (n-1)$$

donde s_x es simplemente la varianza de las x

$$S_{yy} = n \cdot \sum_{i=1}^n (y_i)^2 - \left(\sum_{i=1}^n y_i \right)^2 = n \cdot s_y^2 \cdot (n-1)$$

donde s_y es simplemente la varianza de las y

$$S_{xy} = n \cdot \sum_{i=1}^n x_i \cdot y_i - \sum_{i=1}^n x_i \cdot \sum_{i=1}^n y_i = n \cdot s_{xy} \cdot (n-1)$$

donde s_{xy} es simplemente la covarianza de las x e y

en base a esto, se redefinen las ecuaciones normales, quedando:

$$b = \frac{S_{xy}}{S_{xx}} \quad a = \bar{y} - b \cdot \bar{x} \quad \text{donde } \bar{x} \text{ e } \bar{y} \text{ son, respectivamente las medias de las } x \text{ y de las } y.$$

Luego queremos estimar la varianza “sigma cuadrado” que es la misma para todas las funciones de densidad de probabilidad.

$$s_e^2 = \frac{1}{n-2} \cdot \sum_{i=1}^{n-1} [y_i - (a + b \cdot x_i)]^2$$

$$s_e^2 = \frac{S_{xx} \cdot S_{yy} - S_{xy}^2}{n \cdot (n-2) \cdot S_{xx}}$$

donde s_e se denomina Error Estándar de Estimación, también la suma de los cuadrados dada por $s_e^2 \cdot (n-2)$ recibe el nombre de Suma de Cuadrados Residual o Suma de Cuadrados de Error.

Se puede demostrar que tanto “a” como “b” presentan una distribución normal, cuyas medias (μ_a y μ_b) coinciden con los parámetros α y β . La estimación, $s_e^2 \cdot (n-2)$ se denomina Suma de Cuadrados de Error.

Luego, se pueden obtener estos estadísticos t-student con $n-2$ grados de libertad, que permiten establecer un intervalo de confianza para a y b :

$$t = \frac{a - \alpha}{s_e} \cdot \sqrt{\frac{n \cdot S_{xx}}{S_{xx} + \left(\frac{1}{n} \right)^2}}$$

y

$$t = \frac{b - \beta}{s_e} \cdot \sqrt{\frac{S_{xx}}{n}}$$


Los intervalos de confianza $-t_{\alpha/2} < t < t_{\alpha/2}$ son:

$$a - t_{\frac{\alpha}{2}} \cdot s \cdot e \cdot \sqrt{\frac{n \cdot S_{xx}}{S_{xx} + (n \cdot \bar{x})^2}} < \alpha < a + t_{\frac{\alpha}{2}} \cdot s \cdot e \cdot \sqrt{\frac{n \cdot S_{xx}}{S_{xx} + (n \cdot \bar{x})^2}}$$


$$b - t_{\frac{\alpha}{2}} \cdot s \cdot e \cdot \sqrt{\frac{n}{S_{xx}}} < \beta < b + t_{\frac{\alpha}{2}} \cdot s \cdot e \cdot \sqrt{\frac{n}{S_{xx}}}$$

Errores máximos de estimación de a y b

Intervalo de confianza para ALFA con un nivel de significancia alfa:
Influye en la ORDENADA AL ORIGEN



Intervalo de confianza para BETA con un nivel de significancia alfa:
Influye en la PENDIENTE



Las pruebas sobre β (la pendiente) son muy importantes porque nos dicen si X realmente influye en Y.

- β representa cuánto cambia Y en promedio cuando X aumenta en 1 unidad.
- Si β es muy chico (cercano a 0), quiere decir que los valores de Y varían muy poco (casi nula) con respecto a los de X.
- Si $\beta = 0$, la recta es horizontal, lo que significa que X no afecta a Y (no hay relación lineal entre

ellas).

Para calcular un intervalo de confianza en un determinado punto.

Otro problema es estimar $\alpha + \beta \cdot x$, es decir la media de la distribución de las y (μ_y), para un valor dado de x .

Si x se hace igual a un valor fijo x_0 se desea estimar $\alpha + \beta \cdot x_0$ y sería razonable emplear $a + b \cdot x_0$ (con a y b obtenidos por el método de los mínimos cuadrados).

Puede verificarse que este estimador es insesgado, y que tiene la varianza:

$$\sigma^2 \left[\frac{1}{n} + \frac{n \cdot (x_0 - \bar{x})^2}{S_{xx}} \right]$$

Y estaría dado de esta manera:

y que los límites de confianza del $(1-\alpha) \cdot 100\%$ para $\alpha + \beta \cdot x_0$ están dados por

$$(a + b \cdot x_0) \pm t_{\frac{\alpha}{2}} \cdot s_e \cdot \sqrt{\frac{1}{n} + \frac{n \cdot (x_0 - \bar{x})^2}{S_{xx}}} \quad \text{con } v = n-2 \text{ g.d.l.}$$

Ejemplo

Problema: En relación al ejemplo anterior, construir un intervalo de confianza del 95% para el coeficiente de evaporación cuando la velocidad del aire es de 190 cm/seg.

$$a := 0.05 \quad v := n - 2 = 8 \quad t_{0.025} := qt\left(1 - \frac{\alpha}{2}, v\right) = 2.306$$

$$x_0 := 190$$

$$E := t_{0.025} \cdot s_e \cdot \sqrt{\frac{1}{n} + \frac{n \cdot (x_0 - \text{mean}(x))^2}{S_{xx}}} = 0.116$$

$$(a + b \cdot x_0) - E = 0.661$$

Extremo inferior del intervalo

$$(a + b \cdot x_0) + E = 0.894$$

Extremo superior del intervalo

$$0.661 < \alpha + \beta \cdot x_0 < 0.893$$

Intervalo de confianza

Algo así sería el intervalo de confianza:



Las mejores predicciones las podemos hacer en el medio del intervalo (menor error), las peores en los extremos (mayor error)

5 A-2) REGRESIÓN CURVILÍNEA (logaritmo)

Cuando la relación entre X e Y no es lineal, se cuenta con dos alternativas:

1. Desarrollar un modelo de regresión no lineal
2. Transformar los datos para que se adapten al modelo lineal.

Esta segunda es la más sencilla. Se transforma la ecuación predictora para que los parámetros (α y β) sean lineales, y así para poder tratar el modelo con las técnicas antes vistas y construir el sistema de ecuaciones normales.

Tener en cuenta que cuando cálculo A y B finales, es decir, calcular a y b con intercept y slope (o por determinantes más lento) el valor que después transformó en A y B. Son los valores que tengo que reemplazar en la función ORIGINAL.

Exponencial $\rightarrow A \cdot B^x$

Potencial $\rightarrow A \cdot x^B$

Recíproca $\rightarrow 1/A + B \cdot x$

Una vez obtenidos los valores de las estimaciones para los coeficientes de regresión transformados, éstos deberán retransformarse a su forma original (deshaciendo todas las operaciones efectuadas para linealizarlos), obteniéndose, así, sus verdaderas aproximaciones.

Ejemplos de ecuaciones predictoras no lineales:

Forma funcional que relaciona y con x	Transformación propia	Forma de la regresión lineal simple
Exponencial: $y = \beta_0 e^{\beta_1 x}$	$y^* = \ln y$	Hacer la regresión de y^* contra x
Potencia: $y = \beta_0 x^{\beta_1}$	$y^* = \log y$; $x^* = \log x$	Hacer la regresión de y^* contra x^*
Recíproca: $y = \beta_0 + \beta_1 \left(\frac{1}{x}\right)$	$x^* = \frac{1}{x}$	Hacer la regresión de y contra x^*
Hiperbólica: $y = \frac{x}{\beta_0 + \beta_1 x}$	$y^* = \frac{1}{y}$; $x^* = \frac{1}{x}$	Hacer la regresión de y^* contra x^*

Ejemplo: Si al graficar los puntos (x_i, y_i) , los datos crecen(exponencial) o decrecen(logarítmica), esto indica que la curva de regresión es exponencial o logarítmica. Suponiendo que decrecen la **ecuación**

predictora es: $y = \alpha \cdot \beta^x$, tomando logaritmos en ambos miembros se obtiene la **ecuación predictora transformada**:

$$\log(y) = \log(\alpha) + x \cdot \log(\beta)$$

Vemos que ahora la **ecuación predictora** es lineal. Entonces se debe calcular las **ecuaciones normales** (Con determinantes) para obtener los valores de “a” y “b”, y se calcula el error.

Luego se deben revertir los pasos de la linealidad, obteniendo la regresión curvilínea. En este caso la operación inversa es la exponenciación. Por lo tanto se utiliza la base del logaritmo, y por definición “la base elevada al argumento es igual al resultado”, entonces: $\log_{10}(a) \rightarrow a$ es el argumento, 10 es la base.

Por lo tanto:

$$\begin{pmatrix} A \\ B \end{pmatrix} := \begin{pmatrix} 10^a \\ 10^b \end{pmatrix} = \begin{pmatrix} 99.941 \\ 0.958 \end{pmatrix}$$

Problema: Las cifras siguientes son datos sobre el porcentaje de llantas radiales producidas por cierto fabricante que aún pueden usarse después de recorrer cierto número de millas:

Miles de Millas recorridas (x)	1	2	5	10	20	30	40	50
Porcentaje útil (y)	98.2	91.7	81.3	64.0	36.4	32.6	17.1	11.3
Log(y)	1.992	1.9624	1.910	1.806	1.561	1.5132	1.2330	1.0531

+


- Graficar los datos proporcionados en escala semilogarítmica para advertir si es razonable que la relación es exponencial.
- Ajustar una curva exponencial aplicando el método de mínimos cuadrados a las parejas de puntos $[x_i, \log(y_i)]$.
- Emplear los resultados de la parte b) para estimar qué porcentaje de las llantas radiales del fabricante durarán menos de 25000 millas

a) Se crean los vectores:

$$x := (1 \ 2 \ 5 \ 10 \ 20 \ 30 \ 40 \ 50)^T$$

$$y := (98.2 \ 91.7 \ 81.3 \ 64 \ 36.4 \ 32.6 \ 17.1 \ 11.3)^T$$

$$Ly := \log(y) \quad n := \text{length}(x) \quad i := 0 .. n - 1$$



El patrón global (del segundo gráfico) es **lineal** y esto justifica el ajuste mediante una curva exponencial.

b) Para formar las ecuaciones normales:

$$\sum_i x_i = 158 \quad \sum_i (x_i)^2 = 5.53 \times 10^3 \quad \sum_i Ly_i = 13.031 \quad \sum_i (x_i \cdot Ly_i) = 212.121$$

$$\sum_i Ly_i = n \cdot \log(a) + \log(b) \cdot \sum_i (x_i)$$

$$\sum_i (x_i \cdot Ly_i) = \log(a) \cdot \sum_i (x_i) + \log(b) \cdot \sum_i (x_i)^2$$

$$13.031 = 8 \cdot \log(a) + 158 \cdot \log(b)$$

Ecuaciones normales

$$13.031 = 8 \cdot \log(a) + 158 \cdot \log(b)$$

Ecuaciones normales

$$212.121 = 158 \cdot \log(a) + 5.53 \times 10^3 \cdot \log(b)$$

$$\log(a) = \frac{\begin{vmatrix} 13.031 & 158 \\ 212.121 & 5.53 \times 10^3 \end{vmatrix}}{\begin{vmatrix} 8 & 158 \\ 158 & 5.53 \times 10^3 \end{vmatrix}} = 2$$

$$\log(b) = \frac{\begin{vmatrix} 8 & 13.031 \\ 158 & 212.121 \end{vmatrix}}{\begin{vmatrix} 8 & 158 \\ 158 & 5.53 \times 10^3 \end{vmatrix}} = -0.019$$

$$A := 10^2 = 100$$

$$B := 10^{-0.019} = 0.957$$

Mucho más simple, utilizando Mathcad:


$$\text{in} := \text{intercept}(x, Ly) = 2$$

Ordenada al origen


$$\text{sl} := \text{slope}(x, Ly) = -0.019$$

Pendiente

Lineal



Semilogaritmico



LA GRAFICA ES HACIA ABAJO PORQUE LA BASE DE X ES MENOR A 1

Utilizando la última expresión para $x=25$:

$$A \cdot B^{25} = 33.497$$

Vale decir, el 33.5% durarán menos de 25000 millas.

EN RESUMEN UNA VEZ QUE LO PASAS A LA ECUACIÓN PREDICTORA TRANSFORMADA (EN EL CASO DE EXPONENCIACIÓN QUE LE PONEMOS LOS LOGARITMOS DE MODO QUE QUEDARÍA $\log(Y) = \log(A) + X \log(B)$) SE TRABAJA COMO SI FUERA UNA LINEAL. AL FINAL QUE HACEMOS TODO PARA OBTENER A Y B (DETERMINANTES) ESOS 2 VALORES LOS VOLVEMOS A PONER EN SU FORMA NORMAL. 10 ELEVADO A LA A Y 10 ELEVADO A LA B. ASÍ OBTENEMOS A Y B. EN LUGAR DE HACER EL PROCEDIMIENTO DE DETERMINANTES LOS CALCULAMOS CON INTERCEPT Y SLOPE ($\text{INTERCEPT}(X, \log(Y))$ Y $\text{SLOPE}(X, \log(Y))$).

PARA FUNCION POTENCIAL:

- ✓ Gráfica curva que se dispara rápido → Exponencial.
- ✓ Gráfica curva que crece pero suavemente → Potencial.

PARA DIFERENCIAR!!!

A simple vista no se sabe si es potencial o exponencial. Para **potencial** aplico $\log(y)$ vs $\log(x)$ (**logaritmo completo**) y se observa una línea recta. Para **exponencial** aplico $\log(y)$ y x normal sin modificar (**semilogarítmico**) y se observa una línea recta

La potencial es de la siguiente manera:

$$y = \alpha x^\beta$$

De manera que cuando aplico logaritmo (en base 10, no natural) queda así:

$$\log(y) = \log(\alpha) + \beta \cdot \log(x)$$

De esta manera cuando trabajo con esta función (trabajando como una regresión lineal) y cálculo a y b (Calculados con intercept y slope para que sea más sencillo). Únicamente a le aplicó la transformación a la original. De manera que queda de la siguiente manera:


```
a := intercept(log(x),log(y)) = 0.396
```

```
b := slope(log(x),log(y)) = 2.989
```

```
A := 10a = 2.488
```

```
B := b
```

Entonces quedaría así:



PARA FUNCIÓN RECÍPROCA

$$y = 1/(\alpha + \beta \cdot x)$$

Valor de xi normal y el valor de yi es 1/ yi →


$$[x_i, 1/y_i]$$

Así quedaría →


$$\frac{1}{y} = \alpha + \beta x$$

Para saber que es recíproca le clavo al eje y le clavo 1/yi → Así

De esto:



A esto:




Calculando con intercept y slope $\rightarrow$

$$\underline{a} := \text{intercept}\left(x, \frac{1}{y}\right) = 4.396$$

$$\underline{b} := \text{slope}\left(x, \frac{1}{y}\right) = 3.901$$

A Y B NO SE MODIFICAN ENTONCES YA QUE ESTÁN IGUALES.

Así queda la predicción de la función $1/A + B X$



TEMA B: Regresión Múltiple.


5 B-1) AJUSTE POLINÓMICO (esto le tomaron a Guarnier y a Peretti)

Peretti: vos en ajuste polinómico tenés regresión simple y regresión múltiple. A él directamente le tomaron regresión múltiple. También le preguntó de mínimos cuadrados por qué se empleaban los errores cuadrados y él respondió que se hace pq hay errores positivos y negativos y si hacemos la sumatoria total de todos los errores entonces los negativos se van a ir compensando con los positivos y va a quedar un número más chico del error que realmente es, entonces se toma los errores cuadrados.

La idea es que no se tiene ninguna indicación de la forma. Se probó ajustar exponencialmente y no se dio, se probó ajustar potencialmente y tampoco, se probó reciprocamente y tampoco dio. Entonces lo que se propone para el ajuste es una función polinómica de grado p cuya ecuación predictora está debajo.

Observación:

Dato de color: Pero si se analizacen los errores horizontalmente, ¿la recta del mejor ajuste va a ser la misma? No, va a ser otra recta que tiene la regresión de x sobre y. NORMALMENTE SE TRABAJA CON LOS ERRORES VERTICALES Y NO HORIZONTALES.



Si no sabemos cómo es la relación entre y y x (que consiste en la minimización de los errores verticales respecto a la recta del mejor ajuste. Eso pasa entonces cuando se consideran los errores horizontales en vez de los verticales), suponemos que es estable y podemos aproximarla con una **Serie de Taylor**. Tomando los primeros términos, obtenemos una **regresión polinomial** (Se busca el mejor ajuste de grado mínimo), que ajusta los datos con un polinomio de grado p.

Vale decir, los datos se ajustan a un **polinomio** o ecuación predictora de la forma

$$y = \beta_0 + \beta_1 \cdot x + \beta_2 \cdot x^2 + \dots + \beta_p \cdot x^p$$

notar que si el polinomio es de grado 1 estaríamos en un ajuste lineal, si es de grado dos en un ajuste cuadrático y así ...

donde el grado se determina por observación de los datos o por un método más riguroso como el siguiente: dado un conjunto de datos que consta de n puntos (x_i, y_i) se estiman los coeficientes $\beta_0, \beta_1, \beta_2, \dots, \beta_p$ del polinomio de p-ésimo grado, minimizando:

$$\sum_{i=1}^n \left[y_i - (\beta_0 + \beta_1 \cdot x + \beta_2 \cdot x^2 + \dots + \beta_p \cdot x^p) \right]^2$$

Esa fórmula es la suma de cuadrados de error (que está elevada al cuadrado para eliminar el signo). Hay que lograr que esta suma de cuadrados de error sea mínima y para ellos se deriva parcialmente y se iguala a 0. Se van a tener que hacer p+1 derivadas donde la primera derivada es respecto a β_0 la otra respecto a β_1 y así ...

derivando parcialmente con respecto a $\beta_0, \beta_1, \beta_2, \dots, \beta_p$, igualando estas derivadas parciales a cero, se obtienen las p+1 (debido a que hay $\beta + 1$ de términos) ecuaciones normales, y se arma el SEN (sistema de ecuaciones normales):

$$\begin{bmatrix} n & \sum_i x_i & \dots & \sum_i (x_i)^p \\ \sum_i x_i & \sum_i (x_i)^2 & \dots & \sum_i (x_i)^{p+1} \\ \dots & \dots & \dots & \dots \\ \sum_i (x_i)^p & \sum_i (x_i)^{p+1} & \dots & \sum_i (x_i)^{2 \cdot p} \end{bmatrix} \cdot \begin{pmatrix} b_0 \\ b_1 \\ \dots \\ b_p \end{pmatrix} = \begin{bmatrix} \sum_i y_i \\ \sum_i (y_i \cdot x_i) \\ \dots \\ \sum_i [y_i \cdot (x_i)^p] \end{bmatrix}$$

Un ejemplo de esto para un polinomio de grado 3 es: $y_i = b_0 + b_1 \cdot x + b_2 \cdot x^2 + b_3 \cdot x^3$

En caso de que pidan un polinomio de grado 3 $y_i = b_0 + b_1 \cdot x + b_2 \cdot x^2 + b_3 \cdot x^3$ La cantidad de coeficientes del polinomio determina el tamaño de la matriz.

$$\begin{bmatrix} n & \sum x_i & \sum x_i^2 & \sum x_i^3 \\ \sum x_i & \sum x_i^2 & \sum x_i^3 & \sum x_i^4 \\ \sum x_i^2 & \sum x_i^3 & \sum x_i^4 & \sum x_i^5 \\ \sum x_i^3 & \sum x_i^4 & \sum x_i^5 & \sum x_i^6 \end{bmatrix} \cdot \begin{bmatrix} b_0 \\ b_1 \\ b_2 \\ b_3 \end{bmatrix} = \begin{bmatrix} y_i \\ y_i \cdot x_i \\ y_i \cdot x_i^2 \\ y_i \cdot x_i^3 \end{bmatrix}$$

A B Y

$$B = A^{-1} \cdot Y$$

La matriz A se pasa con el exponente inverso para resolverse

¿Cuándo tengo que parar en el ajuste? En este ejercicio yo tenía 9 puntos y con el pudiera haber hecho un polinomio de grado 9 que hubiese pasado por todos los puntos. Eso no está muy bien porque escapa de la realidad, yo debería tener un polinomio de un grado no tan alto y que no necesariamente pase por todos los puntos. Entonces en qué grado de polinomio me quedo? Para resolver esta situación se recurre a un indicador objetivo que se llama **varianza residual**

Resumen de Ajuste Polinómico:

1. Concepto General

El ajuste polinómico se usa cuando no tenemos información previa sobre la relación entre x y y. Si otros modelos (exponencial, potencial, recíproco) no funcionan, se prueba con un polinomio de grado p para encontrar la mejor aproximación.

Un polinomio de grado p tiene la siguiente forma:

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \dots + \beta_p x^p$$

- Si $p=1$, es una regresión lineal.

- Si $p=2$, es una regresión cuadrática.
- Si $p=3$, es una regresión cúbica, y así sucesivamente.

2. ¿Cómo se determinan los coeficientes $\beta_0, \beta_1, \dots, \beta_p$?

Se emplea el método de mínimos cuadrados, que minimiza la diferencia entre los valores reales y_i y los valores predichos por el polinomio.

Se minimiza la suma de cuadrados del error (SCE):

$$E = \sum_{i=1}^n [y_i - (\beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \dots + \beta_p x_i^p)]^2$$

- Se derivan parcialmente E respecto a cada β_j se iguala a 0.
- Se obtiene un Sistema de Ecuaciones Normales (SEN), que se resuelve para encontrar los coeficientes.
- ES UNA MATRIZ SIMÉTRICA

$$\begin{bmatrix} n & \sum_i x_i & \dots & \sum_i (x_i)^p \\ \sum_i x_i & \sum_i (x_i)^2 & \dots & \sum_i (x_i)^{p+1} \\ \dots & \dots & \dots & \dots \\ \sum_i (x_i)^p & \sum_i (x_i)^{p+1} & \dots & \sum_i (x_i)^{2 \cdot p} \end{bmatrix} \cdot \begin{pmatrix} b_0 \\ b_1 \\ \dots \\ b_p \end{pmatrix} = \begin{bmatrix} \sum_i y_i \\ \sum_i (y_i \cdot x_i) \\ \dots \\ \sum_i [y_i \cdot (x_i)^p] \end{bmatrix}$$

Ejemplo para $p=3$:

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3$$

Tendremos **4 ecuaciones normales** para determinar $\beta_0, \beta_1, \beta_2, \beta_3$.

En caso de que pidan un polinomio de grado 3

$$y_i = b_0 + b_1 \cdot x_i + b_2 \cdot x_i^2 + b_3 \cdot x_i^3$$

La cantidad de coeficientes del polinomio determina el tamaño de la matriz.

$$\begin{bmatrix} n & \sum x_i & \sum x_i^2 & \sum x_i^3 \\ \sum x_i & \sum x_i^2 & \sum x_i^3 & \sum x_i^4 \\ \sum x_i^2 & \sum x_i^3 & \sum x_i^4 & \sum x_i^5 \\ \sum x_i^3 & \sum x_i^4 & \sum x_i^5 & \sum x_i^6 \end{bmatrix} \cdot \begin{bmatrix} b_0 \\ b_1 \\ b_2 \\ b_3 \end{bmatrix} = \begin{bmatrix} y_i \\ y_i \cdot x_i \\ y_i \cdot x_i^2 \\ y_i \cdot x_i^3 \end{bmatrix}$$

A B Y

$$B = A^{-1} \cdot Y$$

La matriz A se pasa con el exponente inverso para resolverse


Ejercicio resuelto:

Cantidad de aditivo (en gr.)	0	1	2	3	4	5	6	7	8
Tiempo de secado (en seg.)	12.0	10.5	10.0	8.0	7.0	8.0	7.5	8.5	9.0

- Dibujar el diagrama de dispersión de modo que permita advertir si es razonable una relación parabólica.
- Ajustar un polinomio de segundo grado por el método de mínimos cuadrados.
- Emplear el resultado de b) para predecir el valor del tiempo de secado cuando se han utilizado 6.5 gr. del aditivo.

$$x := (0 \ 1 \ 2 \ 3 \ 4 \ 5 \ 6 \ 7 \ 8)^T$$


$$y := (12.0 \ 10.5 \ 10.0 \ 8.0 \ 7.0 \ 8.0 \ 7.5 \ 8.5 \ 9.0)^T$$



Calculo los valores de Beta

$$b := \begin{bmatrix} \text{length}(x) & \sum_i x_i & \sum_i (x_i)^2 \\ \sum_i x_i & \sum_i (x_i)^2 & \sum_i (x_i)^3 \\ \sum_i (x_i)^2 & \sum_i (x_i)^3 & \sum_i (x_i)^4 \end{bmatrix}^{-1} \begin{bmatrix} \sum_i y_i \\ \sum_i (x_i \cdot y_i) \\ \sum_i [(x_i)^2 \cdot y_i] \end{bmatrix} = \begin{pmatrix} 12.185 \\ -1.847 \\ 0.183 \end{pmatrix}$$

Y me da así la predicción de la función:



3. ¿Cómo se elige el grado p del polinomio?

El grado p se elige de dos formas:

1. Observación de los datos: Se prueban diferentes valores de p y se elige el que mejor ajuste sin sobreajustar.
2. Método riguroso: Se usa un indicador matemático como:
 - Varianza residual: Evalúa la dispersión del error.
 - Coeficiente de determinación R²: Mide qué tan bien el modelo explica los datos.

● ¿Por qué no elegir p=n-1?

Si hay n puntos, un polinomio de grado n-1 pasaría exactamente por todos, pero esto genera sobreajuste.

4. ¿Qué es el sobreajuste?

El sobreajuste (overfitting) ocurre cuando el modelo se ajusta demasiado a los datos de entrenamiento, capturando ruido en vez de la tendencia real.

🌸 Ejemplo:

Si tienes 9 puntos y ajustas un polinomio de grado 9, la función pasará por todos los puntos, pero el modelo será muy complejo y tendrá mal desempeño con nuevos datos.

✓ Solución:

Se elige un grado menor que equilibre precisión y simplicidad, evitando que el modelo sea demasiado sensible a pequeñas variaciones en los datos.

5 B-2) AJUSTE POLINOMIAL MEDIANTE LA VARIANZA RESIDUAL esto le tomaron a Guarnier y a Peretti

Cuando se ajusta un polinomio a un conjunto de parejas de datos, se suele empezar ajustando con una línea recta (regresión lineal) y se calcula la varianza residual, después se ajusta un polinomio de segundo grado y se calcula la varianza residual para este. A partir del polinomio de segundo grado se van comparando los valores de las varianzas residuales. Este proceso se repite, hasta que la varianza residual produce “el salto decreciente más significativo” (tiene un valor mucho más bajo que el anterior). Y a partir de ahí por más que se siga iterando y aumentando el grado del polinomio es al pedo pq la aproximación va a ser prácticamente igual de buena.

Cada una de estas varianzas residuales está dada por:

$$\sigma_{\text{res}}^2 = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n - p}$$

grados de libertad

Esta sumatoria indica la suma de cuadrados de errores

con $\hat{y}$ determinada por la ecuación del polinomio.

Los grados de libertad se determinan restando el número de puntos considerados y los coeficientes estimados (cantidad de β de la ecuación).

En este caso se toma la sumatoria de y_i (que son los puntos que saco del problema) - el polinomio con los respectivos coeficientes de Beta₀, Beta₁, etc previamente calculados. Ej:

$$\sum_i \frac{(y_i - b_0 - b_1 \cdot x_i)^2}{n - 2}$$

Lineal:

$$\sum_i \frac{[y_i - b_0 - b_1 \cdot x_i - b_2 \cdot (x_i)^2]^2}{n - 3}$$

Cuadrática:

$$\sum_i \frac{[y_i - b_0 - b_1 \cdot x_i - b_2 \cdot (x_i)^2 - b_3 \cdot (x_i)^3]^2}{n - 4}$$

Cúbica:

Cuando tenemos x puntos, el polinomio de grado x pasará por todos los puntos y tendrá una varianza residual nula porque vamos a tener una suma de cuadrados de error igual a 0. Por lo general a medida que vaya aumentando el grado del polinomio va a ir disminuyendo el error.

Peretir es un método para obtener un error que se está cometiendo después de haber realizado el ajuste. Cuando se hace un ajuste por serie de Taylor de un polinomio (en serie de Taylor cada iteración que se hace se eleva un grado más el grado del polinomio y ahí queda una mejor aproximación a los puntos que tienes que hacer) y con la varianza residual lo que se hace es la medición del error que se comete luego de cada iteración. También me pregunto hasta cuando tenía que hacerlo y dijo que era hasta dar un salto significativo en el valor que obtienes y ahí denota que decreció mucho el error y a partir de ahí por más que se siga iterando y aumentando el grado del polinomio es al pedo porque la aproximación va a ser prácticamente igual de buena.

Resumen de Ajuste Polinómico mediante la varianza muestral:

Cuando se ajusta un polinomio a un conjunto de datos, **se comienza con un ajuste lineal** y se va aumentando el grado del polinomio, observando la **varianza residual** para determinar el grado óptimo del polinomio.

La varianza residual es una medida del **error** en el ajuste del modelo. Cuantifica qué tan bien el polinomio se ajusta a los datos, comparando los valores reales y_i con los valores predichos $\hat{y}_i$.

$$\sigma^2 = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n - p}$$

Donde:

- y_i son los valores reales.
- $\hat{y}_i$ son los valores predichos por el polinomio.
- n es el número total de puntos.
- p es el grado del polinomio + 1 (porque hay $p + 1$ coeficientes β).
- $n - p$ son los **grados de libertad**.

¿Cómo usamos este valor de **varianza residual**?

Comenzamos con un ajuste lineal ($p=1$) y calculamos la varianza residual.

Probamos con un polinomio de grado 2, calculamos la varianza residual y la comparamos con la anterior.

Seguimos aumentando el grado del polinomio y registrando la varianza residual en cada paso.

Detenemos el proceso cuando se observa un “salto decreciente significativo”, es decir, cuando el error baja considerablemente en una iteración y en las siguientes iteraciones apenas mejora.

Ejemplo:

Problema: *Dado el siguiente conjunto de datos:*

x	.5	1.5	2.5	5.5	6.5	9.5	10.5	12.5	14.5	15.5
y	3	7	12.5	14.5	16	14.5	16	16	21	23

encontrar el polinomio de mejor ajuste.

Se intenta en primer lugar, el ajuste **lineal**. Para ello se determinan y resuelven las ecuaciones normales:

$x := 0 \quad y := 0$

$\underline{x} := (.5 \ 1.5 \ 2.5 \ 5.5 \ 6.5 \ 9.5 \ 10.5 \ 12.5 \ 14.5 \ 15.5)^T$

$\underline{n} := \text{length}(x) \quad i := 0..n - 1$

$\underline{y} := (3 \ 7 \ 12.5 \ 14.5 \ 16 \ 14.5 \ 16 \ 16 \ 21 \ 23)^T$

Se intenta en primer lugar, el ajuste **lineal**.

$$\begin{pmatrix} b_0 \\ b_1 \end{pmatrix} := \begin{bmatrix} n & \sum_i x_i \\ \sum_i x_i & \sum_i (x_i)^2 \end{bmatrix}^{-1} \cdot \begin{bmatrix} \sum_i y_i \\ \sum_i (y_i \cdot x_i) \end{bmatrix} = \begin{pmatrix} 6.578 \\ 0.984 \end{pmatrix}$$

Luego se calcula la varianza residual

$$\text{var_res}_1 := \frac{\sum_i (y_i - b_0 - b_1 \cdot x_i)^2}{n - 2} = 7.207$$

El segundo ajuste es **cuadrático**

$$\begin{pmatrix} b_0 \\ b_1 \\ b_2 \end{pmatrix} := \begin{bmatrix} n & \sum_i x_i & \sum_i (x_i)^2 \\ \sum_i x_i & \sum_i (x_i)^2 & \sum_i (x_i)^3 \\ \sum_i (x_i)^2 & \sum_i (x_i)^3 & \sum_i (x_i)^4 \end{bmatrix}^{-1} \cdot \begin{bmatrix} \sum_i y_i \\ \sum_i (y_i \cdot x_i) \\ \sum_i [y_i \cdot (x_i)^2] \end{bmatrix} = \begin{pmatrix} 5.399 \\ 1.5 \\ -0.033 \end{pmatrix}$$

$$\text{var_res}_2 := \frac{\sum_i \left[y_i - b_0 - b_1 \cdot x_i - b_2 \cdot (x_i)^2 \right]^2}{n - 3} = 7.58$$

El Tercer ajuste es **cúbico**

$$\begin{pmatrix} b_0 \\ b_1 \\ b_2 \\ b_3 \end{pmatrix} := \begin{bmatrix} n & \sum_i x_i & \sum_i (x_i)^2 & \sum_i (x_i)^3 \\ \sum_i x_i & \sum_i (x_i)^2 & \sum_i (x_i)^3 & \sum_i (x_i)^4 \\ \sum_i (x_i)^2 & \sum_i (x_i)^3 & \sum_i (x_i)^4 & \sum_i (x_i)^5 \\ \sum_i (x_i)^3 & \sum_i (x_i)^4 & \sum_i (x_i)^5 & \sum_i (x_i)^6 \end{bmatrix}^{-1} \cdot \begin{bmatrix} \sum_i y_i \\ \sum_i (x_i \cdot y_i) \\ \sum_i [y_i \cdot (x_i)^2] \\ \sum_i [y_i \cdot (x_i)^3] \end{bmatrix} = \begin{pmatrix} 0.497 \\ 5.793 \\ -0.714 \\ 0.028 \end{pmatrix}$$

$$\text{var_res}_3 := \frac{\sum_i \left[y_i - b_0 - b_1 \cdot x_i - b_2 \cdot (x_i)^2 - b_3 \cdot (x_i)^3 \right]^2}{n - 4} = 1.021$$


Y así hasta llegar a un polinomio de grado 9, que pasará por todos los puntos (varianza residual nula).

Una tabla con las *varianzas residuales* para cada ajuste es la siguiente (hasta el orden cuártico):

Lineal	Cuadrático	Cúbico	Cuártico
7.207	7.58	1.021	0.992

Se ve que el salto mayor se produce entre el ajuste cuadrático y el cúbico, por lo tanto el mejor estimador lo constituye el ajuste cúbico.

Al elegir el cúbico.



5 B) REGRESIÓN MÚLTIPLE esto le tomaron a Guarnier y Peretti

En la regresión simple había una única variable independiente (x) porque se trabajaba en el **plano**, ahora hay más, nos limitamos a 2 variables independientes para trabajar en el espacio. Entonces no se encuentra una línea sino que se encuentra un plano.

Las curvas obtenidas se utilizan para:

- **Predecir** valores de y usando varias x .
- **Optimizar**, encontrando valores de x que hagan y lo más grande o pequeña posible.

En la **regresión múltiple**, se tiene n variables independientes x_i (predictoras) y 1 dependiente y_i , es decir, **coordenadas:** $(X_{1i}, X_{2i}, \dots, X_{ni}, y_i)$ donde otra vez se supone que las x_i se conocen sin error, mientras que las y son valores de variables aleatorias. Nos vamos a limitar solo a 2 variables independientes para poder graficar en el espacio. Por lo que $n = 2$.

Se aplica el método de los mínimos cuadrados para obtener estimaciones de los coeficientes constantes: β_0 , β_1 y β_2 .

Para esto, se minimiza la **suma de los cuadrados del error**, es decir:

$$\sum_{i=1}^n [y_i - (\beta_0 + \beta_1 \cdot x_{1i} + \beta_2 \cdot x_{2i})]^2 \quad (\text{lo que está en corchetes es la ecuación predictora})$$

Se aplican las derivadas parciales (respecto de los coeficientes) a la fórmula de arriba, se igualan a 0, obteniendo el siguiente sistema de ecuaciones normales:

$$\begin{bmatrix} n & \sum_{i=1}^n x_{1i} & \sum_{i=1}^n x_{2i} \\ \sum_{i=1}^n x_{1i} & \sum_{i=1}^n (x_{1i})^2 & \sum_{i=1}^n (x_{1i} \cdot x_{2i}) \\ \sum_{i=1}^n x_{2i} & \sum_{i=1}^n (x_{1i} \cdot x_{2i}) & \sum_{i=1}^n (x_{2i})^2 \end{bmatrix} \cdot \begin{pmatrix} b_0 \\ b_1 \\ b_2 \end{pmatrix} = \begin{bmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n (y_i \cdot x_{1i}) \\ \sum_{i=1}^n (y_i \cdot x_{2i}) \end{bmatrix}$$

Donde b_0 , b_1 y b_2 son estimadores de mínimos cuadrados para β_0 , β_1 y β_2 . (Ejemplo)

Peretti: en regresión lineal es cuando se encuentra un polinomio en 2d, pero en regresión múltiple hay una variable más pq estoy trabajando en el **espacio** (no en el plano), entonces no se encuentra una línea sino que se encuentra un plano. El profe le hizo mucho hincapié en la ecuación modelo de ese plano (le preguntó cuales son variables, cuales son constantes ($b_0, b_1, \dots$), como se hace para minimizar el error y el respondio que también se aplica el método de los mínimos cuadrados)